Die Precision-Recall-Kurve verstehen

KI-Labor, Assignment 5: Fußgängererkennung mit Faster R-CNN (Penn-Fudan)

Ein Detektor liefert Boxen mit einem Score

Für jede Box gibt das Modell an, wie sicher es sich ist: den **Score** zwischen 0 und 1. Eine Box zählt als Treffer, wenn sie eine echte Person mit einer IoU von mindestens 0,5 überlappt.

Abkürzung	Bedeutung	Fall im Bild
TP	True Positive	Box liegt richtig auf einer Person
FP	False Positive	Box ohne passende Person: ein Fehlalarm
FN	False Negative	Person ohne passende Box: verpasst

Precision und Recall stellen zwei verschiedene Fragen

Precision

Wie viele Vorhersagen stimmen?

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Niedrig bedeutet: viele Fehlalarme.

Recall

Wie viele Personen wurden gefunden?

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Niedrig bedeutet: viele verpasste Personen.

Jeder Wert allein täuscht: Wer jede denkbare Box meldet, erreicht einen hohen Recall. Wer nur die eine sicherste Box meldet, erreicht leicht eine hohe Precision.

Die Score-Schwelle regelt den Kompromiss

Schwelle	FP	Precision	Recall
0,3	239	0,633	0,976
0,5	140	0,746	0,974
0,8	64	0,863	0,950

COCO-Modell, Klasse „person“, alle 170 Bilder

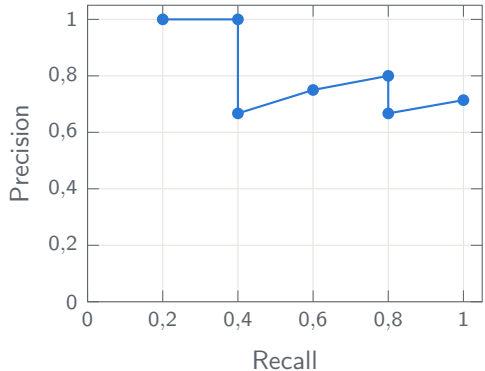
- **Hohe Schwelle:** Das Modell meldet weniger. Die Precision steigt, der Recall sinkt.
- **Niedrige Schwelle:** Das Modell meldet mehr. Der Recall steigt, die Precision sinkt meist.

Die Tabelle zeigt nur drei Schwellen. **Die Kurve zeigt alle auf einmal.**

So entsteht die Kurve: sortieren und mitzählen

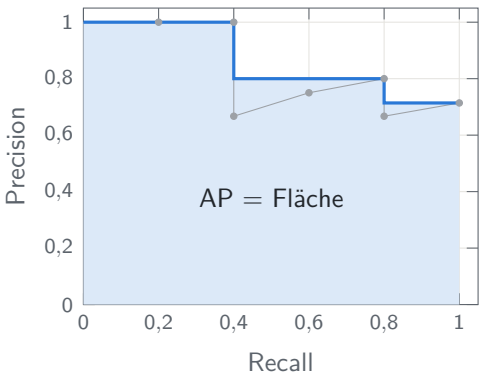
Score	Ergebnis	Precision	Recall
0,99	**TP**	$1/1 = 1{,}00$	$1/5 = 0{,}2$
0,95	**TP**	$2/2 = 1{,}00$	$2/5 = 0{,}4$
0,90	**FP**	$2/3 = 0{,}67$	$2/5 = 0{,}4$
0,80	**TP**	$3/4 = 0{,}75$	$3/5 = 0{,}6$
0,70	**TP**	$4/5 = 0{,}80$	$4/5 = 0{,}8$
0,60	**FP**	$4/6 = 0{,}67$	$4/5 = 0{,}8$
0,40	**TP**	$5/7 = 0{,}71$	$5/5 = 1{,}0$

Erfundenes Rechenbeispiel mit 5 echten Personen



Die Vorhersagen sind nach Score sortiert, jede Zeile entspricht also einer niedrigeren Schwelle. Ein **TP** führt nach rechts, ein **FP** senkrecht nach unten.

Die Fläche unter der geglätteten Kurve ist die Average Precision



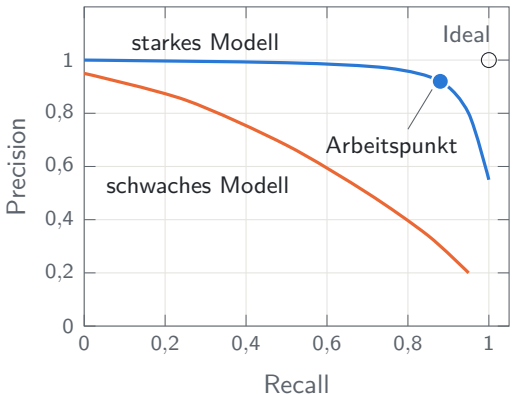
Glätten: Die graue Zickzacklinie wird zur blauen Treppe. Jeder Punkt übernimmt die beste Precision, die weiter rechts noch erreichbar ist.

Fläche ausrechnen:

$$0{,}4 \cdot 1{,}00 + 0{,}4 \cdot 0{,}80 + 0{,}2 \cdot 0{,}71 \approx 0{,}86$$

Die Average Precision fasst die ganze Kurve in einer Zahl zusammen. Genau das rechnet `average_precision` im Notebook.

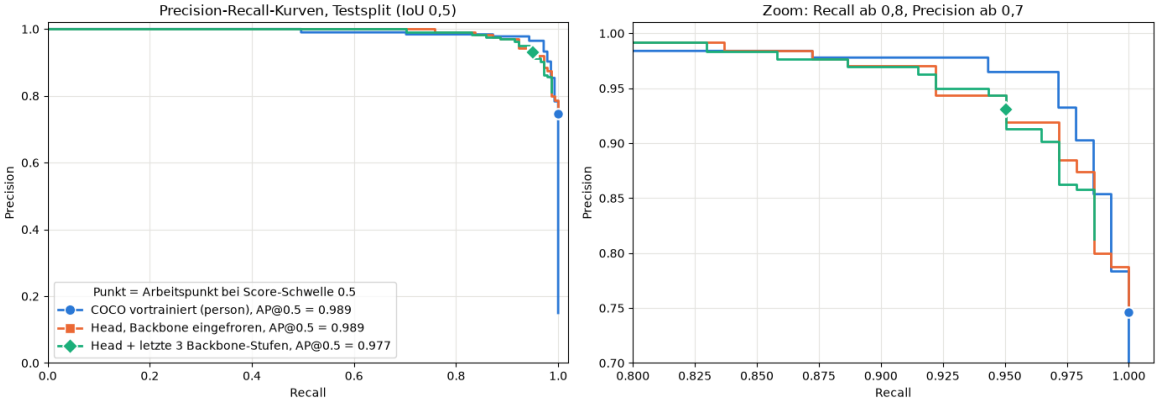
Beim Lesen zählen die Ecke oben rechts und der Arbeitspunkt



Schematische Skizze, keine Messwerte

- **Weiter oben rechts ist besser.** Das Modell findet viele Personen und macht dabei wenige Fehler.
- **Ein spätes Abfallen ist gut.** Die Precision bleibt dann auch bei hohem Recall hoch.
- **Der Arbeitspunkt** ist die Stelle, die eine konkrete Schwelle auf der Kurve auswählt.
- **Die Anwendung entscheidet,** welche Stelle die richtige ist.

In unserem Versuch sind alle drei Modelle sehr gut



Bis zu einem Recall von etwa 0,9 bleibt die Precision bei allen über 0,94. Unterschiede gibt es fast nur danach.

Testsplit: 50 Bilder, 141 Personen, IoU 0,5. Abbildung aus Abschnitt 8 des Notebooks.

Gleiche AP, aber verschiedene Arbeitspunkte

Modell	AP@0,5	Recall	Precision
COCO vortrainiert (person)	0,989	1,000	0,746
Head, Backbone eingefroren	0,989	0,950	0,931
Head + letzte 3 Backbone-Stufen	0,977	0,950	0,931

Recall und Precision bei Score-Schwelle 0,5, gleicher Lauf wie die Abbildung

- Das COCO-Modell und das eingefrorene Modell haben dieselbe AP, verhalten sich bei Schwelle 0,5 aber anders: Das COCO-Modell findet alle Personen und meldet deutlich mehr Fehlalarme.
- Die beiden trainierten Modelle treffen sich hier im selben Punkt. Deshalb ist in der Abbildung nur die Raute zu sehen, das Quadrat liegt darunter.

Drei Fallen beim Interpretieren

- **Fehlende Annotationen drücken die Precision.**
  Nicht jede sichtbare Person ist annotiert. Findet das Modell so eine Person, zählt das als Fehlalarm.

- **Der Zoom übertreibt Unterschiede.**
  Die y-Achse des rechten Diagramms beginnt bei 0,7. Abstände wirken dort größer, als sie sind.

- **Kleine AP-Unterschiede sind oft Zufall.**
  Mit gleichem Code in verschiedenen Umgebungen lag die AP der Variante mit Backbone-Stufen einmal bei 0,986 und einmal bei 0,977. Eine Rangfolge braucht daher mehrere Läufe.

Das Wichtigste in Kürze

1. **Precision** fragt: Wie viele Vorhersagen stimmen? **Recall** fragt: Wie viele Personen wurden gefunden?

2. Die **Kurve** zeigt diesen Kompromiss für alle Score-Schwellen. Oben rechts ist gut.

3. Die **Average Precision** ist die Fläche unter der Kurve, der **Arbeitspunkt** ist eine gewählte Stelle darauf.

4. Zwei Modelle können fast dieselbe AP haben und sich bei einer festen Schwelle trotzdem deutlich unterscheiden.