Der F1-Score

Precision, Recall, harmonisches Mittel und Macro-F1

Assignment 6: LSTM vs. GRU auf TweetEval-Emotion

Warum reicht die Accuracy nicht?

Accuracy = Anteil aller richtig klassifizierten Beispiele.

Bei unausgeglichenen Klassen täuscht sie:

- Baseline „immer *anger*“ im Testset: 39,3 % Accuracy, obwohl das Modell nichts gelernt hat.
- Betrugserkennung mit 1 % Betrugsfällen: „nie Betrug“ ergibt 99 % Accuracy und ist völlig nutzlos.

⇒ Wir brauchen eine Kennzahl, die **pro Klasse** prüft, ob das Modell sie wirklich erkennt.

Die Bausteine: TP, FP, FN

Betrachtet wird immer **eine** Klasse, z. B. *joy*:

	wirklich joy	**wirklich nicht joy**
vorhergesagt joy	TP (Treffer)	FP (Fehlalarm)
vorhergesagt nicht joy	FN (übersehen)	TN

- **TP**: richtig als joy erkannt
- **FP**: fälschlich joy genannt
- **FN**: joy, aber nicht erkannt
- **TN** kommt im F1 gar nicht vor: Die vielen „leichten“ richtig-negativen Fälle blähen den Wert nicht auf.

Precision und Recall

Precision

$$P = \frac{TP}{TP + FP}$$

Von allem, was das Modell „joy“ nennt: Wie viel *ist* wirklich joy?

Sinkt durch Fehlalarme.

Recall

$$R = \frac{TP}{TP + FN}$$

Von allen echten joy-Tweets: Wie viele *findet* das Modell?

Sinkt durch Übersehene.

Jede Kennzahl allein lässt sich austricksen

- **Nur Recall optimieren:** Immer „joy“ sagen $\Rightarrow$ $R = 1{,}0$, aber P ist winzig.
- **Nur Precision optimieren:** Nur beim eindeutigsten Tweet „joy“ sagen $\Rightarrow$ $P = 1{,}0$, aber R ist winzig.

Beides ist nutzlos.

$\Rightarrow$ Wir brauchen **eine** Zahl, die nur hoch ist, wenn beide Werte gut sind.

Der F1-Score

F1 ist das **harmonische Mittel** von Precision und Recall:

$$F_1 = \frac{2}{\frac{1}{P} + \frac{1}{R}} = \frac{2\,P\,R}{P + R} = \frac{2\,TP}{2\,TP + FP + FN}$$

- Wertebereich: 0 (schlecht) bis 1 (perfekt)
- Die letzte Form ist genau die Formel in `macro_f1()` im Notebook, direkt aus den Zählungen berechnet.
- Hoch nur dann, wenn Precision *und* Recall hoch sind.

Was ist das harmonische Mittel?

$$H(a,b) = \frac{2}{\frac{1}{a} + \frac{1}{b}}$$

Kehrwerte bilden, davon den normalen Durchschnitt nehmen, wieder umdrehen.

Warum zählen kleine Werte stärker? Ihr Kehrwert ist riesig:

$$\frac{1}{1{,}0} = 1, \qquad \frac{1}{0{,}1} = 10$$

Beispiel $P = 1{,}0$, $R = 0{,}1$:

$$\frac{1 + 10}{2} = 5{,}5 \quad \Rightarrow \quad H = \frac{1}{5{,}5} \approx 0{,}18$$

Alltagsbeispiel: Durchschnittsgeschwindigkeit

60 km hin mit **30 km/h**, dieselben 60 km zurück mit **90 km/h**.

- Gefühlt: $(30 + 90)/2 = 60$ km/h falsch
- Richtig: Hinweg 2 h, Rückweg 0,67 h $\Rightarrow$ 120 km in 2,67 h = **45 km/h**

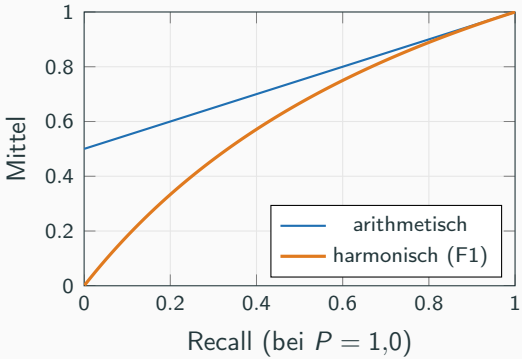
45 km/h ist genau das harmonische Mittel von 30 und 90.

Der langsame Teil zählt mehr, so wie bei F1 der schwächere der beiden Werte.

Arithmetisches vs. harmonisches Mittel

P, R	arithm.	harm. (F1)
0,6 / 0,6	0,60	0,60
0,8 / 0,4	0,60	0,53
1,0 / 0,1	0,55	0,18
1,0 / 0,0	0,50	0,00

Je weiter P und R auseinanderliegen, desto stärker bestraft F1.



Macro-F1: mehrere Klassen

$$\text{Macro-F1} = \frac{1}{K} \sum_{c=1}^{K} F_1^{(c)}$$

- Zwei Ebenen von Durchschnitt:
  1. **F1 pro Klasse**: harmonisches Mittel aus P und R
  2. **Macro-F1**: normaler Durchschnitt über alle K Klassen
- Jede Klasse zählt gleich viel, egal wie häufig sie ist.
- Seltene Klassen, die schlecht erkannt werden, ziehen den Wert sichtbar nach unten.
- Offizielle Metrik für TweetEval-Emotion, im Notebook auch zur Checkpoint-Auswahl genutzt.

Beispiel: Baseline „immer anger“

Anteil von *anger* im Testset: 39,3 %

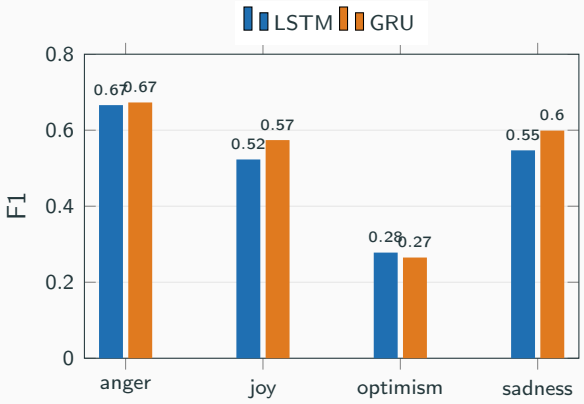
- *anger*: $P = 0{,}393$, $R = 1{,}0 \Rightarrow F_1 = \frac{2 \cdot 0{,}393}{1{,}393} \approx 0{,}56$
- *joy*, *optimism*, *sadness*: nie vorhergesagt $\Rightarrow F_1 = 0$

$$\text{Macro-F1} = \frac{0{,}56 + 0 + 0 + 0}{4} \approx 0{,}141$$

Accuracy 0,393 vs. Macro-F1 0,141

Macro-F1 zeigt, dass das Modell drei von vier Klassen nicht erkennt.

Ergebnisse im Notebook: F1 pro Klasse (Seed 42)



	Acc	Macro-F1
Baseline	0,393	0,141
LSTM	0,574	0,503
GRU	0,601	0,528

optimism wird kaum erkannt ($F_1 \approx 0{,}27$): wenige Beispiele, oft mit *joy* verwechselt. In der Accuracy fällt das kaum auf.

Wann F1, wann nicht?

F1 / Macro-F1 ist sinnvoll, wenn

- die Klassen unausgeglichen sind,
- seltene Klassen genauso wichtig sind wie häufige,
- Fehlalarme und Übersehene etwa gleich schlimm sind.

Andere Kennzahlen passen besser, wenn

- die Klassen ausgeglichen sind $\Rightarrow$ Accuracy reicht,
- ein Fehlertyp viel teurer ist, z. B. Krebs-Screening $\Rightarrow$ vor allem **Recall**.

Zusammenfassung

- **Precision**: Stimmen die Treffer? **Recall**: Werden alle gefunden?
- **F1** = harmonisches Mittel aus beiden, also nur hoch, wenn beide gut sind.
- Das harmonische Mittel liegt nahe am kleineren Wert, deshalb kann eine Schwäche nicht durch eine Stärke ausgeglichen werden.
- **Macro-F1** = Durchschnitt der Klassen-F1, jede Klasse zählt gleich viel.
- Im Notebook: GRU leicht vor LSTM (0,537 vs. 0,520 über 5 Seeds), Unterschied etwa so groß wie die Seed-Streuung.