

Maschinelles Lernen

1. Einführung und Überblick

Prof. Dr. Dennis Janka

Hochschule Karlsruhe
University of
Applied Sciences



September im Jahre 1800...


- Gründung der „**Himmelspolizey**“ auf dem zweiten astronomischen Kongress in Lilienthal
- 24 Astronomen aus Deutschland, Österreich, Italien, Russland, Dänemark, Schweden, Frankreich, England
- Aufgaben: Suche nach weiteren Planeten und Verbesserung von Sternenkatalogen




Franz Xaver von Zach
(1754 - 1832)

Entdeckung von Ceres

- Zwergplanet zwischen Jupiter und Mars
- Entdeckung während der Neujahrsnacht am 1.1.1801
- Beobachtung über 41 Tage, dann Erkrankung Piazzis / Verschwinden von Ceres
- Wie findet man einen Zwergplaneten wieder???



Giuseppe Piazzi
(1746 - 1826)



Ceres

Daten

280 Monatl. Correſp. 1801. SEPTEMBER.

Beobachtungen des zu Palermo d. 1 Jan. 1801 von Prof. Piazzi neu entdeckten Geſtirns.

Bis

1801	Mittlere Sonnen- Zeit	Gerade Aufſteig in Zeit	Gerade Auf- ſteigung in Graden	Nörtl. Abweich.	Geocentri- ſche Länge	Geocentr. Breite	Ort der Sonne + 20" Aberration	Logar. d. Distanz ⊙ ⊕
	St. " "	St. " "	° ' "	° ' "	Z ° ' "	° ' "	Z ° ' "	
Jan.	1 8 43 17,8	3 27 11,25	51 47 48,8	15 37 43,5	1 23 22 58,3	3 6 42,1	9 11 1 30,9	9,9926156
	2 8 39 4,6	3 26 53,85	51 43 27,8	15 41 5,5	1 23 19 44,3	3 2 24,9	9 12 2 28,6	9,9926317
	3 8 34 53,3	3 26 38,4	51 39 36,0	15 44 31,6	1 23 16 58,6	2 58 9,9	9 13 3 26,6	9,9926324
	4 8 30 42,1	3 26 23,15	51 35 47,3	15 47 57,6	1 23 14 15,5	2 53 55,6	9 14 4 24,9	9,9926418
	10 8 6 15,8	3 25 32,1	51 23 1,5	16 10 32,0	1 23 7 59,1	2 29 0,6	9 20 10 17,5	9,9927641
	11 8 2 17,5	3 25 29,73	51 22 26,0					
	13 7 54 26,2	3 25 30,30	51 22 34,5	16 22 49,5	1 23 10 37,6	2 16 59,7	9 23 12 13,8	9,9928490
	14 7 50 31,7	3 25 31,72	51 22 55,8	16 27 5,7	1 23 12 1,2	2 12 56,7	9 24 14 13,5	9,9928809
	17			16 40 13,0				
	18 7 35 11,3	3 25 55, ..	51 28 45,0					
	19 7 31 28,5	3 26 8,15	51 32 2,3	16 49 16,1	1 23 25 59,2	1 53 38,2	9 29 19 53,8	9,9930607
	21 7 24 2,7	3 26 34,27	51 38 34,1	16 58 35,9	1 23 34 21,3	1 46 6,0	10 1 20 40,3	9,9931434
	22 7 20 21,7	3 26 49,42	51 42 21,3	17 3 18,5	1 23 39 1,8	1 42 28,1	10 2 21 32,0	9,9931886
	23 7 16 43,5	3 27 6,90	51 46 43,5	17 8 5,5	1 23 44 15,7	1 38 52,1	10 3 22 22,7	9,9932348
	28 6 58 51,3	3 28 54,55	52 13 38,3	17 32 54,1	1 24 15 15,7	1 21 6,9	10 8 26 20,1	9,9935062
	30 6 51 52,9	3 29 48,14	52 27 2,1	17 43 11,0	1 24 30 9,0	1 14 16,0	10 10 27 46,2	9,9936332
	31 6 48 25,4	3 30 17,25	52 34 18,8	17 48 21,5	1 24 38 7,3	1 10 54,6	10 11 28 28,5	9,9937007
Febr.	1 6 44 59,9	3 30 47,2	52 41 48,0	17 53 36,5	1 24 46 19,3	1 7 30,9	10 12 29 9,6	9,9937703
	2 6 41 35,8	3 31 19,06	52 49 45,9	17 58 57,5	1 24 54 57,9	1 4 10,5	10 13 29 49,9	9,9938423
	5 6 31 31,5	3 33 2,70	53 15 40,5	18 15 1,0	1 25 22 43,4	0 54 28,9	10 16 31 45,5	9,9940751
	8 6 21 39,2	3 34 58,50	53 44 37,5	18 31 23,2	1 25 53 29,5	0 45 5,0	10 19 33 33,3	9,9943276
	11 6 11 58,2	3 37 6,54	54 16 38,1	18 47 58,8	1 26 26 40,0	0 36 2,9	10 22 35 11,4	9,9945823

— 11 —

"Beobachtungen des zu Palermo d. 1. Jan. 1801 von Prof. Piazzi neu entdeckten Gestirns."
 In: *Monatliche Correspondenz zur Beförderung der Erd- und Himmels-Kunde*,
 Hrsg. Franz Xaver von Zach, Sept. 1801.

Wiederentdeckung

- Gauß konnte aus Piazzis **Daten** Ceres' Bahn bestimmen
- **Vorhersage** von Ceres' Position für jeden Tag zwischen 25.11. und 31.12.1801
- Wiederentdeckung von Ceres durch von Zach am 31.12.1801 an der von Gauß vorhergesagten Stelle
- Neue, fundamentale Methode von Gauß: **Methode der kleinsten Quadrate**



Carl Friedrich Gauß
(1777 - 1855)

Gauß' Vorgehen, Schritt 1: „Training“

Beobachtungen des zu Palermo d. 1. Jan. 1801 von Prof. Piazzi neu entdeckten Gekörns.

1801	Mittlere Sonnen- Zeit	Gerade Aufstieg in Zeit	Gerade Auf- steig in Graden	Nördl. Abweich.	Geocent- rische Länge	Geocent- rische Breite	Ort der Sonne + 20° Aberration	Logar. d. Distanz O S
Jan. 1	8 43 17,8	3 27 11,25	54 47 48,8	15 37 43,5	1 23 22 58,3	3 6 42,1	9 11 1 30,9	9,9926156
2	8 39 4,6	3 26 53,85	51 43 27,8	15 41 5,5	1 23 19 44,3	3 2 24,9	9 12 2 28,6	9,9926317
3	8 34 53,3	3 26 38,41	51 39 36,0	15 44 31,6	1 23 16 58,6	2 58 9,9	9 13 3 26,6	9,9926324
4	8 30 43,1	3 26 23,15	51 35 47,8	15 47 57,6	1 23 14 15,5	2 53 55,6	9 14 4 24,9	9,9926418
5	8 26 15,8	3 25 58,12	51 31 1,5	15 50 10,0	1 23 11 30,0	2 49 10,6	9 15 5 22,9	9,9926512
6	8 21 5,5	3 25 42,75	51 26 26,0	15 52 49,5	1 23 8 44,5	2 44 11,1	9 16 6 20,9	9,9926606
7	8 16 40,3	3 25 27,38	51 21 31,5	15 55 38,0	1 23 5 58,0	2 39 11,6	9 17 7 18,9	9,9926700
8	8 11 30,8	3 25 12,01	51 16 36,0	15 58 26,5	1 23 3 11,5	2 34 12,1	9 18 8 16,9	9,9926794
9	8 6 21,3	3 24 56,64	51 11 40,5	16 0 15,0	1 23 0 25,0	2 29 12,6	9 19 9 14,9	9,9926888
10	8 1 11,8	3 24 41,27	51 6 45,0	16 2 4,5	1 22 57 38,5	2 24 13,1	9 20 10 12,9	9,9926982
11	7 56 2,3	3 24 25,90	51 1 49,5	16 4 48,0	1 22 54 52,0	2 19 13,6	9 21 11 10,9	9,9927076
12	7 50 52,8	3 24 10,53	50 56 54,0	16 7 36,5	1 22 52 6,5	2 14 14,1	9 22 12 8,9	9,9927170
13	7 45 43,3	3 23 55,16	50 51 58,5	16 10 25,0	1 22 49 20,0	2 9 14,6	9 23 13 6,9	9,9927264
14	7 40 33,8	3 23 39,79	50 46 63,0	16 13 13,5	1 22 46 33,5	2 4 15,1	9 24 14 4,9	9,9927358
15	7 35 24,3	3 23 24,42	50 41 67,5	16 16 2,0	1 22 43 47,0	2 0 15,6	9 25 15 3,9	9,9927452
16	7 30 14,8	3 23 9,05	50 36 72,0	16 18 50,5	1 22 41 6,5	1 55 16,1	9 26 16 2,9	9,9927546
17	7 25 5,3	3 22 53,68	50 31 76,5	16 21 39,0	1 22 38 20,0	1 50 16,6	9 27 17 1,9	9,9927640
18	7 20 55,8	3 22 38,31	50 26 81,0	16 24 27,5	1 22 35 33,5	1 45 17,1	9 28 18 0,9	9,9927734
19	7 15 46,3	3 22 22,94	50 21 85,5	16 27 16,0	1 22 32 47,0	1 40 17,6	9 29 18 58,9	9,9927828
20	7 10 36,8	3 22 7,57	50 16 90,0	16 30 4,5	1 22 29 60,5	1 35 18,1	9 30 19 56,9	9,9927922
21	7 5 27,3	3 21 52,20	50 11 94,5	16 32 53,0	1 22 26 74,0	1 30 18,6	9 31 20 54,9	9,9928016
22	6 56 17,8	3 21 36,83	50 6 99,0	16 35 41,5	1 22 23 87,5	1 25 19,1	9 32 21 52,9	9,9928110
23	6 51 8,3	3 21 21,46	50 1 103,5	16 38 30,0	1 22 21 1,0	1 20 19,6	9 33 22 50,9	9,9928204
24	6 45 58,8	3 21 6,09	49 56 108,0	16 41 18,5	1 22 18 14,5	1 15 20,1	9 34 23 48,9	9,9928298
25	6 40 49,3	3 20 50,72	49 51 112,5	16 44 7,0	1 22 15 28,0	1 10 20,6	9 35 24 46,9	9,9928392
26	6 35 39,8	3 20 35,35	49 46 117,0	16 46 55,5	1 22 12 41,5	1 5 21,1	9 36 25 44,9	9,9928486
27	6 30 30,3	3 20 19,98	49 41 121,5	16 49 44,0	1 22 9 55,0	1 0 21,6	9 37 26 42,9	9,9928580
28	6 25 20,8	3 19 54,61	49 36 126,0	16 52 32,5	1 22 7 8,5	0 56 22,1	9 38 27 40,9	9,9928674
29	6 20 11,3	3 19 39,24	49 31 130,5	16 55 21,0	1 22 4 22,0	0 51 22,6	9 39 28 38,9	9,9928768
30	6 15 2,3	3 19 23,87	49 26 135,0	16 58 9,5	1 22 1 35,5	0 46 23,1	9 40 29 36,9	9,9928862
Febr. 1	6 10 52,8	3 19 8,50	49 21 139,5	17 0 0,0	1 21 58 49,0	0 41 23,6	9 41 30 34,9	9,9928956
2	6 5 43,3	3 18 53,13	49 16 144,0	17 2 48,5	1 21 56 2,5	0 36 24,1	9 42 31 32,9	9,9929050
3	6 0 33,8	3 18 37,76	49 11 148,5	17 5 37,0	1 21 53 16,0	0 31 24,6	9 43 32 30,9	9,9929144
4	5 55 24,3	3 18 22,39	49 6 153,0	17 8 25,5	1 21 50 29,5	0 26 25,1	9 44 33 28,9	9,9929238
5	5 50 14,8	3 18 6,02	49 1 157,5	17 11 14,0	1 21 47 43,0	0 21 25,6	9 45 34 26,9	9,9929332
6	5 45 5,3	3 17 50,65	48 56 162,0	17 14 2,5	1 21 44 56,5	0 16 26,1	9 46 35 24,9	9,9929426
7	5 40 55,8	3 17 35,28	48 51 166,5	17 16 51,0	1 21 42 10,0	0 11 26,6	9 47 36 22,9	9,9929520
8	5 35 46,3	3 17 19,91	48 46 171,0	17 19 39,5	1 21 39 23,5	0 6 27,1	9 48 37 20,9	9,9929614
9	5 30 36,8	3 17 4,54	48 41 175,5	17 22 28,0	1 21 36 37,0	0 1 27,6	9 49 38 18,9	9,9929708
10	5 25 27,3	3 16 49,17	48 36 180,0	17 25 16,5	1 21 33 50,5	0 0 28,1	9 50 39 16,9	9,9929802
11	5 20 17,8	3 16 33,80	48 31 184,5	17 28 5,0	1 21 31 4,0	0 0 28,6	9 51 40 14,9	9,9929896
12	5 15 8,3	3 16 18,43	48 26 189,0	17 30 53,5	1 21 28 17,5	0 0 29,1	9 52 41 12,9	9,9929990
13	5 10 58,8	3 16 3,06	48 21 193,5	17 33 42,0	1 21 25 31,0	0 0 29,6	9 53 42 10,9	9,9930084
14	5 5 49,3	3 15 47,69	48 16 198,0	17 36 30,5	1 21 22 44,5	0 0 30,1	9 54 43 8,9	9,9930178
15	5 0 39,8	3 15 32,32	48 11 202,5	17 39 19,0	1 21 19 58,0	0 0 30,6	9 55 44 6,9	9,9930272
16	4 55 30,3	3 15 16,95	48 6 207,0	17 42 7,5	1 21 17 11,5	0 0 31,1	9 56 45 4,9	9,9930366
17	4 50 20,8	3 15 1,58	48 1 211,5	17 44 56,0	1 21 14 25,0	0 0 31,6	9 57 46 2,9	9,9930460
18	4 45 11,3	3 14 46,21	47 56 216,0	17 47 44,5	1 21 11 38,5	0 0 32,1	9 58 47 0,9	9,9930554
19	4 40 2,3	3 14 30,84	47 51 220,5	17 50 33,0	1 21 8 52,0	0 0 32,6	9 59 47 58,9	9,9930648
20	4 35 52,8	3 14 15,47	47 46 225,0	17 53 21,5	1 21 6 5,5	0 0 33,1	9 60 48 56,9	9,9930742
21	4 30 43,3	3 14 0,10	47 41 229,5	17 56 10,0	1 21 3 19,0	0 0 33,6	9 61 49 54,9	9,9930836
22	4 25 33,8	3 13 44,73	47 36 234,0	17 58 58,5	1 21 0 32,5	0 0 34,1	9 62 50 52,9	9,9930930
23	4 20 24,3	3 13 29,36	47 31 238,5	18 1 47,0	1 20 57 46,0	0 0 34,6	9 63 51 50,9	9,9931024
24	4 15 14,8	3 13 13,99	47 26 243,0	18 4 35,5	1 20 54 59,5	0 0 35,1	9 64 52 48,9	9,9931118
25	4 10 5,3	3 12 58,62	47 21 247,5	18 7 24,0	1 20 52 13,0	0 0 35,6	9 65 53 46,9	9,9931212
26	4 5 55,8	3 12 43,25	47 16 252,0	18 10 12,5	1 20 49 26,5	0 0 36,1	9 66 54 44,9	9,9931306
27	4 0 46,3	3 12 27,88	47 11 256,5	18 13 1,0	1 20 46 40,0	0 0 36,6	9 67 55 42,9	9,9931400
28	3 55 36,8	3 12 12,51	47 6 261,0	18 15 49,5	1 20 43 53,5	0 0 37,1	9 68 56 40,9	9,9931494
29	3 50 27,3	3 11 57,14	47 1 265,5	18 18 38,0	1 20 41 7,0	0 0 37,6	9 69 57 38,9	9,9931588
30	3 45 17,8	3 11 41,77	46 56 270,0	18 21 26,5	1 20 38 20,5	0 0 38,1	9 70 58 36,9	9,9931682
Febr. 1	3 40 8,3	3 11 26,40	46 51 274,5	18 24 15,0	1 20 35 34,0	0 0 38,6	9 71 59 34,9	9,9931776
2	3 35 58,8	3 11 11,03	46 46 279,0	18 27 3,5	1 20 32 47,5	0 0 39,1	9 72 60 32,9	9,9931870
3	3 30 49,3	3 10 55,66	46 41 283,5	18 30 52,0	1 20 29 61,0	0 0 39,6	9 73 61 30,9	9,9931964
4	3 25 39,8	3 10 40,29	46 36 288,0	18 33 40,5	1 20 26 74,5	0 0 40,1	9 74 62 28,9	9,9932058
5	3 20 30,3	3 10 24,92	46 31 292,5	18 36 29,0	1 20 23 88,0	0 0 40,6	9 75 63 26,9	9,9932152
6	3 15 20,8	3 10 9,55	46 26 297,0	18 39 17,5	1 20 21 1,5	0 0 41,1	9 76 64 24,9	9,9932246
7	3 10 11,3	3 10 4,18	46 21 301,5	18 42 6,0	1 20 18 15,0	0 0 41,6	9 77 65 22,9	9,9932340
8	3 5 2,3	3 9 48,81	46 16 306,0	18 45 54,5	1 20 15 28,5	0 0 42,1	9 78 66 20,9	9,9932434
9	3 0 52,8	3 9 33,44	46 11 310,5	18 48 43,0	1 20 12 42,0	0 0 42,6	9 79 67 18,9	9,9932528
10	2 55 43,3	3 9 18,07	46 6 315,0	18 51 31,5	1 20 9 55,5	0 0 43,1	9 80 68 16,9	9,9932622
11	2 50 33,8	3 9 2,70	46 1 319,5	18 54 20,0	1 20 7 9,0	0 0 43,6	9 81 69 14,9	9,9932716
12	2 45 24,3	3 8 47,33	45 56 324,0	18 57 8,5	1 20 4 22,5	0 0 44,1	9 82 70 12,9	9,9932810
13	2 40 14,8	3 8 31,96	45 51 328,5	19 0 0,0	1 20 1 36,0	0 0 44,6	9 83 71 10,9	9,9932904
14	2 35 5,3	3 8 16,59	45 46 333,0	19 3 48,5	1 20 0 49,5	0 0 45,1	9 84 72 8,9	9,9932998
15	2 30 55,8	3 8 1,22	45 41 337,5	19 6 37,0	1 19 58 3,0	0 0 45,6	9 85 73 6,9	9,9933092
16	2 25 46,3	3 7 45,85	45 36 342,0	19 9 25,5	1 19 55 16,5	0 0 46,1	9 86 74 4,9	9,9933186
17	2 20 36,8	3 7 30,48	45 31 346,5	19 12 14,0	1 19 52 30,0	0 0 46,6	9 87 75 2,9	9,9933280
18	2 15 27,3	3 7 15,11	45 26 351,0	19 15 2,5	1 19 49 43,5	0 0 47,1	9 88 76 0,9	9,9933374
19	2 10 17,8	3 7 0,74	45 21 355,5	19 18 51,0	1 19 46 57,0	0 0 47,6	9 89 77 58,9	9,9933468
20	2 5 8,3	3 6 45,37	45 16 360,0	19 21 39,5	1 19 44 10,5	0 0 48,1	9 90 78 56,9	9,9933562
21	2 0 58,8	3 6 30,00	45 11 364,5	19 24 28,0	1 19 41 24,0	0 0 48,6	9 91 79 54,9	9,9933656
22	1 55 49,3	3 6 14,63	45 6 369,0	19 27 16,5	1 19 38 37,5	0 0 49,1	9 92 80 52,9	9,9933750
23	1 50 39,8	3 6 4,26	45 1 373,5	19 30 5,0	1 19 35 51,0	0 0 49,6	9 93 81 50,9	9,9933844
24	1 45 30,3	3 5 48,89	44 56 378,0	19 33 53,5	1 19 33 4,5	0 0 50,1	9 94 82 48,9	9,9933938
25	1 40 20,8	3 5 33,52	44 51 382,5	19 36 42,0	1 19 30 18,0	0 0 50,6	9 95 83 46,9	9,9934032
26	1 35 11,3							

Gauß' Vorgehen, Schritt 2: Vorhersage und Validierung

- **Vorhersage** mit Hilfe des trainierten Modells:



- **Validierung** des Modells: von Zach beobachtete Ceres an der vom Modell vorhergesagten Position

Von Gauß zum maschinellen Lernen...

Was ist maschinelles Lernen?

- Maschinelles Lernen ist eine Sammlung von Konzepten, mit denen es Computern möglich ist, **Modelle zu identifizieren**, die einerseits **empirische Daten** akkurat beschreiben und andererseits **Vorhersagen** für neue, ähnliche Situationen treffen können (Generalisierbarkeit).
- Damit können Computer z.B.:
 - Objekte in Bildern lokalisieren
 - Natürliche Sprache erkennen
 - Fragen beantworten und Texte verfassen
 - Bei der Diagnose von Krankheiten helfen
 - Verkaufszahlen vorhersagen
 - Positionen von Himmelskörpern vorhersagen
 - ...

„Definition“

“[Machine Learning is the] field of study that gives computers the ability to learn without being explicitly programmed.”


- Arthur Samuel, 1959

Wie funktioniert Maschinelles Lernen?

Wie funktioniert ML?

Beispiel: Katzen und Hunde unterscheiden

- Wir möchten ein Modell entwickeln, das Bilder von Katzen und Bilder von Hunden unterscheiden kann
- Das Modell ist also eine Funktion



- Das Vorgehen besteht aus vier Schritten, die wir im Folgenden betrachten.
- Bei jedem Schritt gibt es viele Fallstricke, die dazu führen können, dass das Modell am Ende schlecht funktioniert.

Schritt 1: Datensammlung

- Der Computer soll aus **Beispielen** lernen, wie man eine Katze von einem Hund unterscheidet
- Das geschieht mit Hilfe eines **Trainingsdatensatzes**, z.B.:



- Wichtig: Für die Bilder des Trainingsdatensatzes ist **bekannt**, ob es sich um eine Katze (blauer Rand) oder Hund (roter Rand) handelt.
- Das Bestimmen der sog. **Labels** (Katze/Hund) für den Trainingsdatensatz kann sehr zeitaufwändig sein.

Schritt 2: Feature Design

- Um zu entscheiden, ob auf einem Bild ein Hund oder eine Katze zu sehen ist, schauen wir (Menschen) auf bestimmte Merkmale (Features):
 - Form/Größe des Kopfes
 - Form/Größe der Ohren
 - Form/Größe der Nase
 - ...
- Ausdrucksstarke Features zu finden, ist im Allgemeinen schwierig und hängt stark von der Aufgabe ab
- Features können auch automatisch gelernt werden (wenn man genügend Daten hat!)
- Für das Beispiel: Wir nehmen an, dass wir für ein Bild folgende beiden Features einfach bestimmen können:
 - Form der Ohren (von rund bis spitz)
 - Größe der Nase (von klein bis groß)


Schritt 2: Feature Design

In den Trainingsdaten:

- Katzen: kleine Nasen und spitze Ohren
- Hunde: runde Ohren, eher große Nasen


Wichtig:

- Jedes Bild kann nun durch nur zwei Zahlen dargestellt werden (Nasengröße, Rundheit der Ohren)
- Ein Bild kann als Punkt in der zweidimensionalen Ebene aufgefasst werden




Schritt 3: Modelltraining

- Mittels Featurerepräsentation wird das Problem ein geometrisches: Finde eine Linie oder Kurve, die Katzen und Hunde im Featureraum trennt.
- Bei einer Linie: Finde korrekte Werte für zwei Parameter (Steigung und Achsenabschnitt)
- Das Finden (auch: Tunen oder Optimieren) der Parameter nennt man **Modelltraining**



Schritt 3: Modelltraining

- Beispiel: Trainiertes Modell teilt den Featureraum in Katzen- und Hunderegion
- Daraus lässt sich eine Rechenregel für jedes beliebige Bild (nicht nur diejenigen aus den Trainingsdaten) ableiten:
 - Wenn die Featurerepräsentation (ear shape, nose size) in der blauen Region liegt, sieht das Modell es als Katze an,
 - Wenn sie in der roten Region liegt, als Hund




Schritt 4: Modellvalidierung

- Um zu beurteilen, wie gut das Modell funktioniert, zeigen wir ihm eine Menge von bisher **ungesehenen** Bildern (sog. Testdatensatz) und überprüfen, ob es die Tiere korrekt erkennt
- Vorgehen:
 - Extrahiere Features aus dem Bild (ear shape, nose size)
 - Überprüfe, auf welcher Seite der Linie die Featurerepräsentation liegt
 - Vergleiche mit tatsächlichem Wert




Schritt 4: Modellvalidierung

- Ein Hund (Boston Terrier) wird von dem Modell als Katze klassifiziert, da er spitze Ohren und eine relativ kleine Nase hat
- Maßnahmen für ein besseres Modell:
 - Mehr Daten (diversere Trainingsdaten)
 - Andere Features extrahieren (z.B. Augenfarbe/Form)
 - Komplexere Entscheidungsregel als durch die Gerade dargestellt (Nichtlineares Modell)



Beispiel: Zusammenfassung



Diese Pipeline wird im Prinzip für jedes ML-Modell benutzt.



Beispiel vs. Definition

“[Machine Learning is the] field of study that gives computers the ability to learn without being explicitly programmed.”



- Arthur Samuel, 1959

→ Wir sagen dem Modell nicht explizit, wo die Grenze zwischen Katzen und Hunden verläuft, sondern diese wird automatisch aus den Daten erkannt.

Gauß Beispiel im ML Framework



	Jahre	Mars			Jupiter		Saturnus		Uranus		Neptun		Merkur
		Rechte Asc.	Declin.	Parallax.	Rechte Asc.	Declin.	Rechte Asc.	Declin.	Rechte Asc.	Declin.	Rechte Asc.	Declin.	
1857	1858	1859	1860	1861	1862	1863	1864	1865	1866	1867	1868	1869	1870
1871	1872	1873	1874	1875	1876	1877	1878	1879	1880	1881	1882	1883	1884
1885	1886	1887	1888	1889	1890	1891	1892	1893	1894	1895	1896	1897	1898
1899	1900	1901	1902	1903	1904	1905	1906	1907	1908	1909	1910	1911	1912
1913	1914	1915	1916	1917	1918	1919	1920	1921	1922	1923	1924	1925	1926
1927	1928	1929	1930	1931	1932	1933	1934	1935	1936	1937	1938	1939	1940
1941	1942	1943	1944	1945	1946	1947	1948	1949	1950	1951	1952	1953	1954
1955	1956	1957	1958	1959	1960	1961	1962	1963	1964	1965	1966	1967	1968
1969	1970	1971	1972	1973	1974	1975	1976	1977	1978	1979	1980	1981	1982
1983	1984	1985	1986	1987	1988	1989	1990	1991	1992	1993	1994	1995	1996
1997	1998	1999	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009	2010



Unterschied: physikalisches Modell, wenige Daten

Beispiel vs. Definition

“[Machine Learning is the] field of study that gives computers the ability to learn without being explicitly programmed.”

- Arthur Samuel, 1959

→ Wir sagen dem Modell nicht explizit, auf welcher Bahn und mit welcher Geschwindigkeit sich Ceres bewegt, sondern dies wird aus den Daten erkannt.

Mathematik des maschinellen Lernens

Mathematisches Framework

Daten = Vektoren




Modelle = Funktionen
(zwischen Vektorräumen)


$$\begin{aligned}x_2 &= mx_1 + b? \\x_2 &= ax_1^2 + bx_1 + c? \\&\dots?\end{aligned}$$

Lernen = Finden der besten Werte von Funktionsparametern


$$x_2 = 1.4x_1 - 3.2$$



Lineare Algebra




Analysis
(+Statistik)



Optimierung

Was kann ein Algorithmus lernen?

Maschinelles Lernen bedeutet, eine **(mathematische) Funktion** an vorhandene Daten anzupassen („fitten“)




Theoretisch kann ein Algorithmus alle Aufgaben lernen, die man als mathematische Funktion, also als Input-Output Beziehung (von Vektoren) formulieren kann.

Beispiele


Maschinelles Lernen: Beispiele

- Spamfilter: Ist eine E-Mail Spam oder vertrauenswürdig?
 x : Text einer E-Mail (bzw. Featuredarstellung davon)
 y : 1 (Spam), 0 (kein Spam)
- Verkaufsvorhersage: Wie viele Einheiten von Produkt Z werden wir nächsten Monat verkaufen?
 x : Kaufdaten (Vergangenheit), wirtschaftliche Faktoren, etc.
 y : Anzahl der verkauften Einheiten



Maschinelles Lernen und KI

- Künstliche Intelligenz (KI) sind Systeme, die Dinge tun, die wir mit (menschlicher) „Intelligenz“ in Verbindung bringen
- Was Leute meinen, wenn sie „KI“ sagen, verändert sich laufend
- Heutzutage wird KI oft synonym mit LLM-basierten Systemen (ChatGPT & Co) verwendet
- Die wichtigsten KI-Anwendungen heutzutage werden durch ML-Modelle „angetrieben“. Das ist aber nicht zwingend notwendig.



Ein schöner Tag beginnt mit einem guten Kaffee!

jura

**Kaffeevollautomat
ENA 8 Touch Full
Metropolitan Black**

- 1,1 Liter Wassertank
- 125 Gramm Bohnenbehälter
- 12 Kaffeespezialitäten
- Puls-Extraktionsprozess (P.E.P.®)
optimiert die Extraktionszeit
- Touchscreen-Farbdisplay
- Auch in weiteren Farbausführungen erhältlich

Bestell-Nr.: 346 728



899.-
Abhol-Barpreis

Künstliche Intelligenz:
die am häufigsten bezogenen
Produkte ordnen sich autom. auf
den Plätzen 1 - 4 an.

**Cappuccino, Latte Macchiato,
Cortado etc. auf Knopfdruck**


Sonderposten
begrenzte Stückzahl
Abgabe nur in haushaltsüblichen Mengen

Gerät
ohne Deko

Maschinelles Lernen: Beispiele aus Computer Vision

A.I. Took a Test to Detect Lung Cancer. It Got an A.


Artificial intelligence may help doctors make more accurate readings of CT scans used to screen for lung cancer.



A colored CT scan showing a tumor in the lung. Artificial intelligence was just as good, and sometimes better, than doctors in diagnosing lung tumors in CT scans, a new study indicates. *Vaisin/Science Source*

$\mathbf{X}$: Farbwerte jedes Pixels

$\mathbf{y}$: Diagnose



$\mathbf{X}$: Farbwerte jedes Pixels

$\mathbf{y}$: Zugehörigkeit zu Segment
(Auto, Straße, Fußgänger, ...)

Maschinelles Lernen: Beispiele aus Natural Language Processing



X: Eingabetext (als Vektor codiert)

y: Übersetzter Text (als Vektor codiert)




ChatGPT

X: Prompt (als Vektor codiert)

y: Antwort (als Vektor codiert)

Maschinelles Lernen für Entscheidungsprobleme




GAMING REPORT TECH

DeepMind's AI agents conquer human pros at StarCraft II

But the humans won a single match, leaving room for improvement on both sides

By James Vincent | Jan 24, 2019, 5:16pm EST

Magnetic control of tokamak plasmas through deep reinforcement learning



Kategorisierung von ML

Maschinelles Lernen: Taxonomie

Im Allgemeinen unterscheidet man drei Ansätze im Maschinellen Lernen:


1. **Überwachtes Lernen („Supervised Learning“)** (siehe Hunde/Katzen Beispiel)
2. **Unüberwachtes Lernen („Unsupervised Learning“)**
3. **Bestärkendes Lernen („Reinforcement Learning“)**

- Jeder dieser Ansätze ist für unterschiedliche Probleme geeignet.
- Für jeden Ansatz gibt es eine Vielzahl verschiedener Algorithmen.
- Es geht bei allen Ansätzen darum, **Funktionen aus Daten** zu lernen

Supervised Learning - Algorithmen

Es existiert eine Vielzahl an verschiedenen Modellen / Algorithmen:

- Lineare Regression
- Logistische Regression
- Support Vector Maschinen
- Entscheidungsbäume
- Random Forests
- Gradient Boosting Machines
- k-Nearest Neighbors
- Neuronale Netzwerke (inkl. Deep Neural Networks)
- ...



Diese Vorlesung

Unsupervised Learning

Keine annotierten/gelabelten Daten, keine Zielgröße y .

Ziel: Muster in einer gegebenen Menge von Datenpunkten zu entdecken.

Anwendungsfälle von unsupervised learning sind:

- **Clusteranalyse:** welche Datenpunkte sind zueinander ähnlich
- **Dimensionsreduktion:** Hochdimensionale Daten mit möglichst wenigen Merkmalen möglichst gut beschreiben
- **Generative Modelle:** Ein Modell, das synthetische Daten generiert, die ähnlich zu den Trainingsdaten sind
- **Anomalie Detektion** (—> Ausreißererkennung)
- Lernen von **Assoziationsregeln** (—> Warenkorbanalyse)

Reinforcement Learning

Methode zur Lösung **sequenzieller Entscheidungsprobleme**, d.h. Probleme der Form:

Entscheidung, neue Information, Entscheidung, neue Information, ...


Ziel: **Policy** (Regelgesetz) lernen

Anwendungsfälle von Reinforcement Learning sind:

- Spiele (Computerspiele, Go, Schach)
- Steuerung von Robotern
- Regelung technischer Prozesse
- Wichtig: Brauche „*Modell der Umgebung*“, das die Auswirkungen einer Entscheidung abbildet.

Reinforcement Learning: Training

- Ziel ist es, eine sog. **Policy** zu lernen
- Policy: mathematische Funktion, die für jede Situation angibt, welche Entscheidung zu treffen ist.
- Training: man lässt eine Policy (den „Agenten“) mit ihrer Umgebung interagieren und vergibt **Belohnungen** bzw. **Bestrafungen** für gute bzw. schlechte Entscheidungen.
- Dadurch lernt das Modell, möglichst gute Entscheidungen (in jeder Situation) zu treffen.




Deep Learning

Deep Learning bezeichnet eine spezielle Familie von Modellen (Funktionen), sog. (tiefe) **neuronale Netze**.

In den letzten 15 Jahren wurden entscheidende Fortschritte im Bereich Deep Learning erzielt.


Aktuelle KI-Systeme basieren meist auf neuronalen Netzen:

- Natural Language Processing / LLMs
- Computer Vision
- Reinforcement Learning



Deep Learning

- Vorteil: Tiefe neuronale Netze können sehr komplexe Probleme lösen
- Nachteil:
 - (Sehr) viele (und gute) Daten nötig
 - Schwierig zu trainieren
- Deep Learning kann in allen Kategorien von ML eingesetzt werden:



Inhalt der Vorlesung

1. Einführung
2. Lineare Regression
3. Optimierung
4. Klassifizierungsprobleme, logistische Regression
5. Generalisierung, Overfitting und Regularisierung
6. Neuronale Netze: Grundlagen
7. Training von neuronalen Netzen
8. Faltungsnetze
9. Autoencoder
10. Sequenzielle Entscheidungsprobleme

Einordnung dieser Vorlesung

- In dieser Vorlesung geht es vor allem darum, **Konzepte** zu vermitteln, die dem maschinellen Lernen zugrunde liegen
- Die neuesten Deep Learning Modelle und Architekturen werden hier nicht besprochen – stattdessen erhält man das Rüstzeug um aktuelle (und zukünftige!) Modelle zu verstehen
- Modul **Künstliche Intelligenz** (INFM210ML):
 - Fokus auf **Anwendung** der hier in Ansätzen vorgestellten Deep Learning Methoden
 - State-of-the art Modelle
- Modul **Data Science** (INFM120ML):
 - **Optimierungsverfahren** und **numerische Methoden**
 - **Datenvorverarbeitung** und explorative **Datenanalyse**

Material

- Skript! Leider nur z.T. fertig :-(
- Folien zur Vorlesung (in ILIAS)
- Folgende Bücher werden zur Vorbereitung auf die Vorlesung verwendet:

