

07.07.2023

**Klausur – Maschinelles Lernen - Teil Janka**

Name: \_\_\_\_\_

Vorname: \_\_\_\_\_

Matrikelnummer: \_\_\_\_\_

Dauer der Prüfung: 60 Minuten

**Erlaubte Hilfsmittel:**

- Es sind keine Hilfsmittel erlaubt.

**Bearbeitungshinweise:**

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die **links daneben liegende** leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden. Die letzte Seite mit der Formelsammlung dürfen Sie ausreißen.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

| Aufgabe     | 1 | 2 | 3 | 4 | 5  | $\Sigma$ | Note |
|-------------|---|---|---|---|----|----------|------|
| Max. Punkte | 9 | 9 | 9 | 9 | 10 | 46       |      |
| Punkte      |   |   |   |   |    |          |      |

**Ich wünsche Ihnen viel Erfolg!**

**Aufgabe 1 (4+4+1=9 Punkte)** Lineare Modelle.

- (a) Beschreiben Sie kurz den allgemeinen Prozess zur Entwicklung eines Supervised Learning Modells.

**Lösung:**

- Ausgangspunkt: Feature/Label-Paare  $(x_i, y_i)$
  - Split in Trainings- und Testdaten
  - Trainieren des Modells auf den Trainingsdaten: Suche Funktion  $f$ , so dass  $f(x_i) \approx y_i$
  - Auswerten des Modells auf den Testdaten
- (b) Eine Firma möchte ein lineares Regressionsmodell entwickeln, das den Jahresumsatz vorhersagt. Dazu sollen als Features der Umsatz des vergangenen Jahres und der Umsatz des Jahres davor verwendet werden (eine Vorhersage kann also nur für die Jahre gemacht werden, bei denen schon Daten für mindestens zwei Jahre bekannt waren).

Die Jahresumsätze, die als Grundlage für die Trainingsdaten dienen, sind wie folgt:

| Jahr | Umsatz [M€] |
|------|-------------|
| 2017 | 30          |
| 2018 | 45          |
| 2019 | 50          |
| 2020 | 57          |
| 2021 | 60          |

Stellen Sie die Least Squares Verlustfunktion für das lineare Regressionsmodell auf (den Parameter  $w_0$  können Sie weglassen).

**Lösung:**

$$L(w_1, w_2) = \frac{1}{3} ((50 - (w_1 45 + w_2 30))^2 + (57 - (w_1 50 + w_2 45))^2 + (60 - (w_1 57 + w_2 50))^2)$$

- (c) Die Modellfunktion einer logistischen Regression ist, im Gegensatz zur linearen Regression, keine lineare Funktion. Warum bezeichnet man ein logistisches Regressionsmodell trotzdem als lineares Modell?

**Lösung:**

Die Entscheidungsgrenze, die die logistische Regression produziert, ist linear.

**Aufgabe 2 (2+4+3=9 Punkte)** Regularisierung und Hyperparametersuche.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?

**Lösung:**

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

- (b) Regularisierung von linearen Modellen.

- i. Nennen Sie eine Möglichkeit ein lineares Modell zu regularisieren.

**Lösung:**

Durch Addition eines Strafterms ( $\ell_1$  oder  $\ell_2$ ) zur Verlustfunktion.

- ii. Beschreiben Sie einen typischen Umstand, bei dem im Falle eines linearen Modells eine Regularisierung notwendig ist.

**Lösung:**

Wenn es mehr Features als Datenpunkte gibt. Auch bei polynomiellen Features (polynomielle Regression).

- iii. Welche beiden Nachteile entstehen durch die Regularisierung eines linearen Modells?

**Lösung:**

Modellgüte wird schlechter, Parameter sind nicht mehr interpretierbar.


- (c) Beschreiben Sie kurz die Hyperparametersuche mit einem Validierungsdatensatz.

**Lösung:**

- i. Kandidatenmenge festlegen
- ii. Für jeden Kandidaten Modell trainieren, auf Modellgüte auf Validierungsdaten testen
- iii. Modelltraining mit gesamtem Trainingsdatensatz mit dem Parameter mit der besten Performance auf den Validierungsdaten

### Aufgabe 3 (4+5=9 Punkte) Neuronale Netze.

(a) Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht haben jeweils einen Bias von  $-1$ , das Neuron der Output Schicht von  $+1$ . In der verdeckten Schicht wird ReLU als Aktivierungsfunktion verwendet. In der Ausgangsschicht kommt keine Aktivierungsfunktion zum Einsatz.

Welchen Ausgabewert würde das Netz für den Eingabevektor  $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$  liefern?

**Lösung:**

$$-2 \max(0, -1 - 1) - 1 \max(0, -2 - 1) + 1 \max(0, 1 + 6 - 1) + 1 = 7$$

(b) Für ein binäres Klassifikationsproblem haben Sie 2000 Trainingsbeispiele gesammelt. Jeder Datenpunkt wird durch 150 Features und ein 0/1-wertiges Label repräsentiert. Für die Vorhersage des Labels möchten Sie ein neuronales Netz trainieren, welches 1000 Parameter hat. Sie trainieren das Modell für 30 Epochen mit dem stochastischen Gradientenabstieg.

Beantworten Sie folgende Fragen zu den Problemdimensionen (keine Begründungen nötig):

i. Wie viele Summanden hat die Verlustfunktion?

**Lösung:**

2000

ii. Welche Dimension hat der Gradient der (gesamten) Verlustfunktion?

**Lösung:**

1000

iii. Welche Dimension hat der Gradient einer Minibatch (Minibatchgröße 10) der Verlustfunktion?

**Lösung:**

1000

iv. Wie oft wird bei einer Minibatchgröße von 10 im Laufe des stochastischen Gradientenverfahrens der Parametervektor aktualisiert (30 Epochen)?

**Lösung:**

$200 * 30 = 6000$

v. Wie oft wird bei einem normalen Gradientenabstiegsverfahren (batch Gradientenabstieg) der Parametervektor aktualisiert (30 Epochen)?


**Lösung:**

30

**Aufgabe 4 (3+3+3=9 Punkte)** Backpropagation. Gegeben sei die Funktion  $f(x) = (e^x \cos x)^2$ .

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für die Funktion  $f$  auf. Bezeichnen Sie dabei die Knoten mit  $x_i, i = 1, 2, \dots$  und geben Sie für jeden Knoten die Funktionsdefinition an.

**Lösung:**



- (b) Vorwärtsphase: Berechnen Sie  $f(0)$  mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten  $x_i, i = 1, 2, \dots$  an.

**Lösung:**

$$x_1 = 0$$

$$x_2 = 1$$

$$x_3 = 1$$

$$x_4 = 1$$

$$x_5 = 1$$

- (c) Rückwärtsphase: Berechnen Sie  $\frac{\partial f}{\partial(x)}$  an der Stelle  $x = 0$  mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten  $\bar{x}_i, i = 1, 2, \dots$  an.

**Lösung:**

$$\bar{x}_5 = 1$$

$$\bar{x}_4 = \bar{x}_5 \frac{\partial x_5}{\partial x_4} = 2x_4 = 2$$

$$\bar{x}_3 = \bar{x}_4 \frac{\partial x_4}{\partial x_3} = 2x_2 = 2$$

$$\bar{x}_2 = \bar{x}_4 \frac{\partial x_4}{\partial x_2} = 2x_3 = 2$$

$$\bar{x}_1 = \bar{x}_2 \frac{\partial x_2}{\partial x_1} + \bar{x}_3 \frac{\partial x_3}{\partial x_1} = 2e^{x_1} - 2 \sin x_1$$

**Aufgabe 5 (2+4+2+2=10 Punkte)** Spezielle neuronale Netze.

- (a) Faltungsschichten werden oft benutzt, um das Vorhandensein bestimmter Muster in Bildern zu erkennen. Erklären Sie kurz, wie das funktioniert.

**Lösung:**

Hohe Werte in der Featuremap bedeuten, dass der Bereich eines Bildes ähnlich zum Filterkern ist. So können Muster, die dem Filterkern ähneln, erkannt werden.

- (b) Für  $28 \times 28$  Pixel Bilder mit 3 Farbkkanälen (RGB) sei eine Faltungsschicht bestehend aus 4 Filtern definiert. Die Filter haben jeweils die Dimension  $3 \times 3$ . Weiterhin wird kein Padding und ein Stride von 1 verwendet.

- (i) Wie viele Parameter hat die Faltungsschicht?

**Lösung:**

Jeder Filter hat  $3 \cdot 3 \cdot 3 + 1 = 28$  Parameter. Die Schicht besteht aus vier Filtern, hat also  $4 \cdot 28 = 112$  Parameter.

- (ii) Welche Dimension hat der Output der Faltungsschicht?

**Lösung:**

Es entstehen 4 Featuremaps der Größe  $26 \times 26$ . Der Output ist also ein Tensor der Dimension  $26 \times 26 \times 4$ .

- (c) Wenn man den Stride ändert, ändert sich die Anzahl der Parameter? Wenn ja: wie, wenn nein: was ändert sich sonst?

**Lösung:**

Nein. Die Output-Dimensionen verringert sich um die Hälfte.

- (d) Beschreiben Sie kurz den Zusammenhang zwischen einem Autoencoder und einer Principal Component Analysis (PCA).

**Lösung:**

Ein linearer Autoencoder (d.h. ohne Aktivierungsfunktion) lernt die gleiche Transformation wie eine PCA.