

13.06.2022

Probeklausur – Maschinelles Lernen (Teil Janka)

Name: _____

Vorname: _____

Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Wissenschaftlicher Taschenrechner (nicht programmierbar, nicht grafikfähig)

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die links daneben liegende leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	Σ	Note
Max. Punkte	12	9	10	8	9	48	
Punkte							

Ich wünsche Ihnen viel Erfolg!

Aufgabe 1 (3+6+3=12 Punkte) Logistische Regression.

Angenommen, wir haben vor einer Klausur Daten von Studierenden mit den folgenden Merkmalen gesammelt: x_1 = "Stunden gelernt", x_2 = "bisheriger Notendurchschnitt" und y = "Klausurnote < 2.0".

Wir haben dafür eine logistische Regression durchgeführt und als Koeffizienten $w_0 = -2$, $w_1 = 0.05$ und $w_2 = -1$ erhalten.

- (a) Berechnen Sie die Wahrscheinlichkeit, dass ein Studierender, der 40 Stunden gelernt hat und einen Notendurchschnitt von 2.3 hat, eine Klausurnote besser als 2.0 bekommt.

- (b) Es seien folgende drei Punkte $x^{(i)} = (x_1^{(i)}, x_2^{(i)})$, $y^{(i)}$, $i \in \{1, 2, 3\}$ gegeben:

- $x^{(1)} = (40, 2.7)$, $y^{(1)} = 0$,
- $x^{(2)} = (5, 3.3)$, $y^{(2)} = 0$,
- $x^{(3)} = (40, 1.3)$, $y^{(3)} = 1$.

Berechnen Sie die Log-Loss Verlustfunktion (Kreuzentropie) für diesen Datensatz mit den angegebenen Parameter w_0, w_1, w_2 .


- (c) Wie lange müsste der Studierende aus (a) lernen, um dem Modell nach eine 50% Chance auf eine Klausurnote besser als 2.0 zu haben?

Aufgabe 2 (2+1+6=9 Punkte) Regularisierung.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?
- (b) Nennen Sie eine Möglichkeit zur Regularisierung von logistischen Regressionsmodellen.
- (c) Gegeben seien 10,000 Datenpunkte um eine lineare Regression mit Regularisierung zu trainieren. Sie wählen zunächst 20% der Daten als Testset. Sie möchten nun 4 verschiedene Werte für λ ausprobieren und testen, ob Lasso oder Ridge Regression bessere Ergebnisse liefert.
- Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen beim Ansatz mit einem Validierungsdatensatz von 25% der Trainingsdaten trainiert werden?
 - Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen trainiert werden, wenn eine 5-fache Kreuzvalidierung mit dem Validierungsdatensatz durchgeführt wird?

Aufgabe 3 (2+3+3+2=10 Punkte) Neuronale Netze.

Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht sowie das Output Neuron haben jeweils keinen Bias. Die verwendete Aktivierungsfunktion ist in der verdeckten Schicht ReLU in der Ausgabeschicht die Sigmoid-Funktion $\sigma(z) = \frac{1}{1+e^{-z}}$.

(a) Für welche Art von überwachtem Lernproblem kann dieses Netz prinzipiell eingesetzt werden?

(b) Schreiben Sie die Funktion auf, die das Netz für einen beliebige Eingabe $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ berechnet.

(c) Welchen Vorhersagewert $\hat{y}$ liefert das Netz für die Eingabe $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 \\ 0.5 \end{pmatrix}$?

(d) Warum benutzt man für das Training von neuronalen Netzen in der Regel den stochastischen Gradientenabstieg (und nicht den gewöhnlichen Gradientenabstieg)?

Aufgabe 4 (3+3+3=9 Punkte) Backpropagation.

Gegeben sei die Funktion $f(x, y) = x^2 + y^2$

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für die Funktion f auf. Bezeichnen Sie dabei die Knoten mit $x_i, i = 1, 2, \dots$ und geben Sie für jeden Knoten die Funktionsdefinition an.

- (b) Vorwärtsphase: Berechnen Sie $f(1, 2)$ mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten $x_i, i = 1, 2, \dots$ an.

- (c) Rückwärtsphase: Berechnen Sie $\frac{\partial f}{\partial(x,y)}$ an der Stelle $(1, 2)$ mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten $\bar{x}_i, i = 1, 2, \dots$ an.

Aufgabe 5 (6+2=8 Punkte) Faltungsnetze.

(a) Für 100×100 Pixel Bilder (RGB) sei eine Faltungsschicht bestehend aus 4 Filtern definiert. Die Filter haben jeweils die Dimension 5×5 . Weiterhin wird kein Padding und ein Stride von 1 verwendet.

(i) Wie viele Parameter hat die Faltungsschicht?

(ii) Welche Dimension hat der Output der Faltungsschicht?

(b) Beschreiben Sie kurz, was eine Max-Pooling Schicht macht.