

30.01.2026

Klausur – Maschinelles Lernen - Teil Emre

WS 2025/26

Name: _____

Vorname: _____

Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Es sind keine Hilfsmittel erlaubt.

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die **links daneben liegende** leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	6	Σ	Note
Max. Punkte	9	8	9	9	8	3	46	
Punkte								

Aufgabe 1 (3+4+2=9 Punkte): Logistische Regression.

Die Bundesanstalt für Straßenwesen hat an einer Kreuzung Fahrradbewegungen aufgezeichnet. Auf Basis dieser Daten soll mithilfe eines logistischen Regressionsmodells vorhergesagt werden, ob es unter gegebenen Bedingungen zu einem Fahrradunfall kommt oder nicht.

Die Trainingsdaten bestehen aus folgenden Merkmalen:

- Label: Unfall (ja = 1 / nein = 0)
- Feature 1: Niederschlagsmenge (in mm)
- Feature 2: Tageszeit (Tag = 1 / Nacht = 0)
- Feature 3: Überquerung von Straßenbahnschienen (ja = 1 / nein = 0)

Wir sehen hier einen Ausschnitt der Trainingsdaten:

	Niederschlagsmenge [mm]	Tageszeit	Überquerung von Straßenbahnschienen	Unfall
Fahrrad 1	0	Nacht	ja	ja
Fahrrad 2	2	Tag	ja	nein
...				

- 1a.) Angenommen, Sie haben ihr Modell für die drei Features trainiert und als Koeffizienten folgende Werte erhalten: $w_0 = 0$, $w_1 = 4$, $w_2 = -1$ und $w_3 = -7$. Welche Unfallwahrscheinlichkeit sagt das Modell für Fahrrad 2 vorher?

Lösung (3 Punkte):

$$\hat{y}(x) = \frac{1}{1 + e^{-(w_0 + w_1 \cdot x_1 + w_2 \cdot x_2 + w_3 \cdot x_3)}} = \frac{1}{1 + e^{-(0 + 4 \cdot 2 - 1 \cdot 1 - 7 \cdot 1)}} = 0.5$$

- 1b.) i. Welche Verlustfunktion benutzt man normalerweise für das Training der logistischen Regression? (ohne Begründung)

Lösung (2 Punkte):

(Binäre) Kreuzentropie.

- ii. Berechnen Sie den Verlust für Fahrrad 2 mit den in (a) angegebenen Parametern.

Lösung (2 Punkte):


$$\ell(x, y) = -\log 0.5 = 0.69$$

- 1c.) Warum wird in der logistischen Regression die Sigmoid-Funktion verwendet?

Lösung (2 Punkte):

- Die Sigmoid-Funktion wird verwendet, weil sie die Ausgabe auf einen Wert zwischen 0 und 1 beschränkt, was als Wahrscheinlichkeit interpretiert werden kann.
- Außerdem ist sie stetig und differenzierbar, was das Training des Modells mit Gradientenverfahren ermöglicht.

Aufgabe 2 (4+2+2=8 Punkte): Klassifikationsmetriken.



2a.) Berechnen Sie die Accuracy, Precision und Recall für das oben dargestellte binäre Klassifikationsproblem. Hinweis: Vereinfachte Brüche sind ausreichend; eine Dezimaldarstellung ist nicht nötig.

Lösung (4 Punkte):

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} = \frac{2 + 3}{10} = \frac{5}{10} = \frac{1}{2} = 0.5$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{2}{2 + 2} = \frac{2}{4} = \frac{1}{2} = 0.5$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{2}{2 + 3} = \frac{2}{5} = 0.4$$

2b.) Erklären Sie in eigenen Worten den Unterschied zwischen Precision und Recall bei einem binären Klassifikationsproblem und erläutern Sie jeweils, welche Fehlklassifikationen (False Positives bzw. False Negatives) dabei besonders relevant sind.

Lösung (2 Punkte):

- Precision gibt an, welcher Anteil der als positiv klassifizierten Beispiele tatsächlich positiv ist und ist besonders sensibel gegenüber False Positives.
- Recall gibt an, welcher Anteil der tatsächlich positiven Beispiele vom Modell korrekt erkannt wird und ist besonders sensibel gegenüber False Negatives.

2c.) Nennen Sie jeweils ein Anwendungsbeispiel mit hoher Relevanz für Recall und ein weiteres mit hoher Relevanz für Precision. Begründen Sie Ihre Antworten kurz.

Lösung (2 Punkte):

- Recall: Beispielsweise bei der medizinischen Diagnostik (z.B. Krebsfrüherkennung), da möglichst alle tatsächlich positiven Fälle erkannt werden sollen und False Negatives schwerwiegende Folgen haben können.
- Precision: Beispielsweise bei der Spam-Erkennung, da fälschlich als Spam klassifizierte wichtige E-Mails (False Positives) vermieden werden sollen.

Aufgabe 3 (2+3+2+2=9 Punkte): Regularisierung und Hyperparametersuche.

3a.) Erklären Sie das Ziel von Regularisierung im maschinellen Lernen.

Lösung (2 Punkte):

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

3b.) Erläutern Sie die wesentlichen Unterschiede zwischen Ridge Regression und Lasso Regression. Gehen Sie dabei insbesondere auf die verwendete Regularisierungsnorm und die Auswirkungen auf die Modellparameter ein.

Lösung (3 Punkte):

- Beide Verfahren fügen dem empirischen Fehler einen Regularisierungsterm hinzu.
- Bei der Ridge Regression wird eine L2-Norm der Gewichte $\|w\|_2^2$ bestraft, bei der Lasso Regression eine L1-Norm $\|w\|_1$.
- L1-Regularisierung führt dazu, dass einige Gewichte exakt null werden, was zu einem spärlichen Modell führt bzw. einer Merkmalsauswahl (Feature Selection).
- L2-Regularisierung führt dazu, dass alle Gewichte verkleinert werden, aber selten exakt null werden.

3c.) Beschreiben Sie das allgemeine Verfahren zur Hyperparametersuche. Gehen Sie dabei auf die Aufteilung der Daten in Trainings-, Validierungs- und Testdaten sowie deren jeweilige Rolle ein.

Lösung (2 Punkte):

- Die Daten werden in Trainings-, Validierungs- und Testdaten aufgeteilt.
- Das Modell wird mit verschiedenen Hyperparameter-Kombinationen (z.B. verschiedene Regularisierungsstärken) auf den Trainingsdaten trainiert.
- Die Leistung des Modells wird auf den Validierungsdaten bewertet, um die beste Hyperparameter-Kombination auszuwählen.
- Schließlich wird die endgültige Modellleistung mit den ausgewählten Hyperparametern auf den Testdaten gemessen, um eine unverzerrte Schätzung der Modellleistung zu erhalten.


3d.) Erklären Sie den Bias-Variance Tradeoff im maschinellen Lernen. Gehen Sie dabei darauf ein, wie sich die Modellkomplexität auf Bias und Varianz auswirken.

Lösung (2 Punkte):

- Der Bias-Variance Tradeoff beschreibt den Konflikt zwischen dem Bias (systematischer Fehler) und der Varianz (Empfindlichkeit gegenüber Trainingsdaten) eines Modells.
- Mit zunehmender Modellkomplexität sinkt typischerweise der Bias, während die Varianz steigt (Overfitting).
- Mit abnehmender Modellkomplexität (z.B. durch stärkere Regularisierung) steigt der Bias, während die Varianz sinkt (Underfitting).

Aufgabe 4 (4+2+3=9 Punkte): Neuronale Netze.

Gegeben ist folgendes neuronale Netz mit drei Eingaben und zwei Ausgaben. Das Neuron in der mittleren Schicht hat einen Bias von 2, die Neuronen in der Ausgabeschicht haben keinen Bias.



4a.) Geben Sie den Ausgabevektor $\hat{y}$ für den Eingabevektor $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$ an.

Lösung (4 Punkte):

$$\hat{y} = \begin{pmatrix} \max \left(-1 \max \left((2, 3, -3) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + 2, 0 \right), 0 \right) \\ \max \left(2 \max \left((2, 3, -3) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + 2, 0 \right), 0 \right) \end{pmatrix}$$

4b.) Geben Sie den Ausgabevektor $\hat{y}$ für den Eingabevektor $\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ an.

Lösung (2 Punkte):

$$\hat{y} = \begin{pmatrix} \max \left(-1 \max \left((2, 3, -3) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} + 2, 0 \right), 0 \right) \\ \max \left(2 \max \left((2, 3, -3) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} + 2, 0 \right), 0 \right) \end{pmatrix} = \begin{pmatrix} \max(-1 \max(4, 0), 0) \\ \max(2 \max(4, 0), 0) \end{pmatrix} = \begin{pmatrix} 0 \\ 8 \end{pmatrix}$$


4c.) Beschreiben Sie kurz, was man beim stochastischen Gradientenverfahren beobachtet, wenn die Lernrate zu groß bzw. zu klein gewählt ist.

Lösung (3 Punkte):

- Ist die Lernrate zu groß, kann das stochastische Gradientenverfahren instabil werden und über das Minimum hinausspringen, sodass die Kostenfunktion oszilliert oder divergiert.
- Ist die Lernrate zu klein, konvergiert das Verfahren zwar stabil, aber sehr langsam und benötigt viele Iterationen.

Aufgabe 5 (2+6=8 Punkte): Backpropagation.

Gegeben ist folgender Berechnungsgraph:



5a.) Geben sie die Funktion f an, die durch diesen Graphen dargestellt ist.

Lösung (2 Punkte):

$$f(x_1, x_2) = (x_1 + x_2) \cdot e^{x_1 + x_2}$$

5b.) Berechnen sie den Gradienten ∇f an der Stelle $(x_1, x_2) = (0, 1)$ mit Hilfe des Backpropagation Algorithmus. Führen sie dazu zunächst die Vorwärtsphase und dann die Rückwärtsphase aus.

Lösung (6 Punkte):

Vorwärtsphase:

$$x_1 = 0$$

$$x_2 = 1$$

$$x_3 = x_1 + x_2 = 0 + 1 = 1$$

$$x_4 = e^{x_3} = e^1 = e$$

$$x_5 = x_3 \cdot x_4 = 1 \cdot e = e$$

Rückwärtsphase:

$$\bar{x}_5 = 1$$

$$\bar{x}_4 = \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_4} = 1 \cdot x_3 = 1 \cdot 1 = 1$$

$$\bar{x}_3 = \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_3} + \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_3} = 1 \cdot x_4 + 1 \cdot e^{x_3} = e + e = 2e$$


$$\bar{x}_2 = \bar{x}_3 \cdot \frac{\partial x_3}{\partial x_2} = 2e \cdot (0 + 1) = 2e$$

$$\bar{x}_1 = \bar{x}_3 \cdot \frac{\partial x_3}{\partial x_1} = 2e \cdot (1 + 0) = 2e$$

$$\nabla f(0, 1) = (2e, 2e)$$

Aufgabe 6 (1+1+1=3 Punkte): Convolutional Neural Network.

Gegeben ist ein Convolutional Neural Network (CNN), das zur Klassifikation von Graustufenbildern der Größe 28×28 verwendet wird.



Das Netzwerk besteht aus folgenden Schichten:

- **Convolutional Layer:** Wendet 8 Faltungsfilter der Größe 3×3 mit einer Stride von 1 und Zero Padding auf das 28×28 große Graustufenbild an und verwendet die ReLU-Aktivierungsfunktion.
- **Max-Pooling Layer:** Reduziert die räumliche Auflösung der Feature Maps, indem er Max-Pooling mit einer Poolgröße von 2×2 und einer Stride von 2 durchführt.
- **Flatten Layer:** Formt die mehrdimensionalen Feature Maps aus dem vorherigen Layer zu einem eindimensionalen Vektor um, der als Eingabe für die vollständig verbundenen Schichten dient.
- **Fully Connected Layer:** Verbindet alle Neuronen des Flatten Layers vollständig miteinander und berechnet mithilfe der Softmax-Aktivierungsfunktion 10 Ausgabewerte, die die Klassenwahrscheinlichkeiten repräsentieren.

6a.) Bestimmen Sie die räumliche Größe (Höhe $\times$ Breite $\times$ Tiefe) der Feature Maps nach dem Convolutional Layer.

Lösung (1 Punkte):

$$W_{\text{out}} = \left\lfloor \frac{W_{\text{in}} - W_K + 2P}{S} \right\rfloor + 1 = \left\lfloor \frac{28 - 3 + 2 \cdot 1}{1} \right\rfloor + 1 = 28$$
$$H_{\text{out}} = W_{\text{out}} = 28$$
$$D_{\text{out}} = K = 8$$
$$(W_{\text{out}}, H_{\text{out}}, D_{\text{out}}) = (28, 28, 8)$$

6b.) Wie viele lernbare Parameter besitzt der Convolutional Layer insgesamt?

Lösung (1 Punkte):

$$K \cdot (W_K \cdot H_K \cdot D_{\text{in}} + 1) = 8 \cdot (3 \cdot 3 \cdot 1 + 1) = 80$$

6c.) Wie viele lernbare Parameter besitzt der Max-Pooling Layer insgesamt?

Lösung (1 Punkte):

0