

08.07.2022

Klausur – Maschinelles Lernen - Teil Janka

Name: _____

Vorname: _____

Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Es sind keine Hilfsmittel erlaubt.

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die links daneben liegende leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	Σ	Note
Max. Punkte	10	9	10	9	8	46	
Punkte							

Ich wünsche Ihnen viel Erfolg!

Aufgabe 1 (3+5+2=10 Punkte) Lineare Regression. Angenommen, wir haben einen Datensatz mit den beiden Features x_1 = “Betriebszugehörigkeit in Monaten” und x_2 = “Hochschulabschluss (0 für nein, 1 für ja)” und möchten damit die Variable y = “Jahreseinkommen eines Angestellten in Tausend EUR” vorhersagen. Wir haben dafür eine lineare Regression durchgeführt und als Koeffizienten $w_0 = 25$, $w_1 = 0.1$ und $w_2 = 15$ erhalten.

- (a) Berechnen Sie die Vorhersage für das Gehalt eines Angestellten mit Hochschulabschluss, der seit 20 Monaten in der Firma ist.

Lösung:

$\hat{y} = 25 + 0.1 \cdot 20 + 15 = 42$. Das Modell würde für den Angestellten 42000EUR Jahresgehalt vorhersagen.

- (b) Es sei folgender Datensatz gegeben:

Name	Betriebszugehörigkeit [Monate]	Hochschulabschluss	Jahresgehalt [TEUR]
Person 1	20	ja	43
Person 2	62	ja	65
Person 3	30	nein	32

Stellen Sie die Least Squares Verlustfunktion für diesen Datensatz und die Parameter w_0, w_1, w_2 aus (a) auf. (Hinweis: Sie müssen das Ergebnis nicht ausrechnen)

Lösung:

$$\begin{aligned}
 L(w_0, w_1, w_2) &= \\
 &= \frac{1}{3} \left((43 - (25 + 0.1 \cdot 20 + 15))^2 + (65 - (25 + 0.1 \cdot 62 + 15))^2 + (32 - (25 + 0.1 \cdot 30))^2 \right) \\
 &= 214.48
 \end{aligned}$$

- (c) Wie könnten Sie überprüfen, ob die angegebenen Parameter w_0, w_1, w_2 die optimalen Parameter für den Datensatz aus (b) sind? (Hinweis: Kurze Beschreibung der mathematischen Vorgehensweise genügt, keine explizite Berechnung verlangt)

Lösung:

Man müsste überprüfen, ob die partiellen Ableitungen der Verlustfunktion verschwinden, d.h. ob $\nabla L(w_0, w_1, w_2) = 0$.

Aufgabe 2 (2+2+2+3=9 Punkte) Regularisierung und Hyperparametersuche.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?

Lösung:

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

- (b) Nennen Sie zwei Möglichkeiten zur Regularisierung von neuronalen Netzen.

Lösung:

- ℓ_1/ℓ_2 Regularisierung
- Dropout
- Early stopping
- (SGD mit kleiner Batchsize – problemabhängig, funktioniert nicht immer)

- (c) Warum benutzt man zur Hyperparametersuche nicht die Testdaten sondern einen separaten Validierungsdatensatz?

Lösung:

Um bei der Hyperparametersuche kein Overfitting auf die Testdaten zu machen.

- (d) Gegeben seien 10,000 Datenpunkte um eine logistische Regression zu trainieren. Sie wählen zunächst 40% der Daten als Testset. Sie möchten nun eine Hyperparametersuche mittels Gittersuche durchführen. Sie möchten nun 10 verschiedene Werte für λ ausprobieren und testen, ob Lasso oder Ridge Regression bessere Ergebnisse liefert.


Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen trainiert werden, wenn eine 3-fache Kreuzvalidierung durchgeführt wird?

Lösung:

$10 \cdot 2 \cdot 3 = 60$ Modelle mit 4000 Trainingsdatenpunkten und 1 Modell mit 6000 Trainingsdatenpunkten.

Aufgabe 3 (5+3+2=10 Punkte) Neuronale Netze.

Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht sowie das Output Neuron haben jeweils keinen Bias. In der verdeckten Schicht wird ReLU als Aktivierungsfunktion verwendet. In der Ausgabeschicht kommt keine Aktivierungsfunktion zum Einsatz.

- (a) Welche Funktion berechnet das Netz für einen beliebigen Eingabevektor $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$?

Lösung:

$$-2 \max(0, x_1) + 0 \max(0, 2x_1) + 1 \max(0, -x_1 + 3x_2) \quad (1)$$

$$= -2 \max(0, x_1) + \max(0, -x_1 + 3x_2) \quad (2)$$

- (b) Welchen Ausgabewert würde das Netz für den Eingabevektor $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$ liefern?

Lösung:

$$-2 \max(0, -1) + \max(0, -(-1) + 3 \cdot 2) = 7$$

- (c) Wie müsste man die Ausgabeschicht dieses Netzes modifizieren, damit man es auf Klassifikationsprobleme mit K Klassen anwenden kann (kurze Beschreibung, keine Formel verlangt)?

Lösung:


Die Ausgabeschicht müsste aus K Neuronen bestehen. Als Aktivierungsfunktion würde man die Softmax-Funktion verwenden.

Aufgabe 4 (3+3+3=9 Punkte) Backpropagation.

Gegeben sei die Funktion $f(x, y) = x^2 \exp y$.

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für die Funktion f auf. Bezeichnen Sie dabei die Knoten mit $x_i, i = 1, 2, \dots$ und geben Sie für jeden Knoten die Funktionsdefinition an.

Lösung:



- (b) Vorwärtsphase: Berechnen Sie $f(2, 0)$ mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten $x_i, i = 1, 2, \dots$ an.

Lösung:

$$\begin{aligned}x_1 &= x = 2 \\x_2 &= y = 0 \\x_3 &= x_1^2 = 4 \\x_4 &= \exp x_2 = 1 \\x_5 &= x_3 x_4 = 4\end{aligned}$$

- (c) Rückwärtsphase: Berechnen Sie $\frac{\partial f}{\partial(x, y)}$ an der Stelle $(2, 0)$ mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten $\bar{x}_i, i = 1, 2, \dots$ an.

Lösung:

$$\begin{aligned}\bar{x}_5 &= 1 \\ \bar{x}_4 &= \bar{x}_5 \frac{\partial x_5}{\partial x_4} = \bar{x}_5 x_3 = 4 \\ \bar{x}_3 &= \bar{x}_5 \frac{\partial x_5}{\partial x_3} = \bar{x}_5 x_4 = 1 \\ \bar{x}_2 &= \bar{x}_4 \frac{\partial x_4}{\partial x_2} = \bar{x}_4 \exp x_2 = 4 \\ \bar{x}_1 &= \bar{x}_3 \frac{\partial x_3}{\partial x_1} = \bar{x}_3 \cdot 2x_1 = 4\end{aligned}$$

Aufgabe 5 (2+2+4=8 Punkte) Autoencoder.

- (a) Beschreiben Sie kurz, wofür ein Autoencoder eingesetzt wird.

Lösung:

Ein Autoencoder ist ein neuronales Netz, dessen Eingabeschicht die gleiche Dimension wie die Ausgabeschicht hat. Das Ziel eines Autoencoders ist es, eine reduzierte Darstellung eines Datensatzes zu berechnen. (Nicht gefragt: Dies wird erreicht, indem mindestens eine der verdeckten Schichten eine niedrigere Dimension als die Ein- und Ausgabeschicht besitzt und gleichzeitig das Modell darauf trainiert wird, die Eingabe zu rekonstruieren).

- (b) Geben Sie die Verlustfunktion an, die beim Training eines Autoencoders minimiert wird.


Lösung:

Der durchschnittliche quadratische Fehler der Rekonstruktion:

$$L(w) = \frac{1}{N} \sum_{i=1}^N \|x^{(i)} - \tilde{x}^{(i)}\|^2$$

- (c) Skizzieren Sie einen Autoencoder, der eine zweidimensionale Darstellung eines dreidimensionalen Trainingsdatensatzes lernt, die (bis auf Drehung und Spiegelung) äquivalent zu der zweidimensionalen Darstellung ist, die eine entsprechende Hauptkomponentenanalyse (PCA) produzieren würde. Geben Sie insbesondere an, wie viele Modellparameter der Autoencoder hat und an welchen Stellen diese in das Modell einfließen.

Lösung:



Die Koeffizientenmatrix wird für beide Schichten verwendet:

$$U = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{pmatrix},$$

d.h., das Netz hat insgesamt 6 Parameter.