

27.01.2023

Klausur – Maschinelles Lernen - Teil Janka

Name: _____

Vorname: _____

Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Es sind keine Hilfsmittel erlaubt.

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die links daneben liegende leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	Σ	Note
Max. Punkte	10	7	9	10	10	46	
Punkte							

Ich wünsche Ihnen viel Erfolg!

Aufgabe 1 (3+3+2+2=10 Punkte) Lineare Modelle.

Angenommen, ein Fahrradverleih möchte für seine Flotte den Bedarf an Leihfahrrädern basierend auf dem Wetter vorhersagen. Dazu gibt es einen Datensatz mit den beiden Features x_1 = “Temperatur” und x_2 = “Regen” und dem Label y = “Anzahl ausgeliehene Fahrräder (pro Tag)”.

- (a) Es sei folgender Datensatz gegeben:

Tag	Temperatur [°C]	Regen [ja/nein]	Anzahl Fahrräder
Tag 1	8	nein	95
Tag 2	20	ja	37
Tag 3	28	nein	160

Nehmen sie ein gewöhnliches lineares Regressionsmodell an und stellen Sie die Least Squares Verlustfunktion für diesen Datensatz auf.

Lösung:

$$L(w_0, w_1, w_2) = \frac{1}{3} ((95 - (w_0 + w_1 \cdot 8 + w_2 \cdot 0))^2 + (37 - (w_0 + w_1 \cdot 20 + w_2 \cdot 1))^2 + (160 - (w_0 + w_1 \cdot 28 + w_2 \cdot 0))^2)$$

- (b) Statt die genaue Anzahl vorherzusagen, soll nun für einen Tag vorhergesagt werden, ob mindestens 100 Fahrräder verliehen werden ($y = 1$) oder weniger ($y = 0$). Eine logistische Regression ergab als Ergebnis die Parameter $w_0 = -15$, $w_1 = 1$, $w_2 = -0.1$. Welche Wahrscheinlichkeit würde das Modell für Tag 1 berechnen? *Hinweis: Sie müssen den Ausdruck nicht auswerten.*

Liegt die Vorhersage näher an 0 oder an 1?

Lösung:

$$\hat{y} = \frac{1}{1 + \exp(-(-15 + 1 \cdot 8))} = \frac{1}{1 + e^7}$$

Die Vorhersage liegt näher an 0.

- (c) Angenommen es regnet nicht. Bei welcher Temperatur beträgt laut dem Modell die Wahrscheinlichkeit, dass mehr als 100 Fahrräder verliehen werden, genau 50%?

Lösung:

$$\hat{y} = \frac{1}{1 + \exp(-(-15 + 1 \cdot x_1))} = 0.5 \Leftrightarrow -(-15 + 1 \cdot x_1) = 0 \Leftrightarrow x_1 = 15$$

- (d) Was wäre eine einfache Möglichkeit die Precision dieses Modells zu verbessern?

Lösung:

Man könnte den Schwellwert, ab dem man eine “1” vorhersagt, erhöhen.

Aufgabe 2 (2+2+3=7 Punkte) Regularisierung und Hyperparametersuche.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?

Lösung:

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

- (b) Gegeben seien 10,000 Datenpunkte um eine logistische Regression zu trainieren. Sie wählen zunächst 50% der Daten als Testset. Sie möchten nun eine Hyperparametersuche mittels Gittersuche durchführen. Sie möchten dabei herausfinden, ob eine ℓ_1 -Regularisierung oder eine ℓ_2 -Regularisierung bessere Ergebnisse liefert. Für jede der Regularisierungen testen Sie nun 4 verschiedene Werte für λ .
Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen trainiert werden, wenn eine 5-fache Kreuzvalidierung durchgeführt wird?

Lösung:

$2 \cdot 4 \cdot 5 = 40$ Modelle mit 4000 Trainingsdatenpunkten und 1 Modell mit 5000 Trainingsdatenpunkten.


- (c) Wofür wird "Early Stopping" eingesetzt? Beschreiben Sie kurz das Vorgehen .

Lösung:

Early Stopping wird als Regularisierungstechnik beim Training von neuronalen Netzen eingesetzt. Während des stochastischen Gradientenverfahrens beobachtet man Trainings- und Testfehler. Typischerweise sinkt anfangs der Fehler auf den Trainings- und Testdaten. Ab einem gewissen Punkt beginnt der Testfehler wieder zu steigen. Dies ist ein Zeichen von Overfitting. Man lädt dann die zuvor gespeicherten Koeffizienten einer vergangenen Iteration, an der der Testfehler geringer war und beendet das Verfahren.

Aufgabe 3 (2+4+3=9 Punkte) Neuronale Netze.

Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht sowie das Output Neuron haben jeweils keinen Bias. In der verdeckten Schicht wird ReLU als Aktivierungsfunktion verwendet. In der Ausgabeschicht kommt keine Aktivierungsfunktion zum Einsatz.

- (a) Wie lauten die Koeffizientenmatrizen des abgebildeten Netzes?

Lösung:

$$W^{[1]} = \begin{pmatrix} 0 & -1 & 1 \\ 2 & 1 & -3 \end{pmatrix}$$

$$W^{[2]} = \begin{pmatrix} 1 & -1 \end{pmatrix}$$

- (b) Welche Funktion berechnet das Netz für einen beliebigen Eingabevektor $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$?

Lösung:

$$\max(-x_2 + x_3, 0) - \max(2x_1 + x_2 - 3x_3, 0)$$


- (c) Beschreiben Sie kurz das “vanishing gradient” Problem und warum es auftritt. Nennen sie eine mögliche Strategie dagegen.

Lösung:

Vanishing gradient bedeutet, dass die Ableitung der Verlustfunktion nach Gewichten in den vorderen Schichten fast Null sind (sie verschwinden). Das passiert, weil die Ableitung ein Produkt von Ableitungen der nachfolgenden Schichten sind. Diese beinhalten immer die Ableitungen der Aktivierungsfunktion, die bei sigmoiden Funktion oft nahe Null ist (das Produkt von vielen kleinen Zahlen ist eine sehr kleine Zahl). Strategien dagegen sind z.B. spezielle Aktivierungsfunktionen (leaky ReLU), adaptive Lernraten oder das Vortrainieren von Schichten, z.B. mittels Autoencodern.

Aufgabe 4 (2+2+3+3=10 Punkte) Backpropagation.

Gegeben sei der folgende Berechnungsgraph:



- (a) Welche Funktion $f(x_1, x_2)$ wird durch den Berechnungsgraphen berechnet?

Lösung:

$$f(x_1, x_2) = x_1^2 \cos(x_2)$$

- (b) Vorwärtsphase: Berechnen Sie $f(-2, 0)$ mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten $x_i, i = 1, 2, \dots$ an.

Lösung:

$$x_1 = -2$$

$$x_2 = 0$$

$$x_3 = x_1^2 = 4$$

$$x_4 = \cos x_2 = 1$$

$$x_5 = x_3 x_4 = 4$$

- (c) Rückwärtsphase: Berechnen Sie $\frac{\partial f}{\partial (x_1, x_2)}$ an der Stelle $(-2, 0)$ mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten $\bar{x}_i, i = 1, 2, \dots$ an.

Lösung:

$$\bar{x}_5 = 1$$


$$\bar{x}_4 = \bar{x}_5 \frac{\partial x_5}{\partial x_4} = \bar{x}_5 x_3 = 4$$

$$\bar{x}_3 = \bar{x}_5 \frac{\partial x_5}{\partial x_3} = \bar{x}_5 x_4 = 1$$

$$\bar{x}_2 = \bar{x}_4 \frac{\partial x_4}{\partial x_2} = -\bar{x}_4 \sin x_2 = 0$$

$$\bar{x}_1 = \bar{x}_3 \frac{\partial x_3}{\partial x_1} = \bar{x}_3 \cdot 2x_1 = -4$$

- (d) Neuronale Netze kann man auch als Berechnungsgraphen auffassen (mit speziellen Knotentypen). Die Variablen, nach denen abgeleitet werden soll (die Koeffizienten des Netzes), sind aber normalerweise den *Kanten* des Graphen zugeordnet. Wie muss man den Rückwärtsmodus aus der vorherigen Aufgabe erweitern, um die Ableitung nach W in folgendem Graphen zu berechnen? (Beziehen Sie sich dabei auf den Punkt $(x_1, x_2) = (-2, 0)$ und W beliebig):



Lösung:

Erst Ableitung bis zum Knoten unmittelbar nach W :

$$\bar{x}_3 = 1$$

Dann x_3 nach W ableiten und multiplizieren

$$\bar{x}_3 \cdot \frac{\partial x_3}{\partial W} = \bar{x}_3 \cdot x_1^2 \cdot 2W = 1 \cdot 4 \cdot 2W = 8W$$

Aufgabe 5 (3+3+4=10 Punkte) Spezielle neuronale Netze.

(a) Sei

$$\begin{pmatrix} 2 & 0 & 1 \\ 0 & 1 & 3 \\ 4 & 1 & 2 \end{pmatrix}$$

ein Eingabevektor eines neuronalen Netzes. Berechnen Sie die Featuremap, die durch Faltung mit der Faltungsmatrix

$$\begin{pmatrix} -1 & -1 \\ 2 & 2 \end{pmatrix}$$

entsteht (kein Padding, Stride 1).

Lösung:

$$\begin{pmatrix} 0 & 7 \\ 9 & 2 \end{pmatrix}$$

- (b) Die Faltung aus Aufgabe (a) kann auch als (lineare) feedforward Schicht eines neuronalen Netzes aufgefasst werden. Aus wie vielen Neuronen besteht der Output (=Output der Faltung)? Wie viele Verbindungen gibt es und wie viele Gewichte sind diesen Verbindungen zugeordnet?

Lösung:

Die Outputschicht (Output der Faltung) hat 4 Neuronen. Jedes Neuron ist mit 4 Neuronen der Eingabeschicht verbunden, also insgesamt 16 Verbindungen. Es gibt aber nur 4 Gewichte (nämlich die Elemente der Faltungsmatrix).

- (c) Beschreiben Sie kurz, was ein Autoencoder ist und wie er funktioniert. Nennen Sie eine Anwendung von Autoencodern.

Lösung:

Ein Autoencoder ist ein neuronales Netz, dessen Eingabeschicht die gleiche Dimension wie die Ausgabeschicht hat. Das Ziel eines Autoencoders ist es, eine reduzierte Darstellung eines Datensatzes zu berechnen. (Nicht gefragt: Dies wird erreicht, indem mindestens eine der verdeckten Schichten eine niedrigere Dimension als die Ein- und Ausgabeschicht besitzt und gleichzeitig das Modell darauf trainiert wird, die Eingabe zu rekonstruieren). Eine mögliche Anwendung ist das Vortrainieren von tiefen neuronalen Netzen.