

26.01.2024

Klausur – Maschinelles Lernen - Teil Janka

Name: _____

Vorname: _____

Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Es sind keine Hilfsmittel erlaubt.

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die links daneben liegende leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	Σ	Note
Max. Punkte	8	10	15	7	6	46	
Punkte							

Ich wünsche Ihnen viel Erfolg!

Aufgabe 1 (4+3+1=8 Punkte) Lineare Modelle.

Sie möchten den Heizenergieverbrauch eines Bürogebäudes für einen gegebenen Tag bestimmen (in [kWh]). Dazu erheben Sie Daten zur Außentemperatur und zur Nutzung des Gebäudes an verschiedenen Tagen, aus denen Sie den Energieverbrauch vorhersagen möchten.

- (a) Es sei folgender Datensatz gegeben:

Tag	Außentemperatur [°C]	Nutzung [wenige Personen/viele Personen]	Heizenergieverbrauch [kWh]
1	4	wenige Personen	800
2	6	viele Personen	700
3	-1	wenige Personen	1000

Nehmen sie ein gewöhnliches lineares Regressionsmodell an und stellen Sie die Least Squares Verlustfunktion für diesen Datensatz auf.

Lösung:

$$L(w_0, w_1, w_2) = \frac{1}{3} \left((95 - (w_0 + w_1 \cdot 8 + w_2 \cdot 0))^2 + (37 - (w_0 + w_1 \cdot 20 + w_2 \cdot 1))^2 + (160 - (w_0 + w_1 \cdot 28 + w_2 \cdot 0))^2 \right)$$

- (b) Umgekehrt möchte das Gebäudemanagement aus diesen Daten vorhersagen, ob an einem Tag viele oder wenige Personen das Gebäude genutzt haben. Dazu wird ein logistisches Regressionsmodell entwickelt, das aus der Außentemperatur und dem Heizenergieverbrauch vorhersagen soll, ob an einem Tag viele ($y = 1$) oder wenige Personen ($y = 0$) das Gebäude genutzt haben.

Eine logistische Regression ergab als Ergebnis für die Features x_1 = "Außentemperatur" und x_2 = "Heizenergieverbrauch" die Parameter $w_0 = -10$, $w_1 = 1$, $w_2 = 0.01$. Was ist die Vorhersage des Modells für Tag 1, wenn ab einem Wert von 0.5 aufgerundet wird?

Lösung:

$$\hat{y} = \frac{1}{1 + \exp(-(-10 + 1 \cdot 4 + 0.01 \cdot 800))} = \frac{1}{1 + e^{-2}} > 0.5$$

Die Vorhersage liegt näher an 1.

- (c) Die Modellfunktion einer logistischen Regression ist, im Gegensatz zur linearen Regression, keine lineare Funktion. Warum bezeichnet man ein logistisches Regressionsmodell trotzdem als lineares Modell?

Lösung:

Die Entscheidungsgrenze, die die logistische Regression produziert, ist linear.

Aufgabe 2 (2+2+2+4=10 Punkte) Regularisierung und Hyperparametersuche.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?

Lösung:

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

- (b) Erklären Sie kurz, wie bei der Ridge-Regression das Ziel der Regularisierung erreicht wird.

Lösung:

Indem ein Strafterm auf die Verlustfunktion addiert wird, wird beim Training nicht die bestmögliche Anpassung an die Trainingsdaten gewählt.

- (c) Erklären Sie kurz, wie beim Early Stopping das Ziel der Regularisierung erreicht wird.

Lösung:

Während des stochastischen Gradientenverfahrens beobachtet man Trainings- und Testfehler. Typischerweise sinkt anfangs der Fehler auf den Trainings- und Testdaten. Ab einem gewissen Punkt beginnt der Testfehler wieder zu steigen. Dies ist ein Zeichen von Overfitting. Man lädt dann die zuvor gespeicherten Koeffizienten einer vergangenen Iteration, an der der Testfehler geringer war und beendet das Verfahren.

- (d) i. Wofür benutzt man Kreuzvalidierung?

Lösung:

Kreuzvalidierung benutzt man, um eine verlässlichere Schätzung des Fehlers auf unbekannten Daten zu bekommen, um z.B. Hyperparameter eines Modells zu trainieren.

- ii. Was ist der Vorteil gegenüber der Methode mit einem Validierungsdatensatz?

Lösung:

Der Vorteil gegenüber der Methode mit einem Validierungsdatensatz besteht darin, dass verschiedene Validierungsdatensätze verwendet werden und der Einfluss der zufälligen Auswahl auf die Schätzung des Modellfehlers geringer ist.


- iii. Was ist ein Nachteil von Kreuzvalidierung?

Lösung:

Ein Nachteil der Kreuzvalidierung besteht darin, dass das Training länger dauert.

Aufgabe 3 (2+4+2+5+2=15 Punkte) Neuronale Netze.

Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht sowie das Output Neuron haben jeweils keinen Bias. In der verdeckten Schicht wird ReLU als Aktivierungsfunktion verwendet. In der Ausgabeschicht kommt keine Aktivierungsfunktion zum Einsatz.

- (a) Wie lauten die Koeffizientenmatrizen des abgebildeten Netzes?

Lösung:

$$W^{[1]} = \begin{pmatrix} 1 & 0 \\ -2 & 0 \\ -1 & 3 \end{pmatrix}$$

$$W^{[2]} = \begin{pmatrix} -2 & -1 & 3 \\ 0 & 0 & 4 \end{pmatrix}$$

- (b) Welche Funktionswert berechnet das Netz für den Eingabevektor $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$?

Lösung:

1. Schicht:

$$\begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix}$$

2. Schicht:

$$\begin{pmatrix} -1 \\ 4 \end{pmatrix}$$

- (c) Wie könnten Sie das Netz erweitern, so dass es als Modellfunktion für ein Mehrklassen-Klassifizierungsproblem geeignet ist (kurze Begründung / Erklärung)?

Lösung:

Nach der hinteren Schicht ein Softmax-Funktion anhängen. Diese transformiert die Ausgabe des Netzes in einen Vektor von Wahrscheinlichkeiten.

- (d) Für ein binäres Klassifikationsproblem haben Sie 10000 Trainingsbeispiele gesammelt. Jeder Datenpunkt wird durch 200 Features und ein 0/1-wertiges Label repräsentiert. Für die Vorhersage des Labels möchten Sie ein neuronales Netz trainieren, welches 1000 Parameter hat. Sie trainieren das Modell für 25 Epochen mit dem stochastischen Gradientenabstieg.

Beantworten Sie folgende Fragen zu den Problemdimensionen (keine Begründungen nötig):

- i. Wie viele Summanden hat die Verlustfunktion?

Lösung:

10000

- ii. Wie oft wird bei einer Minibatchgröße von 100 im Laufe des stochastischen Gradientenverfahrens der Parametervektor aktualisiert (25 Epochen)?

Lösung:

$10000/100 * 25 = 2500$

- iii. Wie oft wird bei einem normalen Gradientenabstiegsverfahren (batch Gradientenabstieg) der Parametervektor aktualisiert (25 Epochen)?

Lösung:

25

- iv. Welche Dimension hat der Gradient der (gesamten) Verlustfunktion?

Lösung:

1000

- v. Welche Dimension hat der Gradient einer Minibatch (Minibatchgröße 10) der Verlustfunktion?

Lösung:

1000

- (e) Was beobachtet man, wenn die Lernrate beim stochastischen Gradientenabstieg zu groß gewählt wird?

Lösung:


Der Zielfunktionswert der Verlustfunktion wird nicht reduziert, sondern erhöht sich (Divergenz des Verfahrens).

Aufgabe 4 (2+2+3=7 Punkte) Backpropagation.

Gegeben sei die Funktion $f(x_1, x_2) = \sin(x_1 x_2) + \cos(x_1 x_2)$

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für die Funktion f auf. Bezeichnen Sie dabei die Knoten mit $x_i, i = 1, 2, \dots$ und geben Sie für jeden Knoten die Funktionsdefinition an.

Lösung:



- (b) Vorwärtsphase: Berechnen Sie $f(0, \pi)$ mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten $x_i, i = 1, 2, \dots$ an.

Lösung:

$$x_1 = 0$$

$$x_2 = \pi$$

$$x_3 = x_1 x_2 = 0$$

$$x_4 = \sin x_3 = 0$$

$$x_5 = \cos x_3 = 1$$

$$x_6 = x_4 + x_5 = 1$$

- (c) Rückwärtsphase: Berechnen Sie den Gradienten $\frac{\partial f}{\partial (x_1, x_2)}$ an der Stelle $f(0, \pi)$ mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten $\bar{x}_i, i = 1, 2, \dots$ an.

Lösung:

$$\bar{x}_6 = 1$$

$$\bar{x}_5 = \bar{x}_6 \frac{\partial x_6}{\partial x_5} = 1$$

$$\bar{x}_4 = \bar{x}_6 \frac{\partial x_6}{\partial x_4} = 1$$

$$\bar{x}_3 = \bar{x}_4 \frac{\partial x_4}{\partial x_3} + \bar{x}_5 \frac{\partial x_5}{\partial x_3} = 1 \cdot \cos 0 - 1 \cdot \sin 0 = 1$$

$$\bar{x}_2 = \bar{x}_3 \frac{\partial x_3}{\partial x_2} = 1 \cdot x_1 = 0$$

$$\bar{x}_1 = \bar{x}_3 \frac{\partial x_3}{\partial x_1} = 1 \cdot x_2 = \pi$$

Aufgabe 5 (3+3=6 Punkte) Spezielle neuronale Netze.

(a) Sei

$$\begin{pmatrix} 2 & -1 & 3 \\ 3 & 1 & 2 \\ -1 & 1 & -2 \end{pmatrix}$$

eine Eingabe (also ein Featurevektor) für ein neuronales Netz. Berechnen Sie die Featuremap, die durch Faltung mit der Faltungsmatrix

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

entsteht (kein Padding, Stride 1).

Lösung:

$$\begin{pmatrix} 5 & 5 \\ 4 & 2 \end{pmatrix}$$

(b) Eine 2×2 -Faltung (kein Padding, Stride 1) kann auch als (lineare) Feedforward Schicht eines neuronalen Netzes aufgefasst werden, mit spezieller Struktur der Neuronen-Verbindungen.

- i. Welche Dimension hat der Output dieser Faltungsschicht, wenn die Eingabe eine 11×11 -Matrix ist?

Lösung:

Die Outputschicht (Output der Faltung) hat 100 Neuronen.

- ii. Wie viele Neuronen-Verbindungen gibt es insgesamt?

Lösung:

Jedes Neuron der Outputschicht ist über den 2×2 Kern mit 4 Neuronen der Inputschicht verbunden. Es gibt also 400 Verbindungen.

- iii. Wie viele Parameter w müssen beim Training optimiert werden?

Lösung:

Es gibt aber nur 4 Gewichte (nämlich die Elemente der 2×2 Faltungsmatrix).