

13.06.2022

Probeklausur – Maschinelles Lernen (Teil Janka)

Name: _____
Vorname: _____
Matrikelnummer: _____

Dauer der Prüfung: 60 Minuten

Erlaubte Hilfsmittel:

- Wissenschaftlicher Taschenrechner (nicht programmierbar, nicht grafikfähig)

Bearbeitungshinweise:

- Schreiben Sie Ihre Antworten in den freien Platz unter die jeweiligen Aufgaben. Es werden ausschließlich die Antworten auf dem Bearbeitungsbogen gewertet. Sollte der vorgesehene Bearbeitungsraum nicht ausreichen, so ist die links daneben liegende leere Rückseite zu verwenden.
- Die Heftklammer darf nicht gelöst werden.
- Verwenden Sie keine Bleistifte und keine Rotstifte.

Aufgabe	1	2	3	4	5	Σ	Note
Max. Punkte	12	9	10	8	9	48	
Punkte							

Ich wünsche Ihnen viel Erfolg!

Aufgabe 1 (3+6+3=12 Punkte) Logistische Regression.

Angenommen, wir haben vor einer Klausur Daten von Studierenden mit den folgenden Merkmalen gesammelt: x_1 = "Stunden gelernt", x_2 = "bisheriger Notendurchschnitt" und y = "Klausurnote < 2.0". Wir haben dafür eine logistische Regression durchgeführt und als Koeffizienten $w_0 = -2$, $w_1 = 0.05$ und $w_2 = -1$ erhalten.

- (a) Berechnen Sie die Wahrscheinlichkeit, dass ein Studierender, der 40 Stunden gelernt hat und einen Notendurchschnitt von 2.3 hat, eine Klausurnote besser als 2.0 bekommt.

Lösung:

Die Wahrscheinlichkeit ist gegeben durch folgende Modellfunktion:

$$f(x_1, x_2) = \frac{1}{1 + e^{-(2+0.05x_1-x_2)}}$$

Für das Vorliegende Beispiel also:

$$f(40, 2.3) = \frac{1}{1 + e^{-(2+0.05 \cdot 40 - 2.3)}} = \frac{1}{1 + e^{2.3}} \approx 0.091$$

Die Wahrscheinlichkeit beträgt 9.1%.

- (b) Es seien folgende drei Punkte $x^{(i)} = (x_1^{(i)}, x_2^{(i)})$, $y^{(i)}$, $i \in \{1, 2, 3\}$ gegeben:

- $x^{(1)} = (40, 2.7)$, $y^{(1)} = 0$,
- $x^{(2)} = (5, 3.3)$, $y^{(2)} = 0$,
- $x^{(3)} = (40, 1.3)$, $y^{(3)} = 1$.

Berechnen Sie die Log-Loss Verlustfunktion (Kreuzentropie) für diesen Datensatz mit den angegebenen Parameter w_0, w_1, w_2 .

Lösung:

Die Kreuzentropie-Funktion ist gegeben durch

$$L(w_0, w_1, w_2) = -\frac{1}{3} \sum_{i=1}^3 y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

Vorhersagen für jeden Punkt:

$$\begin{aligned}\hat{y}^{(1)} &= \frac{1}{1 + e^{2-0.05 \cdot 40 + 2.7}} = \frac{1}{1 + e^{2.7}} \approx 0.063 \\ \hat{y}^{(2)} &= \frac{1}{1 + e^{2-0.05 \cdot 5 + 3.3}} = \frac{1}{1 + e^{5.05}} \approx 0.006 \\ \hat{y}^{(3)} &= \frac{1}{1 + e^{2-0.05 \cdot 40 + 1.3}} = \frac{1}{1 + e^{1.3}} \approx 0.214\end{aligned}$$

Einsetzen in L :

$$\begin{aligned}L(-2, 0.05, -1) &= -\frac{1}{3} (\log(1 - \hat{y}^{(1)}) + \log(1 - \hat{y}^{(2)}) + \log(\hat{y}^{(3)})) \\ &= -\frac{1}{3} (\log 0.94 + \log 0.99 + \log 0.21) \approx 0.54\end{aligned}$$

- (c) Wie lange müsste der Studierende aus (a) lernen, um dem Modell nach eine 50% Chance auf eine Klausurnote besser als 2.0 zu haben?

Lösung:

Es muss gelten:

$$\hat{y} = \frac{1}{1 + e^{2-0.05 \cdot T + 2.3}} = 0.5$$
$$\Leftrightarrow 2 - 0.05T + 2.3 = 0 \Leftrightarrow T = 86 \text{ Stunden.}$$

Aufgabe 2 (2+1+6=9 Punkte) Regularisierung.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?

Lösung:

Das Ziel von Regularisierung ist es, Overfitting, d.h. zu starkes Anpassen an die Trainingsdaten, zu vermeiden. Dies wird erreicht, indem beim Training die Modellflexibilität eingeschränkt wird.

- (b) Nennen Sie eine Möglichkeit zur Regularisierung von logistischen Regressionsmodellen.

Lösung:

ℓ_2 -Regularisierung: Addition eines Terms $\lambda \sum_{i=1}^p w_i^2$ zur Verlustfunktion mit einem Hyperparameter λ .

- (c) Gegeben seien 10,000 Datenpunkte um eine lineare Regression mit Regularisierung zu trainieren. Sie wählen zunächst 20% der Daten als Testset. Sie möchten nun 4 verschiedene Werte für λ ausprobieren und testen, ob Lasso oder Ridge Regression bessere Ergebnisse liefert.

- Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen beim Ansatz mit einem Validierungsdatensatz von 25% der Trainingsdaten trainiert werden?

Lösung:

8 Modelle auf 6000 Datenpunkten.

1 Modell auf 8000 Datenpunkten.

- Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen trainiert werden, wenn eine 5-fache Kreuzvalidierung mit dem Validierungsdatensatz durchgeführt wird?


Lösung:

8 Modelle für jeweils 5 verschiedene Validierungsdatensätze von jeweils $0.8 \cdot 8000 = 6400$ Datenpunkten, also insgesamt 40 Modelle mit jeweils 6400 Datenpunkten.

Schließlich noch 1 Modell auf 8000 Datenpunkten.

Aufgabe 3 (2+3+3+2=10 Punkte) Neuronale Netze.

Gegeben sei das folgende neuronale Netz:



Die Neuronen der verdeckten Schicht sowie das Output Neuron haben jeweils keinen Bias. Die verwendete Aktivierungsfunktion ist in der verdeckten Schicht ReLU in der Ausgabeschicht die Sigmoid-Funktion $\sigma(z) = \frac{1}{1+e^{-z}}$.

- (a) Für welche Art von überwachtem Lernproblem kann dieses Netz prinzipiell eingesetzt werden?

Lösung:

Für ein binäres Klassifikationsproblem (mit 2 Features).

- (b) Schreiben Sie die Funktion auf, die das Netz für einen beliebige Eingabe $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ berechnet.

Lösung:

$$\hat{y} = f(x_1, x_2) = \sigma(1 \cdot \max(x_1 + 2x_2, 0) - 3 \cdot \max(-x_1, 0))$$

- (c) Welchen Vorhersagewert $\hat{y}$ liefert das Netz für die Eingabe $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 \\ 0.5 \end{pmatrix}$?

Lösung:

$$\hat{y} = f(-1, 0.5) = \sigma(1 \cdot \max(-1 + 2 \cdot 0.5, 0) - 3 \cdot \max(1, 0)) = \sigma(-3) = \frac{1}{1+e^3} \approx 0.047.$$

- (d) Warum benutzt man für das Training von neuronalen Netzen in der Regel den stochastischen Gradientenabstieg (und nicht den gewöhnlichen Gradientenabstieg)?

Lösung:

- Rechenzeit: SGD ist (insbesondere bei großen Trainingsdatensätzen) schneller als GD.
- SGD kann dazu beitragen, Overfitting zu verhindern.


Aufgabe 4 (3+3+3=9 Punkte) Backpropagation.

Gegeben sei die Funktion $f(x, y) = x^2 + y^2$

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für die Funktion f auf. Bezeichnen Sie dabei die Knoten mit $x_i, i = 1, 2, \dots$ und geben Sie für jeden Knoten die Funktionsdefinition an.

Lösung:

$$\begin{aligned}x_1 &= x \\x_2 &= y \\x_3 &= x_1^2 \\x_4 &= x_2^2 \\x_5 &= x_3 + x_4\end{aligned}$$



- (b) Vorwärtsphase: Berechnen Sie $f(1, 2)$ mit Hilfe des Berechnungsgraphen. Geben Sie das Zwischenergebnis für jeden Knoten $x_i, i = 1, 2, \dots$ an.

Lösung:

$$\begin{aligned}x_1 &= 1 \\x_2 &= 2 \\x_3 &= 1 \\x_4 &= 4 \\x_5 &= 5\end{aligned}$$

- (c) Rückwärtsphase: Berechnen Sie $\frac{\partial f}{\partial (x, y)}$ an der Stelle $(1, 2)$ mittels Backpropagation. Geben Sie das Zwischenergebnis (die Adjungierten) für jeden Knoten $\bar{x}_i, i = 1, 2, \dots$ an.

Lösung:

$$\bar{x}_5 = 1$$

$$\bar{x}_4 = \bar{x}_5 \frac{\partial x_5}{\partial x_4} = 1 \cdot 1$$

$$\bar{x}_3 = \bar{x}_5 \frac{\partial x_5}{\partial x_3} = 1 \cdot 1$$

$$\bar{x}_2 = \bar{x}_4 \frac{\partial x_4}{\partial x_2} = 1 \cdot 2x_2 = 4$$

$$\bar{x}_1 = \bar{x}_3 \frac{\partial x_3}{\partial x_1} = 1 \cdot 2x_1 = 2$$

Aufgabe 5 (6+2=8 Punkte) Faltungsnetze.

- (a) Für 100×100 Pixel Bilder (RGB) sei eine Faltungsschicht bestehend aus 4 Filtern definiert. Die Filter haben jeweils die Dimension 5×5 . Weiterhin wird kein Padding und ein Stride von 1 verwendet.

- (i) Wie viele Parameter hat die Faltungsschicht?

Lösung:

Jeder Filter hat $3 \cdot 5 \cdot 5 + 1 = 76$ Parameter. Die Schicht besteht aus vier Filtern hat also $4 \cdot 76 = 304$ Parameter.

- (ii) Welche Dimension hat der Output der Faltungsschicht?

Lösung:

Es entstehen 4 Featuremaps der Größe 96×96 . Der Output ist also ein Tensor der Dimension $96 \times 96 \times 4$.

- (b) Beschreiben Sie kurz, was eine Max-Pooling Schicht macht.

Lösung:

Ein Max-Pooling Layer reduziert die Dimension einer Featuremap, indem es blockweise (z.B. 2×2) den Maximalwert der Featuremap ausgibt.