

Maschinelles Lernen – Klausur C

Sommersemester 2026 · Prof. Dr. Dennis Janka

Bearbeitungszeit: 60 Minuten · Erreichbare Punkte: 46

Hinweise: Alle Antworten sind zu begründen, sofern nicht anders angegeben. Unausgewertete Ausdrücke und Brüche sind als Ergebnis zulässig.

Aufgabe 1 (3+3+2+2 = 10 Punkte) Lineare Regression und Optimierung.

Ein Lieferdienst möchte die Lieferzeit vorhersagen. Es gibt die Features x_1 = “Entfernung [km]” und x_2 = “Stoßzeit (0/1)” und das Label y = “Lieferzeit [min]”. Eine lineare Regression lieferte $w_0 = 10$, $w_1 = 2$, $w_2 = 15$.

- (a) Berechnen Sie die vorhergesagte Lieferzeit für eine Lieferung über 8 km während der Stoßzeit.
- (b) Es sei folgender Datensatz gegeben:

	Entfernung [km]	Stoßzeit	Lieferzeit [min]
Fahrt 1	5	nein	22
Fahrt 2	12	ja	48
Fahrt 3	3	ja	31

Stellen Sie die Least-Squares-Verlustfunktion für diesen Datensatz und die Parameter w_0, w_1, w_2 auf. (*Ergebnis nicht ausrechnen.*)


- (c) Wie könnten Sie überprüfen, ob w_0, w_1, w_2 die optimalen Parameter für den Datensatz aus (b) sind? Warum genügt die von Ihnen genannte Bedingung?
- (d) Angenommen, die Prüfung aus (c) ergibt, dass die Parameter *nicht* optimal sind. Welches Verfahren würden Sie einsetzen, um bessere Parameter zu finden? Grenzen Sie es von (c) ab.

Aufgabe 2 (2+2+2+3 = 9 Punkte) Regularisierung.

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?
- (b) Nennen Sie einen Vorteil der ℓ_1 - (Lasso) gegenüber der ℓ_2 -Regularisierung (Ridge).
- (c) Welcher Nachteil entsteht durch eine zu starke Regularisierung? Benennen Sie das zugrundeliegende Prinzip.
- (d) Gegeben seien 15000 Datenpunkte, um eine Ridge-Regression zu trainieren. Sie wählen $\frac{1}{3}$ der Daten als Testset und möchten 6 verschiedene Werte für λ ausprobieren. Wie viele Modelle mit jeweils wie vielen Datenpunkten müssen trainiert werden, wenn eine 5-fache Kreuzvalidierung durchgeführt wird?

Aufgabe 3 (4+2+3 = 9 Punkte) Neuronale Netze.

- (a) Gegeben sei das folgende Netz. Die Biases stehen an den Neuronen. In der verdeckten Schicht wird ReLU verwendet, in der Ausgangsschicht keine Aktivierung. Welchen Ausgabewert liefert das Netz für $(x_1, x_2) = (1, 3)$?



- (b) Was wäre die Konsequenz, wenn man in *allen* Schichten die Identität als Aktivierungsfunktion verwendete? Begründen Sie.
- (c) Für ein binäres Klassifikationsproblem haben Sie 4000 Trainingsbeispiele (250 Features). Sie trainieren ein Netz mit 1500 Parametern für 10 Epochen mit SGD. Beantworten Sie (keine Begründung nötig):
- (i) Summanden der Verlustfunktion?
 - (ii) Dimension des Gradienten der gesamten Verlustfunktion?
 - (iii) Dimension des Gradienten einer Minibatch (Größe 20)?
 - (iv) Updates bei Minibatchgröße 20 (10 Epochen)?
 - (v) Updates beim batch-Gradientenabstieg (10 Epochen)?

Aufgabe 4 (2+3+4 = 9 Punkte) Backpropagation.

Gegeben sei die Funktion $f(x_1, x_2) = e^{x_1 x_2} - x_1 x_2$.

- (a) Stellen Sie einen gerichteten Berechnungsgraphen für f auf und geben Sie für jeden Knoten x_i die Funktionsdefinition an.
- (b) Vorwärtsphase: Berechnen Sie alle Knoten an der Stelle $(x_1, x_2) = (1, 1)$.
- (c) Rückwärtsphase: Berechnen Sie $\nabla f(1, 1)$ mittels Backpropagation und geben Sie alle Adjungierten an.

Aufgabe 5 (3+2+4 = 9 Punkte) Faltungsnetze und Autoencoder.

- (a) Für 32×32 Pixel *Graustufenbilder* (1 Kanal) sei eine Faltungsschicht aus 10 Filtern der Dimension 5×5 definiert (kein Padding, Stride 1).
 - (i) Wie viele Parameter hat die Schicht?
 - (ii) Welche Dimension hat der Output?
- (b) Auf den Output aus (a) wird eine 2×2 -Max-Pooling-Schicht angewendet. Welche Dimension hat der Output danach? Ändert sich die Tiefe?
- (c) Autoencoder:
 - (i) Wofür wird ein Autoencoder eingesetzt und welche Verlustfunktion wird beim Training minimiert?
 - (ii) Ein linearer Autoencoder soll eine 3-dimensionale Darstellung eines 6-dimensionalen Datensatzes lernen. Wie viele Modellparameter hat er? Begründen Sie kurz.

Lösungen – Klausur C

Aufgabe 1 Lineare Regression und Optimierung.

(a) **Lösung:**

$$\hat{y} = 10 + 2 \cdot 8 + 15 \cdot 1 = 10 + 16 + 15 = \mathbf{41} \text{ min.}$$

(b) **Lösung:**

$L(w) = \frac{1}{3} [(22 - (10 + 2 \cdot 5))^2 + (48 - (10 + 2 \cdot 12 + 15))^2 + (31 - (10 + 2 \cdot 3 + 15))^2]$. Bei Fahrt 1 fällt der +15-Term weg (keine Stoßzeit).

(c) **Lösung:**

Prüfen, ob $\nabla L(w) = 0$. Genügt, weil die Least-Squares-Verlustfunktion konvex ist $\Rightarrow$ ein stationärer Punkt ist automatisch das globale Minimum.

(d) **Lösung:**

Gradientenabstieg: iterativ $w \leftarrow w - \eta \nabla L(w)$, bis $\nabla L \approx 0$. Abgrenzung: (c) *prüft* einen gegebenen Punkt (Bedingung erster Ordnung), Gradientenabstieg *sucht* das Optimum iterativ.

Aufgabe 2 Regularisierung.

(a) **Lösung:**

Ziel: Overfitting vermeiden; erreicht durch Einschränken der Modellflexibilität (z.B. Strafterm auf die Gewichte).

(b) **Lösung:**

Lasso (ℓ_1) erzeugt *dünnbesetzte* (sparse) Lösungen: viele Gewichte werden exakt 0, wirkt also wie eine automatische Feature-Selektion. Ridge schrumpft die Gewichte nur, setzt sie aber nicht auf 0.

(c) **Lösung:**

Zu starke Regularisierung erhöht den Bias $\Rightarrow$ Underfitting. Prinzip: Bias-Variance-Trade-off.

(d) **Lösung:**

Trainingspool $= \frac{2}{3} \cdot 15000 = 10000$. Kombinationen: nur Ridge, 6 $\lambda = 6$. Bei 5-facher CV: trainiert auf $\frac{4}{5} \cdot 10000 = 8000$. Also $6 \cdot 5 = \mathbf{30}$ Modelle mit je **8000**, plus **1** finales Modell mit **10000**.

Aufgabe 3 Neuronale Netze.

(a) **Lösung:**

$$h_1 = \max(0, 2 \cdot 1 + (-1) \cdot 3 + 0) = \max(0, -1) = 0; \quad h_2 = \max(0, 1 \cdot 1 + 1 \cdot 3 - 2) = \max(0, 2) = 2; \\ o = (-3) \cdot 0 + 2 \cdot 2 + 1 = \mathbf{5}.$$

(b) **Lösung:**

Das gesamte Netz würde zu einem einzigen linearen (affinen) Modell kollabieren, da die Verkettung linearer Abbildungen wieder linear ist – die Tiefe brächte keinen Gewinn.

(c) **Lösung:**

(i) 4000 (ii) 1500 (iii) 1500 (iv) $\frac{4000}{20} \cdot 10 = 200 \cdot 10 = 2000$ (v) 10.

Aufgabe 4 Backpropagation.

Lösung:

Knoten: $x_3 = x_1 x_2$, $x_4 = e^{x_3}$, $x_5 = x_4 - x_3$ (Fan-out an x_3).

Vorwärts (1, 1): $x_3 = 1$, $x_4 = e^1 = e$, $x_5 = e - 1$.

Rückwärts: $\bar{x}_5 = 1$; $\bar{x}_4 = \bar{x}_5 \cdot 1 = 1$; $\bar{x}_3 = \bar{x}_5 \cdot (-1) + \bar{x}_4 \cdot e^{x_3} = -1 + 1 \cdot e = e - 1$;
 $\bar{x}_1 = \bar{x}_3 \cdot x_2 = (e - 1) \cdot 1 = e - 1$; $\bar{x}_2 = \bar{x}_3 \cdot x_1 = (e - 1) \cdot 1 = e - 1$. $\Rightarrow \nabla f(1, 1) = (e - 1, e - 1)$.

Beachte: $\bar{x}_3$ summiert den -1 -Pfad und den e^{x_3} -Pfad (Fan-out, Minuszeichen!).

Aufgabe 5 Faltungsnetze und Autoencoder.

(a) **Lösung:**

(i) Eingangstiefe 1: $(1 \cdot 5 \cdot 5 + 1) \cdot 10 = (25 + 1) \cdot 10 = \mathbf{260}$. (ii) $(32 - 5) / 1 + 1 = 28 \Rightarrow \mathbf{28 \times 28 \times 10}$.

(b) **Lösung:**

2×2 -Pooling halbiert Höhe und Breite: $\mathbf{14 \times 14 \times 10}$. Die Tiefe (10) bleibt unverändert – Pooling wirkt auf jede Feature-Map einzeln.

(c) **Lösung:**

(i) Ein Autoencoder lernt eine reduzierte Darstellung der Daten (Ein- und Ausgabeschicht gleich groß, verdeckte Schicht kleiner); trainiert auf Rekonstruktion. Verlust: mittlerer quadratischer Rekonstruktionsfehler $\frac{1}{N} \sum_i \|x^{(i)} - \tilde{x}^{(i)}\|^2$. (ii) Netz $6 \rightarrow 3 \rightarrow 6$: Koeffizientenmatrix $U \in \mathbb{R}^{3 \times 6}$ wird für Encoder und Decoder genutzt $\Rightarrow 3 \cdot 6 = \mathbf{18}$ Parameter.