

Maschinelles Lernen – Klausur D

Sommersemester 2026 · Prof. Dr. Dennis Janka

Bearbeitungszeit: 60 Minuten · Erreichbare Punkte: 46

Hinweise: Alle Antworten sind zu begründen, sofern nicht anders angegeben. Brüche und unausgewertete Ausdrücke sind zulässig.

Aufgabe 1 (3+3+3 = 9 Punkte) Logistische Regression.

Ein Mailprogramm soll erkennen, ob eine E-Mail Spam ist ($y = 1$). Features: x_1 = “Anzahl Links”, x_2 = “enthält das Wort *gratis* (0/1)”. Eine logistische Regression lieferte $w_0 = -2$, $w_1 = 0,5$, $w_2 = 2$, mit $\hat{y} = \sigma(w_0 + w_1x_1 + w_2x_2)$, $\sigma(z) = \frac{1}{1+e^{-z}}$.

- Welche Wahrscheinlichkeit berechnet das Modell für eine E-Mail mit 3 Links, die “gratis” enthält? Näher an 0 oder an 1? (*Ausdruck genügt.*)
- Für E-Mails ohne “gratis” ($x_2 = 0$): Ab wie vielen Links stuft das Modell (bei Schwellwert 0,5) die E-Mail als Spam ein?
- Welche Verlustfunktion wird bei der logistischen Regression minimiert? Warum verwendet man dabei den natürlichen Logarithmus?

Aufgabe 2 (2+4+3 = 9 Punkte) Klassifikationsmetriken und Schwellwert.

- Geben Sie die Formeln für Precision und Recall an.
- Ein Klassifikator liefert für 8 Testbeispiele die folgenden Wahrscheinlichkeiten (wahres Label in Klammern):

Wahrsch.	0,9	0,75	0,6	0,4	0,65	0,55	0,3	0,2
wahr	P	P	P	P	N	N	N	N

Füllen Sie bei Schwellwert 0,5 die Konfusionsmatrix aus und berechnen Sie Accuracy, Precision und Recall.


- Erhöhen Sie den Schwellwert auf 0,7. Berechnen Sie Precision und Recall erneut und erklären Sie die Richtung der Änderung.

Aufgabe 3 (2+2+2+3 = 9 Punkte) Generalisierung und Training.

- Was ist das Ziel von Regularisierung und wie wird es erreicht?
- Was macht Dropout und was ist dabei das Besondere? Gehen Sie auf die Skalierung der Aktivierungen ein.
- Beim Training beobachten Sie: der Trainingsfehler sinkt weiter, der Validierungsfehler steigt jedoch wieder. Was passiert hier, und nennen Sie zwei Gegenmaßnahmen.
- Gegeben seien 10000 Datenpunkte. 30 % Testset. Für Lasso *und* Ridge werden je 4 Werte für λ getestet, mit einem festen Validierungsdatensatz von 20 % der Trainingsdaten. Wie viele Modelle mit je wie vielen Datenpunkten?

Aufgabe 4 (3+3+3 = 9 Punkte) Backpropagation mit Kantengewicht.

Betrachten Sie den folgenden Berechnungsgraphen. Das Gewicht W ist der *Kante* von x_1 zu x_2 zugeordnet. Beachten Sie, dass x_2 verzweigt (Fan-out).



- Geben Sie die Funktion $f(x_1)$ an und berechnen Sie die Vorwärtsphase an der Stelle $x_1 = 2$ (W beliebig).
- Berechnen Sie $\frac{\partial f}{\partial W}$ an der Stelle $x_1 = 2$ mittels Backpropagation. Geben Sie die relevanten Adjungierten an.
- Erklären Sie kurz, wie man ein Kantengewicht im Rückwärtsmodus behandelt und wie vorzugehen wäre, wenn dasselbe W mehreren Kanten zugeordnet wäre.

Aufgabe 5 (4+3+3 = 10 Punkte) Faltungsnetze.

- Ein Netz hat zwei aufeinanderfolgende Faltungsschichten (kein Padding, Stride 1). Eingabe: 30×30 RGB-Bilder. Schicht 1: 8 Filter der Größe 3×3 . Schicht 2: 16 Filter der Größe 3×3 .
 - Parameter und Output-Dimension von Schicht 1?
 - Parameter und Output-Dimension von Schicht 2?
- Eine 5×5 -Faltung (kein Padding, Stride 1) auf einem 16×16 -Bild wird als Feedforward-Schicht aufgefasst. Wie viele Output-Neuronen, wie viele Verbindungen und wie viele zu optimierende Parameter gibt es?
- Für ein 28×28 -Bild wird ein 4×4 -Filter mit Stride 3 (kein Padding) verwendet. Ändert sich gegenüber Stride 1 die Anzahl der Parameter? Geben Sie die Output-Dimension bei Stride 3 an.

Lösungen – Klausur D

Aufgabe 1 Logistische Regression.

(a) **Lösung:**

$\hat{y} = \sigma(-2 + 0,5 \cdot 3 + 2 \cdot 1) = \sigma(1,5) = \frac{1}{1+e^{-1,5}}$. Wegen $z = 1,5 > 0$: näher an 1.

(b) **Lösung:**

Schwellwert $0,5 \Leftrightarrow z \geq 0$: $-2 + 0,5 x_1 \geq 0 \Leftrightarrow x_1 \geq 4$. Also ab **4 Links**.

(c) **Lösung:**

Der Log-Loss (binäre Kreuzentropie) $L(w) = -\frac{1}{N} \sum_i [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)]$. Der natürliche Logarithmus wird konventionell verwendet, weil er die einzige Basis ist, die eine saubere Ableitung ($\frac{1}{x}$) liefert – praktisch für die gradientenbasierte Optimierung.

Aufgabe 2 Klassifikationsmetriken und Schwellwert.

(a) **Lösung:**

Precision = $\frac{TP}{TP+FP}$, Recall = $\frac{TP}{TP+FN}$.

(b) **Lösung:**

Bei 0,5 vorhergesagt positiv: 0,9(P), 0,75(P), 0,6(P), 0,65(N), 0,55(N).

		wahr P	wahr N
vorherg.	P	$TP = 3$	$FP = 2$
	N	$FN = 1$	$TN = 2$

Accuracy = $\frac{3+2}{8} = \frac{5}{8}$; Precision = $\frac{3}{5}$; Recall = $\frac{3}{4}$.

(c) **Lösung:**

Bei 0,7 vorhergesagt positiv: nur 0,9(P), 0,75(P). $TP = 2$, $FP = 0$, $FN = 2$, $TN = 4$. Precision = $\frac{2}{2} = 1$; Recall = $\frac{2}{4} = \frac{1}{2}$. Richtung: Precision **steigt** ($\frac{3}{5} \rightarrow 1$, weil FP von 2 auf 0 sinkt), Recall **sinkt** ($\frac{3}{4} \rightarrow \frac{1}{2}$, weil zwei echte Positive (0,6; darunter) jetzt als negativ gelten $\Rightarrow$ FN steigt).

Aufgabe 3 Generalisierung und Training.

(a) **Lösung:**

Overfitting vermeiden durch Einschränken der Modellflexibilität.

(b) **Lösung:**

Dropout setzt in jeder SGD-Iteration eine zufällige Teilmenge von Neuronen auf 0 (Wahrscheinlichkeit p); das Netz lernt robustere Darstellungen. Besonders: Dropout wirkt nur beim Training; bei der Evaluierung wird das volle Netz genutzt. Die Aktivierungen werden beim Training mit $\frac{1}{1-p}$ skaliert, damit die erwartete Summe der Outputs in Training und Evaluierung gleich ist.

(c) **Lösung:**

Overfitting. Gegenmaßnahmen z.B.: Early Stopping, (stärkere) Regularisierung, mehr Trainingsdaten, kleineres Modell (zwei genügen).

(d) **Lösung:**

Trainingspool = $0,7 \cdot 10000 = 7000$. Validierung = $0,2 \cdot 7000 = 1400$, Training auf $7000 - 1400 = 5600$. Kombinationen = $2 \cdot 4 = 8$. Also **8** Modelle mit je **5600**, plus **1** finales Modell mit **7000**.

Aufgabe 4 Backpropagation mit Kantengewicht.(a) **Lösung:**

$f(x_1) = x_2 + x_2^2$ mit $x_2 = Wx_1$, also $f = Wx_1 + (Wx_1)^2$. Vorwärts $x_1 = 2$: $x_2 = 2W$, $x_3 = (2W)^2 = 4W^2$, $x_4 = 2W + 4W^2$.

(b) **Lösung:**

$\bar{x}_4 = 1$; $\bar{x}_3 = \bar{x}_4 \cdot 1 = 1$; $\bar{x}_2 = \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_2} + \bar{x}_3 \cdot \frac{\partial x_3}{\partial x_2} = 1 \cdot 1 + 1 \cdot 2x_2 = 1 + 2(2W) = 1 + 4W$ (Fan-out: zwei Beiträge!). Kantenableitung $\frac{\partial x_2}{\partial W} = x_1$. $\Rightarrow \frac{\partial f}{\partial W} = \bar{x}_2 \cdot x_1 = (1 + 4W) \cdot 2 = \mathbf{2 + 8W}$. (Kontrolle: $f = 2W + 4W^2 \Rightarrow f' = 2 + 8W$.)

(c) **Lösung:**

Ein Kantengewicht behandelt man wie einen zusätzlichen Eingang des Zielknotens: Adjungierte des Zielknotens $\times$ lokale Ableitung des Knotens nach W . Wäre dasselbe W mehreren Kanten zugeordnet, summiert man die Beiträge aller dieser Kanten auf (Weight Sharing).

Aufgabe 5 Faltungsnetze.(a) **Lösung:**

Schicht 1: Parameter $(3 \cdot 3 \cdot 3 + 1) \cdot 8 = 28 \cdot 8 = \mathbf{224}$; Output $(30 - 3) + 1 = 28 \Rightarrow \mathbf{28 \times 28 \times 8}$.
Schicht 2: Eingangstiefe = 8 (Anzahl Filter aus Schicht 1), Parameter $(8 \cdot 3 \cdot 3 + 1) \cdot 16 = (72 + 1) \cdot 16 = 73 \cdot 16 = \mathbf{1168}$; Output $(28 - 3) + 1 = 26 \Rightarrow \mathbf{26 \times 26 \times 16}$.

(b) **Lösung:**

Output $(16 - 5) + 1 = 12 \Rightarrow 12 \times 12 = \mathbf{144}$ Neuronen; Verbindungen $144 \cdot 25 = \mathbf{3600}$; zu optimierende Parameter **25** (Weight Sharing – alle Neuronen teilen denselben 5×5 -Kern).

(c) **Lösung:**

Nein, die Parameterzahl bleibt gleich (stride-unabhängig). Output bei Stride 3: $(28 - 4)/3 + 1 = 8 + 1 = \mathbf{9}$, also 9×9 (pro Filter).