


Maschinelles Lernen

Prof. Dr. Christine Preisach



Willkommen zum Modul Maschinelles Lernen



Vorstellung

Prof. Dr. Christine Preisach

Seit 2021	Professorin für Data Science und Informatik bei IWI Leitung Institut Intelligent Systems Research Group Nachhaltigkeitsbeauftragte der HKA, Teil der Ethikkommission
2017 - 2021	Leiterin Advanced Analytics bei Allianz Lebensversicherung
2010 - 2017	verschiedene Leitungs- und technische Rollen bei SAP
2006 - 2010	Doktorandin im Bereich Maschinelles Lernen an der Uni Freiburg & Hildesheim
2000 - 2006	Informatik Studium an der Uni Freiburg


Kontakt: Raum: E210, Tel. 0721-925-1476

Email: christine.preisach@h-ka.de, Mattermost: christine-preisach

Sprechzeiten: Dienstag 9 - 10 Uhr (bitte rechtzeitig per E-Mail ankündigen)

Lehre

- Aktive Mitarbeit durch Diskussion & Gruppenarbeit
- Praxisnahe Beispiele statt grauer Theorie
- Anpassung an euer Kompetenzlevel
- Handlungskompetenz durch praktisches Einüben





ML & Erneuerbare Energien/Energieeffizienz

Biflex-Industrie:

- Anomalie-Erkennung für E-Auto Ladestationen
- Ladebedarfsprognosen für Fuhrparks mit E-Autos

ECOLITH:

- Nutzung von erneuerbare Energien für Compute-Jobs & Laboraktivität an der Hochschule
- Optimierung der Job-Planung mit ML & Optimierung

ML & Umweltmonitoring

Erkennung und Vorhersage von Waldschäden

Veränderungen der Biodiversität (z.B. Bienen, Plankton) schnell erkennen und Vorhersagen

ML & Nachhaltige Landwirtschaft:

SimpleAgriData:

Nutzung von Sensordaten & Videos in Bio Hühnerställen für Tierwohl und weniger Ressourcenverbrauch

Umfrage

partici.fi/23556850



Organisation




Das Modul Maschinelles Lernen

Umfang: 6 SWS

- 4 SWS Vorlesung Maschinelles Lernen
 - **2 SWS Christine Preisach**
 - 2 SWS Dennis Janka – Schwerpunkt überwachtes Lernen & NN
- 2 SWS Übung

Die Übung:

- 2 SWS Pflicht
- Dozent: Herr Christian Wernet (Lehrbeauftragter)
 - Anwendung von Python und Pytorch
 - Treten Sie dem Kurs [Übung Maschinelles Lernen](#) bei
 - **Kick-Off Donnerstag 19.03. 15:40 Uhr Raum wird noch verkündet**



Organisation


Für diese Vorlesung :

- Folien / Unterlagen und allgemeine Informationen: ILIAS
- Treten Sie bitte dem Ilias Kurs [Vorlesung Maschinelles Lernen – Teil Preisach](#) bei
- **Prüfung:** Klausur 120 Minuten (zusammen mit Dennis Janka)


Bücher...

Klassiker Mustererkennung und Maschinelles Lernen:


[1] Bishop C. M. Pattern Recognition and Machine Learning. 2007.



[2] Richard O. Duda, Peter E. Hart, David G. Stork. Pattern Classification, 2nd Edition. 2000.




[3] Trevor Hastie, Robert Tibshirani, Jerome Friedman. The Elements of Statistical Learning, 2nd Edition, 2009



Bücher...

Mathematik:

[4] Deisenroth M.P., Faisal A.A., Ong C.S. Mathematics for Machine Learning. Cambridge University Press. 2020.



Die Inhalte dieser Vorlesung...

Gliederung

1. Einleitung & Daten + Anwendungsfälle: nur kurz angerissen.... siehe Vorlesung Data Science
2. Distanz- und Ähnlichkeitsmaße (Motivation k-NN)
3. Clustering (k-means, ..., Clustering von Zeitreihen, Clustering für Anomalieerkennung)
4. Transformationen (PCA, Kernel-PCA)
5. Baumbasierte Klassifikations- und Regressionsverfahren & Ensemble Learning (XGBoost)
6. Forecasting (Zeitreihen)
7. Technologiefolgen: Auswirkung von KI & Digitalisierung auf Nachhaltigkeit / Klimawandel

Zeitplan

Woche	Termin	Themen
1	17.03.2026	Einführung/Daten & Orga
2	24.03.2026	Maße
3	31.03.2026	Maße
4	07.04.2026	Ferien
5	14.04.2026	Clustering
6	21.04.2026	Zeitreihen & Clustering & Anomalieerkennung
7	28.04.2026	PCA
8	05.05.2026	PCA
9	12.05.2026	Bäume und XGBoost
10	19.05.2026	Bäume und XGBoost
11	26.05.2026	Ferien
12	02.06.2026	fällt aus (dafür wird das Puzzle der Digitalisierung gemacht)
13	09.06.2026	Technologiefolgen: Auswirkung von KI auf Nachhaltigkeit / Klimawandel & Puzzle der Digitalisierung (3 Stunden)
14	16.06.2026	Forecasting
15	23.06.2026	Forecasting
16	30.06.2026	Wiederholung

Puzzle der Digitalisierung


- **WARUM?:** Weil der digitale Sektor bereits jetzt einen größeren Fußabdruck hat als die ganze zivile Luftfahrtindustrie. Verantwortungsvollere Prozesse sind nötig auf individueller Basis, wie auch bei Firmen und in der öffentlichen Verwaltung.
- **WAS?** Das Puzzle der Digitalisierung ist ein unterhaltsamer und aufklärerischer Workshop aufzubauen auf Kollaboration und **kollektiver Intelligenz**. Das Ziel ist es, dass die Teilnehmer alle Aspekte der Nachhaltigkeit (Umwelt, Klima, Soziales) unserer digitalen Welt kennen lernen und sich mit möglichen Lösungsansätzen auseinandersetzen.
- **WIE?** Der Workshop besteht aus 2 Hauptkomponenten
 - Verständnis: In Teams von 4 bis 8 Teilnehmern werden Links zwischen den Spielkarten identifiziert. Auf diese Weise wird das 'Puzzle' aufgebaut
 - Lösungen: Lösungsansätze werden wiederum auf Karten vorgeschlagen, und auf diese Weise kann diskutiert und reflektiert werden, welche konkreten Maßnahmen Wirkung haben und auf welche Weise genau.




Die Spielkarten basieren auf soliden wissenschaftlichen Daten und Einsichten der IAE(Internationale Energieagentur), UNO, ADEME (Französisches Umweltministerium), Green IT, EcoInfo CNRS und der Projektberichte von 'Shift'.

<https://digitalcollage.org/>

Kategorien von ML Lernansätzen




ML Problemstellungen (in dieser Vorlesung)



Aufgaben des ML / der Mustererkennung


Klassifikation (überwacht):

Neue »Objekte« werden einer vorgegebenen Klasse zugewiesen.




Clustering (unüberwacht):

Aufteilung der Daten in Cluster (Gruppen) ähnlicher Daten, z.B.
Dokumenten-Clustering





Aufgaben des ML / der Mustererkennung

Regression (überwacht): Vorhersage einer kontinuierlichen Größe, sehr häufig über die Zeit, z.B. Aktienkurs, Temperatur, Energieverbrauch



Anomalieerkennung (überwacht oder unüberwacht):

Identifizieren von »Objekten«, die sich signifikant von anderen unterscheiden. Beispiel: Kreditkartenbetrug, Predictive Maintenance



Aufgaben des ML / der Mustererkennung

Assoziationsanalyse (unüberwacht):

Mustererkennung, die innerhalb der Daten stark abhängige Merkmale entdeckt, z.B. Warenkorbanalyse für Recommender Systems.

Eine moderne Sage (Wal Mart):

»Wer Bier kauft, kauft auch Windeln«.

„Das US-Amerikanische Kaufhaus Wal-Mart fand heraus, dass die Kombination Windeln und Bier zu einer bestimmten Uhrzeit besonders häufig von Männern gekauft wird.“

Meldung aus 2012: <https://www.it-business.de/was-windeln-und-bier-mit-big-data-zu-tun-haben-a-363272/>

Daten & Anwendungsfälle




Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist Teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:

- **Umwelt Monitoring**
- Computer Vision
- Natural Language Processing
- Social Network Analysis
- Gestenerkennung /Aktivitätserkennung
- Game Analytics
- Warenkorbanalyse
- ...



Daten für die Vorhersage von Bienenaktivität

Ziel: Erkenntnisse über **Zusammenhänge** zwischen **Bienenaktivität** (Anteil der Bienen mit Pollen) und **Umweltparametern** datenbasiert zu erlangen. Es werden Auswirkungen einzelner Einflussfaktoren auf die Bienen untersucht, um so Hypothesen über konkrete Ursachen des Insektensterbens zu überprüfen.

Daten: 133 Merkmale - die meisten davon **Zeitreihen**

- Zielvariable: Bienenaktivität im Bereich von 0-20 (extrahiert aus visuellem Monitoringsysteme an den Eingängen der Bienenstöcke → unterschiedlich lange Videos in 5-Minuten-Intervallen),
- **Wetterdaten** (Luft- & Bodentemperaturen, Luftdruck, Luftfeuchtigkeit, Niederschlag, Wind, Sonnenscheindauer),
- Geodaten (Geokoordinaten der Bienenstöcke)
- Abgeleitete Daten: Landnutzungsklassen und Bodenfeuchte (SWI) aus Satellitenbildern



Herrmann M. *Vorhersage der Aktivität von Bestäuberinsekten anhand von Umweltfaktoren*. Bachelor-Thesis. 2023.

Preisach C., Herrmann M. *Bee Activity Prediction and Pattern Recognition in Environmental Data*. ICLR 2024 Workshop:

Tackling Climate Change with Machine Learning.


Quelle: [oceli](#)

Daten für die Vorhersage von Bienenaktivität

Lösungsansatz: Nutzung von Methoden des Maschinellen Lernen um **Zusammenhänge zwischen Bienenaktivität und Umweltparametern** zu erkennen und die **Bienenaktivität vorherzusagen**.

Vorgehen:

- Datenintegration und Aggregation auf stündliche Werte
- Datenexploration - insbesondere zu den Landnutzungsklassen
- Datenbereinigung und Erzeugung von neuen Merkmalen
- Lernen von **erklärenden** (z.B. Lineare Regression, Entscheidungsbaum Regression) und **nicht erklärenden Modellen** (Ensemble Learning Modellen und Neuronale Netze) mit der Zielvariable Bienenaktivität
- Evaluation der Modelle bzgl. der Güte der Vorhersage und der Effekte



Quelle: Herrmann 2023


Prof. Dr. Christine Preisach

Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:

- Numerische & Zeitreihen Daten
- **Computer Vision**
- Natural Language Processing
- Social Network Analysis
- Gestenerkennung /Aktivitätserkennung
- Game Analytics
- Warenkorbanalyse
- ...



Optical Character Recognition (OCR)

Beispiel: Digitalisierung von Schlachtberichten

- **Tesseract:**

- Früher Stand der Technik in OCR
- Galt zwischenzeitlich als abgeschlagen
- Wurde inzwischen (ab Version 4) um LSTMs ergänzt


Long Short Term Memory, ein
spezielles rekurrentes neuronales
Netz

- **OCRMyPdf:** Kapselt Tesseract + zusätzliche Verarbeitungsschritte

- **NuExtract** basiert auf einem Large Language Model (Phi-3-Mini)

- **AzureDocument Intelligence & Google Document AI:**

- Komplexer Aufbau aus mehreren Deep Learning (CNN & RNN) und Transformer Modellen
- Kostenpflichtig



Schlachtbericht



nr: Biofino
Resthauser/Ambühren
11.04.2025

Stückzahl gesamt :	11.160
Alter der Tiere :	55
Angeliefertes Gewicht in kg :	27.440
Durchschnittsgewicht :	2,459

Transport Tote 3

Ausged. Entzündungen d. Leibeshöhle u./o. Organe	1
Bauchwassersucht	17
Gelbsucht	
Mangelhafte Ausblutung	
Umfangr. Verletzungen, blutige, wässrige Durchtränkungen	1
Entzündungen der Haut, Unterhaut, Gelenke	5
Verunreinigungen oder Kontaminationen	1
Hochgrad. Abmagerung, erheb. Wachstumsstörungen	1
nicht Schlachtfähig, zu klein	6
Sonstige	25
Anzahl untauglicher Tierkörper gesamt	57

Fußballen Dermatitis :
Grad 0 = 65,4 %
Grad 1 = 18,6 %
Grad 2a = 7,5 %
Grad 2b = 8,5 %


Insgesamt: 1.656 Tiere zerlegt.



3

Projektarbeit Ricardo Lauth: Digitalisierung von Schlachtberichten


Klassifikator



Bild




ggf. Vorverarbeitung
(Computer Vision)



Abstrakte
Beschreibung
(Merkmale)

Zahlenvektor!!!




0


Ergebnis

Bilddaten für Neuronale Netze

Für neuronale Netze werden die Bilddaten inzwischen oft direkt (ohne weitere Vorverarbeitung) als Eingangsdaten für den Klassifikator verwendet.



$(0, 13, 156, 34, 78, \dots)^T$



Farbbild



$(2, 24, 45, 23, 255, 2, \dots)^T$

Welche
Dimension haben
die Vektoren?

In allen Fällen liegen **vektorielle Daten** vor!

Wenn die Bilddaten direkt (ohne weitere Vorverarbeitung) verwendet werden, sogar alle Daten im gleichen Wertebereich 0...255

Erkennung von Waldschäden in Thüringen

Situation: Vermehrt Borkenkäferschäden als Folgen des Klimawandels, dies führt zu extremen Einbußen in Fichtenwäldern → Manuelle Früherkennung von befallenen Bäumen ist sehr aufwändig und großflächig unmöglich

Ziel: Automatisierte frühzeitige Erkennung von Schäden in Fichtenwäldern (durch Schädlinge - z.B. Borkenkäfer) unter Nutzung von Deep Learning auf Satellitenbildern.

Daten:

- Sentinel 2 Satellitenbilder die alle 5-Tage aufgezeichnet wurden (Sentinel 2 nimmt 12 Kanäle auf vs. Farbbild mit RGB mit 3 Kanälen)
- daraus extrahierte Zeitreihen für jedes Pixel (10x10m) über mehrere Jahre.
- Abgeleitete Kennzahlen aus Satellitenbildern (NDVI,...)
- Geokoordinaten





Forest Calamities in Homogeneous Stands – Deep Learning Applied to Bark-Beetle Outbreaks. <https://arxiv.org/abs/2503.12883>

Erkennung von Waldschäden in Thüringen

Lösungsansatz: Nutzung von Methoden des unüberwachten Maschinellen Lernen - Anomalieerkennung-um **Schäden früh** zu erkennen.

Vorgehen:

- Herausfiltern der Tage mit Wolkenbedeckung
- Extraktion der Zeitreihen für jedes Pixel (10m Auflösung) der Testflächen und Berechnung von Kennzahlen/Features
- Lernen eines AutoEncoder Modells (unsupervised learning) mit gesunden Bäumen
- Erkennung von Anomalien für neue Daten
- Evaluation der Ergebnisse




Kirsch M. *Anomaly Detection in Forest Health Dynamics - Utilizing Sentinel-2 Time-Series Data and Autoencoder Models*. Master-Thesis. 2024.

Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:

- Umwelt Monitoring
- Computer Vision
- Natural Language Processing
- Social Network Analysis
- Gestenerkennung /Aktivitätserkennung
- **Game Analytics**
- Warenkorbanalyse
- ...



Game Analytics – Smurf Detection

League of Legends:

- Multiplayer online battle arena
- 5 gegen 5
- In eSport competitions wird (abhängig vom Spieler-Level) in unterschiedlichen Ligen gespielt



- **Aufgabe:** Smurf Detection
- Ein **smurf** (Schlumpf) ist ein **zweiter oder dritter Account**, unter dem ein Spieler in einer (für ihn) zu niedrigen Liga spielt.



Summoner's rift

Game Analytics – Merkmale

29 Merkmale pro Spiel und Spieler:


championId	rstBloodKill
goldEarned	rstBloodAssist
kills	rstTowerKill
lane	rstTowerAssist
role	wardsPlaced
killingsPrees	wardsKilled
creepsPerMinDeltas	deaths
xpPerMinDeltas	assists
goldPerMinDeltas	doubleKills
csDiPerMinDeltas	largestKillingSpree
xpDiPerMinDeltas	minionsKilled
damageTakenPerMinDeltas	neutralMinionsKilled
damageTakenDiPerMinDeltas	neutralMinionsKilledTeamJungle
visionWardsBoughtInGame	neutralMinionsKilledEnemyJungle
sightWardsBoughtInGame	

Betrachten wir die ersten fünf davon...

Game Analytics

Merkmal	Wert	Typ
championID	54239817	qualitativ
goldEarned	15 (Stück oder Tonnen?)	quantitativ
kills	11 (Stück)	quantitativ
lane	{BOTTON, MIDDLE, JUNGLE, TOP}	qualitativ
role	{DUO CARRY, DUO SUPPORT, DUO, SOLO, UNDEFINED}	qualitativ
...	...	...

Heterogene Daten!
Quantitativ und qualitativ bunt gemischt!




Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:


- Umwelt Monitoring
- Computer Vision
- **Natural Language Processing**
- Social Network Analysis
- Gestenerkennung/Aktivitätserkennung
- Game Analytics
- Warenkorbanalyse
- ...



Natural Language Processing (NLP)


NLP ist die automatische Analyse natürlicher gesprochener und geschriebener Sprache.

gesprochene Sprache



speech recognition

geschriebene Sprache



Text Analyse

- Die klassischen Merkmale für text mining sind »**bag of words**« (BOW):
- Jedes Dokument wird mit einem **Vektor** für auftretende Schlüsselwörter assoziiert:

Bemerkung: Man spricht vom »**set of words**« wenn nur zwischen vorhanden und nicht vorhanden differenziert wird (binär also...)

	Wirtschaft	Industrie	Handwerk	Angestellte	Löhne
Dokument 1	1	3	2	0	0
Dokument 2	0	2	1	3	0
Dokument 3	2	0	0	1	1

← »bag of words«

oder alternativ n-gramme aus Schlüsselwörtern:

das ist ein satz ohne besonderen inhalt.

2-gramme (Bigramme):

das ist
ist satz
satz ohne
ohne besonderen
besonderen inhalt

In der Praxis ergeben sich dadurch Merkmalsräume mit einer Dimension von mehr als
100.000 !!!

Text Mining Zahlenbeispiel


»Our English corpus is composed of the entire English Wikipedia, the Reuters corpus and the Wall Street Journal (WSJ) corpus. We consider lower case words and replace digits with a special token. The resulting text is tokenized using the Stanford tokenizer. The final data set contains about **2 billion words**. Our dictionary D consists of all the words appearing at least one **hundred times**. This results in a **202,255 words dictionary** [...] We consider **n-grams up to $n=3$** . Only n-grams with words from our dictionary are considered for both datasets. This results in a set of **34,360 1-gram** representations, **419,918 2-gram** representations, and **921,837 3-gram** representations for the Pang and Lee's dataset. And **67,847 1-gram** representations, **1,842,461 2-gram** representations, and **5,724,871 3-gram** representations for the Maas et al.'s dataset. Because n-gram representations are computed by averaging representations of its word, all n-grams are also represented in a **100-dimensional vector**.«

Die Verarbeitung hochdimensionaler Datenbestände ist oft schwierig (Curse of dimensionality). Oft wird die Dimension im Rahmen der Vorverarbeitung reduziert (PCA, LSA, Word2Vec).

Transformation: LSA und Embedding

- **Idee:** *Reduziere die Dimension* durch Abbildung von Worten, Wordkombinationen in einen **Vektorraum niedrigerer Dimension**.
- Klassische Ansätze: Latent Semantic Analysis (LSA = Singulärwertzerlegung von BOWs), PCA
- Neuere Ansätze: Embedding mit neuronalen Netze, z.B. word2vec von google.

Autoencoder:




Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:

- Umwelt Monitoring
- Computer Vision
- Natural Language Processing
- **Social Network Analysis**
- Gestenerkennung
- Game Analytics
- **Warenkorbanalyse**
- ...



Transaktionsdaten


Ähnlich **hohe Dimensionen** werden in der **Warenkorbanalyse** (z.B. für recommender engines) erreicht, wenn **Transaktionsdaten** (oft Auszüge aus ERP-Systemen) analysiert werden.

Transaktions-ID (TID)	Gekaufte Artikel (items)
1	{Brot, Butter, Windeln, Milch}
2	{Kaffee, Zucker, Kekse, Lachs}
3	{Brot, Butter, Kaffee, Windeln, Milch, Eier}
4	{Brot, Butter, Lachs, Hühnchen}
5	{Eier, Brot, Butter}
6	{Lachs, Windeln, Milch}
7	{Brot, Tee, Zucker, Eier}
8	{Kaffee, Zucker, Hühnchen, Eier}
9	{Brot, Windeln, Milch, Salz}
10	{Tee, Eier, Kekse, Windeln, Milch}

Social Network Analysis

Wird i.d.R. auf **Graphdaten** durchgeführt. Sie zeichnen sich dadurch aus, dass ihre Objekte jeweils durch Knoten in Graphen repräsentiert werden:

- social graph
- computer network graph
- world wide web
- ...



social graph

Die Darstellung und Verarbeitung erfolgt i.d.R. in Form einer Matrix, der sogenannten **Adjazenzmatrix**.

Profilierung – Fährten auf Facebook

Aus „Fährten auf Facebook“, Schwerpunkt Big Data, Bild der Wissenschaft 6/2013


SINGLE, RAUCHER, RELIGIÖS

Wie treffsicher findige Algorithmen selbst intime persönliche Merkmale aus Datenspuren im Internet herauslesen können, belegen die Ergebnisse einer Studie von Michael Kosinski, David Stillwell und Thore Graepel. Die drei britischen Wissenschaftler vom psychometrischen Zentrum der University of Cambridge werteten Kommentare, Fanseiten, Fotos, Videoclips, Links und Likes aus, die rund 60 000 Facebook-Nutzer ihnen freiwillig zur Verfügung gestellt hatten. Daraus konnten sie zielgenau eine breite Palette von Persönlichkeitsmerkmalen erschließen.

Damals bei Microsoft Research Cambridge, 2015 zu Google DeepMind gewechselt

So gelang es den Forschern mit fast 100-prozentiger Sicherheit, Geschlecht und Hautfarbe der Nutzer zu ermitteln. Auch bei der Religionszugehörigkeit und der hetero- oder homosexuellen Orientierung lagen sie zu rund 80 Prozent richtig. Ob jemand raucht oder gerne ein paar Gläser über den Durst trinkt, ließ sich aus Aktivitäten und Aussagen im Netz mit einer ebenso hohen Treffsicherheit folgern wie die Frage, ob der Facebook-Nutzer Single oder in festen Händen ist. Die Grenze zwischen Big Data und Big Brother ist fließend.

Profilierung – You Are What You Like




Anwendungen und ihre Daten

- Stark vereinfacht formuliert: ML-Prozesse bilden Daten auf Wissen ab.
- Die Datenauswahl ist teil des Business Understandings

Die **Struktur der Daten** und die **Datentypen** sind sehr **variabel** und **abhängig von der Anwendung**:

- Umwelt Monitoring
- Computer Vision
- Natural Language Processing
- Social Network Analysis
- **Gestenerkennung / Aktivitätserkennung**
- Game Analytics
- Warenkorbanalyse
- ...



Gestenerkennung

3D Sequenzen von Handpositionen...




Gegeben:


- Sequenz von 3D Handpunkten
- 5 unterschiedliche Gesten (Swipe, Push, L,O,Z)

Gesucht:

Ausgeführte Geste



$$S_1 = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ y_1 & y_2 & \dots & y_n \\ z_1 & z_2 & \dots & z_n \end{pmatrix}$$




$$S_2 = \begin{pmatrix} x'_1 & x'_2 & \dots & x'_m \\ y'_1 & y'_2 & \dots & y'_m \\ z'_1 & z'_2 & \dots & z'_m \end{pmatrix}$$

Die Sequenzen sind unterschiedlich lang!!!

Action / Activity Recognition

Für die **Erkennung von Aktivitäten** werden auch 2D oder 3D Sequenzen von Key Points (Skeletten) verwendet... die wiederum mit ML-Modellen (etwa OpenPose) extrahiert werden.




Auch diese Sequenzen sind ggf. unterschiedlich lang!!!

Quelle: <https://europe.naverlabs.com/blog/towards-understanding-human-actions-out-of-context-with-the-mimetics-dataset/>

Wichtige Eigenschaften von Datenbeständen

- **Dimension**
- **Umfang des Datenbestands**
- **Merkmalstypen & Skalenniveau** von Merkmalen
- Besetzung von Datenbeständen (dünn vs. dicht) - **Sparsity**
- **Datenqualität**



Eigenschaften von Daten: Dimension und Umfang eines Datenbestandes

Im Folgenden wird der Begriff **Datenbestand** mit einer Menge von Datenobjekten assoziiert:

$$\{O_1, O_2, \dots, O_N\}$$

Jedes Element des Datenbestands heißt **Objekt** und wird durch eine Reihe von **Merkmalen** (features) bzw. **Attributen** (attributes) beschrieben, die das Objekt charakterisieren.


Die **Anzahl der Objekte (Zeilen)**: Umfang des Datenbestands.

Die **Anzahl der Merkmale (Spalten)**: Dimension des Datenbestands.

Steuer- nummer	Famili- stand	Zu verst. Einkommen
2456	ledig	24 T€
8721	verheiratet	16 T€
0483	geschieden	84 T€
8726	ledig	62 T€
0922	verheiratet	35 T€

Dimension von Datenbeständen

Unter der **Dimension** eines Datenbestands versteht man die **Anzahl der Merkmale**, die jedes Objekt besitzt




Besondere Situationen sind gegeben, wenn die Anzahl der Merkmale beliebig groß sein kann (Warenkorb)...

Die Verarbeitung hoch-dimensionaler Datenbestände ist oft schwierig "Fluch der Dimensionalität" - **curse of dimensionality**. Oft wird die Dimension im Rahmen der Vorverarbeitung reduziert (PCA, etc.).

Fluch der Dimensionalität

- Begriff von Richard Bellman eingeführt. Beschreibt, dass **der Merkmalsraum** einer Datenmenge fester Größe zunehmend **dünnere besetzt** ist, wenn die **Anzahl der Dimensionen ansteigt**.
- Das Volumen eines Merkmalsraumes **wächst exponentiell in Abhängigkeit der Dimension**.
- Im nieder-dimensionalen Merkmalsraum reichen wenige Daten aus, um den Raum gut abzudecken.



Fluch der Dimensionalität

- **Folgen:**
 - Im höher-dimensionalem Merkmalsraum **wächst auch die benötigte Datenmenge exponentiell**. Jede Kombination der Merkmalsausprägungen sollte mind. **5-mal vorhanden** sein.
 - Daten werden **extrem spärlich**: In hohen Dimensionen sind Datenpunkte so **weit voneinander entfernt, dass sie kaum noch Ähnlichkeiten aufweisen**. Das erschwert das Finden von Mustern.
 - **Distanzen verlieren an Aussagekraft**: In vielen Algorithmen (wie k-Nächste-Nachbarn) werden Distanzen zwischen Punkten berechnet. In hohen Dimensionen sind alle Distanzen ähnlich groß – die Unterscheidungskraft geht verloren.
 - **Overfitting**: Modelle passen sich zu stark an das spärliche Training an und verlieren die Fähigkeit, neue Daten zu verallgemeinern.
 - **Rechenaufwand explodiert**: Die benötigte Datenmenge und Rechenleistung steigt exponentiell mit den Dimensionen.


Dünn besetzte Datenbestände - Beispiel

- **Dünn besetzte Datenbestände (Sparsity)** zeichnen sich dadurch aus, dass **viele Merkmale nur selten von einem Standardwert abweichen**.
- **Beispiel:** Datenbank aller Studierenden der HKA
 - Gegeben sei eine Datenbank aller Studierenden (als Objekte)
 - Die angebotenen Vorlesungen der Hochschule seien Merkmale.
 - Für jeden Studierenden hat das Merkmal »Maschinelles Lernen« den Wert 1, falls er/sie die Vorlesung hört, andernfalls 0.
 - So entstehen Datenbestände, in denen die Mehrheit der Merkmale den Wert 0 hat.
 - Es ist in solchen Fällen effizienter, sich auf die nicht-0 Werte zu konzentrieren: Betrachtet man die Studierenden auf Basis der Vorlesungen, die sie NICHT hören, wären sich die meisten Studierenden sehr ähnlich...

Für solche Datenbestände existieren effiziente, speziell auf diesen Fall zugeschnittene Methoden / Algorithmen!

Themen rund um Daten in der Vorlesung ML

- Die Themen **Datenverstehen** und **Datenvorverarbeitung** machen einen wesentlichen Bestandteil von ML- und KI-Projekten aus!
 - Vorlesung Data Science
- In dieser Vorlesung fokussieren wir uns auf die **Modellierung**!
- **Deployment** wird dann im Modul Künstliche Intelligenz adressiert.



Danke für die Aufmerksamkeit

