

Maschinelles Lernen

Prof. Dr. Christine Preisach



Organisatorisches

- Bis zum **31. Juli 2026** läuft wieder die **Bewerbungsphase** für das Deutschlandstipendium an der HKA
- Ab dem Wintersemester kann unsere Hochschule **bis zu 105 Stipendien** vergeben und neben der finanziellen Unterstützung (300 Euro monatlich) bietet das Deutschlandstipendium außerdem die gute Möglichkeit, spannende Unternehmen und Stiftungen kennenzulernen.
- Lehrevaluation:

<https://k31263.evasys.de/evasys/online.php?pswd=61AD4>



Zeitreiheneigenschaften



Zeitreihen

- **Definition:** Eine Zeitreihe ist eine Folge von Beobachtungen, die in zeitlicher Reihenfolge aufgezeichnet werden.
- Beispiele:
 - Wetterdaten (Temperatur, Niederschlag)
 - Stromverbrauch und Energienetze
 - Aktienkurse, Umsätze über die Zeit, ...
 - Sensordaten in Industrie 4.0 / IoT
 - Verkehrsaufkommen
 - Nutzeraktivität auf Webseiten
 - Medizinische Messdaten (EKG, EEG)

Typische Fragestellungen:

Wie entwickelt sich eine Größe in Zukunft → Zeitreihenvorhersage /Forecasting

Gibt es ungewöhnliche Ereignisse? → Anomalieerkennung

Zu welcher Klasse/Gruppe gehört eine Zeitreihe → Zeitreihenklassifikation oder Clustering

Zeitreihen

- Bei klassischen ML-Datensätzen gilt häufig: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \rightarrow$ Beobachtungen werden oft als **unabhängig** und **identisch verteilt (IID)** betrachtet.
- Bei Zeitreihen gilt das nicht:
 $x_t \rightarrow x_{t+1}$, der aktuelle Wert hängt häufig von vergangenen Werten ab.
- **Konsequenzen:**
 - Die Reihenfolge der Daten ist wichtig
 - Zufälliges Mischen (Shuffling) oft unzulässig
 - Spezielle Trainings- und Evaluationsmethoden nötig
 - Vergangene Informationen müssen explizit berücksichtigt werden
 - Zentrale Eigenschaft: Zeit erzeugt Abhängigkeiten zwischen Beobachtungen.

Zeitreiheneigenschaften

Eine Zeitreihe besteht aus verschiedenen Komponenten:

$$x_t = \text{Trend} + \text{Saison} + \text{Residuum}$$


Trend

- Langfristige Entwicklung der Zeitreihe
- $\uparrow$ steigend | $\downarrow$ fallend | $\rightarrow$ konstant


Saisonalität

- Wiederkehrende Muster (z. B. jährlich, monatlich)
- Fester Zeitraum

Linear Trend Example



Seasonal effect example (Weekly seasonality):
Newspapers Daily Sales



Zeitreiheneigenschaften

Periodizität

- Wiederkehrende Muster ohne festen Zeitraum


Residuum (Rauschen)

- Nicht erklärbare Schwankungen
- Zufällige Einflüsse


Ziel

Struktur verstehen, um bessere Vorhersagen zu treffen

Cycle Example:
Monthly Sunspot Numbers





Example of White Noise Series



Zeitreiheneigenschaften

- **Additive Saisonalität:** Wenn die Saisonalität additiv ist, ist die **Amplitude gleichbleibend**, das heißt unabhängig vom Trend
- **Multiplikative Saisonalität:** ist mit einer mit der Zeit **wachsenden Amplitude** verbunden (also mit einem Trend verbunden).



Quelle: kourntzes.com

Autokorrelation

Was ist das?

- Zusammenhang einer Zeitreihe mit sich selbst
- Vergleich: Wert heute vs. Wert in der Vergangenheit

Interpretation



- + positiv: hohe Werte folgen auf hohe Werte
- negativ: hohe Werte → niedrige Werte
- 0: kein Zusammenhang

Beispiele:


- Temperatur heute $\approx$ Temperatur vor 1 Stunde
- Arbeitslosenzahlen ändern sich langsam

Zeitreihen, die keine Autokorrelation aufweisen, sind echte Zufallsprozesse und werden als weißes Rauschen bezeichnet.

Autokorrelation mit Autocorrelation Function (ACF) berechnen und plotten




ACF: Korrelation mit Lags



Beispiele Zeitreihen

Beispiel 1

Kohlenstoff Dioxid Konzentration (global gemittelt)



Eigenschaften

Granularität: monatlich

Trend: Der Durchschnitt steigt von Jahr zu Jahr


Saisonalität: Erkennbares wiederkehrendes Muster (additive Saisonalität)

Starke Schwankungen

Beispiele Zeitreihen

Beispiel 2

Primärenergieverbrauch – aus verschiedenen Quellen



Granularität: Jährliche Daten

Trend: steigend

Saisonalität: : Keine großen Schwankungen

Beispiele Zeitreihen

Beispiel 3

Windgeschwindigkeit und Globalstrahlung




Abb. 5: Zeitreihe der Monatsmittel der Parameter Globalstrahlung in kWh/m² und Windgeschwindigkeit in 100 Meter Höhe in m/s der letzten 10 Jahre (2012 bis 2021). Datengrundlage wie in den Abbildungen 1 bis 4.

Granularität: Monatliche Daten


Trend: nein

Saisonalität: ja, viele Schwankungen

Beispiele Zeitreihen

Beispiel 4

Wetterdaten Hamburger Stadtteile



Granularität: Minütliche Daten

Trend: Keine Trends

Saisonalität: Relativ regelmäßiges Tagesmuster für Temperatur
Kein eindeutiges Muster bei Wind


Zeitreiheneigenschaften: Stationarität

- Kein Trend
- Keine Saisonalität
- Mittelwert & Varianz bleiben konstant


Warum wichtig?

Viele Modelle (z. B. ARIMA) benötigen stationäre Daten

Beispiel für eine stationäre Zeitreihe



Beispiele für nicht stationäre Zeitreihen



Stationarität – Differenzierung

- Stationäre Zeitreihen sind wichtig, da viele statistischen **Zeitreihenanalysen** und **Prognosemodelle** auf der Annahme der Stationarität basieren.
- Wenn eine Zeitreihe nicht stationär ist, müssen geeignete Transformationen angewendet werden, um sie stationär zu machen, bevor sie analysiert oder modelliert werden kann.
- Eine Möglichkeit ist es, den **Trend** durch **Differenzierung** zu **entfernen**: man bildet dafür die **Differenz von aufeinanderfolgenden Beobachtungen**

**Differenced
Time Series (first order)**


y_t $y'_t = y_t - y_{t-1}$

CYCLE_	WEEK_	DATE_	COLLI_ARR	DIFF_1
1	1	1 1	983	.
1	2	1 2	1478	495
1	3	1 3	1822	345
1	4	1 4	1883	61
1	5	1 5	1913	30
1	6	1 6	2001	88
1	7	1 7	2077	76



← 1478 – 983 = 495

Differenzierung

Beispiel: Trend entfernen durch Differenzierung



$$TS_t - TS_{t-1}$$




Keine signifikante
Autokorrelation mehr

Datenaufbereitungsschritte bei Zeitreihen

Für die **Vorverarbeitung von Zeitreihendaten** gibt es verschiedene Schritte, die üblicherweise durchgeführt werden, um die Daten für die anschließende Analyse oder Modellierung vorzubereiten:

- **Beschreibung von Zeitreiheneigenschaften:** Berücksichtigung spezifischer Eigenschaften von Zeitreihen wie **Autokorrelation**, **Saisonalität** oder **Trends**. Dies kann die Anwendung von Methoden wie der Differenzierung, der Entfernung von saisonalen Effekten oder die Entfernung von Trends beinhalten.
- **Datenbereinigung:** Behandeln von fehlenden Werten, Ausreißern oder ungültigen Datenpunkten. Dies kann durch **Interpolation**, **Glättung** oder Entfernung der betroffenen Daten erfolgen.
- **Datenskalierung:** Skalierung der Zeitreihen auf einen gemeinsamen Wertebereich, um Unterschiede in den Einheiten oder Skalen auszugleichen. Häufige Methoden sind die **Normalisierung** oder **Standardisierung** der Daten.



Datenaufbereitungsschritte bei Zeitreihen

- **Glätten der Daten:** um kurzfristige Schwankungen oder Rauschen zu reduzieren und längerfristige Trends zu erfassen. Dies kann durch Anwendung von **Fensterfunktionen wie dem gleitenden Durchschnitt oder exponentiell gewichteten Durchschnitt** erreicht werden.
- **Aggregation:** Aggregieren der Datenpunkte auf eine **niedrigere zeitliche Auflösung**, um die Menge der Daten zu reduzieren und eine bessere Übersicht über die Zeitreihe zu erhalten. Beispiele für Aggregationsmethoden sind das Zusammenfassen von Stunden- oder Tagesdaten zu Wochen- oder Monatsdurchschnitten.
- **Feature-Engineering:** Erzeugen von zusätzlichen Features aus den vorhandenen Zeitreihendaten, um weitere Informationen für die Modellierung zu extrahieren. Dies kann beispielsweise das Hinzufügen von Lage- oder Streuungsmaßen (Spannweite, Varianz), Trendindikatoren oder saisonalen Komponenten umfassen.

Zeitreihenvorhersage




Zeitreihenvorhersage

Bei der Zeitreihenprognose handelt es sich um den Prozess, auf der Grundlage vergangener Zeitreihendaten, Vorhersagen für die Zukunft zu treffen. Später können diese mit den wahren Werten verglichen werden.

Grundlage für die Prognose von Zeitreihen ist die Annahme, dass es **Einflussfaktoren** gibt die in der Zeitreihe **in der Vergangenheit und in der Zukunft Auswirkungen zeigen werden**.

Beispiele:

- Wettervorhersage (Regen, Sonnenstunden, Temperatur...)
- Umsatzprognose
- Vorhersage der Luftqualität
- Hochwasservorhersage (Vorhersage von Wasserstand und Wasserfluss)



Quelle: www.kdnuggets.com


Zeitreihenvorhersage - Wichtige Begriffe

Univariate Zeitreihe

- **Definition:** Eine Zeitreihe mit nur einer einzigen Messgröße oder Variable, die über die Zeit verfolgt wird.
- **Beispiel:** Die tägliche Temperatur an einem Ort, der Aktienkurs eines Unternehmens, oder die monatlichen Verkaufszahlen eines Produkts.
- **Analyse:** Man betrachtet nur die Entwicklung dieser einen Variable, z.B. Trends, Saisonalitäten oder Autokorrelationen.




Multivariate Zeitreihe

- **Definition:** Eine Zeitreihe, die mehrere Variablen gleichzeitig über die Zeit verfolgt.
- **Beispiel:** Wetterdaten mit Temperatur, Luftfeuchtigkeit und Windgeschwindigkeit
- **Analyse:** Hier untersucht man nicht nur die Entwicklung jeder einzelnen Variable, sondern auch die Wechselwirkungen und Abhängigkeiten zwischen den Variablen.




Zeitreihenvorhersage - Wichtige Begriffe

- **Prognosehorizont:**
 - One-Step Ahead - nur einen Zeitschritt in die Zukunft vorhersagen.
 - Multistep Ahead - mehrere Zeitschritte in die Zukunft vorhersagen.




Zeitreihenvorhersage - Wichtige Begriffe

- **Anzahl und Art des Inputs:**
 - Nur Werte der betrachteten Zeitreihe, es muss definiert werden wie viele Werte man aus der Vergangenheit verwendet - **lag Variablen**
 - Andere **externe(exogene) Variablen**



Sliding Window


- Üblicherweise nutzt man die Sliding Window Methode um mehrerer **Vorgängerwerte/Zeitpunkte (lags)** als **Input für die Vorhersage einzubeziehen**
- Jede Beobachtung enthält dann also so viele Inputs wie das Fenster breit ist: $|\text{Inputs}| = w$



Zeitreihenvorhersage - Wichtige Begriffe

Univariate vs. Multivariate Zeitreihenprognose

- **Univariate Prognose:** Bei der univariaten Zeitreihenprognose wird die zukünftige Entwicklung einer **einzigsten Variable** ausschließlich auf Basis ihrer **eigenen historischen Werte** vorhergesagt.
- Typische Beispiele sind die Vorhersage der **Temperatur für morgen nur anhand der bisherigen Temperaturwerte** oder die **Prognose des Stromverbrauchs auf Basis historischer Verbrauchsdaten**



Univariate Zeitreihenvorhersage - Supervised Learning

- Um Supervised Learning auf Zeitreihendaten verwenden zu können müssen die Zeitreihen in ein anderes für überwachtes Lernen geeignetes Format umgewandelt werden.
- Für eine univariate Zeitreihe und eine Vorhersage mit Prognosehorizont = 1 und dem Vorgängerwert als Input:

1	t
2	0
3	1
4	2
5	3
6	4
7	5
8	6
9	7
10	8
11	9



1	t	t+1
2	0	1.0
3	1	2.0
4	2	3.0
5	3	4.0
6	4	5.0
7	5	6.0
8	6	7.0
9	7	8.0
10	8	9.0
11	9	NaN

- t+1 entspricht der Zielvariable

Univariate Zeitreihenvorhersage - Supervised Learning

- Für eine univariate Zeitreihe und eine Vorhersage mit Prognosehorizont = 1 und dem mehreren Vorgängerwerten (hier $\text{lag} = w = 3$) als Input:

1		t
2	0	0
3	1	1
4	2	2
5	3	3
6	4	4
7	5	5
8	6	6
9	7	7
10	8	8
11	9	9




1		$\text{var1}(t-3)$	$\text{var1}(t-2)$	$\text{var1}(t-1)$	$\text{var1}(t)$
2	3	0.0	1.0	2.0	3
3	4	1.0	2.0	3.0	4
4	5	2.0	3.0	4.0	5
5	6	3.0	4.0	5.0	6
6	7	4.0	5.0	6.0	7
7	8	5.0	6.0	7.0	8
8	9	6.0	7.0	8.0	9

- $\text{var}(t)$ entspricht der Zielvariable
- Vergemeinerung: $(t-w)$ Inputs mit Zeithorizont $(t+h)$ mit $w = \text{Fensterbreite}$

Multivariate Zeitreihenvorhersage - Supervised Learning

- Die **multivariate Zeitreihenprognose** bezieht **mehrere Variablen gleichzeitig in die Vorhersage** ein.
- Hierbei werden neben der **eigenen historischen Werte** auch **andere relevante Einflussgrößen** betrachtet, die auf die Zielgröße einwirken können. Das Modell nutzt also nicht nur die Vergangenheit der Zielvariable, sondern auch die **historischen Werte weiterer Variablen**, um Zusammenhänge und Wechselwirkungen zu erfassen



Multivariate Zeitreihenvorhersage - Supervised Learning

- Für eine multivariate Zeitreihe und eine Vorhersage mit Prognosehorizont = 1 und dem mehreren (hier 2) Vorgängerwerten als Input:

1		var1(t-1)	var2(t-1)	var1(t)	var2(t)	var1(t+1)	var2(t+1)
2	1	0.0	50.0	1	51	2.0	52.0
3	2	1.0	51.0	2	52	3.0	53.0
4	3	2.0	52.0	3	53	4.0	54.0
5	4	3.0	53.0	4	54	5.0	55.0
6	5	4.0	54.0	5	55	6.0	56.0
7	6	5.0	55.0	6	56	7.0	57.0
8	7	6.0	56.0	7	57	8.0	58.0
9	8	7.0	57.0	8	58	9.0	59.0

Übung

1. Es sei folgende Zeitreihe über die Anzahl der Sonnenstunden pro Monat gegeben:

Monat / Jahr	1	2	3	4	5	6	7	8	9	10	11	12
2022	45	85	235	195	250	275	265	270	155	140	75	39
2023	35	90	100	150	244	305	230	185	246	100	42	33

- a. Erstellt aus der obigen Zeitreihe den Trainingsdatensatz für klassische ML-Algorithmen, verwendet dafür einen **Lag von 2** und einem **Prognosehorizont von 1**. Führt das für den Zeitraum **Monat 10 bis 12 in 2023** durch.

Übung

1. Es sei folgende Zeitreihe über die Anzahl der Sonnenstunden pro Monat gegeben:

Monat / Jahr	1	2	3	4	5	6	7	8	9	10	11	12
2022	45	85	235	195	250	275	265	270	155	140	75	39
2023	35	90	100	150	244	305	230	185	246	100	42	33

- a. Erstellt aus der obigen Zeitreihe den Trainingsdatensatz für klassische ML-Algorithmen, verwendet dafür einen **Lag von 2** und einem **Prognosehorizont von 1**. Führt das für den Zeitraum **Monat 10 bis 12 in 2023** durch.

Lösung:

Monat	Feature 1	Feature 2	Zielvariable
10	185	246	100
11	246	100	42
12	100	42	33

Zeitreihenvorhersage - Methoden

Hauptmethoden, die bei der Zeitreihenprognose verwendet werden:

1. **Klassische Zeitreihenanalyse** : Analysen und Prognosen basieren auf der Identifizierung struktureller Komponenten wie **Trend und Saisonalität** und auf der Untersuchung der **Autokorrelation**
➔ **Univariate Zeitreihenanalyse**
2. **Multivariate Zeitreihenanalyse**: Analysen und Prognosen basieren sowohl auf früheren Beobachtungen der Zeitreihe selbst als auch auf der Beziehung mit anderen möglichen Merkmalen ➔
Regressionsalgorithmen
3. **Deep Learning für die Zeitreihenvorhersage**: Verschiedene Algorithmen künstlicher neuronaler Netze zur Vorhersage von Zeitreihen (**univariat** und **multivariat**)

Faktoren die die Prognose beeinflussen & Wahl des Algorithmus

Wichtige Faktoren die die Prognose beeinflussen:

- Prognosehorizont
- Art/Menge der verfügbaren Daten
- Erwartete Vorhersagbarkeit

Wahl der Algorithmus je nach:

- Erforderliche Erklärbarkeit der Ergebnisse
- Art/Anzahl der Inputvariablen
- Anzahl der zu prognostizierenden Zeitreihen

Naive Vorhersagemethoden


Durchschnittsprognose : Wir sagen den Durchschnitt voraus (wobei h der Vorhersagehorizont ist).

$$\hat{y}_{T+h|T} = \bar{y} = (y_1 + \dots + y_T)/T.$$

Für **naive Prognosen** setzen wir einfach alle Prognosen auf den Wert der letzten Beobachtung. Das ist,

$$\hat{y}_{T+h|T} = y_T.$$

Naive saisonale Prognose: Wir setzen jede Vorhersage so, dass sie dem **letzten beobachteten Wert derselben Saison** (z. B. demselben Monat des Vorjahres) entspricht.



Übung

1. Es sei folgende Zeitreihe (2022+2023) über die Anzahl der Sonnenstunden pro Monat gegeben:

Monat / Jahr	1	2	3	4	5	6	7	8	9	10	11	12
2022	45	85	235	195	250	275	265	270	155	140	75	39
2023	35	90	100	150	244	305	230	185	246	100	42	33

b. Erstellt die Vorhersagen für 2024 Januar bis Juni mit den Methoden:

- Durchschnittsprognose
- Naive Prognose
- Naive Saisonale Prognose

Übung

1. Es sei folgende Zeitreihe (2022+2023) über die Anzahl der Sonnenstunden pro Monat gegeben:

Monat / Jahr	1	2	3	4	5	6	7	8	9	10	11	12
2022	45	85	235	195	250	275	265	270	155	140	75	39
2023	35	90	100	150	244	305	230	185	246	100	42	33

- b. Erstellt die Vorhersagen für 2024 Januar bis Juni mit den Methoden:

- Durchschnittsprognose 157,87
- Naive Prognose 33
- Naive Saisonale Prognose

Monat	1	2	3	4	5	6
	35	90	100	150	244	305

Klassische Zeitreihen Analyse

Die wichtigsten Methoden der klassischen Zeitreihenanalyse sind:

- **Zerlegung der Zeitreihe:** betrachtet die Zeitreihe als Überlappung mehrerer elementarer Komponenten (z. B. Trend, Saisonalität, Fehler)
- **Exponentielle Glättung** : Methode, die auf der Gewichtung früherer Beobachtungen basiert und die Überlappung einiger wichtiger Zeitreihenkomponenten (Trend und Saisonalität) berücksichtigt.
- **ARIMA** (AutoRegressive Integrated Moving Average): Klasse **statistischer Modelle**, die darauf abzielen, die **Korrelation** zwischen Werten der Zeitreihe zu verschiedenen Zeitpunkten mithilfe eines **regressionsähnlichen Ansatzes** und unter Berücksichtigung der **Saisonalität** zu behandeln

Exponentielle Glättung

- **Einfache exponentielle Glättung** : Kombination aus **naiver Vorhersage** und **Durchschnittsvorhersage** → gewichteter Durchschnitt früherer Beobachtungen.
- Während beim einfachen **gleitenden Durchschnitt** die vergangenen Beobachtungen gleich gewichtet werden, werden **Exponentialfunktionen** verwendet, um **exponentiell abnehmende Gewichte** über die Zeit zuzuweisen.
- Wir geben **neueren Beobachtungen größeres Gewicht** als Beobachtungen aus der Vergangenheit.
- **Das heißt: Gewichtete Durchschnittswerte** werden berechnet , wobei **die Gewichte exponentiell abnehmen, wenn die Beobachtungen aus weiter zurückliegenden Beobachtungen stammen** – die kleinsten Gewichte sind den ältesten Beobachtungen zugeordnet
- Erweiterte Versionen enthalten Parameter für Trend und Saisonalität

Exponentielle Glättung

$0 \leq \alpha \leq 1$ Ist der Glättungsfaktor.

Der Parameter α steuert, wie stark die neuen bzw. alten Daten gewichtet werden:


- α nahe 1: näher alpha bei 1 desto weniger wichtig sind ferne Werte und desto wichtiger die nahe Vergangenheit,
- α nahe 0: desto näher bei 0 desto wichtiger sind ferne Beobachtungen.

$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots,$$

	$\alpha = 0.2$	$\alpha = 0.4$	$\alpha = 0.6$	$\alpha = 0.8$
y_T	0.2000	0.4000	0.6000	0.8000
y_{T-1}	0.1600	0.2400	0.2400	0.1600
y_{T-2}	0.1280	0.1440	0.0960	0.0320
y_{T-3}	0.1024	0.0864	0.0384	0.0064
y_{T-4}	0.0819	0.0518	0.0154	0.0013
y_{T-5}	0.0655	0.0311	0.0061	0.0003

Quelle: otexts.com

Exponentielle Glättung



$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots,$$

$$\hat{y}_{T+1|T} = \sum_{j=0}^{T-1} \alpha(1 - \alpha)^j y_{T-j} + (1 - \alpha)^T \ell_0.$$


	$\alpha = 0.2$	$\alpha = 0.4$	$\alpha = 0.6$	$\alpha = 0.8$
y_T	0.2000	0.4000	0.6000	0.8000
y_{T-1}	0.1600	0.2400	0.2400	0.1600
y_{T-2}	0.1280	0.1440	0.0960	0.0320
y_{T-3}	0.1024	0.0864	0.0384	0.0064
y_{T-4}	0.0819	0.0518	0.0154	0.0013
y_{T-5}	0.0655	0.0311	0.0061	0.0003

ARIMA

ARIMA (AutoRegressive Integrated Moving Average) ist ein statistisches Modell zur Analyse und Vorhersage von Zeitreihendaten. Es wird eingesetzt, um zukünftige Werte basierend auf historischen Daten zu prognostizieren, es ist für univariate Vorhersage geeignet. ARIMA modelliert die **Autokorrelation** einer Zeitreihe, nachdem sie durch Differenzierung ausreichend stationär gemacht wurde. ARIMA besteht aus 3 Komponenten.

- AR: vergangene Werte erklären den aktuellen Wert (**Auto-Regressive**)
- I: Differenzierung entfernt Trend oder instabiles Niveau (I = Integrated)
- MA: vergangene Prognosefehler korrigieren kurzfristige Abweichungen (**Moving Average** der Fehler)
- Schreibweise: $ARIMA(p, d, q)$ – AR als Fortschreibung vergangener Werte und MA als Fehlerkorrektur additiv.

ARIMA



Erst die Reihe stationarisieren, dann Autokorrelation und Fehlerstruktur modellieren.

Parameter zeigen an, welche Informationen im Modell weitergegeben werden:


- Autoregression - AR(p): Ein AR-Modell nutzt die lineare Regression für die Modellierung des aktuellen Wertes mit einem oder mehreren vergangenen Werten der gleichen Zeitreihe. Der Parameter p gibt an wie viele vergangene Werte benutzt werden (Anzahl der Lags). Die ϕ s sind die Koeffizienten, c der konstante Term der Regression.

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \epsilon_t$$

- Integration I (d): Viele Zeitreihen sind nicht stationär, d.h., ihr Mittelwert und/oder ihre Varianz ändern sich über die Zeit. Durch **Differenzierung** (Subtraktion des vorherigen Werts) kann die Zeitreihe stationär gemacht werden. Der Parameter d entspricht der Anzahl der Differenzierungen. Delta entspricht dem Differenzoperator.

$$\Delta X_t = X_t - X_{t-1}$$

ARIMA



Erst die Reihe stationarisieren, dann Autokorrelation und Fehlerstruktur modellieren.

Parameter zeigen an, welche Informationen im Modell weitergegeben werden:

- Moving Average MA(q): Die zukünftigen Werte hängen nicht nur von vergangenen Werten, sondern auch von vergangenen **Fehlertermen** (Residuen) der Prognose ab.

Ein MA-Modell nutzt die lineare Regression um aktuelle Werte mit einem oder mehreren vergangenen Fehlerterme. Der Parameter q gibt an wie viele Fehlerterme genutzt werden. Damit können kurzfristige Schocks sichtbar werden, ohne dass sie unbegrenzt lange nachklingen. Die Thetas sind die Koeffizienten der Linearen Regression, μ entspricht dem Mittelwert der Zeitreihe.

$$X_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q}$$

Zeitreihenvorhersage mit Regression


Ein lineares Regressionsmodell geht von einem **linearen Zusammenhang** zwischen der Prognosevariablen y und den (externen) Eingangsvariablen x aus $y_t = \beta_0 + \beta_1 x_t$ $y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \dots + \beta_k x_{k,t}$

Aber: x_t ist für die Zeit t nicht unbedingt bekannt – wir benötigen Schätzungen/Vorhersagen für Eingabevariablen

Lösung : Verwenden Eingabevariablen vom Zeitpunkt t (**verzögerte Prädiktoren = lag Variablen**) für die Vorhersage von y zum Zeitpunkt $t+h$


$$y_{t+h} = \beta_0 + \beta_1 x_{1,t} + \dots + \beta_k x_{k,t}$$

Es können verschiedene Regressionsalgorithmen verwendet werden (z. B. entscheidungsbaumbasierte Regression, XGBoost K-NN-Regression, lineare Regression).



$$\hat{y}_t = 0.55 + 0.28x_t$$


Deep Learning – Anwendungen für RNN



Bilderkennung - Convolutional Neural Networks (CNN)




Maschinelle Übersetzung



Zeitreihenvorhersage
Zeitreihenklassifikation

RNN




Strategische Spiele - Deep Reinforcement Learning



Spracherkennung

Rekurrente Neuronale Netzwerke (RNN)


- Rekurrente Neuronale Netzwerke erlauben, im Gegensatz zu Feed-Forward Neuronalen Netzen, **Rückkopplungen** d.h. **Verbindungen zwischen Neuronen derselben Schicht und zu vorangehende Schichten**.
- Ein RNN besteht aus einer Reihe rekurrenter *gleichartiger Zellen* die Teil der *verborgenen Schicht* sind.
- RNNs können **aufgefaltet** werden: in jeder Zelle wird *die gleiche Berechnung* (mit denselben Parametern) auf der aktuellen Eingabe $x_{(t)}$ und auf dem Zustand der vorangegangenen Zelle h_{t-1} durchgeführt.
- RNNs sind also besonders gut für *sequentielle Daten* geeignet, da sie in ihren verborgenen inneren Schicht **zeitliche Abhängigkeiten einer Sequenz** beliebiger Länge $x_{(1)}, \dots, x_{(T)}$ gut **modellieren und speichern** können.



Aufgefalteter RNN Graph


Rekurrente Neuronale Netzwerke (RNN)

- Während des Trainings werden die **Netzgewichte** (Parameter) des RNN aus Trainingsdaten mit dem *Backpropagation in Time Algorithmus* gelernt
 - Gewichte U zwischen Input und der verborgenen Schicht
 - Gewichte W zwischen den verborgenen Neuronen
 - Gewichte V zwischen der verborgenen Schicht und der Output Schicht




Aufgefalteter RNN Graph

Vorhersage mit RNN - Architektur



Vorhersage mit RNN - Architektur




- Jeder Wert geht mit einem *Gewicht* U und der vorhergehende Wert mit einem *Gewicht* W in eine Zelle ein und die Summe daraus geht in eine Aktivierungsfunktion ein

$$a_t = b + W h_{t-1} + U x_t \quad h_t = \sigma(a_t)$$
- Der Zustand der letzten verborgenen Zelle an $t=N$ geht mit einem *Gewicht* V in die Ausgabeschicht ein

$$o = c + V \cdot h_T$$
- Dort wird eine Vorhersage generiert und mit dem wahren Label verglichen (unter Nutzung einer Verlustfunktion)


Zeitreihenvorhersage mit RNN

- Ein RNN (rekurrentes neuronales Netzwerk) ist in der Lage, Informationen aus **früheren Zeitschritten zu speichern und zu nutzen (insbesondere LSTM - Long Short-Term Memory)**
- Es besteht aus einer Eingabe-, einer verborgenen und einer Ausgabeebene
- Es lernt die Gewichte zwischen allen Schichten mithilfe der Backpropagation über die Zeit (durch Berechnung der Gradienten der Verlustfunktion und des Gradientenabstiegs).



Zeitreihenvorhersage mit RNN

- **Vorwärtsschritt** (forward propagation): das Netz wird mit den Input Daten und initialen Werte für die Parameter vorwärts durchlaufen und die update Funktionen des Netzes werden berechnet.
- **Rückwärtsschritt**: Gradienten werden durch backpropagation through time berechnet und das Netz durch Gradientenabstieg trainiert




Zeitreihenvorhersage mit RNN

Aber:

- Bei langen Zeitreihen kommt es zum **Verschwinden von Gradienten** wenn der Gradient kleiner 1 ist, d.h. Informationen vom Anfang der Zeitreihe werden **vergessen**
- oder zum **Explodieren von Gradienten** wenn der Gradient größer 1 ist, das führt zur Instabilität des Netzes
- „Normale“ RNN haben also **kein Langzeitgedächtnis**


Lösungen: Spezielle Formen von RNNs

- LSTM Netzwerke
- GRU Netze (vereinfachte LSTM Variante)
- Transformer (z.B. TimeGPT)



LSTM Netzwerke

- LSTM (Long Short-Term Memory) Netzwerke haben die Fähigkeit auch *lange zurückliegende Informationen* aus der Zeitreihe zu behalten und z.B. für Vorhersage zu nutzen ohne *verschwindende Gradienten*.
- „Normale“ RNNs haben sehr einfache verborgene Zellen, die nur eine Aktivierungsfunktion (z.B. sigmoid) ausführen.
- LSTM haben **spezielle verborgene Zellen - Speicherzellen** genannt - sie bestehen aus 3 *gates* und mehrere *Aktivierungsfunktionen* werden angewandt, die den Informationsfluss steuern:
 - **Forget gate**: Information die für die Vorhersage nicht wichtig ist kann vergessen werden.
 - **Input gate**: Neue, für die Vorhersage wichtige Information wird hinzugefügt
 - **Output gate**: Es wird gefiltert welche Informationen ausgegeben werden.
- Zusätzlich gibt es einen neuen **Zustand** C_t , der das **Langzeitgedächtnis** repräsentiert, dort werden Informationen aus dem vorherigen Zellen gespeichert und weitergeben.
- Den bereits bekannten **Zustand** h_t der das **Kurzzeitgedächtnis** repräsentiert.



verborgene Zelle in LSTM Netzwerk [Olah2015]
Prof. Dr. Christine Preisach – Maschinelles Lernen

Vor- und Nachteile RNNs für Forecasting

Vorteile:

- Kein feature Engineering notwendig – rohe Zeitreihe kann als Input verwendet werden
- Sie haben die Fähigkeit lange zurückliegende Informationen aus der Zeitreihe zu behalten und z.B. für Vorhersage zu nutzen ☐ Langzeitgedächtnis

Nachteile:

- Tuning von vielen Hyperparametern
- Große Datenmengen benötigt
- Gefahr von Overfitting durch komplexe Modelle

Evaluationsprobleme bei Zeitreihen

Warum ist klassische Cross-Validation problematisch?


- Zufälliges Mischen der Daten verletzt die Zeitstruktur
- Modell sieht „Zukunftsdaten“ bereits im Training → unrealistisch gute Ergebnisse (**Data Leakage**)
- **Beispiel für Data Leakage:**
 - Training enthält Daten aus 2022
 - Test enthält Daten aus 2021
→ Zukunft beeinflusst Vergangenheit
- **Korrekte Vorgehensweise: Zeitbasierte Aufteilung**
 - Train: Vergangenheit, Test: Zukunft → entspricht realem Einsatz
 - **Geeignete Methoden:** Hold-Out Split (zeitbasiert), Sliding Window, Expanding Window
- **Wichtiger Hinweis:** Modelle dürfen nur Informationen nutzen, die zum Vorhersagezeitpunkt verfügbar sind

Evaluation der Zeitreihenvorhersage

Wir müssen die Daten in Trainings- und Testdaten aufteilen:

- **Zeitbasierte Aufteilung /Hold-out-split:**

- Bei diesem Ansatz wird die Zeit als Grundlage für die Aufteilung verwendet.
- Die Daten werden in chronologischer Reihenfolge sortiert, und ein bestimmter Zeitpunkt wird als **Trennpunkt** zwischen Trainings- und Testdaten festgelegt.
- Alle Daten vor diesem Zeitpunkt werden für das Training verwendet, während alle Daten danach für das Testen verwendet werden. Dies ist sinnvoll, da das **Modell nur auf vergangenen Daten trainiert** werden sollte und dann auf zukünftige Daten getestet werden kann.
- Es können auch mehrere Splits erstellt werden indem verschiedene Trennpunkte gewählt werden.




Evaluation der Zeitreihenvorhersage

- **Sliding Window Ansatz:**

- Bei dieser Methode wird ein **festes Zeitfenster** über die Daten geschoben, um **mehrere Trainings- und Testsets** zu erstellen.
- Das Fenster bewegt sich schrittweise über die Zeitreihe, wobei **bei jedem Schritt ein neues Modell trainiert und getestet** wird.
- Dies ermöglicht es, die **Leistung des Modells über verschiedene Zeitperioden zu bewerten** und eine bessere Vorstellung davon zu bekommen, wie es in der Praxis funktionieren würde.

Sliding Window




Quelle: [stackoverflow](#)

Prof. Dr. Christine Preisach – Maschinelles Lernen

Evaluation der Zeitreihenvorhersage

- **Expanding Window Ansatz:**
 - Hier wird wie bei dem sliding window Ansatz ein Zeitfenster über die Daten geschoben
 - Dabei wird aber der **Trainingsdatensatz immer größer**.
 - Mit diesem Ansatz kann getestet werden wie sich die **Performance mit mehr bzw. weniger Daten entwickelt**



Evaluation der Zeitreihenvorhersage

Wir können die Genauigkeit unserer Vorhersagen anhand der für Regression üblichen Evaluationsmaßen messen

Maß	Vorteil	Nachteil
MAE	Einfach zu interpretieren, robust gegenüber Ausreißern	Keine starke Bestrafung großer Fehler
MSE	Bestraft große Fehler stärker durch Quadrierung	Empfindlich gegenüber Ausreißern
RMSE	Ergebnisse in der gleichen Einheit wie die Daten → bessere Interpretierbarkeit	Empfindlich gegenüber Ausreißern, kann durch wenige große Fehler stark verzerrt werden
MAPE	Prozentuale Fehlerangabe → gut vergleichbar über verschiedene Datenreihen	Problematisch bei Werten nahe Null, Verzerrung bei sehr kleinen oder großen tatsächlichen Werten
R ²	Gibt an, wie viel Varianz durch das Modell erklärt wird	Kann irreführend sein bei nichtstationären Zeitreihen, nicht robust gegenüber Ausreißern

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2$$

$$RMSE = \frac{1}{n} \sum_{t=1}^n \sqrt{(y_t - \hat{y}_t)^2}$$

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{y_t}$$

$$R^2 = 1 - \frac{\sum (y_t - \hat{y}_t)^2}{\sum (y_t - \bar{y})^2}$$