

Maschinelles Lernen

Prof. Dr. Christine Preisach



Distanzmaße

- Motivation & Einschub k-Nearest Neighbor Klassifikator
- Motivation Clustering k-Means
- Einfache Distanzmaße
- Mahalanobis Distanz
- DTW
- Ähnlichkeitsmaße




**Supervised
Learning**

**Unsupervised
Learning**

Distanzmaße



Transformationen



Maße

In vielen Maschine Learning-Anwendungen werden Ähnlichkeits- und Unähnlichkeitsmaße (Distanzen, Metriken) verwendet.


Erinnerung: Der Mensch löst die Aufgabe »Gruppieren die Merkmalsvektoren in zwei Gruppen« anhand ihrer Nähe, d.h. ihres Abstands zueinander.



Lernen über Ähnlichkeit

Menschliches Lernen nutzt Ähnlichkeiten aus:


- Zum Beispiel über Formen:



Quadrat



Rechteck



Kreis

- Oder andere Eigenschaften (Größe, Gewicht):



Fussball



Handball




Basketball

Motivation Klassifikation k-NN - Beispiel: Ball-Arten

Beispiel: Klassifikation von Bällen


Wir wollen Bälle ihrer Sportart zuordnen (Klassifikationsaufgabe)

Umfang (cm)	Gewicht (g)	Sportart
70.29	444.30	Fussball
77.73	647.53	Basketball
53.34	427.07	Handball
57.09	406.12	Handball
68.28	440.96	Fussball
80.38	648.94	Basketball




Verschiedene Bälle nachgemessen: Fussball, Handball und Basketball

Beispiel: Ball-Arten



2-dimensionaler Raum: Jeder Punkt $\mathbf{p}$ besteht aus 2 Koordinaten:
 $\mathbf{p} = (p_1, p_2)$

Beispiel: Ball-Arten



Idee: Wir nutzen den **Abstand** als Ähnlichkeit und sagen die Klasse vorher, die am nächsten ist!

K-NN Algorithmus


Verfahren: k -Nearest Neighbors (k -NN)

Training: Speichern der Trainingsdaten $\mathbf{X}_{train}$, $\mathbf{Y}_{train}$


Vorhersage: Beispiel $\mathbf{x}$

Bestimme die k nächsten Nachbarn für $\mathbf{x}$ in, $\mathbf{Y}_{train}$
indem alle Distanzen von $\mathbf{x}$ zu $\mathbf{X}_{train}$ berechnet werden
Vorhersage für $\mathbf{x}$ ist die häufigste Klasse der Nachbarn von $\mathbf{x}$

1-nearest neighbours



20-nearest neighbours



<https://kevinzakka.github.io/2016/07/13/k-nearest-neighbor/>

Offene Fragen:

- ➔ Welches k nehmen wir für unser k -NN Modell?
- ➔ Welches Distanzmaß soll gewählt werden?

Vorteile & Nachteile K-NN

Vorteile:

- Einfacher und intuitiver Algorithmus
- Eignung für Regression und Klassifizierung
- Robuster Algorithmus, der häufig als Maßstab für komplexere Algorithmen dient und diese oft übertrifft
- Sehr ausdrucksstark
- K-NN kann sehr komplexe Hypothesen erlernen

Nachteile:


- Die naive Version ist bei großen Datensätzen langsam
- Muss angepasst werden, wenn die Klassen unausgewogen sind (gewichteter nächster Nachbar)
- Empfindlich gegenüber verrauschten/irrelevanten Feature

Motivation Clustering K-Means


Vorweg: K-Means, der einfachste Clusteralgorithmus.

(basic) K-means


- 1: Wähle K initiale Punkte als Zentren
 - 2: **repeat**
 - 3: Ordne jeden Punkt einem Cluster (Zentrum) zu
 - 4: Berechne die Zentren der Cluster neu
 - 5: **until** Zentren verändern sich nicht mehr
-



Initiale Zentren




Zuordnung der Punkte



Aktualisierte Zentren

Die Zuordnung der Punkte zu einem Cluster erfolgt i.d.R. distanzbasiert!

Distanz- und Ähnlichkeitsmaße



Euklidische Distanz

Die intuitivste Form, den Abstand zwischen zwei (quantitativen) Vektoren


$$\vec{p} = \begin{pmatrix} p_1 \\ \vdots \\ p_d \end{pmatrix} \text{ und } \vec{q} = \begin{pmatrix} q_1 \\ \vdots \\ q_d \end{pmatrix} \text{ im } \mathbb{R}^d$$

zu bestimmen, ist die **euklidische Distanz**:

$$d(p, q) = \sqrt{\sum_{k=1}^d (p_k - q_k)^2}$$

wobei d die Dimension und p_k bzw. q_k die jeweils k -te Komponente der Vektoren, also das jeweils k -te Merkmal bezeichnet.

Die euklidische Distanz entspricht gerade dem **gemessenen Abstand zwischen zwei Punkten (Luftlinie)**.



Euklidische Distanz - Herleitung

Die euklidische Distanz entspricht gerade dem **gemessenen Abstand zwischen zwei Punkten (Luftlinie)**.

Die euklidische Distanz kann mit Hilfe des **Satzes von Pythagoras** berechnet werden.

Mit $d=2$ im Kartesischen Koordinatensystem:

Die so gewonnene Formel kann n-Dimensionen verallgemeinert werden.


$$d(p, q) = \sqrt{\sum_{k=1}^d (p_k - q_k)^2}$$

Beispiel:

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_2(\vec{x}, \vec{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2} = \sqrt{(0 - 3)^2 + (0 - 3)^2} = \sqrt{18} = 4,24$$



Minkowski-Distanz

Eine allgemeinere Form, den Abstand von Vektoren $\vec{x}$ und $\vec{y}$ im $\mathbb{R}^d$ zu berechnen, ist die **Minkowski-Distanz**




$$d_r(\vec{x}, \vec{y}) = \left(\sum_{k=1}^d |x_k - y_k|^r \right)^{\frac{1}{r}}$$

$r=1$: **City Block-, Manhattan-, Mannheim-Distanz.**

Bemerkung: Für binäre Merkmalsvektoren ist dies gerade die Anzahl der Bits, um die sich die Vektoren unterscheiden (= Hamming Distanz).

$r=2$: **Euklidische Distanz**

$r \rightarrow \infty$: **Chebyshev Distanz (Maximums-Norm)** $d_\infty(\vec{x}, \vec{y}) = \max_{k=1..d} |x_k - y_k|$



Skalarprodukt – Norm – Metrik

Von jedem Skalarprodukt kann eine Norm abgeleitet werden und von jeder Norm eine Metrik (siehe Skript „Mathematik für Maschinelles Lernen“)

Beispiel: Auf dem $\mathbb{R}^n$ ist die von dem Standardskalarprodukt
$$\langle \vec{x}, \vec{y} \rangle := \vec{x}^T \vec{y}$$

The diagram shows a horizontal green vector with four segments, labeled '1' at the start and 'n' at the end. This is followed by a dot operator, then a vertical red vector with four segments, labeled '1' at the top and 'n' at the bottom. This is followed by an equals sign, then a single blue square containing the number '1'.

abgeleitete Norm die **euklidische Norm** (L2 Norm) - entspricht der Länge des Vektors

$$\|\vec{x}\|_2 := \sqrt{\langle \vec{x}, \vec{x} \rangle} = \|x\|_2 = \left(\sum_{k=1}^d |x_k|^2 \right)^{\frac{1}{2}}$$

Eine **Norm** misst die „Größe“ eines einzelnen Vektors, eine **Distanz** misst den Abstand zwischen zwei Vektoren;

Aus der Norm kann wiederum die **Euklidische Distanz** (die ja eine Metrik ist) abgeleitet werden:

$$d_2(\vec{x}, \vec{y}) := \|\vec{x} - \vec{y}\|_2$$

Euklidische Distanz – L2 Norm

Der Einheitskreis (oder die Einheitskugel) einer Norm $\|\cdot\|$ ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

$$\text{Einheitskreis} = \{ x \in \mathbb{R}^2 : \|x\| = 1 \}$$


$$\text{Einheitskugel} = \{ x \in \mathbb{R}^2 : \|x\| \leq 1 \}$$

L2-Norm: $\|x\|_2 = \sqrt{x^2 + y^2}$ (im $\mathbb{R}^2$)

➔ Form: KREIS

➔ Geometrie: Gerade Luftlinie zwischen zwei Punkten

➔ **Anwendung:** Distanzen in der Physik, Geometrie, Machine Learning



Cityblock-Distanz

$$d_1(\vec{x}, \vec{y}) = \left(\sum_{k=1}^d |x_k - y_k| \right)$$

City Block-, taxicab-, Manhattan-, Mannheim-Distanz.

Die City Block-Distanz entspricht der **Summe der Absolutwerte der Differenzen zweier Vektoren**


Idee: Der Weg, den man zurücklegen muss, um in einer Stadt mit gitterartigen Straßenverlauf (bspw. Manhattan) von einem Punkt zum nächsten zu gelangen. Der Weg entspricht somit der **Aneinanderreihung vertikaler und horizontaler Wegstücke.**

Beispiel:

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_1(\vec{x}, \vec{y}) = |x_1 - y_1| + |x_2 - y_2| = |3| + |3| = 6$$



Cityblock-Distanz – L1 Norm

Die Cityblock Distanz entspricht der L1-Norm

Die **L1-Norm** eines Vektors misst seine

Länge: $d_1(\vec{x}) = \|\vec{x}\|_1 = \left(\sum_{k=1}^d |x_k|\right)$

Die Einheitsraute einer Norm $\|\cdot\|$


ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

L1-Norm: $\|x\|_1 = |x| + |y|$ (im $\mathbb{R}^2$)

→ Form: RAUTE da $|x| + |y| = 1$

→ Geometrie: Nur horizontale und vertikale Bewegungen

→ **Anwendung:** Anwendung: Stadtblöcke, Lagerhaltung, Robustheit gegen Ausreißer



Chebychev Distanz

$r \rightarrow \infty$: **Chebychev Distanz (Maximums-Norm)** $d_\infty(\vec{x}, \vec{y}) = \max_{k=1..d} |x_k - y_k|$

Der Abstand zwischen zwei Vektoren ist der größte ihrer Unterschiede entlang ihrer Koordinatendimensionen.

Schachbrett-Distanz: die **Mindestanzahl von Zügen**, die ein König benötigt, um von einem Feld zum anderen zu gelangen, entspricht der Chebyshev-Distanz.

Einfaches Beispiel: Bewegung eines Königs auf einem Schachbrett


Zur Bestimmung wie viele Züge ein König minimal benötigt, um von einem Feld auf ein anderes zu gelangen. Es gilt das Maximum der durchzuführenden Reihenwechsel und Linienwechsel zu bestimmen.

Beispiel:

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_\infty(\vec{x}, \vec{y}) = \max_{k=1..2} |x_k - y_k| = \max_{k=1..2} |0 - 3|, |0 - 3| = 3$$



	a	b	c	d	e	f	g	h	
8	5	4	3	2	2	2	2	2	8
7	5	4	3	2	1	1	1	2	7
6	5	4	3	2	1	♔	1	2	6
5	5	4	3	2	1	1	1	2	5
4	5	4	3	2	2	2	2	2	4
3	5	4	3	3	3	3	3	3	3
2	5	4	4	4	4	4	4	4	2
1	5	5	5	5	5	5	5	5	1
	a	b	c	d	e	f	g	h	

Chebyshev-Distanz – Maximums Norm

Die Euklidische Distanz entspricht der L1-Norm

Die L_∞ -**Norm** (Maximums Norm) eines Vektors misst seine

Länge: $d_1(\vec{x}) = \|x\|_\infty = \left(\sum_{k=1}^d |x_k|\right)^\infty$

Das Einheitsviereck einer Norm $\|\cdot\|$


ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

L_∞ -**Norm** : $\|x\|_\infty = \max(|x|, |y|)$ (im $\mathbb{R}^2$)

➔ Form: VIERECK da $\max(|x|, |y|)=1$

➔ Geometrie: Die größere Koordinatendifferenz bestimmt den Abstand

➔ **Anwendung:** Schachbrettabstand, Abstände in Graphen/Netzwerken




Normen Beispiel

BEISPIEL: Punkt (0.8, 0.3)

Berechnet:

- L_2 (Euklidisch):
 - L_1 (Manhattan):
 - L_∞ (Maximum):
-
- Beurteilt die Ergebnisse bzgl. des Einheitskreises




Normen

Alle drei beschreiben denselben Begriff „Abstand = 1“, aber:

- Die FORM ändert sich je nach Distanzmaß
- Die NACHBARSCHAFTEN sehen unterschiedlich aus
- Welche Punkte „nahe beieinander“ sind, hängt von der Norm ab!

BEISPIEL: Punkt (0.8, 0.3)

- L_2 (Euklidisch): $\sqrt{0.8^2 + 0.3^2} \approx 0.86 \rightarrow$ Innerhalb des Einheitskreises
 - L_1 (Manhattan): $|0.8| + |0.3| = 1.10 \rightarrow$ Außerhalb
 - L_∞ (Maximum): $\max(0.8, 0.3) = 0.80 \rightarrow$ Innerhalb
- Der gleiche Punkt ist bei L_1 zu weit weg, bei L_∞ näher!



Metrik

Distanzfunktionen wie die Minkowski-Distanz haben folgende **Eigenschaften**:

1. Positive Definitheit

$$d(\vec{x}, \vec{y}) \geq 0 \text{ für alle } \vec{x} \text{ und } \vec{y}$$

$$d(\vec{x}, \vec{y}) = 0 \text{ genau dann wenn } \vec{x} = \vec{y}$$

2. Symmetrie

$$d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x}) \text{ für alle } \vec{x} \text{ und } \vec{y}$$

3. Dreiecksungleichung

$$d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}) \text{ für alle } \vec{x}, \vec{y} \text{ und } \vec{z}$$

Metrik

Dreiecksungleichung:

$$d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}) \text{ für alle } \vec{x}, \vec{y} \text{ und } \vec{z}$$

- Die Dreiecksungleichung besagt, dass der direkte Abstand zwischen zwei Punkten stets höchstens so groß ist wie die Summe der Abstände über einen Umweg über einen dritten Punkt.
- Die Dreiecksungleichung ist unverzichtbar, weil sie garantiert, dass die Metrik dem gewohnten Verhalten von Abständen entspricht und damit die Grundlage für die gesamte Theorie der metrischen Räume bildet.

Distanzfunktionen, die diese **drei Eigenschaften** erfüllen, heißen **Metrik**.

Alle Minkowski-Distanzen sind Metriken.

Die Dreiecksungleichung besagt, dass die Summe zweier Seitenlängen eines Dreiecks stets größer ist als die dritte Seitenlänge.

$$a + b > c \quad a + c > b \quad b + c > a$$

