

# Maschinelles Lernen

Prof. Dr. Christine Preisach



# Distanzmaße

- Motivation & Einschub k-Nearest Neighbor Klassifikator
- Motivation Clustering k-Means
- Einfache Distanzmaße
- Mahalanobis Distanz
- DTW
- Ähnlichkeitsmaße




**Supervised  
Learning**

**Unsupervised  
Learning**

**Distanzmaße**



**Transformationen**



# Maße

In vielen Maschine Learning-Anwendungen werden Ähnlichkeits- und Unähnlichkeitsmaße (Distanzen, Metriken) verwendet.


**Erinnerung:** Der Mensch löst die Aufgabe »Gruppieren die Merkmalsvektoren in zwei Gruppen« anhand ihrer Nähe, d.h. ihres Abstands zueinander.



# Lernen über Ähnlichkeit

Menschliches Lernen nutzt Ähnlichkeiten aus:


- Zum Beispiel über Formen:



**Quadrat**



**Rechteck**



**Kreis**

- Oder andere Eigenschaften (Größe, Gewicht):



Fussball



Handball




Basketball

# Motivation Klassifikation k-NN - Beispiel: Ball-Arten

## Beispiel: Klassifikation von Bällen


Wir wollen Bälle ihrer Sportart zuordnen (Klassifikationsaufgabe)

| Umfang (cm) | Gewicht (g) | Sportart   |
|-------------|-------------|------------|
| 70.29       | 444.30      | Fussball   |
| 77.73       | 647.53      | Basketball |
| 53.34       | 427.07      | Handball   |
| 57.09       | 406.12      | Handball   |
| 68.28       | 440.96      | Fussball   |
| 80.38       | 648.94      | Basketball |




Verschiedene Bälle nachgemessen: Fussball, Handball und Basketball

# Beispiel: Ball-Arten



2-dimensionaler Raum: Jeder Punkt  $\mathbf{p}$  besteht aus 2 Koordinaten:  
 $\mathbf{p} = (p_1, p_2)$

# Beispiel: Ball-Arten



**Idee:** Wir nutzen den **Abstand** als Ähnlichkeit und sagen die Klasse vorher, die am nächsten ist!

# K-NN Algorithmus


**Verfahren:**  $k$ -Nearest Neighbors ( $k$ -NN)

**Training:** Speichern der Trainingsdaten  $\mathbf{X}_{train}$ ,  $\mathbf{Y}_{train}$


**Vorhersage:** Beispiel  $\mathbf{x}$

Bestimme die  $k$  nächsten Nachbarn für  $\mathbf{x}$  in,  $\mathbf{Y}_{train}$   
indem alle Distanzen von  $\mathbf{x}$  zu  $\mathbf{X}_{train}$  berechnet werden  
Vorhersage für  $\mathbf{x}$  ist die häufigste Klasse der Nachbarn von  $\mathbf{x}$

1-nearest neighbours



20-nearest neighbours



<https://kevinzakka.github.io/2016/07/13/k-nearest-neighbor/>

**Offene Fragen:**

- ➔ Welches  $k$  nehmen wir für unser  $k$ -NN Modell?
- ➔ Welches Distanzmaß soll gewählt werden?

# Vorteile & Nachteile K-NN

## Vorteile:

- Einfacher und intuitiver Algorithmus
- Eignung für Regression und Klassifizierung
- Robuster Algorithmus, der häufig als Maßstab für komplexere Algorithmen dient und diese oft übertrifft
- Sehr ausdrucksstark
- K-NN kann sehr komplexe Hypothesen erlernen

## Nachteile:

- Die naive Version ist bei großen Datensätzen langsam
- Muss angepasst werden, wenn die Klassen unausgewogen sind (gewichteter nächster Nachbar)
- Empfindlich gegenüber verrauschten/irrelevanten Feature

# Motivation Clustering K-Means


Vorweg: K-Means, der einfachste Clusteralgorithmus.

---


(basic) K-means

---


- 1: Wähle K initiale Punkte als Zentren
  - 2: **repeat**
  - 3:     Ordne jeden Punkt einem Cluster (Zentrum) zu
  - 4:     Berechne die Zentren der Cluster neu
  - 5: **until** Zentren verändern sich nicht mehr
- 



Initiale Zentren




Zuordnung der Punkte



Aktualisierte Zentren

**Die Zuordnung der Punkte zu einem Cluster erfolgt i.d.R. distanzbasiert!**

# Distanz- und Ähnlichkeitsmaße



# Euklidische Distanz

Die intuitivste Form, den Abstand zwischen zwei (quantitativen) Vektoren


$$\vec{p} = \begin{pmatrix} p_1 \\ \vdots \\ p_d \end{pmatrix} \text{ und } \vec{q} = \begin{pmatrix} q_1 \\ \vdots \\ q_d \end{pmatrix} \text{ im } \mathbb{R}^d$$

zu bestimmen, ist die **euklidische Distanz**:

$$d(p, q) = \sqrt{\sum_{k=1}^d (p_k - q_k)^2}$$

wobei  $d$  die Dimension und  $p_k$  bzw.  $q_k$  die jeweils  $k$ -te Komponente der Vektoren, also das jeweils  $k$ -te Merkmal bezeichnet.

Die euklidische Distanz entspricht gerade dem **gemessenen Abstand zwischen zwei Punkten (Luftlinie)**.



# Euklidische Distanz - Herleitung

Die euklidische Distanz entspricht gerade dem **gemessenen Abstand zwischen zwei Punkten (Luftlinie)**.

Die euklidische Distanz kann mit Hilfe des **Satzes von Pythagoras** berechnet werden.

Mit  $d=2$  im Kartesischen Koordinatensystem:

Die so gewonnene Formel kann n-Dimensionen verallgemeinert werden.


$$d(p, q) = \sqrt{\sum_{k=1}^d (p_k - q_k)^2}$$

**Beispiel:**

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_2(\vec{x}, \vec{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2} = \sqrt{(0 - 3)^2 + (0 - 3)^2} = \sqrt{18} = 4,24$$



# Minkowski-Distanz

Eine allgemeinere Form, den Abstand von Vektoren  $\vec{x}$  und  $\vec{y}$  im  $\mathbb{R}^d$  zu berechnen, ist die **Minkowski-Distanz**




$$d_r(\vec{x}, \vec{y}) = \left( \sum_{k=1}^d |x_k - y_k|^r \right)^{\frac{1}{r}}$$

$r=1$ : **City Block-, Manhattan-, Mannheim-Distanz.**

Bemerkung: Für binäre Merkmalsvektoren ist dies gerade die Anzahl der Bits, um die sich die Vektoren unterscheiden (= Hamming Distanz).

$r=2$ : **Euklidische Distanz**

$r \rightarrow \infty$ : **Chebyshev Distanz (Maximums-Norm)**  $d_\infty(\vec{x}, \vec{y}) = \max_{k=1..d} |x_k - y_k|$



# Skalarprodukt – Norm – Metrik

Von jedem Skalarprodukt kann eine Norm abgeleitet werden und von jeder Norm eine Metrik (siehe Skript „Mathematik für Maschinelles Lernen“)

Beispiel: Auf dem  $\mathbb{R}^n$  ist die von dem Standardskalarprodukt  
$$\langle \vec{x}, \vec{y} \rangle := \vec{x}^T \vec{y}$$

The diagram shows a horizontal green vector with four segments, labeled '1' at the start and 'n' at the end. This is followed by a dot operator, then a vertical red vector with four segments, labeled '1' at the top and 'n' at the bottom. This is followed by an equals sign, then a single blue square containing the number '1'.

abgeleitete Norm die **euklidische Norm** (L2 Norm) - entspricht der Länge des Vektors

$$\|\vec{x}\|_2 := \sqrt{\langle \vec{x}, \vec{x} \rangle} = \|x\|_2 = \left( \sum_{k=1}^d |x_k|^2 \right)^{\frac{1}{2}}$$

Eine **Norm** misst die „Größe“ eines einzelnen Vektors, eine **Distanz** misst den Abstand zwischen zwei Vektoren;

Aus der Norm kann wiederum die **Euklidische Distanz** (die ja eine Metrik ist) abgeleitet werden:

$$d_2(\vec{x}, \vec{y}) := \|\vec{x} - \vec{y}\|_2$$

# Euklidische Distanz – L2 Norm

Der Einheitskreis (oder die Einheitskugel) einer Norm  $\|\cdot\|$  ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

$$\text{Einheitskreis} = \{ x \in \mathbb{R}^2 : \|x\| = 1 \}$$


$$\text{Einheitskugel} = \{ x \in \mathbb{R}^2 : \|x\| \leq 1 \}$$

**L2-Norm:**  $\|x\|_2 = \sqrt{x^2 + y^2}$  (im  $\mathbb{R}^2$ )

➔ Form: KREIS

➔ Geometrie: Gerade Luftlinie zwischen zwei Punkten

➔ **Anwendung:** Distanzen in der Physik, Geometrie, Machine Learning



# Cityblock-Distanz

$$d_1(\vec{x}, \vec{y}) = \left( \sum_{k=1}^d |x_k - y_k| \right)$$

**City Block-, taxicab-, Manhattan-, Mannheim-Distanz.**

Die City Block-Distanz entspricht der **Summe der Absolutwerte der Differenzen zweier Vektoren**


**Idee:** Der Weg, den man zurücklegen muss, um in einer Stadt mit gitterartigen Straßenverlauf (bspw. Manhattan) von einem Punkt zum nächsten zu gelangen. Der Weg entspricht somit der **Aneinanderreihung vertikaler und horizontaler Wegstücke.**

**Beispiel:**

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_1(\vec{x}, \vec{y}) = |x_1 - y_1| + |x_2 - y_2| = |3| + |3| = 6$$



# Cityblock-Distanz – L1 Norm

Die Cityblock Distanz entspricht der L1-Norm

Die **L1-Norm** eines Vektors misst seine

**Länge:**  $d_1(\vec{x}) = \|\vec{x}\|_1 = \left(\sum_{k=1}^d |x_k|\right)$

Die Einheitsraute einer Norm  $\|\cdot\|$


ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

**L1-Norm:**  $\|x\|_1 = |x| + |y|$  (im  $\mathbb{R}^2$ )

→ Form: RAUTE da  $|x| + |y| = 1$

→ Geometrie: Nur horizontale und vertikale Bewegungen

→ **Anwendung:** Anwendung: Stadtblöcke, Lagerhaltung, Robustheit gegen Ausreißer



# Chebychev Distanz

$r \rightarrow \infty$ : **Chebychev Distanz (Maximums-Norm)**  $d_\infty(\vec{x}, \vec{y}) = \max_{k=1..d} |x_k - y_k|$

Der Abstand zwischen zwei Vektoren ist der größte ihrer Unterschiede entlang ihrer Koordinatendimensionen.

**Schachbrett-Distanz:** die **Mindestanzahl von Zügen**, die ein König benötigt, um von einem Feld zum anderen zu gelangen, entspricht der Chebyshev-Distanz.

**Einfaches Beispiel:** Bewegung eines Königs auf einem Schachbrett


Zur Bestimmung wie viele Züge ein König minimal benötigt, um von einem Feld auf ein anderes zu gelangen. Es gilt das Maximum der durchzuführenden Reihenwechsel und Linienwechsel zu bestimmen.

**Beispiel:**

$$\vec{x} = (0,0)^T$$

$$\vec{y} = (3,3)^T$$

$$d_\infty(\vec{x}, \vec{y}) = \max_{k=1..2} |x_k - y_k| = \max_{k=1..2} |0 - 3|, |0 - 3| = 3$$



|   | a | b | c | d | e | f | g | h |   |
|---|---|---|---|---|---|---|---|---|---|
| 8 | 5 | 4 | 3 | 2 | 2 | 2 | 2 | 2 | 8 |
| 7 | 5 | 4 | 3 | 2 | 1 | 1 | 1 | 2 | 7 |
| 6 | 5 | 4 | 3 | 2 | 1 | ♔ | 1 | 2 | 6 |
| 5 | 5 | 4 | 3 | 2 | 1 | 1 | 1 | 2 | 5 |
| 4 | 5 | 4 | 3 | 2 | 2 | 2 | 2 | 2 | 4 |
| 3 | 5 | 4 | 3 | 3 | 3 | 3 | 3 | 3 | 3 |
| 2 | 5 | 4 | 4 | 4 | 4 | 4 | 4 | 4 | 2 |
| 1 | 5 | 5 | 5 | 5 | 5 | 5 | 5 | 5 | 1 |
|   | a | b | c | d | e | f | g | h |   |

# Chebyshev-Distanz – Maximums Norm

Die Euklidische Distanz entspricht der L1-Norm

Die  $L_\infty$ -**Norm** (Maximums Norm) eines Vektors misst seine

**Länge:**  $d_1(\vec{x}) = \|x\|_\infty = \left(\sum_{k=1}^d |x_k|\right)^\infty$

Das Einheitsviereck einer Norm  $\|\cdot\|$


ist die Menge aller Punkte mit Abstand genau 1 vom Ursprung:

$L_\infty$ -**Norm** :  $\|x\|_\infty = \max(|x|, |y|)$  (im  $\mathbb{R}^2$ )

➔ Form: VIERECK da  $\max(|x|, |y|)=1$

➔ Geometrie: Die größere Koordinatendifferenz bestimmt den Abstand

➔ **Anwendung:** Schachbrettabstand, Abstände in Graphen/Netzwerken




# Normen Beispiel

**BEISPIEL:** Punkt (0.8, 0.3)

Berechnet:

- $L_2$  (Euklidisch):
  - $L_1$  (Manhattan):
  - $L_\infty$  (Maximum):
- 
- Beurteilt die Ergebnisse bzgl. des Einheitskreises




# Normen

Alle drei beschreiben denselben Begriff „Abstand = 1“, aber:

- Die FORM ändert sich je nach Distanzmaß
- Die NACHBARSCHAFTEN sehen unterschiedlich aus
- Welche Punkte „nahe beieinander“ sind, hängt von der Norm ab!

**BEISPIEL:** Punkt (0.8, 0.3)

- $L_2$  (Euklidisch):  $\sqrt{0.8^2 + 0.3^2} \approx 0.86 \rightarrow$  Innerhalb des Einheitskreises
  - $L_1$  (Manhattan):  $|0.8| + |0.3| = 1.10 \rightarrow$  Außerhalb
  - $L_\infty$  (Maximum):  $\max(0.8, 0.3) = 0.80 \rightarrow$  Innerhalb
- Der gleiche Punkt ist bei  $L_1$  zu weit weg, bei  $L_\infty$  näher!



# Metrik

Distanzfunktionen wie die Minkowski-Distanz haben folgende **Eigenschaften**:

**1. Positive Definitheit**

$$d(\vec{x}, \vec{y}) \geq 0 \text{ für alle } \vec{x} \text{ und } \vec{y}$$

$$d(\vec{x}, \vec{y}) = 0 \text{ genau dann wenn } \vec{x} = \vec{y}$$

**2. Symmetrie**

$$d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x}) \text{ für alle } \vec{x} \text{ und } \vec{y}$$

**3. Dreiecksungleichung**

$$d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}) \text{ für alle } \vec{x}, \vec{y} \text{ und } \vec{z}$$

# Metrik

## Dreiecksungleichung:

$$d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}) \text{ für alle } \vec{x}, \vec{y} \text{ und } \vec{z}$$


- Die Dreiecksungleichung besagt, dass der direkte Abstand zwischen zwei Punkten stets höchstens so groß ist wie die Summe der Abstände über einen Umweg über einen dritten Punkt.
- Die Dreiecksungleichung ist unverzichtbar, weil sie garantiert, dass die Metrik dem gewohnten Verhalten von Abständen entspricht und damit die Grundlage für die gesamte Theorie der metrischen Räume bildet.

Distanzfunktionen, die diese **drei Eigenschaften** erfüllen, heißen **Metrik**.

**Alle Minkowski-Distanzen sind Metriken.**

Die Dreiecksungleichung besagt, dass die Summe zweier Seitenlängen eines Dreiecks stets größer ist als die dritte Seitenlänge.


$$a + b > c \quad a + c > b \quad b + c > a$$



# Was passiert wenn die Datenpunkte nicht skaliert sind?

# Was passiert wenn die Datenpunkte nicht skaliert sind?

- Distanzen sind bei skalierten bzw. nicht skalierten Daten völlig anders!



- Beispiel Alter in Jahren [10-100] vs. Jahreseinkommen [0-500.000] → Einkommen dominiert die Distanz!
- Lösung beide Variablen normieren → Alle Features in [0,1]

# Distanzen & unterschiedliche Einheiten

- Distanzen sind bei skalierten bzw. nicht skalierten Daten völlig anders!

## Beispiel: Alter und Körpergröße bei männlichen Jugendlichen



X: Alter in Jahren, Y: Körpergröße in m

- Person A: [14 Jahre, 1.60m], Person B: [15 Jahre, 1.75m]

- OHNE Normalisierung:  $d_2(A, B) = \sqrt{((15 - 14)^2 + (1,75 - 1,60)^2)} = \sqrt{1 + 0,0225} = 1,01$


- Wenn wir in Zentimetern statt Metern messen

- $d_2(A', 'B = \sqrt{((15 - 14)^2 + (175 - 160)^2)} = \sqrt{1 + 225} = 15,0$



|                   |      |      |      |      |      |      |
|-------------------|------|------|------|------|------|------|
| Alter (in Jahren) | 14   | 16   | 16   | 12   | 15   | 17   |
| Größe (in m)      | 1,60 | 1,75 | 1,80 | 1,50 | 1,55 | 1,80 |




# Beispiel: Verschiedene Skalen



# Skalierung

- Die Daten können numerische Variablen mit sehr **unterschiedlichen Skalen** enthalten. Viele Methoden des maschinellen Lernens benötigen Variablen mit der **gleichen Skalierung**
- Skalierung von numerischen Variablen führt bei vielen Methoden des maschinellen Lernen (z.B. Lineare Regression, logistische Regression und distanzbasierte Methoden) zu qualitativ besseren Modellen
- **Min-Max-Normalisierung** : Skaliert die Daten auf den Bereich von 0 bis 1
$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$
- **Z-Score-Standardisierung** :
  - Verwendet den Mittelwert und die Standardabweichung,
  - Nach der Standardisierung haben die Variablen einen Mittelwert von 0 und eine Varianz von 1
  - Wird häufig beim maschinellen Lernen verwendet
  - Annahme der Normalverteilung
$$x' = \frac{x - \bar{x}}{\sigma}$$

# Skalierung



- Features werden auf den gleichen Bereich transformiert und damit vergleichbar und besser nutzbar durch viele Algorithmen

# Nachteile der Minkowski Metrik

- Die Minkowski Metrik ist nicht Skaleninvariant
- Ist für korrelierte Merkmale nicht geeignet

**→ Lösung: Mahalanobis Distanz**

# Notation

... wir setzen i.d.R. voraus, dass die Daten **vektorisert** sind, jedes **Objekt** also repräsentiert ist durch einen Vektor von  $d$  Merkmalen (Dimension  $d$ ).

$$\vec{g}_i \in \mathbb{R}^d \quad \text{für } i = 1, \dots, N$$

Ein **Merkmal** wiederum fassen wir oft als eine Stichprobe eines Zufallsexperiments auf, das durch eine Zufallsvariable (ZV) repräsentiert wird.

$$X, Y \text{ oder } X_1, \dots, X_d$$

**Zugehörige Stichproben:**  $\vec{X}, \vec{Y}$  oder  $\vec{X}_1, \dots, \vec{X}_d$

Die Verteilung der Zufallsvariablen ist dabei oft unbekannt, wohl aber werden Maßzahlen wie Erwartungswert  $EX$  geschätzt, z.B.

→ Erwartungswert  $\mu = EX$  (z.B. durch Mittelwert  $m$ ) und

→ Varianz  $\sigma^2 = Var(X)$  (z.B. durch korrigierte empirische Varianz  $s^2$ )

# Mahalanobis-Distanz

Die **Mahalanobis-Distanz** ist eine sehr wichtige Metrik. Sie basiert auf der (meist empirisch ermittelten) **invertierten Kovarianzmatrix** eines Datenbestands.

Beispiel: Gegeben sei ein Datenbestand mit  $N$  Objekten, die jeweils durch die beiden Merkmale Alter  $X$  und Größe  $Y$  repräsentiert seien.


Dann ist die Kovarianzmatrix definiert durch

$$C = \begin{pmatrix} Cov(X, X) & Cov(X, Y) \\ Cov(Y, X) & Cov(Y, Y) \end{pmatrix}$$

Da die wahre Verteilung der Merkmale jedoch in der Regel nicht bekannt ist, werden die Kovarianzen empirisch geschätzt.

# Varianz und Kovarianz

Die Varianz eines Merkmals beschreibt dessen Streuung



- Gibt an wie stark die **Beobachtungen um den Mittelwert streuen**.
- Nutzt die **quadrierten Abstände zum Mittelwert**.

# Empirische Varianz

Die **Varianz** eines Merkmals  $X$  lässt sich aus den Daten schätzen:

Bezeichne  $x_k$  den Wert des Merkmals  $X$  für das  $k$ -te Objekt aus dem Datenbestand.

Dann ist

$$\bar{X} = \frac{1}{N} \sum_{k=1}^N x_k$$

der **Mittelwert** (als Schätzer für den Erwartungswert) und

$$Var(X) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})^2$$

einen Schätzer für die **Varianz** (=empirische Varianz) von Merkmal  $X$ .

# Empirische Varianz

Beispiel: Bestellung des Gerichtes „Penne all’ Arrabbiata“ in einem Restaurant

| Wochentag | MO | DI | MI | DO | FR | SA | SO | MO | DI | MI | DO | FR | SA | SO |
|-----------|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| Anzahl    | 5  | 2  | 12 | 8  | 6  | 1  | 20 | 7  | 0  | 3  | 12 | 8  | 5  | 9  |

$$Var(X) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})^2$$


$n = 14$ ,  $\bar{x} = 7$  Wie stark streut die Bestellung dieses Gerichts um den Mittelwert?

| Wochentag           | MO | DI | MI | DO | FR | SA | SO  | MO | DI | MI | DO | FR | SA | SO |
|---------------------|----|----|----|----|----|----|-----|----|----|----|----|----|----|----|
| Anzahl              | 5  | 2  | 12 | 8  | 6  | 1  | 20  | 7  | 0  | 3  | 12 | 8  | 5  | 9  |
| $x_i - \bar{x}$     | -2 | -5 | 5  | 1  | -1 | -6 | 13  | 0  | -7 | -4 | 5  | 1  | -2 | 2  |
| $(x_i - \bar{x})^2$ | 4  | 25 | 25 | 1  | 1  | 36 | 169 | 0  | 49 | 16 | 25 | 1  | 4  | 4  |


- Empirische Varianz: 25,71
- Was heißt das für das Restaurant? Mit wie viele Gerichten pro Tag soll geplant werden?
- **Nachteil:** Varianz ist nicht gut interpretierbar, da sie nicht in der ursprünglichen Einheit dargestellt ist

# Varianz und Kovarianz


Die Varianz eines Merkmals beschreibt dessen Streuung




Die Kovarianz zweier Merkmale beschreibt das **Maß ihrer linearen Abhängigkeit**



Positive lineare Abhängigkeit:  
„Je mehr Schokolade wir essen,  
desto schwerer sind wir“



Kein (linearer) Zusammenhang:  
Störche  $\nrightarrow$  Kinder  
Kinder  $\nrightarrow$  Störche



Negative lineare Abhängigkeit:  
„Je mehr gefahrene Strecke,  
desto weniger Sprit im Tank“

**Achtung: Sowohl Varianz als auch Kovarianz sind skalenabhängig!**

# Empirische Varianz und Kovarianz

Mit analoger Bezeichnung für das Merkmal  $Y$  ergibt sich die empirische **Kovarianz** als

$$\text{Cov}(X, Y) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y})$$

Sie gibt an, **wie sehr sich die die Variablen gemeinsam verändern.**

# Empirische Kovarianz - Interpretation

- **Interpretation der empirischen Kovarianz:** Die empirische Kovarianz wird zur Beschreibung eines **Zusammenhangs zwischen zwei metrischen Merkmalen** herangezogen:
  - **Ist der Wert der empirischen Kovarianz positiv, gibt es einen positiven Zusammenhang vor** (hohe Werte in der einen Variablen treten tendenziell gemeinsam mit hohen Werten in der anderen Variablen auf, niedrige mit niedrigen Werten)
  - **Ist der Wert der empirischen Kovarianz negativ, gibt es einen negativen Zusammenhang** (hohe Werte in der einen Variablen treten tendenziell gemeinsam mit niedrigen Werten in der anderen Variablen auf, bzw. niedrige in der einen mit hohen in der anderen Variable)
- Liegt der Wert der **empirischen Kovarianz** bei etwa **Null**, liegen **keine** Anhaltspunkte dafür vor, dass ein **(linearer) Zusammenhang** der Werte, der einen mit den Werten der anderen Variablen existiert.

$$\text{Cov}(X, Y) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y})$$

# Mahalanobis-Distanz

Die **Mahalanobis-Distanz** ist eine sehr wichtige Metrik. Sie basiert auf der (meist empirisch ermittelten) **invertierten Kovarianzmatrix** eines Datenbestands.

**Beispiel:** Gegeben sei ein Datenbestand mit  $N$  Objekten, die jeweils durch die beiden Merkmale Alter  $X$  und Größe  $Y$  repräsentiert seien.

Dann ist die **Kovarianzmatrix** definiert durch

$$C = \begin{pmatrix} Cov(X, X) & Cov(X, Y) \\ Cov(Y, X) & Cov(Y, Y) \end{pmatrix}$$

Da die wahre Verteilung der Merkmale jedoch in der Regel nicht bekannt ist, werden die Kovarianzen empirisch geschätzt.

# Übung Kovarianz Matrix

- **Beispiel: Alter und Körpergröße bei männlichen Jugendlichen**

X: Alter in Jahren, Y: Körpergröße in m

|                   |      |      |      |      |      |      |
|-------------------|------|------|------|------|------|------|
| Alter (in Jahren) | 14   | 16   | 16   | 12   | 15   | 17   |
| Größe (in m)      | 1,60 | 1,75 | 1,80 | 1,50 | 1,55 | 1,80 |

- Berechnet die Kovarianz Matrix.

$$\text{Cov}(X, Y) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y})$$

$$C = \begin{pmatrix} \text{Cov}(X, X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & \text{Cov}(Y, Y) \end{pmatrix}$$

# Übung Kovarianz Matrix

- **Beispiel: Alter und Körpergröße bei männlichen Jugendlichen**

X: Alter in Jahren, Y: Körpergröße in m

|                   |      |      |      |      |      |      |
|-------------------|------|------|------|------|------|------|
| Alter (in Jahren) | 14   | 16   | 16   | 12   | 15   | 17   |
| Größe (in m)      | 1,60 | 1,75 | 1,80 | 1,50 | 1,55 | 1,80 |

Arithmetisches Mittel  $\bar{x} = 15$

Arithmetisches Mittel  $\bar{y} = 10/6 = 1,667$

$$Cov(x, y) = \frac{(14 - 15) \cdot (1,60 - 1,667) + (16 - 15) \cdot (1,75 - 1,667) + (16 - 15) \cdot (1,8 - 1,667) + (12 - 15) \cdot (1,5 - 1,667) + (15 - 15) \cdot (1,55 - 1,667) + (17 - 15) \cdot (1,8 - 1,667)}{6 - 1}$$

= 0,21

$$Cov(x, x) = \frac{(14 - 15)^2 + (16 - 15)^2 + (16 - 15)^2 + (12 - 15)^2 + (15 - 15)^2 + (17 - 15)^2}{6 - 1} = \frac{16}{5}$$

$$Cov(y, y) = \dots = 0,0176$$

**Vermutung:** Es liegt ein **positiver Zusammenhang** zwischen X und Y vor.

$$C = \begin{pmatrix} \frac{16}{5} & 0,21 \\ 0,21 & 0,018 \end{pmatrix}$$

# Eigenschaften der Kovarianzmatrix

- $Cov(X, X) = Var(X) \rightarrow$  auf der Diagonalen steht die **Varianz** - diese ist **nichtnegativ**
- Die Kovarianzmatrix ist **symmetrisch**  $Cov(X, Y) = Cov(Y, X)$
- Der Wert der empirischen Kovarianz **hängt** wesentlich **von der Größe der betrachteten Beobachtungswerte ab (Skalierung)**, d.h. zum Beispiel von der Einheit die verwendet wird, es macht also einen Unterschied, ob das Einkommen und die Ausgaben von Personen in Euro oder in Eurocent gemessen werden, oder die Körpergröße in Meter oder Zentimeter.
  - **Konsequenz:**
    - Das **Vorzeichen** der Kovarianz gibt lediglich einen Hinweis auf **das gemeinsame Wachstumsverhalten** beider Merkmale
    - Die Kovarianz erlaubt **keine Aussage** über die **Stärke des Zusammenhangs**.

$$Cov(X, Y) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y})$$

# Mahalanobis-Distanz

Die **Mahalanobis-Distanz** ist eine sehr wichtige Metrik. Sie basiert auf der (meist empirisch ermittelten) **invertierten Kovarianzmatrix** eines Datenbestands.

**Beispiel:** Gegeben sei ein Datenbestand mit  $N$  Objekten, die jeweils durch die beiden Merkmale Alter  $X$  und Größe  $Y$  repräsentiert seien.

Dann ist die **Kovarianzmatrix** des Datenbestandes definiert durch

$$C = \begin{pmatrix} Var(X) & Cov(X, Y) \\ Cov(Y, X) & Var(Y) \end{pmatrix}$$

Da die wahre Verteilung der Merkmale jedoch in der Regel nicht bekannt ist, werden die Kovarianzen empirisch geschätzt, also die Stichprobenvarianz und –kovarianz verwendet.

# Empirische Kovarianz vs. Korrelation

- Die Kovarianz ist ein nichtstandardisiertes Zusammenhangsmaß und hat daher nur eine geringe Vergleichbarkeit.
- Die Korrelation (Pearson's Korrelationskoeffizient) ist die standardisierte Kovarianz (Kovarianz geteilt durch die Standardabweichung)
- Werte liegen zwischen -1 und +1

$$r_{x,y} = \frac{Cov(X, Y)}{\sqrt{Var(X) \cdot Var(Y)}}$$

# Empirische Varianz und Kovarianz für mehrere Variablen


Für mehr als zwei, also z.B.  $d$  Merkmale  $X_1, \dots, X_d$  ist die **Kovarianzmatrix** definiert als

$$C = (c_{ij}) = \left( \text{Cov}(X_i, X_j) \right)$$

Für einen Datenbestand, der aus  $N$  Objekten  $\vec{g}_1, \dots, \vec{g}_N$  (in vektorieller Darstellung) besteht, kann die Kovarianzmatrix auch aus der **zentrierten Datenmatrix** berechnet werden:

**1. Zentrierung:** Berechne den Mittelwert  $\vec{g}_{mean} = \frac{1}{N} \sum_{n=1}^N \vec{g}_n$  und zentriere die Daten für  $n = 1, \dots, N$ :

$$\Delta \vec{g}_n = \vec{g}_n - \vec{g}_{mean}$$



Das entspricht einer **Verschiebung der Daten in ein neues Koordinatensystem:**

$$\text{Cov}(X, Y) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y})$$

# Empirische Varianz und Kovarianz

**2. Aufstellen der (zentrierten Datenmatrix):** Die  $N$  zentrierten Vektoren werden **spaltenweise** in die Datenmatrix geschrieben.

$$G = (\Delta\vec{g}_1 | \dots | \Delta\vec{g}_N) \in \mathbb{R}^{d \times N}$$

**3. Berechnung der (empirischen) Kovarianzmatrix:**

$$C = \frac{1}{N-1} G G^T \in \mathbb{R}^{d \times d}$$

# Beispiel – Kovarianzmatrix berechnen

**Beispiel:** Gegeben sei nochmal der Datenbestand vom Umfang  $N=5$

$$\left\{ \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\}$$

Kovarianzmatrix berechnen über zentrierte Datenmatrix → Tafel

# Empirische Varianz und Kovarianz

**Beispiel:** Gegeben sei der zweidimensionale Datenbestand mit 5 Objekten  $N = 5$  und einer Dimension von 2:

$$\left\{ \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\}$$

$X$  bezeichne das erste Merkmal und  $Y$  das zweite Merkmal. Dann ist

$$\bar{X} = \frac{1}{N} \sum_{k=1}^N x_k = \frac{1}{5} (0 + 1 + 0 - 1 + 0) = 0$$

$$\bar{Y} = \frac{1}{N} \sum_{k=1}^N y_k = \frac{1}{5} (2 + 0 - 2 + 0 + 0) = 0$$

und

$$Var(X) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})^2 = \frac{1}{4} ((0-0)^2 + (1-0)^2 + (0-0)^2 + (-1-0)^2 + (0-0)^2) = \frac{1}{2}$$

$$Var(Y) = \frac{1}{N-1} \sum_{k=1}^N (y_k - \bar{Y})^2 = \frac{1}{4} ((2-0)^2 + (0-0)^2 + (-2-0)^2 + (0-0)^2 + (0-0)^2) = 2$$

$$Cov(X, Y) = Cov(Y, X) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{X})(y_k - \bar{Y}) = 0$$

also

$$C = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{pmatrix}$$

# Mahalanobis-Distanz

Sie basiert auf der (meist empirisch ermittelten) **invertierten Kovarianzmatrix eines Datenbestands**. Auf Basis der Kovarianz eines Datenbestands ist die **Mahalanobis-Distanz** nun definiert als

$$d_C(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T C^{-1} (\vec{x} - \vec{y})}$$

wobei  $\vec{x}$  und  $\vec{y}$  wieder Vektoren im (Merkmalsraum)  $\mathbb{R}^d$  bezeichnen

# Einschub: Invertieren von Matrizen

Für manche Matrizen  $A$  gibt es eine inverse Matrix  $A^{-1}$ , das heißt es gilt:

$$A \cdot A^{-1} = A^{-1} \cdot A = I$$

Wobei  $I$  die sogenannte Einheitsmatrix ist.

Die Multiplikation mit der Einheitsmatrix ergibt die Matrix selbst:  $A \cdot I = I \cdot A = A$

Eine Inverse existiert nur für **quadratische Matrizen**  $A$  für die die **Determinante ungleich 0** ist

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$\det(A) = (\text{Produkt Hauptdiagonale}) - (\text{Produkt Nebendiagonale})$$

Solche invertierbaren Matrizen nennt man **regulär**

# Beispiel Mahalanobis-Distanz

**Beispiel:** Gegeben sei nochmal der Datenbestand vom Umfang  $N=5$

$$\left\{ \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\}$$

mit der Kovarianzmatrix

$$C = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{pmatrix}$$

Hat die Matrix eine Inverse?

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$\det(A) = (\text{Produkt Hauptdiagonale}) - (\text{Produkt Nebendiagonale})$$

# Beispiel Mahalanobis-Distanz

**Beispiel:** Gegeben sei nochmal der Datenbestand vom Umfang  $N=5$

$$\left\{ \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\}$$

mit der Kovarianzmatrix

$$C = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{pmatrix}$$

Hat die Matrix eine Inverse?

$$C^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$$

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$\det(A) = (\text{Produkt Hauptdiagonale}) - (\text{Produkt Nebendiagonale})$

# Beispiel Mahalanobis-Distanz

**Aufgabe:** Berechnen Sie den Abstand der Vektoren

$$\vec{x} = \begin{pmatrix} 0 \\ \sqrt{2} \end{pmatrix} \text{ und } \vec{y} = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} \text{ jeweils zu } \vec{o} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Skizzieren Sie die Daten und Vektoren in ein 2d-Koordinatensystem.

$$d_C(\vec{a}, \vec{o}) = \sqrt{(\vec{a} - \vec{o})^T C^{-1} (\vec{a} - \vec{o})}$$
$$d_C(\vec{b}, \vec{o}) = \sqrt{(\vec{b} - \vec{o})^T C^{-1} (\vec{b} - \vec{o})}$$

Berechnen Sie den Abstand des Vektors

$\vec{a} = \begin{pmatrix} 0 \\ \sqrt{2} \end{pmatrix}$  zu  $\vec{o} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$  ( $\vec{o}$  entspricht  $\vec{g}_{mean}$ ) mit  $C^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$

$$d_C(\vec{a}, \vec{o}) = \sqrt{(\vec{a} - \vec{o})^T C^{-1} (\vec{a} - \vec{o})}$$

$$d_C(\vec{a}, \vec{o}) = \sqrt{(0 \ \sqrt{2}) \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 0 \\ \sqrt{2} \end{pmatrix}}$$


$$= \sqrt{(0 \ \sqrt{2}) \begin{pmatrix} 0 \\ \frac{1}{2} \sqrt{2} \end{pmatrix}}$$

$$= \sqrt{\frac{1}{2} \sqrt{2} \sqrt{2}}$$

$$= \sqrt{\frac{1}{2} \sqrt{4}}$$

$$= \sqrt{1}$$

$$= 1$$



$$\begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \cdot \begin{pmatrix} 0 \\ \sqrt{2} \end{pmatrix} = \left( 0 \cdot 0 + \frac{1}{2} \cdot \sqrt{2} \right) = \begin{pmatrix} 0 \\ \frac{1}{2} \sqrt{2} \end{pmatrix}$$

Berechnen Sie den Abstand des Vektors

$$\vec{b} = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} \text{ zu } \vec{o} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} (\vec{o} \text{ entspricht } \vec{g}_{mean}) \text{ mit } C^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$$

$$d_C(\vec{b}, \vec{o}) = \sqrt{(\vec{b} - \vec{o})^T C^{-1} (\vec{b} - \vec{o})}$$

$$d_C(\vec{b}, \vec{o}) = \sqrt{\begin{pmatrix} \frac{1}{\sqrt{2}} & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}}$$

$$= \sqrt{\begin{pmatrix} \frac{1}{\sqrt{2}} & 0 \end{pmatrix} \begin{pmatrix} 2\frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}}$$

$$= \sqrt{2 \frac{1}{\sqrt{2}} \frac{1}{\sqrt{2}} + 0}$$

$$= \sqrt{2 \frac{1}{\sqrt{4}}}$$

$$= \sqrt{1}$$

$$= 1$$

# Mahalanobis-Distanz

Sie basiert auf der (meist empirisch ermittelten) **invertierten Kovarianzmatrix eines Datenbestands**. Auf Basis der Kovarianz eines Datenbestands ist die **Mahalanobis-Distanz** nun definiert als

$$d_C(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T C^{-1} (\vec{x} - \vec{y})}$$

wobei  $\vec{x}$  und  $\vec{y}$  wieder Vektoren im (Merkmalsraum)  $\mathbb{R}^d$  bezeichnen

**Bemerkung:** Die euklidische Distanz kann als

$$d(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T (\vec{x} - \vec{y})} = \sqrt{(\vec{x} - \vec{y})^T I (\vec{x} - \vec{y})}$$

geschrieben werden. **Inwieweit unterscheiden sich die beiden Metriken?**

Statt der inversen Kovarianzmatrix wird die **Einheitsmatrix** genutzt, dies ist genau dann der Fall, wenn die einzelnen Komponenten die Vektoren **unkorreliert** sind und jeweils **Varianz 1** besitzen.


# Mahalanobis-Distanz

Das heißt, dass die Mahalanobis Distanz wie die euklidische Distanz funktioniert, wobei die **Streuung der Daten herausgerechnet** und somit die **Verteilung** der Datenpunkte quasi **normalisiert/standardisiert wird** (durch die Multiplikation mit der inversen Kovarianzmatrix).

$$d_C(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T C^{-1} (\vec{x} - \vec{y})}$$

**Die Mahalanobis Distanz führt 3 geometrische Operationen durch:**


1. Verschiebung um  $\mu$
2. Drehung der Daten (siehe PCA) – Kovarianzmatrix kann man in eine Rotationsmatrix (Eigenvektoren) und eine Diagonalmatrix mit Varianzen zerlegen
3. Skalierung/Streckung durch Inverse der Kovarianzmatrix



# Vorteile und Interpretation der Mahalanobis Distanz

## Interpretation der Mahalanobis Distanz:

- Die Mahalanobis-Distanz ist ein statistisches Abstandsmaß, das die **Korrelationen** zwischen Variablen bzw. unterschiedliche Varianzen von Variablen in einem **mehrdimensionalen Raum** berücksichtigt.
- Sie wird verwendet, um den **standardisierten Abstand zwischen zwei Vektoren** oder einem Vektor und einem Datensatz (misst, wie weit ein Vektor von der „Mitte“ (dem Mittelwert) des Datensatzes entfernt ist) zu bestimmen. Die Mahalanobis Distanz ist skaleninvariant.
- Diese **Metrik** berücksichtigt nicht nur die Einzelwerte der Merkmale, sondern auch deren **Wechselwirkungen**, wie sie von der **Kovarianzmatrix** erfasst werden.
- Wenn die Distanz klein ist heißt das, dass der Datenpunkt der durchschnittlichen Verteilung der Daten sehr ähnlich ist
- Wenn die Distanz groß ist, heißt das, dass die **Abweichung zum Mittelwert der Daten groß** ist



# Vorteile und Einsatzgebiete für die Mahalanobis Distanz

Die Mahalanobis-Distanz bietet sich an, wenn:

- Merkmale **mit unterschiedlichen Skalenniveaus** vorliegen - die Variablen müssen also nicht auf die gleiche Skala normalisiert werden (weil eine Standardisierung in der Mahalanobisdistanz durchgeführt wurde)
- die **Merkmale stark korreliert** sind (andere Distanzmaße berücksichtigen die Korrelation nicht, sondern nehmen an dass die Variablen unkorreliert sind)

## Anwendungsbeispiele:

- Als Distanzmaß für **Anomalieerkennung** - Punkte mit hoher Mahalanobis-Distanz zum Datenmittelwert gelten als **Ausreißer**
- Distanzmaß für Clustering - Gruppierung von Datenpunkten unter Berücksichtigung der Verteilung
- Klassifikation mit Linearer Diskriminanz Analyse (Fishers LDA) nutzt Mahalanobis Distanz

# Nachteile der Mahalanobis Distanz

## **Anfälligkeit bei hoher Dimensionalität**

In hochdimensionalen Daten (wenn die Anzahl der Variablen nahe oder größer als die Anzahl der Beobachtungen ist) kann die Kovarianzmatrix singulär (nicht invertierbar) oder nahezu singulär sein, was die Berechnung unmöglich macht oder zu numerischen Problemen führt.

## **Voraussetzung der Normalverteilung**

Die Mahalanobis-Distanz basiert auf der Annahme, dass die Daten multivariat normalverteilt sind. Bei stark nicht-normalverteilten Daten kann das Ergebnis verzerrt oder weniger aussagekräftig sein.

## **Rechenaufwand**

Die Berechnung der Inversen der Kovarianzmatrix kann bei sehr großen Datensätzen oder sehr vielen Variablen rechenintensiv sein.

## **Interpretationsschwierigkeiten**


Im Gegensatz zur euklidischen Distanz ist die Mahalanobis-Distanz weniger intuitiv zu verstehen, da sie die Datenverteilung und Korrelationen mit einbezieht.

# Vergleich Euklidische Distanz und Mahalanobis Distanz



## Nachteile Euklidische Distanz

- **Skalierung und Korrelation** der Variablen **nicht berücksichtigt**
- Distanzen werden durch Ausreißer oder schiefe Verteilungen **verzerrt**
- Es wird auch davon ausgegangen, dass die **Variablen unabhängig** sind und die gleiche Bedeutung haben, was in einigen Fällen möglicherweise nicht zutrifft.

- Euklidische Distanz:



- Mahalanobis Distanz:



# Vergleich Euklidische Distanz und Mahalanobis Distanz

## Beispiel:

Punkt A=(3,3)

Punkt B=(3,-3)


A und B haben die gleiche euklidische Distanz zum Mittelwert: 4.24

Aber ihre Mahalanobis-Distanzen zum Mittelwert sind sehr verschieden: A = 1.58, B = 4.74

## Warum?

A liegt entlang der langen Achse der Punktwolke. Dort ist viel natürliche Streuung, also ist der Punkt trotz gleicher Entfernung relativ normal.

B liegt quer zur Wolke. Dort gibt es wenig Streuung, also ist der Punkt viel ungewöhnlicher.




# Vergleich Euklidische Distanz und Mahalanobis Distanz

Die Euklidische Distanz behandelt alle Richtungen gleich.

Die Mahalanobis Distanz passt sich an Form, Streckung und Neigung der Daten an.

**Euklidische Distanz** beantwortet die Frage: „Wie weit weg?“

**Mahalanobis Distanz:** „Wie ungewöhnlich relativ zur Datenform?“



# Mahalanobis Distanz – Norm

Die **Mahalanobis-Distanz** ist eine *Norm* wenn die Kovarianzmatrix positivdefinit ist (invertierbar) und ist eine **Metrik**.


Die Einheitsellipse einer Norm  $\|\cdot\|$   $\|x\|_{\Sigma^{-1}} := \sqrt{x^T \Sigma^{-1} x}$  ist die Menge aller Punkte mit Mahalanobis Abstand genau 1 vom Ursprung:

Die Mahalanobisdistanz misst den Abstand relativ zur Form der Daten. Punkte mit gleichem Mahalanobis-Abstand liegen in 2D auf Ellipsen, weil die Kovarianzmatrix Streuung und Korrelation berücksichtigt. Richtungen mit **hoher Varianz zählen weniger**, Richtungen mit **geringer Varianz zählen mehr**.

Deshalb kann ein Punkt auf der langen Seite weiter weg liegen und trotzdem denselben Mahalanobisdistanz haben wie ein näherer Punkt auf der kurzen Seite.

$$D_M(x, y) = \|x - y\|_{\Sigma^{-1}} = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

**Mahalanobis-Distanz: Punkte mit gleichem Abstand bilden Ellipsen**



# Metrik

Distanzfunktionen wie die Minkowski-Distanz haben folgende **Eigenschaften**:

**1. Positive Definitheit**

$$d(\vec{x}, \vec{y}) \geq 0 \text{ für alle } \vec{x} \text{ und } \vec{y}$$

$$d(\vec{x}, \vec{y}) = 0 \text{ genau dann wenn } \vec{x} = \vec{y}$$

**2. Symmetrie**

$$d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x}) \text{ für alle } \vec{x} \text{ und } \vec{y}$$

**3. Dreiecksungleichung**

$$d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}) \text{ für alle } \vec{x}, \vec{y} \text{ und } \vec{z}$$

## Weitere Distanzmaße



# Mengendifferenz

Viele Distanzmaße erfüllen nicht alle drei Eigenschaften einer Metrik (in der Regel ist die Dreiecksungleichung verletzt, manchmal auch die Symmetrie):

**Mengendifferenz:** Für zwei diskrete Mengen  $A$  und  $B$  bezeichne  $A-B$  die Menge aller Elemente von  $A$ , ohne die Elemente von  $B$ .

Beispiel:

$$A = \{1,2,3,4\}$$

$$B = \{1,2,3\}$$

$$A - B =$$

$$B - A =$$

# Mengendifferenz

Viele Distanzmaße erfüllen nicht alle drei Eigenschaften einer Metrik (in der Regel ist die Dreiecksungleichung verletzt, manchmal auch die Symmetrie):

**Mengendifferenz:** Für zwei diskrete Mengen  $A$  und  $B$  bezeichne  $A-B$  die Menge aller Elemente von  $A$ , ohne die Elemente von  $B$ .

Beispiel:

$$A = \{1,2,3,4\}$$

$$B = \{1,2,3\}$$

$$A - B = \{4\}$$

$$B - A = \emptyset$$

Offensichtlich ist die Mengendifferenz keine Metrik, wohl aber

$$d(A, B) = |A - B| + |B - A|$$

# Zeitdifferenzen

Hier noch **Zeitdifferenzen** als Beispiel einer **nicht symmetrischen Distanz**:

Definiere

$$d(t_1, t_2) = \begin{cases} t_2 - t_1 & \text{falls } t_1 \leq t_2 \\ 24 + t_2 - t_1 & \text{sonst} \end{cases}$$

Dann ist z.B.

$$d(13:00, 14:00) = 1 \text{ Stunde}$$

$$d(14:00, 13:00) = 23 \text{ Stunden}$$

# Euklidischen Distanz auf Zeitreihen


- Angenommen wir haben 2 Zeitreihen Q und C
- Die Euklidische Distanz berechnet für jeden Zeitpunkt den quadrierten Abstand der Werte in Q und C. Diese Abstände werden aufsummiert, daraus wird dann die Wurzel gezogen.

$$ED(Q, C) \equiv \sqrt{\sum_{i=1}^n (q_i - c_i)^2}$$

- Voraussetzung: **Q und C sind gleich lang**

$$Q = q_1, q_2, \dots, q_i, \dots, q_n$$

$$C = c_1, c_2, \dots, c_i, \dots, c_n$$






Quelle: Batista et al. (2013). CID: An efficient complexity-invariant distance for time series.

# Nachteile der Euklidischen Distanz

## Verzerrungen:

- **Offset Verzerrung:** Wenn wir versuchen, zwei Zeitreihen zu vergleichen, die auf **unterschiedlichen Skalen gemessen wurden**, z. B. Celsius und Fahrenheit, werden sie nicht gut übereinstimmen, selbst wenn sie ähnliche Muster haben. Um die tatsächliche zugrundeliegende Ähnlichkeit zu messen, müssen wir die Werte normalisieren (Scaling)
- **Verschiebung:** Manche Zeitreihen haben das gleiche Muster, sind aber über die Zeit verschoben
- Wenn Teile der Zeitreihen gleich sind die Zeitreihen aber **unterschiedlich lang** sind, ist die Euklidische Distanz nicht geeignet





# Dynamic Time Warping

Bisher sind wir davon ausgegangen, dass alle Objekte durch einen Vektor derselben Dimension  $d$  repräsentiert wird.

**Was jedoch, wenn das nicht der Fall ist?**

**Beispiel:** Wie groß ist der Abstand von Zeitreihen, wie z.B. bei (digitalen Aufnahmen) gesprochener Sprache?




# Distanz von Gesten zueinander

Jede aufgezeichnete Geste besteht aus einer Sequenz von 3D-Koordinaten.

Da Gesten **unterschiedlich schnell durchgeführt** werden, sind die Sequenzen unterschiedlich lang:



Letztlich stehen wir hier vor einem **Korrespondenzproblem**...



Gegeben:


- Sequenz von 3D Handpunkten
- 5 unterschiedliche Gesten (Swipe, Push, L,O,Z)

Gesucht:

Ausgeführte Geste

# Distanz von Gehsequenzen zueinander

Zwei Wiederholungen einer Gehsequenz, aufgenommen mit einem Motion-Capture-System. Während es Unterschiede in der **Gehgeschwindigkeit** zwischen den Wiederholungen gibt, bleiben die räumlichen Pfade der Gliedmaßen sehr ähnlich





# Distanz von geschriebenen Zeichen

## Beispiel Schrifterkennung auf Tablets:

Jedes (geschriebene) Zeichen besteht aus einer Sequenz von 2D-Koordinaten.

Die Sequenzen sind aber nicht gleich lang:




$$d(\text{rote Sequenz, blaue Sequenz}) = ?$$

# Distanz von geschriebenen Zeichen

## Beispiel Schrifterkennung auf Tablets:

Welche Punkte in rot und blau kann man einander zuordnen um eine optimale Übereinstimmung der Sequenzen zu erhalten?



# Dynamic Time Warping

DTW sucht eine **optimale Übereinstimmung** zwischen zwei gegebenen Sequenzen (z. B. Zeitreihen) mit bestimmten Einschränkungen und Regeln berechnet.

Gegeben seien zwei (ggf. unterschiedlich lange) Sequenzen


$$\vec{s} = (s_1, s_2, s_3, \dots, s_n) \text{ und } \vec{t} = (t_1, t_2, t_3, \dots, t_m)$$

sowie ein **lokales Maß**

$$d'(s_i, t_j), i = 1, \dots, n, j = 1, \dots, m$$

auf den Elementen der Sequenz.


Im Beispiel Gestenerkennung könnte  $d'$  z.B. die euklidische Distanz auf den (normalisierten) 3D-Koordinaten sein:




# Dynamic Time Warping

## Dynamic Time Warping (DTW) - Dynamische Zeitnormierung

- Nutzt eine verzogene („Gewarped“) Zeitachse
- Kann auch bei **unterschiedlich langen** oder **verschieden skalierten** Zeitreihen genutzt werden
- Ist gegenüber **Zeitverschiebungen** robust
- Durch Verwendung von Dynamic Time Warping (DTW) werden **Muster gestaucht/gestreckt** und so optimal aufeinander angepasst
- Berechnet das **optimale Alignment (Übereinstimmung/Zuordnung)** von zwei Zeitreihen



Euclidean Matching




Dynamic Time Warping Matching

Quelle: [databricks](https://databricks.com)

# Dynamic Time Warping

## Dynamic Time Warping (DTW) Algorithmus

- Gegeben seien zwei Zeitreihen,  $X$  und  $Y$ , mit den Längen  $n$  und  $m$ .
- Erstelle eine  $n \times m$  Matrix  $D$ , in der jeder Eintrag  $D[i, j]$  die Kosten (Distanz) für die Ausrichtung der Teilsequenz  $X[1:i]$  mit  $Y[1:j]$  repräsentiert.  
Die Kosten können beispielsweise der euklidischen oder Cityblock-Distanz zwischen den Elementen der Sequenzen entsprechen.
- Berechne die Kosten für die Zeitreihen, indem du die **lokalen Kosten** (Distanz) für die Teilsequenzen betrachtest und die Kosten **des besten Vorgängers** (mit minimale Distanz) addierst. Das bedeutet, dass du die Kosten (Distanz) von  $D[i-1, j]$ ,  $D[i, j-1]$  und  $D[i-1, j-1]$  vergleichst und das Minimum auswählst.
- Finde den Pfad mit **den niedrigsten Gesamtkosten** von  $D[1,1]$  nach  $D[n, m]$ . Dieser Pfad repräsentiert das optimale Alignement (Übereinstimmung) der Zeitreihen.
- Die **Distanz der beiden Zeitreihen** kann als die **Gesamtkosten des Pfades** betrachtet werden.



Quelle: [databricks](https://databricks.com)

# Matrix der lokalen Kosten

## Lokale Kosten

|          |          |           |           |         |  |  |           |
|----------|----------|-----------|-----------|---------|--|--|-----------|
| $t_m$    |          | $d'_{1m}$ | $d'_{2m}$ | $\dots$ |  |  | $d'_{nm}$ |
|          |          |           |           |         |  |  |           |
| $\vdots$ | $\vdots$ | $\vdots$  |           |         |  |  | $\vdots$  |
| $t_2$    |          | $d'_{12}$ | $d'_{22}$ | $\dots$ |  |  | $d'_{n2}$ |
| $t_1$    |          | $d'_{11}$ | $d'_{21}$ | $\dots$ |  |  | $d'_{n1}$ |
|          |          |           |           |         |  |  |           |
|          | $s_1$    | $s_2$     | $\dots$   |         |  |  | $s_n$     |

$$d'_{ij} := d'(s_i, t_j)$$

Dann wird jeder Pfad  $\phi$  von links unten nach rechts oben durch die Matrix mit seinen Kosten assoziiert:

$$d(\phi) = \sum_{ij \in \phi} d'(s_i, t_j)$$

Gesucht ist der **Pfad mit den minimalen** Kosten (Optimierungsproblem)

$$\hat{\phi} = \operatorname{argmin}_{\phi} d(\phi)$$

## Randbedingungen

- Anfang und Ende der beiden Zeitreihen müssen jeweils aufeinander gematcht werden, Anfang und Ende des Pfades sind Anfang und Ende der Zeitreihen
- **Monotonie** - monoton ansteigende Indizes in i und j; alle Indizes sollten mindestens einmal vorkommen
- Schrittweitenbedingung (0,1), (1,0), (1,1)

# Matrix der kumulierten Kosten

## Kumulierte Kosten

|          |          |          |          |         |  |  |          |
|----------|----------|----------|----------|---------|--|--|----------|
| $t_m$    | $\infty$ | $d_{1m}$ | $d_{2m}$ | $\dots$ |  |  | $d_{nm}$ |
|          |          |          |          |         |  |  |          |
| $\vdots$ | $\vdots$ | $\vdots$ |          |         |  |  | $\vdots$ |
| $t_2$    | $\infty$ | $d_{12}$ | $d_{22}$ | $\dots$ |  |  | $d_{n2}$ |
| $t_1$    | $\infty$ | $d_{11}$ | $d_{21}$ | $\dots$ |  |  | $d_{n1}$ |
|          | 0        | $\infty$ | $\infty$ |         |  |  | $\infty$ |
|          |          | $s_1$    | $s_2$    | $\dots$ |  |  | $s_n$    |

Es kann eine genaue Lösung für dieses Optimierungsproblem mit Hilfe der **dynamischen Programmierung** gefunden werden.

Die Matrix der kumulierten Kosten

$$d_{ij} = d'_{ij} + \min\{d_{i-1j}, d_{ij-1}, d_{i-1j-1}\}$$

liefert den Pfad **minimaler globaler Kosten** und insb. ist

$$d(\vec{s}, \vec{t}) = d_{nm}$$

# Dynamic Time Warping - Python Code

```
int DTWDistance(s: array [1..n], t: array [1..m]) {
    DTW := array [0..n, 0..m]

    for i := 1 to n
        for j := 1 to m
            DTW[i, j] := infinity
    DTW[0, 0] := 0

    for i := 1 to n
        for j := 1 to m
            cost := d(s[i], t[j])
            DTW[i, j] := cost + minimum(DTW[i-1, j ],
                                         DTW[i , j-1],
                                         DTW[i-1, j-1])

    return DTW[n, m]
}
```

# Dynamic Time Warping - Beispiel

Gegeben seien die beiden  $2d$ -Sequenzen

$$\vec{s} = ((0,0), (1,0), (1,4), (2,5)) \text{ und } \vec{t} = ((1,0), (3,0), (1,3))$$

und die City-Block-Distanz als lokales Maß.

|       | Lokale Kosten |       |       |       |  |
|-------|---------------|-------|-------|-------|--|
| $t_3$ |               |       |       |       |  |
| $t_2$ |               |       |       |       |  |
| $t_1$ |               |       |       |       |  |
|       | $s_1$         | $s_2$ | $s_3$ | $s_4$ |  |

Kumulierte Kosten

# Dynamic Time Warping - Beispiel

Gegeben seien die beiden  $2d$ -Sequenzen

$$\vec{s} = ((0,0), (1,0), (1,4), (2,5)) \text{ und } \vec{t} = ((1,0), (3,0), (1,3))$$

und die City-Block-Distanz als lokales Maß.

Lokale Kosten

|       |  |       |       |       |       |
|-------|--|-------|-------|-------|-------|
| $t_3$ |  | 4     | 3     | 1     | 3     |
| $t_2$ |  | 3     | 2     | 6     | 6     |
| $t_1$ |  | 1     | 0     | 4     | 6     |
|       |  |       |       |       |       |
|       |  | $s_1$ | $s_2$ | $s_3$ | $s_4$ |

Kumulierte Kosten

|       |          |          |          |          |          |
|-------|----------|----------|----------|----------|----------|
| $t_3$ | $\infty$ | 8        | 6        | 4        | 7        |
| $t_2$ | $\infty$ | 4        | 3        | 7        | 11       |
| $t_1$ | $\infty$ | 1        | 1        | 5        | 11       |
|       | 0        | $\infty$ | $\infty$ | $\infty$ | $\infty$ |
|       |          | $s_1$    | $s_2$    | $s_3$    | $s_4$    |

$$\vec{s} = ((0,0), (1,0), (1,4), (2,5))$$

$$\vec{t} = ((1,0), (3,0), (1,3))$$

# Dynamic Time Warping – Vor- und Nachteile

## Vorteile:



- Sequenzen unterschiedlicher Länge können verglichen werden
- Sequenzen mit zeitversetzten Mustern werden berücksichtigt
- Unterschiedliche Geschwindigkeiten (z.B. bei Aktivitäten) werden unterstützt

## Nachteile:

- DTW ist nicht skaleninvariant
- Besonders bei langen Sequenzen kann DTW sehr rechenintensiv sein (typisch  $O(n \times m)$  für Sequenzen der Länge  $n$  und  $m$ ).

# Anwendung von Distanzen in Zeitreihen

- Ähnliche Zeitreihen finden → **Matching / Suche**
- Sub-Sequence Matching
- Zeitreihen nach Ähnlichkeit sortieren
- Clustering von Zeitreihen



Quelle: Batista et al. (2013). CID: An efficient complexity-invariant distance for time series.

# Ähnlichkeiten

Anstelle von Distanzmaßen werden mitunter auch **Ähnlichkeitsmaße** verwendet. Ein Ähnlichkeitsmaß für Vektoren im  $\mathbb{R}^d$  ist gegeben, wenn für alle  $\vec{x}, \vec{y} \in \mathbb{R}^d$  gilt:

1.  $s$  ist eine Abbildung in das Intervall  $[0,1]$
2. Definitheit:  $s(\vec{x}, \vec{y}) = 1$  genau dann wenn  $\vec{x} = \vec{y}$
3. Symmetrie:  $s(\vec{x}, \vec{y}) = s(\vec{y}, \vec{x})$  für alle  $\vec{x}$  und  $\vec{y}$

**Bemerkung:**

Der Begriff  
„Ähnlichkeit“ ist  
nicht einheitlich  
definiert!

**Bemerkung:** Im Gegensatz zu Ähnlichkeiten messen **Metriken Unähnlichkeiten**

# Ähnlichkeiten binärer Vektoren

Ähnlichkeitsmaße zwischen Objekten, die nur **binäre Merkmale** haben, heißen **Ähnlichkeitskoeffizienten**.

Entsprechend der Definition von Ähnlichkeiten indiziert ein Wert von 1 Übereinstimmung der Objekte und ein Wert von 0 indiziert, dass zwei Objekte maximal unähnlich sind.

$f_{00}$  = Anzahl der Merkmale, mit  $x=0$  und  $y=0$ .

$f_{01}$  = Anzahl der Merkmale, mit  $x=0$  und  $y=1$ .


$f_{10}$  = Anzahl der Merkmale, mit  $x=1$  und  $y=0$ .

$f_{11}$  = Anzahl der Merkmale, mit  $x=1$  und  $y=1$ .

Daraus lässt sich beispielsweise der **SMC (Simple Matching Coefficient)** ableiten:

$$\text{SMC}(\vec{x}, \vec{y}) = \frac{f_{11} + f_{00}}{f_{11} + f_{00} + f_{10} + f_{01}}$$

# Distanz- und Ähnlichkeitsmaße



# Ähnlichkeiten binärer Vektoren

Für **dünn besetzte Daten** (viele Merkmale = Null) wäre der SimpleMatchingCoefficient immer sehr ähnlich. Dieser Tatsache trägt der **JSC (Jaccard Similarity Coefficient)** Rechnung:

$$\text{JSC}(\vec{x}, \vec{y}) = \frac{f_{11}}{f_{11} + f_{10} + f_{01}}$$

Beispiel:

$$\begin{aligned}\vec{x} &= (1, 0, 0, 0, 0, 0, 0, 0, 0, 0)^T \\ \vec{y} &= (0, 0, 0, 0, 0, 0, 0, 1, 0, 1)^T\end{aligned}$$

$$\text{SMC}(\vec{x}, \vec{y}) = \frac{f_{11} + f_{00}}{f_{11} + f_{00} + f_{10} + f_{01}} = \frac{0 + 7}{2 + 1 + 0 + 7} = 0.7$$

$$\text{JSC}(\vec{x}, \vec{y}) = \frac{f_{11}}{f_{11} + f_{10} + f_{01}} = \frac{0}{2 + 1 + 0} = 0$$

# Ähnlichkeitsmaße für Dokumente

Auch Dokumente liefern i.d.R. sehr dünn besetzte Merkmalsvektoren:

|            | Wirtschaft | Industrie | Handwerk | Angestellte | Löhne |       |
|------------|------------|-----------|----------|-------------|-------|-------|
| Dokument 1 | 1          | 3         | 2        | 0           | 0     | ← BOW |
| Dokument 2 | 0          | 2         | 1        | 3           | 0     |       |
| Dokument 3 | 2          | 0         | 0        | 1           | 1     |       |

Daher wird auch für Dokumente ein Ähnlichkeitsmaß eingesetzt, das dieser Tatsache Rechnung trägt, aber nicht auf binäre Daten eingeschränkt ist.

# Ähnlichkeitsmaße für Dokumente


Die **Kosinus-Ähnlichkeit** ist für zwei Vektoren  $\vec{x}, \vec{y} \in \mathbb{R}^d$  gegeben durch

- **Bemerkung:** Es ist  $d_{cos}(\vec{x}, \vec{y}) = \cos(\alpha)$  wobei  $\alpha$  der Winkel zwischen den beiden Vektoren ist.
- Die **Kosinus-Ähnlichkeit ist gleich 1**, wenn der **Winkel 0** ist, auch wenn die Länge der Vektoren unterschiedlich ist. Die Kosinus Ähnlichkeit ist gleich **0** wenn der **Winkel 90 Grad** ist (orthogonale Vektoren) und **-1** wenn die Vektoren in die entgegengesetzte Richtung weisen (**180 Grad**).


$$d_{cos}(\vec{x}, \vec{y}) = \frac{\langle \vec{x}, \vec{y} \rangle}{\|\vec{x}\| \|\vec{y}\|} = \left\langle \frac{\vec{x}}{\|\vec{x}\|}, \frac{\vec{y}}{\|\vec{y}\|} \right\rangle \in [-1, 1]$$

# Ähnlichkeitsmaße für Dokumente

- **Beispiel:**



cosine similarity is 0.94  
this corresponds to angle of 20°



cosine similarity is 0.47  
this corresponds to angle of 61°

- Die Kosinus-Ähnlichkeit ist groß oder nahe 1 für zwei Vektoren, die in eine ähnliche Richtung zeigen, was auf semantische Ähnlichkeit hinweist.
- Die Kosinus Ähnlichkeit ist bei zwei Vektoren, die in sehr unterschiedliche Richtungen zeigen, gering. Bei Vektoren, die in entgegengesetzte Richtungen zeigen, wäre sie negativ.

# Ähnlichkeitsmaße für Dokumente

Die **Kosinus-Ähnlichkeit** ist für zwei Vektoren  $\vec{x}, \vec{y} \in \mathbb{R}^d$  gegeben durch

$$d_{cos}(\vec{x}, \vec{y}) = \frac{\langle \vec{x}, \vec{y} \rangle}{\|\vec{x}\| \|\vec{y}\|} = \left\langle \frac{\vec{x}}{\|\vec{x}\|}, \frac{\vec{y}}{\|\vec{y}\|} \right\rangle \in [-1, 1]$$

- **Bemerkung:** Es ist  $d_{cos}(\vec{x}, \vec{y}) = \cos(\alpha)$  wobei  $\alpha$  der Winkel zwischen den beiden Vektoren ist.
  - Die **Kosinus-Ähnlichkeit ist gleich Eins**, wenn der **Winkel Null** ist, auch wenn die Länge der Vektoren unterschiedlich ist.
  - Insbesondere ist die Kosinus-Ähnlichkeit kein Ähnlichkeitsmaß im Sinn der vorangegangenen Definition.
- ➔ **Wie könnte man die Kosinus-Ähnlichkeit anpassen, sodass die Regeln erfüllt werden?**

# Welches Distanzmaß soll ich nutzen?

Q1: Zeitliche Sequenzen unterschiedlicher Länge?

└ Ja → DTW

└ Nein → Q2

Q2: Binäre Daten?

└ Ja → Hamming oder Jaccard (je nach Sparsity)

└ Nein → Q3

Q3: Hochdimensional & dünn besetzt?

└ Ja → Cosinus-Ähnlichkeit

└ Nein → Q4


Q4: Variablen stark korreliert?

└ Ja → Mahalanobis

└ Nein → Euklidisch (oder Minkowski je nach Vorliebe)



# Zusammenfassung Distanz- & Ähnlichkeitsmaße

- Distanzmaße/-metriken messen **Unähnlichkeiten**, **Ähnlichkeitsmaße** messen Ähnlichkeit zwischen Vektoren
- Distanz- und Ähnlichkeitsmaße werden in ML&DS sehr breit eingesetzt: Clustering, distanz-basierte Klassifikation (z.B. K-NN), Anomalie-Erkennung, in der Feature Extraktion, Suche & Matching
- Die allgemeine **Minkowski Distanz** ist eine **Metrik**, viele Distanzmaße können davon abgeleitet werden ( $r=1 \rightarrow$  Cityblock Distanz,  $r=2 \rightarrow$  euklidische Distanz,  $r=\infty \rightarrow$  Chebyshev ...)
- Die **Mahalanobis Distanz** ist ein multidimensionales Distanzmaß, die Zusammenhänge in den Daten berücksichtigt und gut für **unterschiedlich skalierte und stark korrelierte Daten** geeignet ist
- Die Mahalanobis Distanz arbeitet, wie die euklidische Distanz, wobei die **Streuung der Daten herausgerechnet** und somit die **Verteilung** der Datenpunkte **normalisiert/standardisiert wird** (durch die Multiplikation mit der inversen Kovarianzmatrix).




# Zusammenfassung Distanz- & Ähnlichkeitsmaße

- **Dynamic Time Warping - DTW** ist ein Distanzmaß (keine Metrik) das invariant gegenüber Verschiebungen in Sequenzen (Zeitreihen) ist und das auf Sequenzen unterschiedlicher Länge berechnet werden kann.
- Die DTW-Distanz wird über das Finden des optimalen Alignments (Übereinstimmung/Zuordnung) der Datenpunkte einer Zeitreihe berechnet.
- Die Gesamtkosten (kumulierten Kosten) aller Alignments des **optimalen Pfades in der Kostenmatrix** ergeben die Distanz zwischen 2 Sequenzen.



# Zusammenfassung Ähnlichkeitsmaße

- **Ähnlichkeitskoeffizienten** sind **Ähnlichkeitsmaße** für **binäre Vektoren** zum Beispiel **SMC (Simple Matching Coefficient)**. Für dünnbesetzte Daten ist der **JSC (Jaccard Similarity Coefficient)** besser geeignet.
- Für **nicht-binäre Vektoren** wird häufig die **Kosinus Ähnlichkeit** (cosine similarity) verwendet, dabei wird der Kosinus des Winkels der beiden betroffenen Vektoren bestimmt, bez. das **normierte Skalarprodukt** berechnet



# Links

## Mahalabnobis Distanz:

- [Mahalanobis Distance - Understanding the math with examples \(python\)](#)
- [Buch - Pattern Recognition \(Bishop\)](#) - S.80

## DTW:

- [An introduction to Dynamic Time Warping](#)

## Mathematische Grundlagen:

- [Mathematics for Machine Learning](#)
  - Kapitel 2 insbesondere Matrizen, S.22-26
  - Kapitel 3 insbesondere - Norm, Skalarprodukt, Metrik/Distanzen, Kosinus Ähnlichkeit, S. 70-77