

Klausuraufgaben zur Prüfung Maschinelles Lernen

Bearbeitungszeit: 60 Minuten

Erlaubte Hilfsmittel: Keine.

Aufgabe	1	2	3	4	5	Σ
Punkte	8	6	10	10	16	50
erreichte Punkte						

Viel Erfolg!

Name: _____ Matrikelnummer: _____

Aufgabe 1 (1+3+2+2=8 Punkte) Zum Aufwärmen.

a) Welche Rolle spielt Data Mining im KDD-Prozess?

~~Data Mining entspricht der Mustererkennung.~~

b) Welche Besonderheiten zeichnen Data Mining gegenüber der klassischen Mustererkennung aus?

~~Data Mining ist die Analyse von großen Datenbeständen nach neuem und nützlichen (ggf. wettbewerbsrelevantem) Wissen.~~

c) Sie sollen einen Datenbestand mit einer Dimension von 100.000 (z.B. bestehend aus „bag of words“) mit einem distanzbasierten Ansatz clustern. Mit welcher Schwierigkeit rechnen Sie? Wie heißt dieses Phänomen?

~~Der Merkmalsraum wird sehr dünn besetzt sein. Stichwort „Fluch der Dimension“.~~

d) Welche der folgenden Methoden ordnet man dem überwachten Lernen (ÜL) zu, welche dem unüberwachten (UÜL)?

1) Künstliche Neuronale Netze: ÜL

2) K-Means: UÜL

3) Support Vektor Maschine: ÜL

4) ~~Recommender Engine durch Faktorisierung einer User-Item-Matrix $R = PQ^T$: ÜL~~

Aufgabe 2 (2+4= 6 Punkte) Maße

a) Sie betrachten die Menge aller Einkäufe in einem Supermarkt. Jeder Einkauf ist durch einen Merkmalsvektor repräsentiert. Dabei entspricht jedes Merkmal einem Artikel des Sortiments und nimmt den Wert „1“ an, wenn der Artikel im jeweiligen Einkauf (mindestens einmal) gekauft wurde, und „0“ sonst. Welches der beiden folgenden Maße verwenden Sie, um die Ähnlichkeit von Einkäufen anhand der vorhandenen Merkmalsvektoren zu bemessen? Begründung.

$$\text{SMC}(\vec{x}, \vec{y}) = \frac{f_{11} + f_{00}}{f_{10} + f_{01} + f_{11} + f_{00}}$$

$$\text{JSC}(\vec{x}, \vec{y}) = \frac{f_{11}}{f_{10} + f_{01} + f_{11}}$$

Beide Maße sind für binäre Merkmalsvektoren geeignet. Der JSC insbesondere dann, wenn die Vektoren dünn besetzt sind, was im skizzierten Szenario der Fall sein wird. Also den JSC.

b) Berechnen Sie die Ähnlichkeit der beiden Einkäufe im Sinne des SMC und des JSC.

$$\vec{x} = (1\ 0\ 0\ 1\ 0\ 0\ 0\ 0\ 1)^T$$

$$\vec{y} = (0\ 0\ 0\ 1\ 0\ 1\ 1\ 0\ 0)^T$$

Es ist

$$\text{SMC}(\vec{x}, \vec{x}) = \frac{f_{11} + f_{00}}{f_{10} + f_{01} + f_{11} + f_{00}} = 6/10$$

$$\text{JSC}(\vec{x}, \vec{x}) = \frac{f_{11}}{f_{10} + f_{01} + f_{11}} = 1/5$$

Aufgabe 3 (4+2+4 = 10 Punkte) Transformationen

a) Berechnen Sie für die Merkmalsvektoren

$$\vec{g}_1 = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \vec{g}_2 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \vec{g}_3 = \begin{pmatrix} -1 \\ -2 \end{pmatrix}, \vec{g}_4 = \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \vec{g}_5 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

die Datenmatrix

$$G = (\Delta \vec{g}_1 \mid \Delta \vec{g}_2 \mid \Delta \vec{g}_3 \mid \Delta \vec{g}_4 \mid \Delta \vec{g}_5)$$

und die Kovarianzmatrix

$$C = \frac{1}{N-1} G G^T$$

Es ist

$$\vec{g}_{mean} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

also

$$G = \begin{pmatrix} 2 & -1 & -1 & 0 & 0 \\ 4 & 0 & -2 & -2 & 0 \end{pmatrix}$$

und

$$C = \frac{1}{4} \begin{pmatrix} 6 & 10 \\ 10 & 24 \end{pmatrix}$$

b) Beim sogenannten Kernel-Trick werden Methoden, mit denen lineare Probleme gelöst werden können, auf nichtlineare Probleme adaptiert. Erläutern Sie das Prinzip des Kernel-Tricks für die Hauptkomponenten-Analyse. Welche Rolle spielt dabei die Kovarianzmatrix?

Beim Kernel-Trick werden die Daten vor der linearen Verarbeitung mit einer nichtlinearen Transformation in einen ggf. höherdimensionalen Raum transformiert. Die Transformation wird aber de facto nicht durchgeführt, statt dessen wird das Skalarprodukt, das den linearen Charakter modelliert durch eine nichtlineare Funktion ersetzt, die dann beides auf einmal realisiert: erst nichtlineare Transformation, dann Skalarprodukt. Bei der PCA z.B. wird die Kovarianzmatrix ersetzt durch eine Matrix, deren Einträge durch die Kernelfunktion berechnet werden.


c) Bezeichne $\vec{x}_1 = (2, -1, -1, 0, 0)^T$ den (zentrierten) Vektor des ersten Merkmals aus obigem Beispiel und $\vec{x}_2 = (4, 0, -2, -2, 0)^T$ den des zweiten Merkmals sowie $k(\vec{x}_i, \vec{x}_j) = (\vec{x}_i^T \vec{x}_j + 1)^2$ eine polynomiale Kernelfunktion. Wie lautet die Matrix, die bei der entsprechenden Kernel-PCA diagonalisiert wird für das obige Beispiel? Summen, Brüche, Potenzen etc. können stehen bleiben.

$$\begin{pmatrix} k(\vec{x}_1, \vec{x}_1) & k(\vec{x}_1, \vec{x}_2) \\ k(\vec{x}_2, \vec{x}_1) & k(\vec{x}_2, \vec{x}_2) \end{pmatrix} = \begin{pmatrix} (6+1)^2 & (10+1)^2 \\ (10+1)^2 & (24+1)^2 \end{pmatrix}$$

Aufgabe 4 (4+2+2+2 = 10 Punkte) K-means.

Der eindimensionale Datenbestand

$$\vec{x}_1 = (-5) \quad \vec{x}_2 = (-4) \quad \vec{x}_3 = (-2) \quad \vec{x}_4 = (-1) \\ \vec{x}_5 = (3) \quad \vec{x}_6 = (4) \quad \vec{x}_7 = (6) \quad \vec{x}_8 = (7)$$




soll in Cluster eingeteilt werden.

a) Wenden Sie K-means für $K = 2$ mit den (eindimensionalen) initialen Zentren $\vec{z}_1 = (-3)$ und $\vec{z}_2 = (0)$ an bis zur Konvergenz. Hinweis: Lassen Sie „unrunde“ Brüche stehen, die verschwinden nämlich im Lauf der weiteren Iterationen von selbst.

Im ersten Schritt erfolgt die Zuordnung

$$C_1 = \{\vec{x}_1, \vec{x}_2, \vec{x}_3\} \text{ und } C_2 = \{\vec{x}_4, \vec{x}_5, \vec{x}_6, \vec{x}_7, \vec{x}_8\}$$




Die Zentren werden damit wie folgt aktualisiert

$$\vec{z}_1 = \frac{1}{3}(-5 - 4 - 2) = -\frac{11}{3} \text{ und } \vec{z}_2 = \frac{1}{5}(-1 + 3 + 4 + 6 + 7) = \frac{19}{5}$$

und damit ergeben sich die neuen Cluster durch

$$C_1 = \{\vec{x}_1, \vec{x}_2, \vec{x}_3, \vec{x}_4\} \text{ und } C_2 = \{\vec{x}_5, \vec{x}_6, \vec{x}_7, \vec{x}_8\}$$



Die Zentren werden damit wie folgt aktualisiert

$$\vec{z}_1 = \frac{1}{4}(-5 - 4 - 2 - 1) = -\frac{12}{4} = -3 \text{ und } \vec{z}_2 = \frac{1}{4}(3 + 4 + 6 + 7) = \frac{20}{4} = 5$$

und liegen damit beide im Schwerpunkt ihrer Cluster. Der Algorithmus terminiert an dieser Stelle.

b) Berechnen Sie für das Ergebnis aus der vorangegangenen Aufgabe den quadratischen Fehler

$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k)$$

für die City-Block-Distanz!!!!

Es ist

$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k) = 2(1^2 + 1^2 + 2^2 + 2^2) = 20$$

c) Wie groß ist der SSE im **günstigsten** Fall, wenn statt zwei vier Cluster berechnet werden also $K = 4$ ist?

Im günstigsten Fall liegen die Zentren immer genau zwischen zwei Objekten, damit ergibt sich der SSE von

$$SSE = \sum_{k=1}^4 \left(\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right) = 8 \left(\frac{1}{4} \right) = 2$$

d) Warum ist der SSE nicht geeignet, Ergebnisse mit verschiedenen Anzahlen von Clustern miteinander zu vergleichen? Welche Alternative gibt es?

Der SSE ist nicht invariant gegenüber verschiedenen Clusteranzahlen. Im Extremfall von K gleich Umfang Datenbestand kann er sogar null werden. Eine Alternative ist der Silhouettenkoeffizient.

Aufgabe 5 (2+4+2+4+4 = 16 Punkte) Graphbasiertes Clustern.


a) Welches Problem kann auftreten, wenn ein Graph durch Minimierung des sogenannten Cuts

$$\text{cut}(A, B) = \sum_{i \in A, j \in B} w_{ij}$$

geclustert wird?

Der Cut bevorzugt das Abtrennen von kleinen Clustern.

b) Gegeben sei der rechte Graph mit Knoten $V = \{v_1, \dots, v_3\}$ und den gewichteten Kanten wie in der Grafik dargestellt. Berechnen Sie den normalisierten Schnitt



$$\text{Ncut}(A, B) = \frac{\text{cut}(A, B)}{\text{assoc}(A, V)} + \frac{\text{cut}(A, B)}{\text{assoc}(B, V)}$$

mit

$$\text{cut}(A, B) = \sum_{v_i \in A, v_j \in B} w_{i,j} \quad \text{und} \quad \text{assoc}(A, V) = \sum_{v_i \in A, v_j \in V} w_{i,j}$$

für alle möglichen Partitionen mit nichtleeren Mengen. Brüche, Summen etc. können stehen bleiben.

$$1) \text{Ncut}(\{v_1\}, \{v_2, v_3\}) = \text{Ncut}(\{v_2\}, \{v_1, v_3\}) = \frac{0.1+0.2}{0.1+0.2} + \frac{0.1+0.2}{0.1+0.2+0.1} = 1 + \frac{3}{4}$$

$$2) \text{Ncut}(\{v_3\}, \{v_1, v_2\}) = \frac{0.1+0.1}{0.1+0.1} + \frac{0.1+0.1}{0.1+0.1+0.2} = 1 + \frac{1}{2}$$

c) Welche Partitionen werden auf Basis des Cuts und welche auf Basis des normalisierten Schnitts erzeugt?

Jeweils die gleichen Partitionen: $A = \{v_1, v_2\}$ und $B = \{v_3\}$


d) Für einen Graphen mit fünf Knoten $V = \{v_1, \dots, v_5\}$ soll der normalisierte Schnitt durch einen Eigenvektoransatz gelöst werden. Der entsprechende Indikatorvektor laute $\vec{x} = (-0.2, 0.2, 0.3, -0.3, 1.25)^T$. Welche Partitionen ergeben sich für den Schwellwert 0 und welche, wenn der Mittelwert aus den Einträgen des Indikatorvektors als Schwellwert heran gezogen wird?

Schwelle 0: $A = \{v_1, v_4\}$, $B = \{v_2, v_3, v_5\}$, Schwelle Mittelwert

0.25: $A = \{v_1, v_2, v_4\}$, $B = \{v_3, v_5\}$.

e) Gegeben sei folgendes Bild mit 3x3 Pixeln (indiziert mit $i = 0, \dots, 8$) und ganzzahligen Grauwerten $I(i)$, $i = 0, \dots, 8$.

1	2	1
2	3	1
2	4	5



Vervollständigen Sie den Graphen rechts um gewichtete Kanten, sodass dieser das Bild links repräsentiert, wobei:

- die Anordnung der Knoten denen der Pixel im Bild entsprechen soll (also Pixel links oben entspricht Knoten links oben etc.)

- die Gewichte $w_{i,j}$ gemäß folgender Vorschrift berechnet werden ($d_{\infty}(i,j)$ bezeichne die Chebychev-Distanz der Pixel i und j):

$$w_{i,j} = \begin{cases} e^{-|I(i)-I(j)|} & \text{für } d_{\infty}(i,j) \leq 1 \\ 0 & \text{sonst} \end{cases}$$

- der Graph ausgedünnt wird, indem Kanten mit einem Gewicht von weniger als 0.2 gelöscht werden.
- Beachten Sie: Es ist $e^0 = 1$, $e^{-1} \approx 0.37$, $e^{-2} \approx 0.14$.

Sie können Kanten mit unterschiedlichen Gewichten farblich kennzeichnen, oder die Gewichte an die Kanten dazuschreiben.

1	2	1
2	3	1
2	4	5

