

Klausuraufgaben zur Prüfung Maschinelles Lernen

Bearbeitungszeit: 60 Minuten

Erlaubte Hilfsmittel: Keine.

Aufgabe	1	2	3	4	Σ
Punkte	8	16	8	14	46
erreichte Punkte					

Viel Erfolg!

Name: _____ Matrikelnummer: _____

Aufgabe 1 (1+3+2+2=8 Punkte) Zum Aufwärmen.

~~a) Welche Rolle spielt Data Mining im KDD-Prozess?~~

~~Data Mining entspricht der Mustererkennung.~~

~~b) Welche Besonderheiten zeichnen Data Mining gegenüber der klassischen Mustererkennung aus?~~

~~Data Mining ist die Analyse von großen Datenbeständen nach neuem und nützlichen (ggf. wettbewerbsrelevantem) Wissen.~~

~~c) Nennen Sie einen wesentlichen Unterschied zwischen dem KDD-Prozessmodell und dem CRISP-DM.~~

~~KDD: sequentiell und CRISP-DM zyklisch~~

d) Welche der folgenden Anwendungen lässt sich durch eine Anomaliedetektion (AD) realisieren, welche durch eine Assoziationsanalyse (AA)?

- 1) Kreditkartenbetrug: AD
- 2) Cross- oder up-selling: AA
- 3) Detektion gefährlicher Situationen: AD
- 4) Empfehlungsmaschinen: AA

Aufgabe 2 (4+4+2+2+2+2 = 16 Punkte) Transformationen - PCA und SVM

a) Berechnen Sie für die Merkmalsvektoren

$$\vec{g}_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \vec{g}_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \vec{g}_3 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \vec{g}_4 = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

$$\vec{g}_5 = \begin{pmatrix} \frac{2}{\sqrt{2}} \\ 0 \end{pmatrix}, \vec{g}_6 = \begin{pmatrix} -\frac{2}{\sqrt{2}} \\ 0 \end{pmatrix}, \vec{g}_7 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \vec{g}_8 = \begin{pmatrix} 0 \\ -2 \end{pmatrix}$$

die Datenmatrix

$$G = (\Delta \vec{g}_1 \mid \Delta \vec{g}_2 \mid \Delta \vec{g}_3 \mid \Delta \vec{g}_4 \mid \Delta \vec{g}_5 \mid \Delta \vec{g}_6 \mid \Delta \vec{g}_7 \mid \Delta \vec{g}_8)$$

und die Kovarianzmatrix

$$C = \frac{1}{N-1} G G^T$$

Es ist

$$\vec{g}_{mean} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

also

$$G = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & 0 & \frac{2}{\sqrt{2}} & -\frac{2}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & 1 & -1 & 0 & 0 & 2 & -2 \end{pmatrix}$$

und

$$C = \frac{1}{7} \begin{pmatrix} 5 & 0 \\ 0 & 10 \end{pmatrix}$$

b) Stellen Sie das charakteristische Polynom auf und berechnen Sie die Eigenwerte.

Es ist

$$\begin{aligned} p(\lambda) &= \det(C - \lambda I) \\ &= \begin{vmatrix} \frac{5}{7} - \lambda & 0 \\ 0 & \frac{10}{7} - \lambda \end{vmatrix} \\ &= \left(\frac{5}{7} - \lambda\right)\left(\frac{10}{7} - \lambda\right) \end{aligned}$$

Die Eigenwerte betragen also $\lambda_1 = \frac{10}{7}$ und $\lambda_2 = \frac{5}{7}$.

c) Berechnen Sie die Matrix, die statt der Kovarianzmatrix diagonalisiert wird, wenn statt der linearen PCA eine Kernel-PCA mit dem polynomialen Kernel $k(\vec{x}_1, \vec{x}_2) = (\vec{x}_1^T \vec{x}_2 + 1)^2$ angewandt wird.

$$\begin{pmatrix} k(\vec{x}_1, \vec{x}_1) & k(\vec{x}_1, \vec{x}_2) \\ k(\vec{x}_2, \vec{x}_1) & k(\vec{x}_2, \vec{x}_2) \end{pmatrix} = \begin{pmatrix} 36 & 1 \\ 1 & 121 \end{pmatrix}$$

d) Bezeichnet $\vec{g} = (x_1, x_2)^T$ einen Datenvektor, so lautet die zu diesem Kernel gehörige Transformation $\Phi(\vec{g}) = (1, \sqrt{2}x_1, \sqrt{2}x_1x_2, \sqrt{2}x_2, x_1^2, x_2^2)^T$. Berechnen Sie $\Phi(\vec{g}_1)$.

$$\Phi(\vec{g}_1) = (1, 1, 0, 0, \frac{1}{2}, 0)^T$$

e) Warum ist es kein Problem, dass die Transformation in einen fünfdimensionalen Merkmalsraum abbildet, wo der ursprüngliche Merkmalsraum doch nur die Dimension zwei hatte und hohe Dimensionen grundsätzlich ein Problem sind?

Weil die Transformation gar nicht angewandt wird. Vielmehr wird die Kombination Transformation mit Skalarprodukt angewandt, also der Kernel selbst und der führt nicht in eine höhere Dimension.

f) Bei einer linearen Support-Vektor-Maschine lässt sich die Entscheidungsfunktion f schreiben als

$$f(\vec{g}) = -\alpha + \sum_{i=1}^N \alpha_n \vec{g}^T \vec{g}_i$$

Wie lautet die Entscheidungsfunktion, wenn stattdessen eine SVM mit dem oben genannten Kernel angewandt wird?

$$f(\vec{g}) = -\alpha + \sum_{i=1}^N \alpha_n k(\vec{g}, \vec{g}_i) == -\alpha + \sum_{i=1}^N \alpha_n (\vec{g}^T \vec{g}_i + 1)^2$$

Aufgabe 3 (2+4+2= 8 Punkte) Dynamic Time Warping

a) Die Berechnung der DTW ist kostenintensiv, lohnt sich also nur für Daten, für die andere Maße nicht oder nicht sinnvoll eingesetzt werden können. Für welche Form von Daten lässt sich DTW sinnvoll einsetzen?

Sequenzen von Daten, die nicht äquidistant abgetastet sind und unterschiedlich lang sind.

b) Dynamic Time Warping: Berechnen Sie für die Sequenzen

$$\vec{x}_1 = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \vec{x}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \vec{x}_3 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \vec{x}_4 = \begin{pmatrix} 4 \\ -2 \end{pmatrix}$$

und

$$\vec{y}_1 = \begin{pmatrix} -2 \\ 1 \end{pmatrix}, \vec{y}_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \vec{y}_3 = \begin{pmatrix} 3 \\ -2 \end{pmatrix}$$

die City-Block-Distanzen und tragen Sie diese in die linke Grafik ein. Verwenden Sie diese Distanzen als Grundlage für ein Dynamic Time Warping (rechte Grafik).

	7	7	3	1
	5	1	3	7
	1	3	5	9

∞	13	9	5	6
∞	6	2	5	12
∞	1	4	9	18
0	∞	∞	∞	∞

c) Wie groß sind die minimalen Kosten?

Die minimalen Kosten betragen 6.

Aufgabe 4 (2+2+2+2+4+2 = 14 Punkte) K-means und so.

Sie haben für **jeden** Studierenden der Hochschule Karlsruhe zu **jedem** angebotenen Modul die Information, ob das Modul erfolgreich abgelegt wurde oder nicht (z.B. 1 für Modul xyz erfolgreich abgelegt, 0 sonst).

a) Sie implementieren einen K-Means, um die Studierenden anhand dieser Information in Gruppen (Cluster) zu unterteilen. Welches Distanz- oder Ähnlichkeitsmaß verwenden Sie? Begründung.

Die Daten sind binär und asymmetrisch. Von daher bietet sich der JSC an.

b) Was spricht gegen die Verwendung des SSE, wenn es um die Frage geht, wie groß K im Idealfall zu wählen ist?

Der SSE ist nicht invariant gegenüber der Anzahl von Clustern

c) Welches Maß ist besser geeignet?

Der Silhouettenkoeffizient.

d) Mit Standard-Distanzmaßen (also z.B. Minkowski-Distanzen) liefern K-Means und C-Means sphärische Cluster. Für den C-Means wurde von Gustafson und Kessel eine Erweiterung für elliptische Cluster entwickelt, die für jedes Cluster ein eigenes Distanzmaß vorsieht. Das Maß für das k-te Cluster berechnet sich mit Hilfe der Matrix

$$S_k = \sum_{\vec{x} \in C_k} w_{k,\vec{x}}^p (\vec{x} - \vec{z}_k)(\vec{x} - \vec{z}_k)^T$$

durch

$$d_k(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T \sqrt{\det S_k} S_k^{-1} (\vec{x} - \vec{y})}$$

Dieser Ansatz soll nun auf den K-Means übertragen werden, sodass dieser auch elliptische Cluster unterstützt. Wie müsste die Matrix S_k für den K-Means sinnvoller Weise definiert werden?

$$S'_k = \sum_{\vec{x} \in C_k} (\vec{x} - \vec{z}_k)(\vec{x} - \vec{z}_k)^T$$

e) Berechnen Sie Ihre Variante der modifizierten Matrix S_k für ein Cluster k mit Zentrum

$$\vec{z}_k = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

das aus den Daten

$$\vec{x}_1 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \vec{x}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \vec{x}_3 = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \vec{x}_4 = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

besteht.

$$\begin{aligned} S'_k &= \sum_{\vec{x} \in C_k} (\vec{x} - \vec{z}_k)(\vec{x} - \vec{z}_k)^T \\ &= \begin{pmatrix} 2 \\ 0 \end{pmatrix} (2 \ 0) + \begin{pmatrix} 0 \\ 1 \end{pmatrix} (0 \ 1) + \begin{pmatrix} -2 \\ 0 \end{pmatrix} (-2 \ 0) + \begin{pmatrix} 0 \\ -1 \end{pmatrix} (0 \ -1) \\ &= \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \\ &= \begin{pmatrix} 8 & 0 \\ 0 & 2 \end{pmatrix} \end{aligned}$$

f) In welchem Zusammenhang steht dieses Vorgehen zur Mahalanobis-Distanz?

Vernachlässigen Sie bei Ihren Überlegungen die Skalierung $\sqrt{\det S_k}$.

S'_k ist gerade die mit $N-1$ multiplizierte Kovarianz-Matrix. Von daher unterscheidet sich d_k nur um eine Skalierung von der Mahalanobisdistanz.