

Klausuraufgaben zur Prüfung Maschinelles Lernen

Bearbeitungszeit: 60 Minuten

Erlaubte Hilfsmittel: Keine.

Aufgabe	1	2	3	4	Σ
Punkte	8	14	10	14	46
erreichte Punkte					

Viel Erfolg!

Name: _____ Matrikelnummer: _____

Aufgabe 1 (1+3+2+2=8 Punkte) Zum Aufwärmen.

~~a) Welche Rolle spielt Data Mining im KDD-Prozess?~~

~~Data Mining entspricht der Mustererkennung.~~

~~b) Welche Besonderheiten zeichnen Data Mining gegenüber der klassischen Mustererkennung aus?~~

~~Data Mining ist die Analyse von großen Datenbeständen nach neuem und nützlichen (ggf. wettbewerbsrelevantem) Wissen.~~

~~c) Erläutern Sie den Unterschied zwischen den Begriffen „schwache KI“ und „starke KI“.~~

~~Starke KI versteht sich als Nachbildung allgemeiner menschlicher Intelligenz, „schwache KI“ ist fokussiert auf begrenzte Bereiche (Stichwort Expertensysteme).~~

~~d) Welche der folgenden Anwendungen lässt sich der „schwachen KI“ zuordnen, welche der „starken KI“?~~

~~1) Schachcomputer: schwach~~

~~2) Humanoider Roboter als (universell einsetzbare) Haushaltshilfe: stark~~

~~3) Autonomes Fahrzeug: schwach, man könnte auch allerdings stark zulassen. Das hängt davon ab, wie man autonomes Fahrzeug definiert.~~

~~4) Face ID (bildbasiertes Login System auf iOS Geräten): schwach~~

Aufgabe 2 (4+2+4+2+2 = 14 Punkte) PCA und Distanzmaße

a) Berechnen Sie für die Merkmalsvektoren

$$\vec{g}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \vec{g}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \vec{g}_3 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \vec{g}_4 = \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \vec{g}_5 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

die Datenmatrix

$$G = (\Delta \vec{g}_1 \mid \Delta \vec{g}_2 \mid \Delta \vec{g}_3 \mid \Delta \vec{g}_4 \mid \Delta \vec{g}_5)$$

und die Kovarianzmatrix

$$C = \frac{1}{N-1} G G^T$$

Es ist

$$\vec{g}_{mean} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

also

$$G = \begin{pmatrix} 1 & 0 & -1 & 0 & 0 \\ 0 & 2 & 0 & -2 & 0 \end{pmatrix}$$

und

$$C = \frac{1}{4} \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{pmatrix}$$

b) Geben Sie für diese Kovarianzmatrix das charakteristische Polynom an.

$$p(\lambda) = \begin{vmatrix} \frac{1}{2} - \lambda & 0 \\ 0 & 2 - \lambda \end{vmatrix} = (\frac{1}{2} - \lambda)(2 - \lambda)$$

c) Skizzieren Sie obigen Datenbestand und zeichnen Sie den Einheitskreis bzgl. der Mahalanobisdistanz mit obiger Kovarianzmatrix.

Der Ansatz

$$d_M(\vec{x}, \vec{y}) = 1$$

führt zu

$$\sqrt{(x \ y) \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}} = 1$$

was äquivalent ist zu

$$2x^2 + \frac{1}{2}y^2 = 1$$

wird also gelöst von Punkten, die auf einer Ellipse um den Ursprung des Koordinatensystems mit Halbachsen $a = \frac{1}{\sqrt{2}}$ und $b = \sqrt{2}$

d) Was ändert sich (bzgl. der Merkmale), wenn Sie für einen Algorithmus die Mahalanobis-Distanz mit obiger Kovarianz-Matrix verwenden statt der euklidischen Distanz?


Die Achsen werden entsprechend der Datenverteilung - genau genommen entsprechend der Streuung der Merkmale - skaliert.

e) Was ist der Vorteil der Verwendung der Mahalanobisdistanz gegenüber einer Skalierung des Merkmalsraums bzgl. des jeweiligen Minimums und Maximums der Merkmale (also etwa einer Skalierung, sodass das der minimale Wert immer auf -1 und der maximale Wert immer auf 1 abgebildet wird)?

Zwei Aspekte: Erstens ist die Variante mit der M-Distanz wesentlich robuster gegenüber Rauschen. MIN/MAX-Lösungen sind ja extrem empfindlich gegenüber Rauschen. Zweiter Aspekt: M-Distanz regularisiert auch bzgl. Korrelation der Merkmale, das macht MIN/MAX (wie jede andere achsenweise Skalierung auch) nicht. Für einen der genannten Aspekte gab es volle Punkte...

Aufgabe 3 (4+2+2+2= 10 Punkte) SVM

a) Eine lineare (Zweiklassen-)SVM liefert eine Hyperebene, die zwei Klassen voneinander trennt. Die Hyperebene kann durch die Normalform $\vec{n}^T \vec{x} = \alpha$ mit einem Normalenvektor $\vec{n}$ der Länge eins und einem Skalar α geschrieben werden. Welche Hyperebene erwarten Sie im folgenden Fall für die Klassen „Kreis“ und „Raute“ bei Anwendung einer SVM? Gehen Sie dabei von einer Hard Margin Modellierung aus. Skizzieren Sie die Ebene und geben Sie eine Normalform der Ebene an.



$\vec{n}^T \vec{x} = \alpha$ mit $\vec{n} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ und $\alpha = \sqrt{8}$ ist eine mögliche Lösung.

b) Für die Soft Margin Variante der SVM wird die Optimierungsaufgabe um Schlupfvariablen ξ_n und eine Variable C erweitert und das Optimierungsproblem lautet dann

$$\begin{aligned} &\text{Minimiere } \frac{1}{2} \|\vec{n}\|^2 + C \sum_{n=1}^N \xi_n \\ &\text{durch Anpassung der Variablen } \vec{n}, \alpha \text{ und } \xi_n \text{ unter den Nebenbedingungen} \\ &y_n (\vec{n}^T \vec{g}_n - \alpha) \geq 1 - \xi_n \text{ für alle } n = 1, \dots, N. \end{aligned}$$

Wofür stehen die Variablen y_n ?

Für die Klassenzugehörigkeit des Datums $\vec{g}_n$, also +1 für Positivklasse, -1 für Negativklasse.

c) Was bewirken die Variablen ξ_n in den Nebenbedingungen?

Die Variablen ermöglichen, dass die Daten auch innerhalb des Margins oder gar auf der „falschen“ Seite der Trennhyperebene liegen können.


d) Inwieweit beeinflusst die Variable C das Verhalten der SVM bzw. das Ergebnis?

Beschreiben Sie was passiert, wenn C sehr groß gewählt wird.

C steuert, wie stark diese „Fehlrate“ in der Summe über alle Daten bestraft wird. Ist C groß, wird der Fehler stark bestraft und es besteht die Gefahr eines Overfits.

Aufgabe 4 (4+2+2+4+2 = 14 Punkte) Cluster-Algorithmen.


a) Skizzieren Sie (durch Einkreisen), welche Cluster entstehen, wenn der DBSCAN mit $\text{MinPts}=2$ (d.h. bei Kernpunkten liegen mindestens zwei weitere Punkte in der jeweiligen ε -Umgebung), der euklidischen Distanz und mit $\varepsilon = 1.1$ (links) und $\varepsilon = 1.5$ (rechts) angewandt wird. Markieren Sie Ausreißer farblich.



b) Für die Bestimmung der Parameter MinPts und ε wird in der Regel ein sogenanntes „Ellbogen-Kriterium“ angewandt. Hierfür werden mehrere Werte für MinPts untersucht und für jeden Wert ein zweidimensionales Diagramm erzeugt. Erläutern Sie, was an den beiden Achsen des Diagramms (Hoch- und Rechtsachse) angetragen wird.


Auf der Rechtsachse werden alle Elemente des Datenbestands angetragen und auf der Hochachse der Abstand zum MinPts sten Nachbarn.

c) Welche (ganzzahligen) Werte für ε und MinPts bieten sich nach dem Ellbogen-Kriterium für die folgende Situation an? Begründung.



Das Diagramm für $K = 3$ hat den ausgeprägtesten Knick und zwar für ungefähr den (Hochachsen-)Wert 1. Damit sollte $\text{MinPts}=3$ und $\varepsilon \approx 1$ gewählt werden.

d) Skizzieren Sie (wieder durch Einkreisen), welche Cluster Sie als ideale Lösungen erwarten würden, wenn der K-means mit $K = 2$ einmal mit der euklidischen Distanz (links) und mit der Cosinus-Ähnlichkeit (rechts) angewandt wird.



e) Warum ist der SSE nur mit Vorsicht anzuwenden, wenn mit Ausreißern zu rechnen ist?

Die Distanzen der Ausreißer zu den Zentren geht (wie bei allen Objekten) quadratisch ein. Da die Distanz bei Ausreißern groß ist, verstärkt die Quadrierung den Einfluss der Ausreißer.