

Klausuraufgaben zur Prüfung Maschinelles Lernen

Bearbeitungszeit: 120 Minuten

Erlaubte Hilfsmittel: Keine.

Aufgabe	1	2	3	4	5	Σ
Punkte	8	10	8	10	10	46
erreichte Punkte						

Viel Erfolg!

Name: _____ Matrikelnummer: _____

~~**Aufgabe 1** (1+3+2+2=8 Punkte) Zum Aufwärmen.~~

~~a) Welche Rolle spielt Data Mining im KDD-Prozess?~~

~~Data Mining entspricht der Mustererkennung.~~

~~b) Welche Besonderheiten zeichnen Data Mining gegenüber der klassischen Mustererkennung aus?~~

~~Data Mining ist die Analyse von großen Datenbeständen nach neuem und nützlichen (ggf. wettbewerbsrelevantem) Wissen.~~

~~c) In den 80er Jahren entstanden zahlreiche KI-Programme für stark eingeschränkte Wissensbereiche. Wie nennt man solche Programme? Nennen Sie ein Beispiel.~~

~~Expertensystem. Schachcomputer.~~

d) Welche der folgenden Aufgaben ordnet man dem überwachten Lernen (ÜL) zu, welche dem unüberwachten Lernen (UÜL)?

1) Regression: ÜL

2) Klassifikation: ÜL

3) Clustering: UÜL

4) Ausreißerdetektion: UÜL

Aufgabe 2 (4+2+2+2 = 10 Punkte) Mahalanobis-Distanz

a) Berechnen Sie für den Datenbestand

$$\vec{g}_1 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \vec{g}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \vec{g}_3 = \begin{pmatrix} -2 \\ -2 \end{pmatrix}, \vec{g}_4 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \vec{g}_5 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

die Kovarianzmatrix mit der Formel

$$C = \frac{1}{N-1} \sum_{k=1}^N (\vec{g}_k - \vec{g}_{mean})(\vec{g}_k - \vec{g}_{mean})^T.$$

$$\begin{aligned} C &= \frac{1}{N-1} \sum_{k=1}^N (\vec{g}_k - \vec{g}_{mean})(\vec{g}_k - \vec{g}_{mean})^T \\ &= \frac{1}{4} \left(\begin{pmatrix} 2 \\ 2 \end{pmatrix} \begin{pmatrix} 2 & 2 \end{pmatrix} + \begin{pmatrix} -1 \\ 1 \end{pmatrix} \begin{pmatrix} -1 & 1 \end{pmatrix} + \begin{pmatrix} -2 \\ -2 \end{pmatrix} \begin{pmatrix} -2 & -2 \end{pmatrix} + \begin{pmatrix} 1 \\ -1 \end{pmatrix} \begin{pmatrix} 1 & -1 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \end{pmatrix} \right) \\ &= \frac{1}{4} \left(\begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix} + \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + \begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix} + \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \right) \\ &= \frac{1}{4} \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix} \end{aligned}$$

b) Die Inverse der Kovarianzmatrix lautet

$$C^{-1} = \frac{1}{8} \begin{pmatrix} 5 & -3 \\ -3 & 5 \end{pmatrix}.$$

Berechnen Sie den Abstand der Vektoren $\vec{x}_0 = (1, 0)^T$ und $\vec{x}_1 = (\sqrt{2}, \sqrt{2})^T$ zum Ursprung des Koordinatensystems $\vec{o} = (0, 0)^T$ bezüglich der Mahalanobisdistanz zur Kovarianzmatrix C .

$$d_C(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T C^{-1} (\vec{x} - \vec{y})}$$

Es ist

$$\begin{aligned} d_C(\vec{x}, \vec{o}) &= \frac{1}{\sqrt{8}} \sqrt{(x, y) \begin{pmatrix} 5 & -3 \\ -3 & 8 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}} \\ &= \frac{1}{\sqrt{8}} \sqrt{5x^2 - 6xy + 5y^2} \end{aligned}$$

und damit $d_C(\vec{x}_0, \vec{o}) = \sqrt{\frac{5}{8}}$ und $d_C(\vec{x}_1, \vec{o}) = \sqrt{\frac{8}{8}} = 1$

c) Skizzieren Sie die beiden Vektoren in einem zweidimensionalen Koordinatensystem. Wie groß sind die euklidischen Abstände von $\vec{x}_0$ und $\vec{x}_1$ zum Ursprung des Koordinatensystems?

$$d_2(\vec{x}_0, \vec{o}) = 1 \text{ und } d_2(\vec{x}_1, \vec{o}) = 2$$

d) Welche Formen nehmen die Einheitskreise von Mahalanobis-Distanzen immer an? Welche speziell für den Fall, dass die Kovarianzmatrix eine Diagonalmatrix ist, die zugrunde liegenden Daten also unkorreliert?

Es handelt sich immer um Ellipsen, bei diagonalen Kovarianzmatrizen immer um achsenparallele Ellipsen.


Aufgabe 3 (2+4+2 = 8 Punkte) Dynamic Time Warping

a) Skizzieren Sie die beiden folgenden Sequenzen in ein gemeinsames Koordinatensystem (mit je einer Farbe oder einem Symbol pro Sequenz):

$$\vec{x}_1 = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \vec{x}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \vec{x}_3 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \vec{x}_4 = \begin{pmatrix} 4 \\ -1 \end{pmatrix}$$

und

$$\vec{y}_1 = \begin{pmatrix} -2 \\ 1 \end{pmatrix}, \vec{y}_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \vec{y}_3 = \begin{pmatrix} 3 \\ -2 \end{pmatrix}$$



b) Berechnen Sie für die Sequenzen die City-Block-Distanzen und tragen Sie diese in die linke Grafik ein. Verwenden Sie diese Distanzen als Grundlage für ein Dynamic Time Warping (rechte Grafik). Wie groß sind die minimalen Kosten?


	7	7	4	2
	5	1	2	6
	1	3	4	8

∞	13	9	6	6
∞	6	2	4	10
∞	1	4	8	16
0	∞	∞	∞	∞

c) Verbinden Sie in der Grafik von Aufgabenteil a) die korrespondierenden Elemente der Sequenzen für diese Lösung.


Aufgabe 4 (2+4+2+2=10 Punkte) Kernel-Trick

a) Die nebenstehenden Daten stellen Trainingsdaten für eine nichtlineare SVM mit zwei Klassen **Raute** und **Kreis** dar.



Die Daten sollen mit der Transformation $\Phi : \mathbb{R}^2 \rightarrow \mathbb{R}^3, (x, y) \mapsto (x, y, \underbrace{x^2 + y^2}_{=z})$ in einen

höherdimensionalen Raum transformiert werden. Welche Werte nehmen die z -Koordinaten der Trainingsdaten an? Schreiben Sie die jeweiligen Werte neben die Rauten/Kreise in die Grafik.



b) Geben Sie die Normalform einer Hyperebene (des $\mathbb{R}^3$) an, die die transformierten Daten der beiden Klassen im $\mathbb{R}^3$ voneinander trennt.

z.B. $\langle \vec{x}, \vec{n} \rangle = \alpha$ mit $\vec{n} = (0, 0, 1)^T$ und $\alpha = 2$.


c) Trennt Ihre Ebene die beiden Klassen im $\mathbb{R}^3$ auch dann noch, wenn zur Klasse Raute das Datum $(3, 0)^T$ hinzukommt? Begründung.

Nein, das Datum liegt oberhalb der transformierten Daten der Kreis-Klasse. Der Datensatz ist dann auch im transformierten Raum nicht mehr linear trennbar.

d) ~~Es gibt Kernel, die auf einer Transformation beruhen, die in einen unendlichdimensionalen Merkmalsraum abbilden. Warum ist dies kein Problem für das Training von nichtlinearen SVMs oder Kernel-PCAs?~~

~~Weil die Transformation gar nicht angewandt wird. Vielmehr wird die Kombination Transformation mit Skalarprodukt angewandt, also der Kernel selbst und der führt nicht in eine höhere Dimension.~~

Aufgabe 5 (2+2+2+2+2 = 10 Punkte) Clusteralgorithmen K-means und C-means. Der folgende Datenbestand ist in die Cluster **Raute** und **Kreis** eingeteilt:



a) Wie müssen die Zentren bei K-means (im Aktualisierungsschritt) gesetzt werden, wenn der SSE mit der euklidischen Distanz optimiert wird? Zeichnen Sie die Zentren in die Grafik ein.

Auf die Schwerpunkte der Cluster.

b) Berechnen Sie für das Beispiel den quadratischen Fehler (ein Kästchen hat jeweils die Einheit 1)

$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k)$$

für die **City-Block-Distanz!!!!**

Es ist

$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k) = 36$$


c) Warum ist der SSE nicht geeignet, Ergebnisse mit verschiedenen Anzahlen von Clustern miteinander zu vergleichen? Welche Alternative gibt es?

Der SSE ist nicht invariant gegenüber verschiedenen Clusteranzahlen. Im Extremfall von K gleich Umfang Datenbestand kann er sogar null werden. Eine Alternative ist der Silhouettenkoeffizient.

~~d) Worin unterscheidet sich der C-means vom K-means? Welcher Parameter des C-means ist für Ähnlichkeit bzw. Unähnlichkeit der beiden Algorithmen verantwortlich und wie muss er gesetzt werden, sodass der C-means dem K-means möglichst ähnlich ist?~~

~~Der C-means liefert im Gegensatz zum K-means unscharfe Clustereinteilung. Die Schärfe der Einteilung wird durch den fuzzier p bestimmt, der jeden Wert echt größer als eins annehmen darf. Je näher p an der unteren Grenze 1 liegt, desto schärfer wird die Klasseneinteilung und umso ähnlicher wird das Ergebnis dem K-means.~~

~~e) In der Vorlesung wurde in diesem Zusammenhang ein Beispiel besprochen, in dem die Auswirkung der Wahl des Fuzziers für die Aktualisierung der Gewichte beim C-means verdeutlicht wurde (im Bild rechts). Dabei wurden fiktive Distanzen eines Objekts $\vec{x}$ zu den Zentren von 5 Clustern angenommen (links):~~



~~Erläutern Sie, wie die Grafik rechts zu verstehen ist.~~

~~Rechts sind die neuen Gewichte für das Objekt $\vec{x}$ für die Cluster 1 und 3 angezeigt. Wenn der Fuzzier groß gewählt wird, unterscheiden die sich kaum, wenn er klein gewählt wird, wird das Gewicht zu Cluster 1, zu dem das Objekt am nächsten liegt, fast eins und das zu Cluster 3 sehr groß. Im Grenzübergang werden die Gewichte binär 1 und 0.~~