

Klausuraufgaben zur Prüfung Maschinelles Lernen

Bearbeitungszeit: 120 Minuten

Erlaubte Hilfsmittel: Keine.

Aufgabe	1	2	3	4	Σ
Punkte	8	14	10	14	46
erreichte Punkte					

Viel Erfolg!

Nachname: _____ **Vorname:** _____ **Matrikelnummer:** _____

Aufgabe 1 (1+3+2+2=8 Punkte) Zum Aufwärmen.

a) Welche Rolle spielt Data Mining im KDD-Prozess?

Data Mining entspricht der Mustererkennung.

b) Welche Besonderheiten zeichnen Data Mining gegenüber der klassischen Mustererkennung aus?

Data Mining ist die Analyse von großen Datenbeständen nach neuem und nützlichen (ggf. wettbewerbsrelevantem) Wissen.

c) Was versteht man unter dem Stichwort „Fluch der Dimension“?

Hochdimensionale Merkmalsräume, oft dünn besetzt, d.h. Dimension $\gg$ Umfang Datenbestand.

d) Welche der folgenden Methoden ordnet man dem überwachten Lernen (ÜL) zu, welche dem unüberwachten (UÜL)?

1) Hauptkomponentenanalyse: ÜL

2) DBSCAN: UÜL

3) Support Vektor Maschine: ÜL

4) Autoencoder: UÜL

Aufgabe 2 (2+2+4+2+2+2= 14 Punkte) Maße

a) Skizzieren Sie die Einheitskreise der Minkowski-Distanzen $d_r(\vec{x}, \vec{y}) = \sqrt[r]{\sum_{i=1}^d |x_i - y_i|^r}$ für $r = 1$ und $r = 2$.

b) Skizzieren Sie den Datenbestand

$$\left\{ \begin{pmatrix} 4 \\ 4 \end{pmatrix}, \begin{pmatrix} -4 \\ -4 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 2 \\ -2 \end{pmatrix}, \begin{pmatrix} -2 \\ 2 \end{pmatrix} \right\}$$

c) In der Vorlesung wurde gezeigt, dass die Inverse der Kovarianzmatrix zu diesen Daten lautet wie folgt

$$C^{-1} = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \underbrace{\begin{pmatrix} \frac{1}{16} & 0 \\ 0 & \frac{1}{4} \end{pmatrix}}_{:=C'} \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

Skizzieren Sie den Einheitskreis bzgl. der Mahalanobisdistanz

$$d_C(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T C^{-1} (\vec{x} - \vec{y})}$$

zu dieser Kovarianzmatrix in die Skizze aus der vorangegangenen Teilaufgabe. Tipp: Stellen Sie hierfür die Gleichung

$$\sqrt{(\vec{x} - \vec{y})^T C' (\vec{x} - \vec{y})} = 1$$

auf und berücksichtigen Sie die Drehmatrizen separat, z.B. durch gezielten Blick auf die Daten.

Die linke und rechte Matrix beschreiben je eine Rotation um 45 Grad bzw. -45 Grad. Sei

$$C' = \begin{pmatrix} \frac{1}{16} & 0 \\ 0 & \frac{1}{4} \end{pmatrix}$$

Nur der innere Teil ohne die Rotationsmatrizen. Damit ist

$$d_{C'}(\vec{x}, \vec{0}) = 1$$

und

$$\sqrt{(x \ y) \begin{pmatrix} \frac{1}{16} & 0 \\ 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}} = 1$$

was äquivalent ist zu

$$\frac{1}{16}x^2 + \frac{1}{4}y^2 = 1$$

wird also gelöst von Punkten, die auf einer Ellipse um den Ursprung mit Halbachsen $a = \frac{1}{4}$ und $b = \frac{1}{2}$. Diese wird noch um 45 Grad gedreht (die Richtung kann man auch den Daten entnehmen!!!).

d) Was unterscheidet die Mahalanobisdistanz in ihrer Definition von der euklidischen Distanz?

Die Inverse der Kovarianzmatrix. Für die euklidische Distanz würde hier die Einheitsmatrix stehen.

e) Was ist ein entscheidender Vorteil der Mahalanobisdistanz?

Invarianz gegenüber Skalenniveau

f) Welches der beiden Maße

$$\text{SMC}(\vec{x}, \vec{y}) = \frac{f_{11} + f_{00}}{f_{10} + f_{01} + f_{11} + f_{00}}$$

$$\text{JSC}(\vec{x}, \vec{y}) = \frac{f_{11}}{f_{10} + f_{01} + f_{11}}$$

ist für Daten der folgenden Art besser geeignet? Berechnen Sie dieses Maß für

$$\vec{x} = (1\ 0\ 0\ 1\ 0\ 0\ 0\ 0\ 1)^T$$



$$\vec{y} = (0\ 0\ 0\ 1\ 0\ 1\ 1\ 0\ 0)^T$$

JSC. Es ist

$$\text{JSC}(\vec{x}, \vec{x}) = \frac{f_{11}}{f_{10} + f_{01} + f_{11}} = 1/5$$

Aufgabe 3 (4+2+2+2= 10 Punkte) SVM und Kernel-Trick

a) Welche Hyperebene erwarten Sie im folgenden Fall für die Klassen „Kreis“ und „Raute“ bei Anwendung einer SVM? Gehen Sie dabei von einer Hard-Margin-Modellierung aus. Skizzieren Sie die Ebene und geben Sie eine Normalform der Ebene an.



$\vec{n}^T \vec{x} = \alpha$ mit $\vec{n} = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ und $\alpha = 0$ ist eine mögliche Lösung.


b) Die SVM wird durch die Optimierungsaufgabe

Minimiere $\frac{1}{2} \|\vec{n}\|^2$
 durch Anpassung der Variablen $\vec{n}, \alpha$ unter den Nebenbedingungen
 $y_n (\vec{n}^T \vec{g}_n - \alpha) \geq 1$ für alle $n = 1, \dots, N$.

Wofür stehen die Variablen y_n ?

Für die Klassenzugehörigkeit des Datums $\vec{g}_n$, also $+1$ für Positivklasse, -1 für Negativklasse.

c) Bei der Soft Margin Variante wird ein (Hyper-)Parameter C eingeführt. Was wird durch diesen Parameter gesteuert? Beschreiben Sie was passiert, wenn C sehr groß gewählt wird. Argumentieren Sie mit folgender Grafik



C steuert, wie stark diese „Fehlrate“ in der Summe über alle Daten bestraft wird. Ist C groß, wird der Fehler stark bestraft und es besteht die Gefahr eines Overfits.

d) Für den Kernel Trick werden Daten implizit in (ggf. höherdimensionale) Räume transformiert und in diesen Räumen das Skalarprodukt gebildet. Für einen Datensatz mit nur einem Merkmal sei die Transformation durch $\Phi: \mathbb{N} \rightarrow \{0, 1\}^\infty$ mit

$$\Phi(n) = (\underbrace{1, \dots, 1}_{n \text{ mal}}, 0, \dots)^T$$

gegeben. Als Skalarprodukt wird das Standardskalarprodukt verwendet. Berechnen Sie


$$k(n, m) = \langle \Phi(n), \Phi(m) \rangle$$

für $n = 5$ und $m = 10$.

Aufgabe 4 (4+4+2+2+2 = 14 Punkte) Cluster Algorithmen

Der eindimensionale Datenbestand

$$\vec{x}_1 = (-7), \vec{x}_2 = (-6), \vec{x}_3 = (-4), \vec{x}_4 = (-3) \\ \vec{x}_5 = (1), \vec{x}_6 = (2), \vec{x}_7 = (4), \vec{x}_8 = (5)$$



soll in Cluster eingeteilt werden.

a) Wenden Sie K-means für $K = 2$ mit den (eindimensionalen) initialen Zentren $\vec{z}_1 = (0)$ und $\vec{z}_2 = (3)$ an bis zur Konvergenz. Hinweis: Lassen Sie „unrunde“ Brüche stehen, die verschwinden nämlich im Lauf der weiteren Iterationen von selbst.

Im ersten Schritt erfolgt die Zuordnung

$$C_1 = \{\vec{x}_1, \vec{x}_2, \vec{x}_3\} \text{ und } C_2 = \{\vec{x}_4, \vec{x}_5, \vec{x}_6, \vec{x}_7, \vec{x}_8\}$$

Die Zentren werden damit wie folgt aktualisiert

$$\vec{z}_1 = \frac{1}{3}(-5 - 4 - 2) = -\frac{11}{3} \text{ und } \vec{z}_2 = \frac{1}{5}(-1 + 3 + 4 + 6 + 7) = \frac{19}{5}$$

und damit ergeben sich die neuen Cluster durch

$$C_1 = \{\vec{x}_1, \vec{x}_2, \vec{x}_3, \vec{x}_4\} \text{ und } C_2 = \{\vec{x}_5, \vec{x}_6, \vec{x}_7, \vec{x}_8\}$$

Die Zentren werden damit wie folgt aktualisiert

$$\vec{z}_1 = \frac{1}{4}(-5 - 4 - 2 - 1) = -\frac{12}{4} = -3 \text{ und } \vec{z}_2 = \frac{1}{4}(3 + 4 + 6 + 7) = \frac{20}{4} = 5$$

und liegen damit beide im Schwerpunkt ihrer Cluster. Der Algorithmus terminiert an dieser Stelle.

b) Berechnen Sie für das Ergebnis aus der vorangegangenen Aufgabe den quadratischen Fehler


$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k)$$

für die City-Block-Distanz!!!!

Es ist

$$SSE = \sum_{k=1}^2 \sum_{\vec{x} \in C_k} d^2(\vec{x}, \vec{z}_k) = 2(1^2 + 1^2 + 2^2 + 2^2) = 20$$

~~**c)** Sie suchen im folgenden Datenbestand A typische Vertreter. Welchen Clusteralgorithmus würden Sie hierfür verwenden? Wird der Algorithmus auch auf Datenbestand B funktionieren? Begründung.~~



~~Auf Datenbestand A kann man PAM, CLARA oder CLARANS verwenden, da sie prototypisch sind. Auf B werden Sie nicht einsetzbar sein, weil sie konvexe Cluster liefern.~~

d) Welche Zielfunktion wird für den K-means typischer Weise gewählt? Wie heißt sie und welche Konsequenz hat ihre Verwendung auf die Aktualisierung der Zentren, wenn die euklidische Distanz verwendet wird?

Für den K-means wird typischerweise mit dem mittleren quadratischen Fehler SSE formuliert. Wenn die euklidische Distanz gewählt wurde, hat sie zur Folge, dass Zentren optimal aktualisiert werden, wenn sie auf die Schwerpunkte der Cluster gelegt werden.

e) Welchen Rechenaufwand verursacht der K-means? Ist der Algorithmus als effizient einzuordnen?

Der K-means hat einen im Datenumfang linearen Aufwand und ist damit ein effizienter Algorithmus.