



University of Applied Sciences
Fakultät für Informatik und Wirtschaftsinformatik

Maschinelles Lernen

Aufgabensammlung mit ausführlichen Lösungen
Alle Altklausuren neu gelöst · Vorlesungsübungen · eigene Zusatzaufgaben

Übungen zur Kombiklausur

Sommersemester 2026

Referenten: Prof. Dr. Christine Preisach
Prof. Dr. Dennis Janka

Bearbeiter: Devin Uyan

Inhaltsverzeichnis

Hinweise zur Benutzung	1
I Aufgaben zum Teil Preisach	
Maße · Clustering · PCA	2
1 Distanz- und Ähnlichkeitsmaße	2
2 Clustering	8
3 PCA und Kernel-PCA	12
II Aufgaben zum Teil Janka	
Lineare Modelle · Neuronale Netze · CNN & Autoencoder	16
4 Lineare Regression	16
5 Logistische Regression und Klassifikationsmetriken	19
6 Regularisierung, Hyperparametersuche, Generalisierung	23
7 Neuronale Netze: Forward-Pass und SGD	27
8 Backpropagation	32
9 Faltungsnetze und Autoencoder	37

Hinweise zur Benutzung

- Jede Aufgabe trägt ihre **Quelle** im Kopf:
Altklausur (z. B. *Klausur SS22, A1, abgewandelt*), Vorlesungsübung
oder *Eigene Aufgabe*. Klausuraufgaben wurden neu formuliert
und mit **ausführlicheren Lösungswegen** versehen als in den offiziellen Lösungen.
- Erst selbst rechnen, dann Lösung ansehen;
die grünen Boxen stehen direkt unter der Aufgabe.
- Die blauen **Strategie-Boxen** am Anfang jedes Abschnitts fassen das Lösungsrezept
und die typischen Fehler zusammen.
- Der Janka-Teil der Klausur dauert 60 Minuten und hat 46 Punkte
($\approx 1,3$ Minuten pro Punkt); Zeitmanagement üben!

Teil I

Aufgaben zum Teil Preisach

Maße · Clustering · PCA

1 Distanz- und Ähnlichkeitsmaße

Strategie & typische Fehler

Rezepte: Distanzen stur nach Formel; bei der Kovarianzmatrix *immer* zuerst Mittelwerte, dann zentrieren, Nenner $N - 1$; bei Mahalanobis zuerst $\mathbf{C}^{-1}$ (Diagonalmatrix: Kehrwerte!); bei DTW Rand mit ∞ initialisieren und zellenweise $d_{ij} = d'_{ij} + \min(\text{links, unten, diagonal})$.

Typische Fehler: Nenner N statt $N - 1$; vergessen, die Wurzel zu ziehen (bzw. zu erwähnen, dass mit Quadraten verglichen werden darf); bei Jaccard die f_{00} mitgezählt.

Aufgabe 1.1

Eigene Aufgabe · Grundlagen

Gegeben seien die Punkte $\vec{x} = (1, 5)^T$ und $\vec{y} = (4, 1)^T$.

- Berechnen Sie die euklidische, die Cityblock- und die Chebyshev-Distanz zwischen $\vec{x}$ und $\vec{y}$.
- Ordnen Sie die drei Werte der Größe nach und begründen Sie, warum diese Ordnung *immer* gilt.
- Der Punkt $P = (0,6; 0,9)$: Liegt er innerhalb oder außerhalb des Einheitskreises der L_2 -, L_1 - und L_∞ -Norm?

Lösung

(a) Differenzvektor: $(1 - 4, 5 - 1) = (-3, 4)$.

$$d_2 = \sqrt{(-3)^2 + 4^2} = \sqrt{25} = 5$$

$$d_1 = |-3| + |4| = 7$$

$$d_\infty = \max(3, 4) = 4$$

(b) $d_\infty \leq d_2 \leq d_1$, hier $4 \leq 5 \leq 7$. Begründung: d_∞ nimmt nur die größte Komponente; d_1 summiert alle Komponenten voll auf (Umweg über das Gitter); d_2 (Luftlinie) liegt dazwischen, denn $\max_k |v_k| \leq \sqrt{\sum_k v_k^2} \leq \sum_k |v_k|$.

(c) L_2 : $\sqrt{0,36 + 0,81} = \sqrt{1,17} \approx 1,08 > 1 \Rightarrow$ *außerhalb*. L_1 : $0,6 + 0,9 = 1,5 > 1 \Rightarrow$ *außerhalb*. L_∞ : $\max(0,6; 0,9) = 0,9 < 1 \Rightarrow$ *innerhalb*. Derselbe Punkt ist je nach Norm „nah“ oder „fern“.

Aufgabe 1.2

Eigene Aufgabe (Konzept) · Metrik-Eigenschaften

- (a) Nennen Sie die drei Eigenschaften, die eine Distanzfunktion zur *Metrik* machen.
- (b) Zeigen Sie, dass die Zeitdifferenz auf der 24-Stunden-Uhr, $d(t_1, t_2) = t_2 - t_1$ falls $t_1 \leq t_2$, sonst $24 + t_2 - t_1$, *keine* Metrik ist.
- (c) Ist DTW eine Metrik? Begründen Sie kurz.

Lösung

- (a)
- (1) Positive Definitheit: $d(\vec{x}, \vec{y}) \geq 0$ und $d(\vec{x}, \vec{y}) = 0 \Leftrightarrow \vec{x} = \vec{y}$;
 - (2) Symmetrie: $d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x})$;
 - (3) Dreiecksungleichung: $d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z})$.
- (b) Gegenbeispiel zur Symmetrie: $d(13:00, 14:00) = 1 \text{ h}$, aber $d(14:00, 13:00) = 24 + 13 - 14 = 23 \text{ h} \neq 1 \text{ h}$. Eigenschaft (2) verletzt $\Rightarrow$ keine Metrik.
- (c) Nein. DTW verletzt i. A. die Dreiecksungleichung (und durch das Warping kann $d(\vec{s}, \vec{t}) = 0$ auch für $\vec{s} \neq \vec{t}$ auftreten, z. B. bei gestreckten Versionen derselben Sequenz). DTW ist ein *Distanzmaß*, keine Metrik.

Aufgabe 1.3

Vorlesungsübung Preisach, ausgearbeitet · Kovarianzmatrix

Alter X [Jahre] und Körpergröße Y [m] von sechs Jugendlichen:

X	14	16	16	12	15	17
Y	1,60	1,75	1,80	1,50	1,55	1,80

Berechnen Sie die empirische Kovarianzmatrix $\mathbf{C}$ und interpretieren Sie das Vorzeichen der Kovarianz. Warum erlaubt die Kovarianz keine Aussage über die *Stärke* des Zusammenhangs, und welches Maß behebt das?

Lösung

Mittelwerte: $\bar{X} = \frac{14+16+16+12+15+17}{6} = 15$, $\bar{Y} = \frac{1,60+1,75+1,80+1,50+1,55+1,80}{6} = 1,667$

Varianz X (Nenner $N - 1 = 5$):

$$\text{Var}(X) = \frac{(-1)^2 + 1^2 + 1^2 + (-3)^2 + 0^2 + 2^2}{5} = \frac{16}{5} = 3,2$$

Kovarianz:

$$\begin{aligned} \text{Cov}(X, Y) &= \frac{1}{5} [(-1)(-0,067) + 1 \cdot 0,083 + 1 \cdot 0,133 \\ &\quad + (-3)(-0,167) + 0 \cdot (-0,117) + 2 \cdot 0,133] = \frac{1}{5} \cdot 1,05 = 0,21 \end{aligned}$$

Varianz Y: $\text{Var}(Y) = \frac{0,067^2 + 0,083^2 + 0,133^2 + 0,167^2 + 0,117^2 + 0,133^2}{5} \approx 0,018$

$$\mathbf{C} = \begin{pmatrix} 3,2 & 0,21 \\ 0,21 & 0,018 \end{pmatrix}$$

Interpretation: $\text{Cov} > 0 \Rightarrow$ positiver linearer Zusammenhang (ältere Jugendliche sind tendenziell größer). Die Kovarianz ist *skalenabhängig* (Meter vs. Zentimeter ändert den Wert um Faktor 100), daher nur Richtungs-, keine Stärkeaussage.

Abhilfe: **Pearson-Korrelation** $r = \frac{0,21}{\sqrt{3,2 \cdot 0,018}} \approx 0,87$
(starker positiver Zusammenhang, Werte in $[-1, 1]$).

Aufgabe 1.4

Vorlesungsübung Preisach, ausgearbeitet · Mahalanobis

Ein zentrierter Datenbestand habe die Kovarianzmatrix $\mathbf{C} = \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix}$.

- Prüfen Sie, ob $\mathbf{C}$ invertierbar ist, und geben Sie $\mathbf{C}^{-1}$ an.
- Berechnen Sie die Mahalanobis-Distanz der Punkte $\vec{x} = (0, 2)^T$ und $\vec{y} = (1/2, 0)^T$ jeweils zum Ursprung $\vec{o}$.
- Vergleichen Sie mit den euklidischen Distanzen und erklären Sie den Unterschied geometrisch.

Lösung

(a) $\det \mathbf{C} = \frac{1}{2} \cdot 2 - 0 = 1 \neq 0 \Rightarrow$ invertierbar (regulär).

Diagonalmatrix $\Rightarrow$ Kehrwerte: $\mathbf{C}^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}$.

(b)

$$d_C(\vec{x}, \vec{o}) = \sqrt{(0, 2) \begin{pmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 0 \\ 2 \end{pmatrix}} = \sqrt{0^2 \cdot 2 + 2^2 \cdot \frac{1}{2}} = \sqrt{2} \approx 1,41$$

$$d_C(\vec{y}, \vec{o}) = \sqrt{\left(\frac{1}{2}\right)^2 \cdot 2 + 0} = \sqrt{\frac{1}{2}} \approx 0,71$$

(c) Euklidisch: $d_2(\vec{x}, \vec{o}) = 2$ und $d_2(\vec{y}, \vec{o}) = 0,5$, Faktor 4. Mahalanobis: Faktor 2. Grund: In y -Richtung streuen die Daten stark ($Var = 2$), Abweichungen dort sind „normal“ und werden heruntengewichtet; in x -Richtung ist die Streuung klein ($Var = \frac{1}{2}$), Abweichungen zählen doppelt. Punkte gleicher Mahalanobis-Distanz liegen auf *Ellipsen*, die der Datenform folgen.

Aufgabe 1.5

Vorlesungsbeispiel, als Klausuraufgabe ausgearbeitet · DTW

Gegeben die 2D-Sequenzen

$$\vec{s} = ((0,0), (1,0), (1,4), (2,5)), \quad \vec{t} = ((1,0), (3,0), (1,3))$$

mit der Cityblock-Distanz als lokalem Maß.

- Stellen Sie die Matrix der lokalen Kosten auf.
- Berechnen Sie die Matrix der kumulierten Kosten und die DTW-Distanz.
- Geben Sie den optimalen Pfad (das Alignment) an.
- Nennen Sie die drei Randbedingungen für gültige Warping-Pfade.

Lösung

(a) **Lokale Kosten** $d'_{ij} = \|s_i - t_j\|_1$, z. B. $d'(s_1, t_1) = |0-1| + |0-0| = 1$;
 $d'(s_3, t_3) = |1-1| + |4-3| = 1$:

	s_1	s_2	s_3	s_4
t_3	4	3	1	3
t_2	3	2	6	6
t_1	1	0	4	6

(b) **Kumulierte Kosten** mit $d_{ij} = d'_{ij} + \min(d_{i-1,j}, d_{i,j-1}, d_{i-1,j-1})$,
 Start links unten, Ränder ∞ :

	s_1	s_2	s_3	s_4
t_3	8	6	4	7
t_2	4	3	7	11
t_1	1	1	5	11

Rechenbeispiele (Vorgänger: links, unten, diagonal): $d_{21} = 0 + \min(1, \infty, \infty) = 1$;
 $d_{22} = 2 + \min(4, 1, 1) = 3$; $d_{33} = 1 + \min(6, 7, 3) = 4$; $d_{43} = 3 + \min(4, 11, 7) = 7$.

$$d_{DTW}(\vec{s}, \vec{t}) = d_{43} = 7$$

(c) **Pfad** (fett markiert): $(s_1, t_1) \rightarrow (s_2, t_1) \rightarrow (s_2, t_2) \rightarrow (s_3, t_3) \rightarrow (s_4, t_3)$,
 s_2 wird auf t_1 und t_2 gematcht (Stauchung), t_3 auf s_3 und s_4 (Streckung).

(d)

- (1) *Randbedingung*: Anfang auf Anfang, Ende auf Ende;
- (2) *Monotonie*: Indizes monoton steigend, jeder Index kommt mindestens einmal vor;
- (3) *Schrittweite*: nur $(0, 1)$, $(1, 0)$, $(1, 1)$.

Aufgabe 1.6

Eigene Aufgabe · SMC, Jaccard, Kosinus

Zwei Kunden eines Online-Shops, dargestellt als binäre Kaufvektoren über 10 Produkte:

$$\vec{x} = (1, 0, 1, 0, 0, 0, 0, 0, 1, 0)^T \quad \vec{y} = (1, 0, 0, 0, 0, 0, 0, 1, 1, 0)^T$$

- (a) Berechnen Sie SMC und Jaccard-Koeffizient.
- (b) Welches der beiden Maße ist hier angemessener? Begründung.
- (c) Berechnen Sie zusätzlich die Kosinus-Ähnlichkeit der beiden Vektoren.
- (d) Für welche Datenart ist die Kosinus-Ähnlichkeit das Standardmaß und warum ist ihre *Längeninvarianz* dort erwünscht?

Lösung

(a) Zählung: $f_{11} = 2$ (Positionen 1, 9); $f_{10} = 1$ (Position 3); $f_{01} = 1$ (Position 8); $f_{00} = 6$.

$$\text{SMC} = \frac{2+6}{10} = 0,8 \quad \text{JSC} = \frac{2}{2+1+1} = 0,5$$

(b) Jaccard. Kaufdaten sind *dünn besetzt*, die gemeinsamen Nullen (beide haben Produkt k nicht gekauft) sagen nichts über Ähnlichkeit aus und blähen den SMC künstlich auf.

(c) $\langle \vec{x}, \vec{y} \rangle = 2$; $\|\vec{x}\| = \sqrt{3}$, $\|\vec{y}\| = \sqrt{3}$:

$$d_{\cos} = \frac{2}{\sqrt{3} \cdot \sqrt{3}} = \frac{2}{3} \approx 0,67$$

(d) Für Dokumente (Bag-of-Words-Vektoren) und Embeddings. Ein doppelt so langes Dokument mit denselben Wortanteilen zeigt in dieselbe Richtung, die Kosinus-Ähnlichkeit bleibt 1. Inhaltliche Ähnlichkeit soll nicht von der Dokumentlänge abhängen.

Aufgabe 1.7

Eigene Aufgabe · k-NN und Maßwahl

- (a) Gegeben die Trainingspunkte mit Klassen: $A(1,1) \rightarrow \oplus$, $B(2,2) \rightarrow \oplus$, $C(5,1) \rightarrow \ominus$, $D(6,2) \rightarrow \ominus$, $E(3,5) \rightarrow \oplus$. Klassifizieren Sie den Punkt $Q = (4,2)$ mit 1-NN und mit 3-NN (euklidische Distanz).
- (b) Wählen Sie für folgende Situationen jeweils das passende Maß und begründen Sie in einem Satz:
- (i) Vergleich von Gesten-Sequenzen unterschiedlicher Länge,
 - (ii) Warenkorb-Vektoren,
 - (iii) stark korrelierte Sensormerkmale mit verschiedenen Einheiten,
 - (iv) BOW-Dokumentvektoren.

Lösung

(a) Quadrierte euklidische Distanzen zu $Q(4,2)$
(Wurzel für den Vergleich unnötig, Monotonie!):

$$d^2(A) = 9 + 1 = 10;$$

$$d^2(B) = 4 + 0 = 4;$$

$$d^2(C) = 1 + 1 = 2;$$

$$d^2(D) = 4 + 0 = 4;$$

$$d^2(E) = 1 + 9 = 10.$$

1-NN: nächster Nachbar ist $C (\ominus) \Rightarrow$ Klasse $\ominus$.

3-NN: die drei nächsten sind $C (\ominus)$, $B (\oplus)$, $D (\ominus) \Rightarrow$ Mehrheit $\ominus$.

(b)

- (i) **DTW**, einziges Maß für unterschiedlich lange, zeitverzerrte Sequenzen.
- (ii) **Jaccard**, binär und dünn besetzt, gemeinsame Nullen ignorieren.
- (iii) **Mahalanobis**, berücksichtigt Korrelation und skaliert eingebaut.
- (iv) **Kosinus-Ähnlichkeit** – hochdimensional, dünn besetzt, längeninvariant.

2 Clustering

Strategie & typische Fehler

Rezepte: SSE = erst Zentren (Mittelwert pro Koordinate!), dann quadrierte Abstände summieren, *keine* Wurzel beim SSE! k-Means von Hand: Tabelle mit Distanzen zu allen Zentren führen. DBSCAN: erst alle Kernpunkte markieren ($> MinPts$ Nachbarn im ε -Radius), dann Rand, Rest ist Rauschen.

Typische Fehler: SSE mit Wurzel; beim Zentren-Update einzelne Punkte vergessen; bei der Silhouette a und b vertauschen.

Aufgabe 2.1

Vorlesungsübung Preisach, ausgearbeitet · SSE

Gegeben die Punkte

$$A(1, 2), \quad B(2, 1), \quad C(1, 1), \quad D(6, 5), \quad E(7, 6), \quad F(6, 7)$$

mit der Clusterzuordnung $C_1 = \{A, B, C\}$, $C_2 = \{D, E, F\}$.

- Berechnen Sie die Clusterzentren.
- Berechnen Sie für jeden Punkt den quadrierten euklidischen Abstand zu seinem Zentrum und daraus den SSE.
- Warum ist der Schwerpunkt (Mittelwert) die SSE-optimale Position des Zentrums?

Lösung

$$(a) \quad \vec{z}_1 = \left(\frac{1+2+1}{3}, \frac{2+1+1}{3}\right) = \left(\frac{4}{3}, \frac{4}{3}\right), \quad \vec{z}_2 = \left(\frac{6+7+6}{3}, \frac{5+6+7}{3}\right) = \left(\frac{19}{3}, 6\right)$$

(b) Cluster 1:

$$d^2(A) = \left(1 - \frac{4}{3}\right)^2 + \left(2 - \frac{4}{3}\right)^2 = \frac{1}{9} + \frac{4}{9} = \frac{5}{9} \quad d^2(B) = \frac{4}{9} + \frac{1}{9} = \frac{5}{9} \quad d^2(C) = \frac{1}{9} + \frac{1}{9} = \frac{2}{9}$$

Cluster 2:

$$d^2(D) = \left(6 - \frac{19}{3}\right)^2 + (5 - 6)^2 = \frac{1}{9} + 1 = \frac{10}{9} \quad d^2(E) = \frac{4}{9} + 0 = \frac{4}{9} \quad d^2(F) = \frac{1}{9} + 1 = \frac{10}{9}$$

$$SSE = \underbrace{\frac{12}{9}}_{C_1} + \underbrace{\frac{24}{9}}_{C_2} = \frac{36}{9} = \boxed{4}$$

(c) Der SSE ist als Funktion der Zentrumskoordinaten eine nach oben geöffnete Parabel(-summe); Nullsetzen der Ableitung $\frac{\partial}{\partial \vec{z}_k} \sum_{\vec{g} \in C_k} \|\vec{g} - \vec{z}_k\|^2 = -2 \sum (\vec{g} - \vec{z}_k) \stackrel{!}{=} 0$ liefert genau $\vec{z}_k = \frac{1}{|C_k|} \sum_{\vec{g} \in C_k} \vec{g}$. Jede andere Position erhöht den SSE.

Aufgabe 2.2

Eigene Aufgabe · k-Means von Hand

Gegeben die 1D-Punkte $\{2, 4, 10, 12, 3, 20, 30, 11, 25\}$
und die initialen Zentren $z_1 = 2, z_2 = 4$ ($K = 2$).

- Führen Sie k-Means aus, bis sich die Zentren nicht mehr ändern (Zuordnung und Zentren je Iteration angeben).
- Charakterisieren Sie k-Means anhand der vier Begriffspaare aus der Vorlesung (partitionierend/hierarchisch, exklusiv/überlappend, vollständig/partiell, K fest/dynamisch).

Lösung

(a)

Iteration 1: Zuordnung nach nächstem Zentrum (Grenze bei 3): $C_1 = \{2, 3\}$, $C_2 = \{4, 10, 12, 20, 30, 11, 25\}$. Neue Zentren: $z_1 = 2,5$; $z_2 = \frac{4+10+12+20+30+11+25}{7} = 16$.

Iteration 2: Grenze bei $\frac{2,5+16}{2} = 9,25$: $C_1 = \{2, 3, 4\}$, $C_2 = \{10, 11, 12, 20, 25, 30\}$. Neue Zentren: $z_1 = 3$; $z_2 = 18$.

Iteration 3: Grenze bei 10,5: $C_1 = \{2, 3, 4, 10\}$, $C_2 = \{11, 12, 20, 25, 30\}$. Neue Zentren: $z_1 = 4,75$; $z_2 = 19,6$.

Iteration 4: Grenze bei 12,175: $C_1 = \{2, 3, 4, 10, 11, 12\}$, $C_2 = \{20, 25, 30\}$. Neue Zentren: $z_1 = 7$; $z_2 = 25$.

Iteration 5: Grenze bei 16: Zuordnung unverändert
 $\Rightarrow$ **Konvergenz** mit $C_1 = \{2, 3, 4, 10, 11, 12\}$, $C_2 = \{20, 25, 30\}$, Zentren 7 und 25.

(b) k-Means ist *partitionierend* (feste Aufteilung, kein Baum),
exklusiv (jeder Punkt genau ein Cluster), *vollständig* (jeder Punkt wird zugeordnet)
und arbeitet mit *vorgegebener* Clusteranzahl K .

Aufgabe 2.3

Eigene Aufgabe · Silhouette

Für einen Punkt $\vec{x}$ wurden berechnet: mittlerer Abstand zum eigenen Cluster $a(\vec{x}) = 2$,
mittlerer Abstand zum nächstgelegenen fremden Cluster $b(\vec{x}) = 6$.

- Berechnen Sie die Silhouette $s(\vec{x})$ und interpretieren Sie den Wert.
- Welche Werte ergäben sich für $(a, b) = (4, 4)$ und $(a, b) = (6, 2)$,
und was bedeuten sie?
- Wozu dient der *Silhouettenkoeffizient* (Mittel über alle Punkte)
und warum eignet er sich zur Wahl von K ?

Lösung

(a) $s = \frac{b-a}{\max(a,b)} = \frac{6-2}{6} = \frac{2}{3} \approx 0,67$, nahe +1: Punkt passt gut in sein Cluster und ist klar vom Nachbarcluster getrennt.

(b) (4, 4): $s = 0$, Grenzfall zwischen zwei Clustern. (6, 2): $s = \frac{2-6}{6} = -\frac{2}{3}$, der Punkt liegt näher am fremden Cluster, vermutlich *falsch zugeordnet*.

(c) Der Silhouettenkoeffizient $\frac{1}{N} \sum_{\vec{x}} s(\vec{x}) \in [-1, 1]$ bewertet die Gesamtqualität einer Clusterung; nahe 1 = gut. Er ist weitgehend *unabhängig von K* und erlaubt daher den Vergleich von Clusterungen mit verschiedenem K (Rousseeuw: $K = 2..n$ testen, Maximum wählen), idealerweise kombiniert mit der Elbow-Methode.

Aufgabe 2.4

Eigene Aufgabe · DBSCAN

Gegeben die Punkte auf der Zahlengeraden

$$P = \{1, 2, 3, 7, 8, 9, 15\}$$

mit $\varepsilon = 1,5$ und $MinPts = 2$

(Bedingung Kernobjekt: *mehr als MinPts* Punkte in der ε -Umgebung, der Punkt selbst zählt mit).

- Bestimmen Sie für jeden Punkt die ε -Umgebung und klassifizieren Sie ihn als Kern-, Rand- oder Rauschpunkt.
- Geben Sie die resultierenden Cluster an.
- Erklären Sie die Begriffe *direkt erreichbar*, *erreichbar* und *verbunden* und geben Sie an, welche dieser Relationen symmetrisch sind.
- Warum kann DBSCAN nichtkonvexe Cluster finden, k-Means aber nicht?

Lösung

(a) Umgebungen (Punkte mit Abstand $< 1,5$, inkl. selbst):

Punkt	U_ϵ	$ U_\epsilon $	Typ ($> 2?$)
1	$\{1, 2\}$	2	kein Kern
2	$\{1, 2, 3\}$	3	Kernpunkt
3	$\{2, 3\}$	2	kein Kern
7	$\{7, 8\}$	2	kein Kern
8	$\{7, 8, 9\}$	3	Kernpunkt
9	$\{8, 9\}$	2	kein Kern
15	$\{15\}$	1	kein Kern

1, 3 liegen in der Umgebung des Kernpunkts 2 $\Rightarrow$ **Randpunkte**; 7, 9 analog zu Kernpunkt 8 $\Rightarrow$ **Randpunkte**; 15 ist weder Kern noch erreichbar $\Rightarrow$ **Rauschpunkt**.

(b) Cluster 1 = $\{1, 2, 3\}$, Cluster 2 = $\{7, 8, 9\}$; 15 bleibt Ausreißer (DBSCAN ist *partiell*).

(c) *Direkt erreichbar*: $\vec{x} \in U_\epsilon(\vec{y})$ und $\vec{y}$ ist Kernobjekt. *Erreichbar*: Kette direkter Erreichbarkeiten (nur das letzte Glied darf Randpunkt sein; transitiv). *Verbunden*: beide Punkte sind von einem gemeinsamen dritten Punkt aus erreichbar. Symmetrie: direkte Erreichbarkeit und Erreichbarkeit sind nur *für Kernobjekte* symmetrisch;

Verbundenheit ist immer symmetrisch.

(d) k-Means ordnet jeden Punkt dem nächsten *Zentrum* zu – die Cluster Grenzen sind Voronoi-Zellen, also konvex; verschachtelte Ringe oder Halbmonde lassen sich so nicht trennen. DBSCAN definiert Cluster über *Dichteverbundenheit*:

Die Form ergibt sich aus den Daten selbst und kann beliebig sein.

Aufgabe 2.5

Eigene Aufgabe (Konzept) · Verfahrensvergleich

- (a) Erklären Sie die Elbow-Methode zur Wahl von K (inkl. Skizze der typischen Kurve).
- (b) Single vs. Complete vs. Average vs. Centroid Linkage:
Ordnen Sie jeder Methode ihre Definition zu.
- (c) Warum ist der *Medoid* robuster gegen Ausreißer als der Schwerpunkt?
Nennen Sie den zugehörigen Algorithmus und seine beiden Phasen.
- (d) Nennen Sie zwei Gründe, warum das k-Means-Ergebnis zweimal hintereinander unterschiedlich ausfallen kann, und die Standard-Abhilfe.

Lösung

- (a) Für $K = 1, 2, 3, \dots$ k-Means laufen lassen und den SSE plotten. Der SSE fällt monoton; gewählt wird das K am „Ellenbogen“, wo die Abnahme deutlich abflacht, davor bringt jedes zusätzliche Cluster viel, danach kaum noch etwas.
- (b) Single = *minimaler* paarweiser Abstand zwischen den Clustern; Complete = *maximaler*; Average = *Durchschnitt* aller Paare; Centroid = Abstand der *Schwerpunkte*.
- (c) Der Medoid ist ein *echter Datenpunkt* mit minimaler durchschnittlicher Distanz zu allen Punkten seines Clusters, Extremwerte ziehen ihn nicht wie einen Mittelwert nach außen. Algorithmus: **PAM** mit *BUILD*-Phase (initiale Medoids) und *SWAP*-Phase (iterativ Medoid gegen Nicht-Medoid tauschen, solange die Gesamtdistanz sinkt). Nachteil: quadratische Laufzeit.
- (d)
- (1) Zufällige Initialisierung der Zentren
→ Konvergenz in unterschiedliche *lokale* Minima (das exakte Problem ist NP-hart);
 - (2) ggf. zufällige Reihenfolge/leere Cluster-Behandlung. Abhilfe: mehrfacher Lauf mit verschiedenen Initialisierungen, Auswahl des Ergebnisses mit kleinstem SSE.

3 PCA und Kernel-PCA**Strategie & typische Fehler****Rezept PCA-Rechenaufgabe:**

- (1) Mittelwert,
- (2) zentrieren,
- (3) $\mathbf{C} = \frac{1}{N-1} \mathbf{G} \mathbf{G}^T$,
- (4) $\det(\mathbf{C} - \lambda \mathbf{I}) = 0$ lösen (Eigenwerte *absteigend* nummerieren!),
- (5) $(\mathbf{C} - \lambda_i \mathbf{I}) \vec{e}_i = 0$ lösen und *normieren*,
- (6) transformieren $\vec{g}' = \mathbf{U}^T (\vec{g} - \vec{g}_{mean})$,
- (7) ggf. reduzieren + rekonstruieren.

Typische Fehler: Zentrierung vergessen; Nenner N statt $N - 1$;
Eigenvektoren nicht normiert; bei der Rücktransformation $\vec{g}_{mean}$ vergessen.

Aufgabe 3.1

Vorlesungsbeispiel, vollständig ausgearbeitet · PCA komplett

Gegeben die Merkmalsvektoren

$$\vec{g}_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \vec{g}_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \vec{g}_3 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}, \quad \vec{g}_4 = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \quad \vec{g}_5 = \begin{pmatrix} 5 \\ 5 \end{pmatrix}$$

- (a) Berechnen Sie Mittelwert, zentrierte Datenmatrix und Kovarianzmatrix.
- (b) Berechnen Sie Eigenwerte und normierte Eigenvektoren;
stellen Sie die Transformationsmatrix $\mathbf{U}$ auf.
- (c) Wie viel Varianz erklärt die erste Hauptkomponente?
- (d) Transformieren Sie $\vec{x} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$, reduzieren Sie auf $i_0 = 1$ Komponente und rekonstruieren Sie den Punkt.

Lösung

(a) $\vec{g}_{mean} = \frac{1}{5} \begin{pmatrix} 3+1+4+2+5 \\ 3+1+2+4+5 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$. Zentriert: $\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} -2 \\ -2 \end{pmatrix}, \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 2 \end{pmatrix}$.

$$G = \begin{pmatrix} 0 & -2 & 1 & -1 & 2 \\ 0 & -2 & -1 & 1 & 2 \end{pmatrix} \quad \mathbf{C} = \frac{1}{4} G G^T = \frac{1}{4} \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix} = \begin{pmatrix} 2,5 & 1,5 \\ 1,5 & 2,5 \end{pmatrix}$$

(Kontrolle GG^T : Diagonale $0 + 4 + 1 + 1 + 4 = 10$; Nebendiagonale $0 + 4 - 1 - 1 + 4 = 6$.)

(b) Charakteristisches Polynom:

$$\det(\mathbf{C} - \lambda I) = (2,5 - \lambda)^2 - 1,5^2 = 0 \Leftrightarrow \lambda^2 - 5\lambda + 4 = 0 \Rightarrow \lambda_{1,2} = \frac{5 \pm \sqrt{25 - 16}}{2} = \frac{5 \pm 3}{2}$$

$$\boxed{\lambda_1 = 4, \quad \lambda_2 = 1} \quad (\text{absteigend!})$$

Eigenvektor zu $\lambda_1 = 4$: $(\mathbf{C} - 4I)\vec{e} = \begin{pmatrix} -1,5 & 1,5 \\ 1,5 & -1,5 \end{pmatrix} \vec{e} = \vec{0} \Rightarrow e_1 = e_2$, normiert: $\vec{e}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

Zu $\lambda_2 = 1$: $e_1 = -e_2$, normiert $\vec{e}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$.

$$\mathbf{U} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

(c) $\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{4}{5} = 80\%$ der Gesamtvarianz ($\text{tr}(\mathbf{C}) = 5 = \lambda_1 + \lambda_2$ ✓).

(d) Transformation:

$$\vec{x}' = \mathbf{U}^T (\vec{x} - \vec{g}_{mean}) = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} -3 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -4 \\ 2 \end{pmatrix} \approx \begin{pmatrix} -2,83 \\ 1,41 \end{pmatrix}$$

Reduktion ($i_0 = 1$): $\vec{x}'' = \frac{1}{\sqrt{2}} \begin{pmatrix} -4 \\ 0 \end{pmatrix}$. Rekonstruktion:

$$\vec{x}_{rek} = \vec{g}_{mean} + \mathbf{U} \vec{x}'' = \begin{pmatrix} 3 \\ 3 \end{pmatrix} + \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} -4 \\ 0 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} + \begin{pmatrix} -2 \\ -2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Der rekonstruierte Punkt liegt auf der ersten Hauptachse ($y = x$),
die Information senkrecht dazu ging durch die Reduktion verloren.

Aufgabe 3.2 PCA-Beispiel 2 der Vorlesung, nachgerechnet · PCA mit unsymmetrischen Daten

Gegeben $\vec{x}_1 = \begin{pmatrix} -2 \\ 1 \end{pmatrix}$, $\vec{x}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$, $\vec{x}_3 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ ($n = 3$).

(a) Zentrieren Sie die Daten und stellen Sie die Kovarianzmatrix auf.

(b) Berechnen Sie die Eigenwerte
und die relative erklärte Varianz der ersten Hauptkomponente.

Lösung

(a) $\vec{\mu} = \frac{1}{3} \begin{pmatrix} -2+0+2 \\ -1+1+1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1/3 \end{pmatrix}$. Zentriert: $\begin{pmatrix} -2 \\ -4/3 \end{pmatrix}, \begin{pmatrix} 0 \\ 2/3 \end{pmatrix}, \begin{pmatrix} 2 \\ 2/3 \end{pmatrix}$.

$$\mathbf{C} = \frac{1}{2} \begin{pmatrix} (-2)^2 + 0 + 2^2 & (-2)(-\frac{4}{3}) + 0 + 2 \cdot \frac{2}{3} \\ \cdot & (\frac{4}{3})^2 + (\frac{2}{3})^2 + (\frac{2}{3})^2 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 8 & 4 \\ 4 & \frac{8}{3} \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & \frac{4}{3} \end{pmatrix}$$

(b) $\det(\mathbf{C} - \lambda I) = (4 - \lambda)(\frac{4}{3} - \lambda) - 4 = \lambda^2 - \frac{16}{3}\lambda + \frac{4}{3} = 0$, also $3\lambda^2 - 16\lambda + 4 = 0$:

$$\lambda_{1,2} = \frac{16 \pm \sqrt{256 - 48}}{6} = \frac{16 \pm \sqrt{208}}{6} \Rightarrow \lambda_1 \approx 5,07, \quad \lambda_2 \approx 0,26$$

Erklärte Varianz PC1: $\frac{5,07}{5,33} \approx 95\%$, die Projektion auf eine Dimension ist hier fast verlustfrei.

Aufgabe 3.3**Eigene Aufgabe (Konzept) · PCA-Verständnis**

- (a) Was sind die Hauptkomponenten einer PCA, geometrisch und algebraisch? Welche Eigenschaft haben die transformierten Merkmale untereinander?
- (b) Warum müssen die Daten vor der PCA skaliert/standardisiert werden? Was passiert sonst?
- (c) Ein Datensatz hat $N = 40$ Bilder mit je $d = 10\,304$ Pixeln (Eigenfaces). Wie viele Eigenwerte ungleich Null kann die Kovarianzmatrix höchstens haben, und welches numerische Problem tritt bei $\mathbf{C} \in \mathbb{R}^{10304 \times 10304}$ auf?
- (d) Nennen Sie vier Vorteile und drei Nachteile/Fallstricke der PCA.

Lösung

(a) Geometrisch: die orthogonalen Richtungen *maximaler Varianz* der zentrierten Daten (neues, gedrehtes Koordinatensystem). Algebraisch: die *Eigenvektoren der Kovarianzmatrix*; die zugehörigen Eigenwerte sind die Varianzen entlang dieser Richtungen. Die transformierten Merkmale sind **unkorreliert**, und jeder Merkmalsvektor lässt sich als Linearkombination der Eigenvektoren darstellen.

(b) Die PCA maximiert Varianz, Merkmale mit großen Zahlenwerten (z. B. Einkommen in Euro) dominieren die Kovarianzmatrix unabhängig von ihrem Informationsgehalt. Merkmale mit kleiner Streuung werden „plattgemacht“, selbst wenn sie trennwirksam sind. Daher vorher Standardisierung (z-Score).

(c) Höchstens $N = 40$ Eigenwerte $\neq 0$ (Rang der Datenmatrix ist durch die Anzahl der Beispiele beschränkt). Problem: $\mathbf{C}$ hat $10\,304^2 \approx 1,06 \cdot 10^8$ Einträge, Speicher/Numerik-Probleme, Singularitäten durch dünne Besetzung. Ausweg: Singulärwertzerlegung (SVD) der Datenmatrix G statt Eigenzerlegung von $\mathbf{C}$.

(d) Vorteile: Dimensionsreduktion, Rauschreduktion, unkorrelierte Features (oft bessere Modelle), bessere Visualisierung (zusätzlich: Kompression). Nachteile: setzt *lineare* Zusammenhänge voraus; empfindlich gegenüber *Ausreißern* und *Skalierung*; Hauptkomponenten inhaltlich schwer interpretierbar; Trainingsmenge muss repräsentativ sein.

Aufgabe 3.4

Vorlesungsübung Preisach, ausgearbeitet · Kernel-Matrix

Gegeben die Datenpunkte $\vec{g}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, $\vec{g}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$, $\vec{g}_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

- (a) Berechnen Sie die Kernelmatrix K für den *linearen* Kernel $k(\vec{u}, \vec{v}) = \vec{u}^T \vec{v}$.
- (b) Welche Dimension hat K allgemein (bei N Punkten in $\mathbb{R}^d$), und worin unterscheidet sie sich von der Kovarianzmatrix?
- (c) Erklären Sie den Kernel-Trick in zwei Sätzen. Warum berechnet man ϕ nie explizit?
- (d) Geben Sie die Formeln des polynomiellen und des RBF-Kernels an. Was ist der Spezialfall des polynomiellen Kernels mit $c = 0$, $r = 1$?

Lösung

(a) $K_{ij} = \vec{g}_i^T \vec{g}_j$:

$$K = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

(z. B. $K_{13} = 1 \cdot 1 + 0 \cdot 1 = 1$, $K_{33} = 1 + 1 = 2$.)

(b) $K \in \mathbb{R}^{N \times N}$, ein Eintrag pro *Punktepaar*; die Kovarianzmatrix ist $d \times d$ (ein Eintrag pro *Merkmalspaar*). Bei der Kernel-PCA wird deshalb die $(N \times N)$ Kernelmatrix zentriert und zerlegt.

(c) Statt die Daten explizit mit einer nichtlinearen Abbildung ϕ in einen höherdimensionalen Raum zu transformieren, ersetzt man überall das Skalarprodukt durch eine Kernelfunktion $k(\vec{u}, \vec{v}) = \phi(\vec{u})^T \phi(\vec{v})$, die dieses Skalarprodukt *direkt* liefert. Das ist erheblich effizienter, der Zielraum kann sogar unendlichdimensional sein (RBF), explizites ϕ wäre unmöglich.

(d) Polynomiell: $k(\vec{u}, \vec{v}) = (\vec{u}^T \vec{v} + c)^r$; RBF/Gauß: $k(\vec{u}, \vec{v}) = e^{-\|\vec{u} - \vec{v}\|^2 / (2\sigma^2)} = e^{-\gamma \|\vec{u} - \vec{v}\|^2}$.
Spezialfall $c = 0, r = 1$: der *lineare Kernel* = gewöhnliches Skalarprodukt (keine Änderung gegenüber der normalen PCA).

Teil II

Aufgaben zum Teil Janka

Lineare Modelle · Neuronale Netze · CNN & Autoencoder

4 Lineare Regression

Strategie & typische Fehler

Rezept „Loss aufstellen“: pro Datenpunkt eine Klammer $(y_i - (w_0 + w_1x_{i1} + w_2x_{i2}))^2$, alles summieren, Faktor $\frac{1}{N}$ davor. Kategorische Features als 0/1 kodieren und die Kodierung *hinschreiben*.

Typische Fehler: $\frac{1}{N}$ vergessen; Kodierung nicht angegeben; bei „ w_0 weglassen“ trotzdem w_0 hingeschrieben; Feature- und Labelspalte verwechselt (SS23: Features sind die *Vorjahresumsätze*!).

Aufgabe 4.1

Klausur SS22, A1, abgewandelt · Vorhersage + Loss

Ein Modell sagt das Jahreseinkommen [T€] von Angestellten vorher aus x_1 = Betriebszugehörigkeit [Monate] und x_2 = Hochschulabschluss (0 = nein, 1 = ja). Lineare Regression ergab $w_0 = 25$, $w_1 = 0,1$, $w_2 = 15$.

- Vorhersage für eine Angestellte mit Abschluss und 20 Monaten Zugehörigkeit?
- Stellen Sie die Least-Squares-Verlustfunktion für folgenden Datensatz auf und werten Sie sie für die gegebenen Parameter aus:

	Zugehörigkeit [Mon.]	Abschluss	Gehalt [T€]
P1	20	ja	43
P2	62	ja	65
P3	30	nein	32

- Wie prüft man mathematisch, ob die gegebenen Parameter optimal sind (kein Ausrechnen verlangt)?

Lösung

(a) $\hat{y} = 25 + 0,1 \cdot 20 + 15 \cdot 1 = 42 \Rightarrow$ das Modell sagt 42 000 € Jahresgehalt vorher.

(b) Kodierung ja = 1, nein = 0:

$$L(w_0, w_1, w_2) = \frac{1}{3} \left[(43 - (w_0 + 20w_1 + w_2))^2 + (65 - (w_0 + 62w_1 + w_2))^2 + (32 - (w_0 + 30w_1))^2 \right]$$

Auswertung mit (25, 0,1, 15): Vorhersagen 42, 46,2, 28; Residuen 1, 18,8, 4:

$$L = \frac{1}{3} (1^2 + 18,8^2 + 4^2) = \frac{1}{3} (1 + 353,44 + 16) = \frac{370,44}{3} \approx 123,5$$

(Hinweis: Die offizielle Musterlösung gibt 214,48 an, dieser Wert lässt sich mit den angegebenen Zahlen nicht reproduzieren (Rechenfehler in der Musterlösung).

Nachrechnen ergibt $370,44/3 = 123,48$.

Bewertet wird ohnehin primär der korrekte **Aufbau** der Verlustfunktion.)

(c) Notwendige Optimalitätsbedingung prüfen:

Der **Gradient der Verlustfunktion muss verschwinden**,

d. h. alle partiellen Ableitungen $\frac{\partial L}{\partial w_0} = \frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial w_2} = 0$, kompakt $\nabla L(w_0, w_1, w_2) = \mathbf{0}$.

Aufgabe 4.2

Klausur SS23, A1, abgewandelt · Loss mit Zeitreihen-Features

Eine Firma sagt den Jahresumsatz aus den Umsätzen der beiden Vorjahre vorher (x_1 = Vorjahr, x_2 = vorletztes Jahr; ohne w_0). Umsatzhistorie:

Jahr	2017	2018	2019	2020	2021
Umsatz [M€]	30	45	50	57	60

(a) Welche Trainingspaare $(\mathbf{x}_i, y_i)$ entstehen aus dieser Tabelle?

(b) Stellen Sie die Least-Squares-Verlustfunktion auf.

(c) Beschreiben Sie den allgemeinen Entwicklungsprozess eines Supervised-Learning-Modells in vier Schritten.

Lösung

(a) Eine Vorhersage braucht zwei zurückliegende Jahre, erst ab 2019 möglich:

$$((45, 30), 50), \quad ((50, 45), 57), \quad ((57, 50), 60)$$

(b)

$$L(w_1, w_2) = \frac{1}{3} \left[(50 - (45w_1 + 30w_2))^2 + (57 - (50w_1 + 45w_2))^2 + (60 - (57w_1 + 50w_2))^2 \right]$$

(c)

(1) Feature-Label-Paare $(\mathbf{x}_i, y_i)$ sammeln;

(2) Split in Trainings- und Testdaten;

(3) Training auf den Trainingsdaten: Funktion f mit $f(\mathbf{x}_i) \approx y_i$ suchen (= Loss minimieren);

(4) Evaluation auf den Testdaten mit geeigneter Metrik (z. B. RMSE, R^2).

Aufgabe 4.3

Klausur WS23/24, A1, abgewandelt · Loss mit kategorischem Feature

Heizenergieverbrauch [kWh] eines Bürogebäudes aus Außentemperatur [°C] und Nutzung (wenige/viele Personen):

Tag	Temperatur	Nutzung	Verbrauch
1	4	wenige	800
2	6	viele	700
3	-1	wenige	1000

Stellen Sie die Least-Squares-Verlustfunktion für ein gewöhnliches lineares Regressionsmodell auf (Kodierung angeben!).

Lösung

Kodierung: $x_2 = 0$ für „wenige“, $x_2 = 1$ für „viele“ Personen.

$$L(w_0, w_1, w_2) = \frac{1}{3} \left[(800 - (w_0 + 4w_1))^2 + (700 - (w_0 + 6w_1 + w_2))^2 + (1000 - (w_0 - w_1))^2 \right]$$

Achtung: Bei Tag 3 ist die Temperatur negativ, $w_1 \cdot (-1)$ sauber einsetzen.

Aufgabe 4.4

Eigene Aufgabe · Gütemaße und Bias-Variance

Ein Regressionsmodell liefert auf dem Testdatensatz die Vorhersagen $\hat{y} = (10, 14, 8)$ bei echten Werten $y = (12, 14, 4)$; der Mittelwert der echten Werte ist $\bar{y} = 10$.

- Berechnen Sie MSE, RMSE und MAE.
- Berechnen Sie R^2 und interpretieren Sie den Wert.
- Modell A hat Trainings- $R^2 = 0,97$ / Test- $R^2 = 0,55$;
Modell B hat 0,78 / 0,74. Diagnostizieren Sie beide Modelle (Bias/Variance) und nennen Sie je zwei Maßnahmen.

Lösung

(a) Residuen: $(12-10, 14-14, 4-8) = (2, 0, -4)$.

$$MSE = \frac{4 + 0 + 16}{3} = \frac{20}{3} \approx 6,67 \quad RMSE = \sqrt{6,67} \approx 2,58 \quad MAE = \frac{2 + 0 + 4}{3} = 2$$

(b) $RSS = 20$; $TSS = (12-10)^2 + (14-10)^2 + (4-10)^2 = 4 + 16 + 36 = 56$.

$$R^2 = 1 - \frac{20}{56} \approx 0,64$$

Das Modell erklärt rund 64 % der Varianz der Zielvariablen, deutlich besser als die Mittelwert-Vorhersage ($R^2 = 0$), aber nicht perfekt ($R^2 = 1$).

(c) **Modell A: Overfitting** (hohe Variance), großer Abstand Training/Test.

Maßnahmen: mehr/diversere Daten, Komplexität reduzieren, Regularisierung (Ridge/Lasso), Kreuzvalidierung zur Modellwahl.

Modell B: gut generalisierend, leichter Bias, Training und Test nah beieinander. Falls die Güte insgesamt nicht reicht (Underfitting): Komplexität erhöhen, z. B. nichtlineare Features ergänzen oder flexibleres Modell wählen.

5 Logistische Regression und Klassifikationsmetriken

Strategie & typische Fehler

Rezepte: Wahrscheinlichkeit $= \sigma(w_0 + \mathbf{w}^T \mathbf{x})$; Exponent sauber ausrechnen, Vorzeichen prüfen (e^{-z} !). „Näher an 0 oder 1?“: Vorzeichen des linearen Arguments z ansehen ($z > 0 \Rightarrow \hat{y} > 0,5$). 50%-Fragen: $z = 0$ setzen. Metriken: erst TP/FP/FN/TN zählen, dann Brüche, unvereinfachte Brüche reichen oft.

Typische Fehler: Minuszeichen im Exponenten verschlampt; Precision und Recall verwechselt (Merkhilfe: **Recall** = wie viele der echten Positiven *abgerufen* wurden).

Aufgabe 5.1

Probeklausur SS22, A1, abgewandelt · Logistische Regression komplett

Vor einer Klausur wurden erhoben: $x_1 =$ „Stunden gelernt“, $x_2 =$ „bisheriger Notendurchschnitt“; Label $y = 1$, falls Klausurnote $< 2,0$. Logistische Regression ergab $w_0 = -2$, $w_1 = 0,05$, $w_2 = -1$.

- Mit welcher Wahrscheinlichkeit erreicht ein Studierender mit 40 Lernstunden und Schnitt 2,3 eine Note besser als 2,0?
- Berechnen Sie den Log-Loss für den Datensatz $((40; 2,7), 0), ((5; 3,3), 0), ((40; 1,3), 1)$.
- Wie viele Stunden müsste der Studierende aus (a) lernen, um auf 50 % Wahrscheinlichkeit zu kommen?

Lösung

(a) $z = -2 + 0,05 \cdot 40 - 2,3 = -2,3$:

$$\hat{y} = \frac{1}{1 + e^{2,3}} \approx \frac{1}{1 + 9,97} \approx 0,091 \Rightarrow \approx 9,1 \%$$

(b) Vorhersagen:

$$\hat{y}^{(1)} = \sigma(-2 + 2 - 2,7) = \sigma(-2,7) \approx 0,063;$$

$$\hat{y}^{(2)} = \sigma(-2 + 0,25 - 3,3) = \sigma(-5,05) \approx 0,006;$$

$$\hat{y}^{(3)} = \sigma(-2 + 2 - 1,3) = \sigma(-1,3) \approx 0,214.$$

$$L = -\frac{1}{3} [\log(1 - 0,063) + \log(1 - 0,006) + \log(0,214)] = -\frac{1}{3} [-0,065 - 0,006 - 1,542] \approx 0,54$$

(Für $y = 0$ zählt $\log(1 - \hat{y})$, für $y = 1$ zählt $\log \hat{y}$.)

(c) $\sigma(z) = 0,5 \Leftrightarrow z = 0$:

$$-2 + 0,05 T - 2,3 = 0 \Leftrightarrow T = \frac{4,3}{0,05} = 86 \text{ Stunden}$$

Aufgabe 5.2

Klausur WS25/26, A1, abgewandelt · Vorhersage + Einzel-Loss

Unfallvorhersage an einer Kreuzung:

$x_1 = \text{Niederschlag [mm]}$, $x_2 = \text{Tageszeit (Tag = 1)}$, $x_3 = \text{Schienenüberquerung (ja = 1)}$;
 $y = 1$ bei Unfall. Training ergab $w_0 = 0$, $w_1 = 4$, $w_2 = -1$, $w_3 = -7$.

- Unfallwahrscheinlichkeit für: 2 mm Niederschlag, Tag, Schienenüberquerung?
- Welche Verlustfunktion wird beim Training verwendet? Berechnen Sie den Verlust für diese Beobachtung, wenn tatsächlich *kein* Unfall passierte.
- Begründen Sie zweifach, warum die Sigmoid-Funktion verwendet wird.

Lösung

(a) $z = 0 + 4 \cdot 2 - 1 \cdot 1 - 7 \cdot 1 = 0$: $\hat{y} = \sigma(0) = \frac{1}{1+e^0} = 0,5$.

(b) **(Binäre) Kreuzentropie / Log-Loss**. Für $y = 0$:

$$\ell = -\log(1 - \hat{y}) = -\log(0,5) \approx 0,69$$

(c)

- Sie beschränkt die Ausgabe auf $(0, 1)$, interpretierbar als Wahrscheinlichkeit.
- Sie ist stetig und differenzierbar, Training mit Gradientenverfahren möglich (die Stufenfunktion des Perzeptrons wäre es nicht).

Aufgabe 5.3

Klausur WS22/23, A1, abgewandelt · Schwellwert und Precision

Fahrradverleih: $x_1 = \text{Temperatur } [^{\circ}\text{C}]$, $x_2 = \text{Regen (ja = 1)}$;
 $y = 1$, wenn ≥ 100 Räder verliehen werden.

Logistische Regression: $w_0 = -15$, $w_1 = 1$, $w_2 = -0,1$.

- Welche Wahrscheinlichkeit berechnet das Modell für einen regenfreien Tag mit 8°C ?
Liegt die Vorhersage näher an 0 oder 1?
- Bei welcher Temperatur (ohne Regen) liegt die Wahrscheinlichkeit bei genau 50%?
- Nennen Sie eine einfache Möglichkeit, die *Precision* des Modells zu erhöhen, und erklären Sie den Mechanismus.

Lösung

(a) $z = -15 + 8 = -7$: $\hat{y} = \frac{1}{1+e^z} \approx 0,0009$, deutlich näher an **0** ($z < 0 \Rightarrow \hat{y} < 0,5$).

(b) $-15 + x_1 = 0 \Rightarrow x_1 = 15^{\circ}\text{C}$.

(c) Den **Schwellwert** B (Default 0,5) **erhöhen**: Das Modell sagt nur noch bei sehr hoher Sicherheit „positiv“. Dadurch sinkt die Zahl der False Positives, und $\text{Precision} = \frac{TP}{TP+FP}$ steigt (auf Kosten des Recalls, es werden mehr echte Positive verpasst).

Aufgabe 5.4

Klausur WS25/26, A2, abgewandelt + erweitert · Konfusionsmatrix

Ein binärer Klassifikator liefert auf 10 Testbeispielen:

	echt 1	echt 0
Vorhersage 1	2	2
Vorhersage 0	3	3

- Berechnen Sie Accuracy, Precision, Recall und False Positive Rate.
- Erklären Sie den Unterschied zwischen Precision und Recall und welche Fehlklassifikationen jeweils relevant sind.
- Nennen Sie je ein Anwendungsbeispiel mit hoher Relevanz für Recall bzw. Precision (mit Begründung).
- Warum kann bei stark unausgewogenen Klassen (99,9% negativ) die Accuracy in die Irre führen?

Lösung

(a) $TP = 2, FP = 2, FN = 3, TN = 3$:

$$\text{Accuracy} = \frac{2+3}{10} = 0,5 \quad \text{Precision} = \frac{2}{2+2} = 0,5$$

$$\text{Recall} = \frac{2}{2+3} = 0,4 \quad \text{FPR} = \frac{2}{2+3} = 0,4$$

(b) **Precision:** Anteil der als positiv klassifizierten Beispiele, die tatsächlich positiv sind, sensibel gegenüber *False Positives*.

Recall: Anteil der tatsächlich positiven Beispiele, die das Modell findet, sensibel gegenüber *False Negatives*.

(c) *Recall:* medizinische Diagnostik (Krebsfrüherkennung), ein übersehener Kranker (FN) hat schwerwiegende Folgen.

Precision: Spam-Filter, eine wichtige Mail fälschlich im Spam-Ordner (FP) ist teurer als gelegentlicher durchgerutschter Spam.

(d) Der Trivialklassifikator „immer negativ“ erreicht dort 99,9% Accuracy, erkennt aber keinen einzigen positiven Fall (Recall = 0). Accuracy allein ist bei unausgewogenen Klassen ungeeignet, Precision/Recall (oder F1) betrachten.

Aufgabe 5.5

Eigene Aufgabe · Softmax und Mehrklassen-Konfusionsmatrix

- (a) Ein Netz liefert für 3 Klassen die Scores $\mathbf{z} = (2, 0, -1)^T$. Berechnen Sie $\text{softmax}(\mathbf{z})$ (gerundet auf 2 Stellen) und die vorhergesagte Klasse.
- (b) Begründen Sie kurz, warum Softmax-Ausgaben als Wahrscheinlichkeitsverteilung gelten dürfen.
- (c) Wettervorhersage mit 3 Klassen, Konfusionsmatrix (Zeilen = Vorhersage, Spalten = echt):

	Regen	Schnee	Sonne
Regen	70	10	10
Schnee	20	90	5
Sonne	10	20	60

Berechnen Sie die Accuracy sowie Recall für „Schnee“ und „Sonne“.

Lösung

(a) $e^2 \approx 7,39$, $e^0 = 1$, $e^{-1} \approx 0,37$; Summe $\approx 8,76$:

$$\text{softmax}(\mathbf{z}) \approx (0,84, 0,11, 0,04)^T$$

Vorhersage: Klasse 1

(größter Score bleibt größte Wahrscheinlichkeit, Softmax ist ordnungserhaltend).

(b) Alle Komponenten liegen in $(0, 1)$ (Exponentialfunktion ist positiv) und summieren sich per Konstruktion (Normierung durch $\sum_j e^{z_j}$) zu 1.

(c) $N = 295$; Diagonale = $70 + 90 + 60 = 220$:

$$\text{Accuracy} = \frac{220}{295} \approx 0,75$$

Recall(„Schnee“) = $\frac{90}{10+90+20} = 0,75$ (Spaltensumme!);

Recall(„Sonne“) = $\frac{60}{10+5+60} = 0,80$.

6 Regularisierung, Hyperparametersuche, Generalisierung

Strategie & typische Fehler

Rezept „Modelle zählen“:

- (1) Testset abziehen $\rightarrow$ Trainingsmenge;
- (2) Anzahl Kandidaten = $(\lambda\text{-Werte}) \times (\text{Verfahren})$;
- (3) mal k bei k -facher CV; Trainingsgröße pro Lauf = $\frac{k-1}{k}$ der Trainingsmenge;
- (4) + 1 **finales Modell** auf der ganzen Trainingsmenge nicht vergessen!

Standardantwort Regularisierung (kam in allen 5 Klausuren):

Ziel ist es, Overfitting (zu starkes Anpassen an die Trainingsdaten) zu vermeiden; erreicht wird das, indem beim Training die Modellflexibilität eingeschränkt wird.

Aufgabe 6.1

Klausur SS22, A2, abgewandelt · Regularisierung + Gittersuche

- (a) Was ist das Ziel von Regularisierung und wie wird es im Allgemeinen erreicht?
- (b) Nennen Sie zwei Möglichkeiten zur Regularisierung von neuronalen Netzen.
- (c) Warum benutzt man zur Hyperparametersuche nicht die Testdaten, sondern einen separaten Validierungsdatensatz?
- (d) 10 000 Datenpunkte, davon 40 % als Testset.
Gittersuche über 10 Werte für λ , jeweils für Lasso und Ridge, mit 3-facher Kreuzvalidierung:
Wie viele Modelle mit jeweils wie vielen Datenpunkten werden trainiert?

Lösung

- (a) Ziel: **Overfitting vermeiden** (zu starkes Anpassen an die Trainingsdaten). Erreicht wird das, indem beim Training die **Modellflexibilität eingeschränkt** wird (z. B. Strafterm auf große Koeffizienten).
- (b) Zwei aus: ℓ_1 -/ ℓ_2 -Strafterm (Weight Decay), **Dropout**, **Early Stopping** (SGD mit kleiner Batchgröße, problemabhängig).
- (c) Wer Hyperparameter anhand des Testfehlers wählt, optimiert implizit auf die Testdaten, der Testfehler wird ein zu optimistischer Schätzer (*Overfitting auf die Testdaten*). Das Validierungsset übernimmt die Auswahl, die Testdaten bleiben für die finale, unverzerrte Bewertung.
- (d) Trainingsmenge: 60 % = 6 000 Punkte. Kandidaten: $10 \cdot 2 = 20$; mit 3-facher CV: $20 \cdot 3 = 60$ **Modelle** mit je $\frac{2}{3} \cdot 6\,000 = 4\,000$ Trainingspunkten. Danach **1 finales Modell** mit dem besten Hyperparameter auf allen **6 000** Punkten.

Aufgabe 6.2 Klausur WS22/23, A2, abgewandelt · Gittersuche-Variante + Early Stopping

- (a) 10 000 Datenpunkte, 50 % Testset. Gittersuche: ℓ_1 - vs. ℓ_2 -Regularisierung, je 4 Werte für λ , 5-fache Kreuzvalidierung. Wie viele Modelle mit wie vielen Punkten?
- (b) Wofür wird Early Stopping eingesetzt? Beschreiben Sie das Vorgehen.

Lösung

- (a) Trainingsmenge 5 000. Kandidaten $2 \cdot 4 = 8$; mit 5-facher CV: $8 \cdot 5 = 40$ **Modelle** mit je $\frac{4}{5} \cdot 5\,000 = 4\,000$ Punkten; plus **1 finales Modell** auf **5 000** Punkten.
- (b) Early Stopping ist eine **Regularisierungstechnik** beim Training neuronaler Netze. Während des (stochastischen) Gradientenverfahrens beobachtet man Trainings- und Validierungs-/Testfehler: Anfangs sinken beide; ab einem Punkt steigt der Validierungsfehler wieder, obwohl der Trainingsfehler weiter fällt, ein Zeichen für beginnendes Overfitting. Man stoppt dann das Verfahren und lädt die zwischengespeicherten Koeffizienten der Iteration mit dem geringsten Validierungsfehler.

Aufgabe 6.3 Probeklausur SS22, A2c, abgewandelt · Validierungsset vs. CV

10 000 Datenpunkte für eine regularisierte lineare Regression, 20 % als Testset. Getestet werden 4 Werte für λ , jeweils für Lasso und Ridge.

- (a) Ansatz *Validierungsset*: 25 % der Trainingsdaten als Validierungsmenge. Wie viele Modelle mit wie vielen Punkten?
- (b) Ansatz *5-fache Kreuzvalidierung* (statt festem Validierungsset): Wie viele Modelle mit wie vielen Punkten?
- (c) Nenne Pro und Contra der Kreuzvalidierung gegenüber dem festen Validierungsset.

Lösung

- (a) Trainingsmenge 8 000; davon 25 % = 2 000 Validierung $\Rightarrow$ 6 000 zum Trainieren.
Kandidaten $4 \cdot 2 = 8 \Rightarrow$ **8 Modelle** à **6 000** Punkte
+ **1 finales Modell** auf **8 000** Punkten.
- (b) $8 \cdot 5 = 40$ **Modelle** mit je $\frac{4}{5} \cdot 8\,000 = 6\,400$ Punkten
+ **1 finales Modell** auf **8 000** Punkten.
- (c) *Vorteil:* stabilere Fehlerschätzung, jeder Punkt ist genau einmal Validierungspunkt, der Einfluss der zufälligen Aufteilung sinkt. *Nachteil:* k -fache Rechenzeit.

Aufgabe 6.4 Klausuren SS23 A2 / WS23/24 A2 / WS25/26 A3, kombiniert · Ridge vs. Lasso, Bias-Variance

- (a) Nennen Sie eine Möglichkeit, ein *lineares* Modell zu regularisieren, und einen typischen Umstand, der das nötig macht.
- (b) Welche beiden Nachteile entstehen durch die Regularisierung eines linearen Modells?
- (c) Erläutern Sie die Unterschiede zwischen Ridge- und Lasso-Regression (Norm, Wirkung auf die Parameter).
- (d) Erklären Sie den Bias-Variance-Tradeoff und den Einfluss der Modellkomplexität.
- (e) Beschreiben Sie die Rollen von Trainings-, Validierungs- und Testdaten bei der Hyperparametersuche.

Lösung

(a) Addition eines Strafterms (ℓ_1 oder ℓ_2) zur Verlustfunktion.

Nötig z. B., wenn es *mehr Features als Datenpunkte* gibt
oder bei *polynomiellen Features* / One-Hot-Encoding mit vielen Ausprägungen.

(b)

(1) Die Modellgüte auf den Trainingsdaten wird schlechter
(bewusst eingeschränkte Flexibilität);

(2) die Parameter sind nicht mehr direkt interpretierbar
(geschrumpfte Koeffizienten spiegeln nicht mehr den „wahren“ Einfluss wider).

(c) Beide addieren einen Strafterm zum empirischen Fehler.

Ridge bestraft die quadrierte ℓ_2 -Norm $\|\mathbf{w}\|_2^2$:

alle Koeffizienten werden *verkleinert*, aber selten exakt Null.

Lasso bestraft die ℓ_1 -Norm $\|\mathbf{w}\|_1$:

viele Koeffizienten werden *exakt Null*, spärliches Modell,

automatische Featureauswahl.

(d) **Bias** = systematischer Fehler durch zu starke Modellannahmen; **Varianz** = Empfindlichkeit des gelernten Modells gegenüber den (zufälligen) Trainingsdaten. Mit steigender Komplexität sinkt der Bias, die Varianz steigt (Richtung Overfitting); mit sinkender Komplexität (z. B. stärkere Regularisierung) steigt der Bias, die Varianz sinkt (Richtung Underfitting).

Gesucht ist der Sweet Spot mit minimalem Generalisierungsfehler.

(e)

Training: Modell für jede Hyperparameter-Kombination fitten.

Validierung: Leistung vergleichen
und beste Kombination auswählen.

Test: erst ganz am Ende einmalig die endgültige Modellleistung messen,
unverzerrte Schätzung des Generalisierungsfehlers.

Aufgabe 6.5

Eigene Aufgabe · Data Leakage

Beurteilen Sie für jedes Szenario, ob Data Leakage vorliegt,
und geben Sie die Abhilfe an:

- (a) Röntgenbilder mehrerer Patienten werden zufällig *bildweise* in Training und Test gesplittet; von manchen Patienten liegen mehrere Bilder vor.
- (b) Für die Vorhersage des Jahreseinkommens (USD) ist das Feature `MonthlySalaryGBP` enthalten.
- (c) Bei der Kreditvergabe wird das Feld `LatePaymentReminders` als Feature genutzt.
- (d) Die Z-Score-Standardisierung wird vor dem Train-Test-Split auf dem Gesamtdatensatz berechnet.

Lösung

(a) Leakage (schlechter Split): Dieselben Patienten tauchen in Training und Test auf, das Modell kann Patienteneinheiten wiedererkennen.

Abhilfe: nach *Patienten* splitten, nicht nach Bildern.

(b) Leakage (Stellvertreter-Label): Das Monatsgehalt ist eine (lineare) Funktion des Labels, perfekte, aber wertlose Vorhersage.

Abhilfe: Label-Duplikate/Stellvertreter entfernen.

(c) Leakage (Zukunftsinformation): Mahnungen existieren zum Zeitpunkt der Kreditvergabe noch nicht; das Feld wird erst später befüllt.

Abhilfe: Spalte löschen, nur Informationen verwenden, die zum Vorhersagezeitpunkt verfügbar sind.

(d) Leakage (Vorverarbeitung): $\bar{x}$ und σ enthalten Information aus den Testdaten.

Abhilfe: Skalierungsparameter nur auf den Trainingsdaten bestimmen und dann auf beide Mengen anwenden.

7 Neuronale Netze: Forward-Pass und SGD**Strategie & typische Fehler**

Rezept Forward-Pass: Pro verdecktem Neuron: gewichtete Summe der Eingänge + Bias, dann ReLU ($= \max(0, \cdot)$); Ergebnisse mit den Output-Gewichten summieren (+ Output-Bias). Bei Matrizenform: Zeile i von $\mathbf{W}^{[1]}$ = Gewichte, die *zum* i -ten Neuron führen.

Typische Fehler: ReLU auf negative Summe nicht angewendet ($\max(0, -3) = 0$, nicht $-3!$); Bias vergessen; bei der Funktionsformel Terme mit Gewicht 0 mitgeschleppt.

SGD-Dimensionen: Summanden = N ; Gradientendimension = Anzahl Parameter (*immer*, auch bei Minibatch!); Updates = Epochen $\times N/m$.

Aufgabe 7.1

Klausur SS22, A3, abgewandelt · Forward-Pass ohne Bias

Ein Netz hat 2 Eingänge (x_1, x_2), eine verdeckte Schicht mit 3 ReLU-Neuronen (ohne Bias) und ein lineares Output-Neuron (ohne Bias, keine Aktivierung).

Gewichte:

$$\mathbf{W}^{[1]} = \begin{pmatrix} 1 & 0 \\ 2 & 0 \\ -1 & 3 \end{pmatrix} \quad \mathbf{W}^{[2]} = \begin{pmatrix} -2 & 0 & 1 \end{pmatrix}$$

- Welche Funktion berechnet das Netz für beliebiges $(x_1, x_2)^T$?
- Welchen Wert liefert das Netz für $(x_1, x_2) = (-1, 2)$?
- Wie müsste die Ausgabeschicht modifiziert werden, um das Netz auf Klassifikationsprobleme mit K Klassen anzuwenden?

Lösung

(a) Verdeckte Neuronen: $a_1 = \max(0, x_1)$, $a_2 = \max(0, 2x_1)$, $a_3 = \max(0, -x_1 + 3x_2)$.
Output:

$$\begin{aligned} f(x_1, x_2) &= -2 \max(0, x_1) + 0 \cdot \max(0, 2x_1) + 1 \cdot \max(0, -x_1 + 3x_2) \\ &= -2 \max(0, x_1) + \max(0, -x_1 + 3x_2) \end{aligned}$$

(b)

$$f(-1, 2) = -2 \underbrace{\max(0, -1)}_{=0} + \max(0, 1 + 6) = 0 + 7 = \boxed{7}$$

(c) Ausgabeschicht mit K **Neuronen** statt einem; als Aktivierung die **Softmax-Funktion**, die die K Scores in eine Wahrscheinlichkeitsverteilung transformiert.

Aufgabe 7.2

Klausur SS23, A3a, abgewandelt · Forward-Pass mit Bias

Wie zuvor, aber: die verdeckten Neuronen haben jeweils Bias -1 ,
das Output-Neuron Bias $+1$.

Gewichte:

$$\mathbf{W}^{[1]} = \begin{pmatrix} 1 & 0 \\ 2 & 0 \\ -1 & 3 \end{pmatrix} \quad \mathbf{W}^{[2]} = \begin{pmatrix} -2 & -1 & 1 \end{pmatrix}$$

Welchen Wert liefert das Netz für $(x_1, x_2) = (-1, 2)$?

Lösung

Verdeckte Schicht (ReLU nach Summe *inklusive* Bias):

$$a_1 = \max(0, 1 \cdot (-1) + 0 \cdot 2 - 1) = \max(0, -2) = 0$$

$$a_2 = \max(0, 2 \cdot (-1) + 0 \cdot 2 - 1) = \max(0, -3) = 0$$

$$a_3 = \max(0, -1 \cdot (-1) + 3 \cdot 2 - 1) = \max(0, 6) = 6$$

Output: $\hat{y} = -2 \cdot 0 - 1 \cdot 0 + 1 \cdot 6 + 1 = \boxed{7}$ (Originalzahlen der Klausur ergeben 6,
Mechanik identisch: Bias in die Summe, ReLU, dann Output-Bias addieren.)

Aufgabe 7.3

Klausur WS23/24, A3, abgewandelt · Matrizen ablesen + 2 Output-Neuronen

Gegeben ein Netz: 2 Eingänge, verdeckte Schicht mit 3 ReLU-Neuronen, Ausgabeschicht mit 2 linearen Neuronen (alle ohne Bias).

Kanten: Neuron 1 erhält $1 \cdot x_1$;

Neuron 2 erhält $-2 \cdot x_1$;

Neuron 3 erhält $-1 \cdot x_1 + 3 \cdot x_2$.

Output 1 = $-2a_1 - a_2 + 3a_3$; Output 2 = $4a_3$.

- Geben Sie die Koeffizientenmatrizen $\mathbf{W}^{[1]}$, $\mathbf{W}^{[2]}$ an.
- Berechnen Sie die Ausgabe für $(x_1, x_2) = (2, 1)$.
- Wie erweitert man das Netz für ein Mehrklassen-Klassifizierungsproblem?

Lösung

(a) Zeile = Ziel-Neuron, Spalte = Eingang:

$$\mathbf{W}^{[1]} = \begin{pmatrix} 1 & 0 \\ -2 & 0 \\ -1 & 3 \end{pmatrix} \quad \mathbf{W}^{[2]} = \begin{pmatrix} -2 & -1 & 3 \\ 0 & 0 & 4 \end{pmatrix}$$

(b)

Verdeckte Schicht: $a_1 = \max(0, 2) = 2$; $a_2 = \max(0, -4) = 0$; $a_3 = \max(0, -2 + 3) = 1$.
Output:

$$\hat{\mathbf{y}} = \begin{pmatrix} -2 \cdot 2 - 1 \cdot 0 + 3 \cdot 1 \\ 4 \cdot 1 \end{pmatrix} = \boxed{\begin{pmatrix} -1 \\ 4 \end{pmatrix}}$$

(c) An die Ausgabeschicht eine **Softmax-Funktion** anhängen, sie transformiert die Ausgaben in einen Vektor von Klassenwahrscheinlichkeiten
(bei K Klassen: K Output-Neuronen).

Aufgabe 7.4

Klausur WS25/26, A4, abgewandelt · Verschachtelte ReLU

Ein Netz hat 3 Eingänge, *ein* verdecktes ReLU-Neuron

mit Gewichten $(2, 3, -3)$ und Bias 2,

sowie zwei ReLU-Output-Neuronen mit Gewichten -1 bzw. 2 (ohne Bias).

- Geben Sie $\hat{\mathbf{y}}$ als Formel für beliebiges $(x_1, x_2, x_3)^T$ an.
- Berechnen Sie $\hat{\mathbf{y}}$ für $(1, 1, 1)^T$.
- Was beobachtet man beim SGD, wenn die Lernrate zu groß bzw. zu klein gewählt ist?

Lösung

(a) Mit $h = \max(2x_1 + 3x_2 - 3x_3 + 2, 0)$:

$$\hat{\mathbf{y}} = \begin{pmatrix} \max(-1 \cdot h, 0) \\ \max(2 \cdot h, 0) \end{pmatrix}$$

(b) $h = \max(2 + 3 - 3 + 2, 0) = 4$:

$$\hat{\mathbf{y}} = \begin{pmatrix} \max(-4, 0) \\ \max(8, 0) \end{pmatrix} = \boxed{\begin{pmatrix} 0 \\ 8 \end{pmatrix}}$$

(Bemerkung: Output 1 ist für *jede* Eingabe 0

oder $-h \leq 0$ vor ReLU, ein „totes“ Neuron, sobald $h \geq 0$.)

(c) *Zu groß*: Verfahren wird instabil, springt über das Minimum hinaus, die Kostenfunktion oszilliert oder **divergiert**.

Zu klein: stabil, aber **sehr langsame** Konvergenz (viele Iterationen nötig).

Aufgabe 7.5

Klausuren SS23 A3b / WS23/24 A3d, kombiniert · SGD-Dimensionen

Für ein binäres Klassifikationsproblem liegen $N = 10\,000$ Trainingsbeispiele mit je 200 Features vor.

Das neuronale Netz hat 1 000 Parameter und wird 25 Epochen mit stochastischem Gradientenabstieg trainiert.

- Wie viele Summanden hat die Verlustfunktion?
- Welche Dimension hat der Gradient der gesamten Verlustfunktion?
- Welche Dimension hat der Gradient einer Minibatch (Batchgröße 10)?
- Wie oft wird der Parametervektor bei Minibatchgröße 100 in 25 Epochen aktualisiert?
- Wie oft beim klassischen (Batch-)Gradientenabstieg in 25 Epochen?
- Warum benutzt man für NN-Training i. d. R. SGD statt Batch-Gradientenabstieg (zwei Gründe)?

Lösung

- (a) $N = 10\,000$ (ein Summand pro Trainingsbeispiel; die Featurezahl 200 ist hier irrelevant!).
- (b) **1 000**, der Gradient lebt im Parameterraum.
- (c) Ebenfalls **1 000**, die Batchgröße ändert nur, *wie viele Summanden* in die Schätzung eingehen, nicht die Dimension.
- (d) Updates pro Epoche $= \frac{10\,000}{100} = 100$; gesamt $100 \cdot 25 = \mathbf{2\,500}$.
- (e) 1 Update pro Epoche $\Rightarrow \mathbf{25}$.
- (f)
- (1) **Rechenzeit**: SGD ist bei großen Datensätzen viel schneller (Kosten pro Schritt unabhängig von N , Daten müssen nicht komplett in den Speicher).
- (2) SGD wirkt **regularisierend**: das Rauschen der wechselnden Teilsummen verhindert die Konvergenz in ein Minimum, das nur Eigenheiten der Trainingsdaten abbildet.

Aufgabe 7.6

Eigene Aufgabe · Parameter zählen + Konzepte

- (a) Ein vollvernetztes Netz hat die Architektur $784 \rightarrow 128 \rightarrow 64 \rightarrow 10$ (mit Bias in jeder Schicht).
Wie viele lernbare Parameter hat es insgesamt?
- (b) Warum muss die Aktivierungsfunktion nichtlinear sein?
- (c) Erklären Sie das Vanishing-Gradient-Problem (Ursache!) und nennen Sie zwei Gegenmaßnahmen.
- (d) Was besagt das Universal-Approximation-Theorem und was garantiert es *nicht*?

Lösung

(a) Pro Schicht: Neuronen $\times$ Eingänge + Neuronen (Bias):

$$\underbrace{128 \cdot 784 + 128}_{100\,480} + \underbrace{64 \cdot 128 + 64}_{8\,256} + \underbrace{10 \cdot 64 + 10}_{650} = \boxed{109\,386}$$

(b) Die Verkettung linearer Funktionen ist wieder linear, ohne nichtlineare Aktivierung kollabiert das ganze Netz zu einem einzigen linearen Modell, egal wie viele Schichten es hat.

(c) Die Ableitung nach Gewichten *vorderer* Schichten ist ein *Produkt* der Aktivierungs-Ableitungen aller nachfolgenden Schichten (Kettenregel). Bei sigmoiden Funktionen ist σ' fast überall nahe Null (max. 0,25), das Produkt vieler kleiner Zahlen wird winzig, vordere Schichten lernen kaum noch.

Gegenmaßnahmen: (Leaky) **ReLU** als Aktivierung,
adaptive Lernraten (Adagrad, RMSProp, Adam),
Vortrainieren von Schichten (z. B. mit Autoencodern).

(d) Schon ein Netz mit *einer* verdeckten Schicht kann (mit genügend Neuronen) jede stetige Funktion beliebig genau approximieren, also jedes Regressions-/Klassifikationsproblem mit stetiger Modellfunktion darstellen.

Es garantiert *nicht*, dass man die Gewichte effizient *finden* kann, und sagt nichts über die nötige Neuronenzahl oder die Generalisierung.

8 Backpropagation

Strategie & typische Fehler

Rezept (immer gleich):

- (1) Graph: jede elementare Operation ein Knoten x_i mit Funktionsdefinition;
- (2) Vorwärtsphase: Werte aller Knoten an der gegebenen Stelle;
- (3) Rückwärtsphase: $\bar{x}_N = 1$, dann rückwärts $\bar{x}_i = \sum_{j \text{ Kind}} \bar{x}_j \cdot \partial x_j / \partial x_i$,
Werte aus der Vorwärtsphase einsetzen!

Typische Fehler:

bei Verzweigungen (ein Knoten hat mehrere Kinder) die Summe vergessen;
 Ableitungen symbolisch statt numerisch eingesetzt;
 sin / cos-Vorzeichen ($\frac{d}{dx} \cos x = -\sin x$).

Aufgabe 8.1

Klausur SS22, A4, abgewandelt $\cdot f(x, y) = x^2 e^y$

Gegeben $f(x, y) = x^2 \exp(y)$.

- (a) Stellen Sie den Berechnungsgraphen auf (Knoten x_i mit Funktionsdefinition).
- (b) Vorwärtsphase: Berechnen Sie $f(2, 0)$ mit allen Zwischenergebnissen.
- (c) Rückwärtsphase: Berechnen Sie $\nabla f(2, 0)$ mit allen Adjungierten $\bar{x}_i$.

Lösung

(a) $x_1 = x$; $x_2 = y$; $x_3 = x_1^2$; $x_4 = \exp(x_2)$; $x_5 = x_3 \cdot x_4$ (Output).

(b) $x_1 = 2$; $x_2 = 0$; $x_3 = 4$; $x_4 = e^0 = 1$; $x_5 = 4 \cdot 1 = 4$.

(c)

$$\bar{x}_5 = 1$$

$$\bar{x}_4 = \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_4} = 1 \cdot x_3 = 4$$

$$\bar{x}_3 = \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_3} = 1 \cdot x_4 = 1$$

$$\bar{x}_2 = \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_2} = 4 \cdot e^{x_2} = 4$$

$$\bar{x}_1 = \bar{x}_3 \cdot \frac{\partial x_3}{\partial x_1} = 1 \cdot 2x_1 = 4$$

$$\nabla f(2, 0) = (4, 4) \quad \text{Probe: } \partial_x f = 2xe^y = 4; \partial_y f = x^2 e^y = 4 \checkmark$$

Aufgabe 8.2

Klausur SS23, A4, abgewandelt · $f(x) = (e^x \cos x)^2$, mit Verzweigung

Gegeben $f(x) = (e^x \cos x)^2$.

(a) Berechnungsgraph aufstellen.

(b) Vorwärtsphase bei $x = 0$.

(c) Rückwärtsphase: $f'(0)$ über die Adjungierten.

Lösung

(a) $x_1 = x$; $x_2 = e^{x_1}$; $x_3 = \cos x_1$; $x_4 = x_2 \cdot x_3$; $x_5 = x_4^2$.

Achtung: x_1 hat zwei Kinder (x_2 und x_3), Verzweigung!

(b) $x_1 = 0$; $x_2 = e^0 = 1$; $x_3 = \cos 0 = 1$; $x_4 = 1$; $x_5 = 1$.

(c)

$$\bar{x}_5 = 1$$

$$\bar{x}_4 = \bar{x}_5 \cdot 2x_4 = 2$$

$$\bar{x}_3 = \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_3} = 2 \cdot x_2 = 2$$

$$\bar{x}_2 = \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_2} = 2 \cdot x_3 = 2$$

$$\bar{x}_1 = \bar{x}_2 \cdot \frac{\partial x_2}{\partial x_1} + \bar{x}_3 \cdot \frac{\partial x_3}{\partial x_1} = 2e^{x_1} + 2 \cdot (-\sin x_1) = 2 - 0 = 2$$

$$f'(0) = 2 \quad \text{Probe: } f'(x) = 2e^{2x}(\cos^2 x - \sin x \cos x), \quad f'(0) = 2 \checkmark$$

Aufgabe 8.3 Klausur WS22/23, A4, abgewandelt · $x_1^2 \cos(x_2)$ + Ableitung nach Kantengewicht

Gegeben der Berechnungsgraph: $x_3 = x_1^2$; $x_4 = \cos x_2$; $x_5 = x_3 x_4$.

- (a) Welche Funktion $f(x_1, x_2)$ berechnet der Graph?
- (b) Vorwärts- und Rückwärtsphase an der Stelle $(-2, 0)$.
- (c) Nun wird die Kante von x_3 nach x_5 mit einem Gewicht W versehen:
 $x_5 = W x_3 x_4$, wie in einem neuronalen Netz.
 Berechnen Sie $\partial x_5 / \partial W$ an der Stelle $(x_1, x_2) = (-2, 0)$, W beliebig.

Lösung

(a) $f(x_1, x_2) = x_1^2 \cos(x_2)$.

(b) Vorwärts: $x_1 = -2$; $x_2 = 0$; $x_3 = 4$; $x_4 = 1$; $x_5 = 4$.
 Rückwärts:

$$\begin{aligned}\bar{x}_5 &= 1 \\ \bar{x}_4 &= \bar{x}_5 \cdot x_3 = 4 \\ \bar{x}_3 &= \bar{x}_5 \cdot x_4 = 1 \\ \bar{x}_2 &= \bar{x}_4 \cdot (-\sin x_2) = 4 \cdot 0 = 0 \\ \bar{x}_1 &= \bar{x}_3 \cdot 2x_1 = 1 \cdot (-4) = -4\end{aligned}$$

$$\nabla f(-2, 0) = (-4, 0).$$

(c) Erst die Adjungierte am Knoten unmittelbar *nach* W
 (hier der Produkt-Knoten, $\bar{x}_5 = 1$), dann nach W nachdifferenzieren:

$$\frac{\partial x_5}{\partial W} = \bar{x}_5 \cdot x_3 x_4 = 1 \cdot 4 \cdot 1 = 4$$

(In der Klausurvariante mit $x_5 = (W x_3 x_4)$ in quadrierter Form ergab sich entsprechend $8W$, Mechanik: Rückwärtslauf bis zum Knoten nach W , dann $\bar{z} \cdot \partial z / \partial W$.)

Aufgabe 8.4 Klausur WS23/24, A4, abgewandelt · $\sin(x_1 x_2) + \cos(x_1 x_2)$, Verzweigung

Gegeben $f(x_1, x_2) = \sin(x_1 x_2) + \cos(x_1 x_2)$.

- (a) Berechnungsgraph aufstellen.
- (b) Vorwärtsphase bei $(0, \pi)$.
- (c) Rückwärtsphase: $\nabla f(0, \pi)$.

Lösung

(a) $x_3 = x_1 x_2$; $x_4 = \sin x_3$; $x_5 = \cos x_3$; $x_6 = x_4 + x_5$. (x_3 hat zwei Kinder!)

(b) $x_1 = 0$; $x_2 = \pi$; $x_3 = 0$; $x_4 = 0$; $x_5 = 1$; $x_6 = 1$.

(c)

$$\begin{aligned}\bar{x}_6 &= 1; & \bar{x}_5 &= \bar{x}_6 \cdot 1 = 1; & \bar{x}_4 &= \bar{x}_6 \cdot 1 = 1 \\ \bar{x}_3 &= \bar{x}_4 \cos x_3 + \bar{x}_5 \cdot (-\sin x_3) = 1 \cdot 1 - 1 \cdot 0 = 1 \\ \bar{x}_2 &= \bar{x}_3 \cdot x_1 = 1 \cdot 0 = 0 \\ \bar{x}_1 &= \bar{x}_3 \cdot x_2 = 1 \cdot \pi = \pi\end{aligned}$$

$$\nabla f(0, \pi) = (\pi, 0)$$

Aufgabe 8.5 Klausur WS25/26, A5, abgewandelt · $(x_1 + x_2) e^{x_1 + x_2}$, doppelte Verzweigung

Gegeben der Graph: $x_3 = x_1 + x_2$; $x_4 = e^{x_3}$; $x_5 = x_3 \cdot x_4$.

- (a) Welche Funktion f stellt der Graph dar?
- (b) Berechnen Sie ∇f an der Stelle $(0, 1)$ per Backpropagation (Vorwärts- und Rückwärtsphase).

Lösung

(a) $f(x_1, x_2) = (x_1 + x_2) e^{x_1 + x_2}$.

(b) **Vorwärts:** $x_1 = 0$; $x_2 = 1$; $x_3 = 1$; $x_4 = e$; $x_5 = e$.

Rückwärts (x_3 hat die Kinder x_4 und x_5):

$$\begin{aligned}\bar{x}_5 &= 1 \\ \bar{x}_4 &= \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_4} = x_3 = 1 \\ \bar{x}_3 &= \bar{x}_5 \cdot \frac{\partial x_5}{\partial x_3} + \bar{x}_4 \cdot \frac{\partial x_4}{\partial x_3} = 1 \cdot x_4 + 1 \cdot e^{x_3} = e + e = 2e \\ \bar{x}_2 &= \bar{x}_3 \cdot 1 = 2e & \bar{x}_1 &= \bar{x}_3 \cdot 1 = 2e\end{aligned}$$

$$\nabla f(0, 1) = (2e, 2e) \approx (5,44, 5,44)$$

Aufgabe 8.6

Eigene Aufgabe · $f(x, y) = x \sin(xy) + y^2$

Berechnen Sie ∇f an der Stelle $(1, 0)$ per Backpropagation (Graph, Vorwärts-, Rückwärtsphase).

Vorsicht: x kommt an zwei Stellen vor!

Lösung

Graph: $x_1 = x$; $x_2 = y$; $x_3 = x_1 x_2$; $x_4 = \sin x_3$; $x_5 = x_1 \cdot x_4$; $x_6 = x_2^2$; $x_7 = x_5 + x_6$.
 Verzweigungen: x_1 (Kinder x_3, x_5) und x_2 (Kinder x_3, x_6).

Vorwärts bei $(1, 0)$: $x_1 = 1$; $x_2 = 0$; $x_3 = 0$; $x_4 = 0$; $x_5 = 0$; $x_6 = 0$; $x_7 = 0$.

Rückwärts:

$$\begin{aligned}\bar{x}_7 &= 1; & \bar{x}_6 &= 1; & \bar{x}_5 &= 1 \\ \bar{x}_4 &= \bar{x}_5 \cdot x_1 = 1 \\ \bar{x}_3 &= \bar{x}_4 \cdot \cos x_3 = 1 \cdot 1 = 1 \\ \bar{x}_2 &= \bar{x}_3 \cdot x_1 + \bar{x}_6 \cdot 2x_2 = 1 \cdot 1 + 1 \cdot 0 = 1 \\ \bar{x}_1 &= \bar{x}_3 \cdot x_2 + \bar{x}_5 \cdot x_4 = 1 \cdot 0 + 1 \cdot 0 = 0\end{aligned}$$

$$\nabla f(1, 0) = (0, 1) \quad \text{Probe: } \partial_x f = \sin(xy) + xy \cos(xy) = 0; \quad \partial_y f = x^2 \cos(xy) + 2y = 1 \quad \checkmark$$

Aufgabe 8.7

Eigene Aufgabe (Konzept) · Warum Backpropagation?

- (a) Warum berechnet man Gradienten neuronaler Netze nicht einfach symbolisch „von Hand“ mit der Kettenregel?
- (b) Was besagt die Pfad-Interpretation der multivariaten Kettenregel, und warum ist direkte Pfad-Summation unpraktikabel?
- (c) Welches Prinzip macht Backpropagation effizient, und wie oft wird jeder Knoten dabei bearbeitet?
- (d) Aus welchen zwei Phasen besteht der Algorithmus und was wird in jeder Phase gespeichert/berechnet?

Lösung

(a) Die Verkettungen werden bei tiefen Netzen extrem unhandlich; für zehntausende Parameter ist symbolisches Differenzieren praktisch unmöglich und numerisch ineffizient, gleiche Teilableitungen würden zigfach neu berechnet.

(b) Die Ableitung des Outputs nach einem Eingangsknoten ist die *Summe über alle Pfade* zwischen beiden, mit *Produkt* der lokalen Ableitungen entlang jedes Pfades. Die Pfadanzahl wächst exponentiell (3 Schichten à 100 Neuronen: 10^6 Pfade), direkte Summation scheidet aus.

(c) **Dynamische Programmierung:** Die einmal berechnete Ableitung $\partial f / \partial x_j$ eines Knotens wird von allen Pfaden wiederverwendet, die durch ihn laufen. Jeder Knoten/jede Kante wird nur (zweimal) bearbeitet, kein exponentielles Wachstum.

(d) **Vorwärtsphase:** Funktion auswerten, **Werte aller Knoten speichern.**

Rückwärtsphase: Graph von hinten traversieren, Adjungierte $\bar{x}_i = \partial f / \partial x_i$ mit der Kettenregel aus den Kindern berechnen, dabei werden die gespeicherten Vorwärtswerte eingesetzt.

9 Faltungsnetze und Autoencoder

Strategie & typische Fehler

Die zwei CNN-Formeln auswendig:

$$W_{out} = \lfloor (W_{in} - W_K + 2P)/S \rfloor + 1$$

$$\#Param = K(W_K H_K D_{in} + 1).$$

Typische Fehler:

bei RGB die Tiefe $D_{in} = 3$ in der Parameterformel vergessen;

Bias (+1 *pro Filter*) vergessen;

Pooling-Schicht Parameter zugeschrieben (sie hat **keine**!);

beim Falten Kern und Bildausschnitt nicht elementweise multipliziert.

Aufgabe 9.1

Klausur WS23/24, A5, abgewandelt · Faltung von Hand

Gegeben die Eingabe und der Faltungskern (kein Padding, Stride 1):

$$I = \begin{pmatrix} 2 & -1 & 3 \\ 3 & 1 & 2 \\ -1 & 1 & -2 \end{pmatrix} \quad W = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

- Berechnen Sie die Featuremap.
- Die Eingabe sei nun eine 11×11 -Matrix, der Kern bleibt 2×2 :
Welche Dimension hat der Output?
Wie viele Neuronen-Verbindungen gibt es insgesamt,
und wie viele *Gewichte* müssen trainiert werden?

Lösung

(a) Vier 2×2 -Fenster, jeweils elementweise multiplizieren
(hier: einfach summieren, da alle Kerngewichte 1):

$$(1, 1) : 2 - 1 + 3 + 1 = 5$$

$$(1, 2) : -1 + 3 + 1 + 2 = 5$$

$$(2, 1) : 3 + 1 - 1 + 1 = 4$$

$$(2, 2) : 1 + 2 + 1 - 2 = 2$$

$$\text{Featuremap} = \begin{pmatrix} 5 & 5 \\ 4 & 2 \end{pmatrix}$$

(b) Output: $(11 - 2 + 0)/1 + 1 = 10$ pro Richtung $\Rightarrow 10 \times 10 = \mathbf{100 \text{ Neuronen}}$.
Jedes Output-Neuron ist über den 2×2 -Kern mit 4 Input-Neuronen verbunden
 $\Rightarrow \mathbf{400 \text{ Verbindungen}}$. Aber durch **Weight Sharing** gibt es nur **4 Gewichte**
(die Kerneinträge; +1 Bias, falls vorgesehen),
das ist der zentrale Effizienzvorteil der Faltungsschicht gegenüber fully connected.

Aufgabe 9.2 Klausur SS23, A5 / Probeklausur A5, kombiniert · Dimensionen und Parameter

- (a) Für 28×28 -RGB-Bilder sei eine Faltungsschicht mit 4 Filtern der Größe 3×3 definiert (kein Padding, Stride 1). Wie viele Parameter hat die Schicht, und welche Dimension hat ihr Output?
- (b) Gleiche Frage für 100×100 -RGB-Bilder mit 4 Filtern à 5×5 (kein Padding, Stride 1).
- (c) Ändert sich die Parameteranzahl, wenn man den Stride erhöht? Was ändert sich stattdessen?
- (d) Erklären Sie kurz, wie Faltungsschichten Muster in Bildern erkennen.

Lösung

- (a) Parameter: je Filter $3 \cdot 3 \cdot 3 + 1 = 28$ ($\text{RGB} \Rightarrow D_{in} = 3!$);
gesamt $4 \cdot 28 = \mathbf{112}$. Output: $\frac{28-3}{1} + 1 = 26 \Rightarrow \mathbf{26 \times 26 \times 4}$.
- (b) Je Filter $5 \cdot 5 \cdot 3 + 1 = 76$; gesamt $4 \cdot 76 = \mathbf{304}$. Output: $\frac{100-5}{1} + 1 = 96 \Rightarrow \mathbf{96 \times 96 \times 4}$.
- (c) **Nein**, die Parameterzahl hängt nur von Kerngröße, Tiefe und Filteranzahl ab. Es ändert sich die *Output-Dimension* (bei Stride 2 etwa halbiert), weniger Abtastpositionen, gröbere Erkennung.
- (d) Der Kern wird über alle Bildausschnitte geschoben; wo ein Ausschnitt dem Kern *ähnelt*, entsteht ein **hoher Wert** in der Featuremap. So werden Regionen markiert, die dem gesuchten Muster entsprechen; welche Muster nützlich sind, wird beim Training gelernt.

Aufgabe 9.3 Klausur WS25/26, A6, abgewandelt · CNN-Architektur durchrechnen

Ein CNN klassifiziert Graustufenbilder der Größe 28×28 :

- **Conv**: 8 Filter 3×3 , Stride 1, *Zero-Padding* ($P = 1$), ReLU
- **MaxPool**: 2×2 , Stride 2
- **Flatten**, dann **Dense** auf 10 Klassen (Softmax)

- (a) Größe der Featuremaps nach dem Conv-Layer?
- (b) Wie viele lernbare Parameter hat der Conv-Layer?
- (c) Wie viele lernbare Parameter hat der MaxPool-Layer?
- (d) (Zusatz) Wie viele Parameter hat der Dense-Layer?

Lösung

- (a) $W_{out} = \lfloor \frac{28-3+2 \cdot 1}{1} \rfloor + 1 = 28 \Rightarrow \mathbf{28 \times 28 \times 8}$
(Half-Padding erhält die Dimension, Tiefe = Filteranzahl).
- (b) $8 \cdot (3 \cdot 3 \cdot 1 + 1) = \mathbf{80}$ (Graustufen: $D_{in} = 1$).
- (c) **0**, Pooling hat keine lernbaren Parameter.
- (d) Nach Pooling: $14 \times 14 \times 8 = 1568$ Werte; Dense auf 10 Klassen:
 $10 \cdot 1568 + 10 = \mathbf{15\,690}$ Parameter.

Aufgabe 9.4

Eigene Aufgabe · Max-Pooling und Architektur

- (a) Wenden Sie 2×2 -Max-Pooling mit Stride 2 auf folgende Featuremap an:

$$\begin{pmatrix} 1 & 3 & 2 & 0 \\ 4 & 2 & 7 & 1 \\ 6 & 0 & 3 & 2 \\ 1 & 2 & 0 & 5 \end{pmatrix}$$

- (b) Was leistet Max-Pooling konzeptionell, und welchen Vorteil bringt es für nachfolgende Schichten?
- (c) Geben Sie das typische CNN-Architekturmuster (Schema) an und erklären Sie die Arbeitsteilung zwischen Faltungs- und FC-Schichten.

Lösung

- (a) Blockweise Maxima:

$$\begin{pmatrix} \max(1, 3, 4, 2) & \max(2, 0, 7, 1) \\ \max(6, 0, 1, 2) & \max(3, 2, 0, 5) \end{pmatrix} = \begin{pmatrix} 4 & 7 \\ 6 & 5 \end{pmatrix}$$

- (b) Es prüft, *ob* ein Feature irgendwo in einer Region vorhanden ist, und verwirft die exakte Position (Translations-Toleranz).

Vorteil: kleinere Featuremaps $\Rightarrow$ deutlich weniger Parameter in den nachfolgenden Schichten.

- (c) INPUT $\rightarrow$ [[CONV $\rightarrow$ RELU]*N $\rightarrow$ POOL?]*M $\rightarrow$ [FC $\rightarrow$ RELU]*K $\rightarrow$ FC.

Die Faltungs-/Pooling-Blöcke betreiben **Feature Learning**

(hierarchisch: Kanten $\rightarrow$ Formen $\rightarrow$ komplexe Muster);

die Fully-Connected-Schichten **gewichten** diese Features zur Klassenentscheidung (wie ein lineares Modell auf gelernten Features).

Am Ende bildet eine FC-Schicht (mit Softmax) auf die Klassen ab.

Aufgabe 9.5

Klausur SS22, A5, abgewandelt · Autoencoder

- (a) Beschreiben Sie kurz, was ein Autoencoder ist und wofür er eingesetzt wird.
- (b) Geben Sie die Verlustfunktion an, die beim Training minimiert wird.
- (c) Skizzieren Sie einen Autoencoder, der eine *zweidimensionale* Darstellung eines *dreidimensionalen* Datensatzes lernt, die (bis auf Drehung/Spiegelung) der PCA entspricht. Wie viele Parameter hat er, und wo fließen sie ein?
- (d) Beschreiben Sie in einem Satz den Zusammenhang zwischen linearem Autoencoder und PCA.

Lösung

(a) Ein Autoencoder ist ein neuronales Netz, dessen **Eingabeschicht dieselbe Dimension wie die Ausgabeschicht** hat und das darauf trainiert wird, seine **Eingabe zu rekonstruieren**. Da die mittlere Schicht (Code/Bottleneck) weniger Neuronen hat, lernt das Netz eine **reduzierte Darstellung** der Daten.

Einsatz: Dimensionsreduktion/Feature Learning,
Vortrainieren tiefer Netze, Anomalieerkennung.

(b) Mittlerer quadratischer Rekonstruktionsfehler:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}^{(i)} - \mathbf{x}'^{(i)}\|^2$$

(c) Architektur $3 \rightarrow 2 \rightarrow 3$, *ohne* Aktivierungsfunktionen,
mit **geteilten Gewichten**: Encoder $U \in \mathbb{R}^{2 \times 3}$, Decoder $V = U^T$.

Damit hat das Netz genau die **6 Parameter** der Matrix $U = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{pmatrix}$, die sowohl in der Encoder- als auch (transponiert) in der Decoder-Schicht verwendet werden.

(d) Ein *linearer* Autoencoder (ohne Aktivierungsfunktion) lernt die gleiche Transformation wie eine PCA, er minimiert denselben Rekonstruktionsfehler, dessen Optimum die PCA-Projektionsmatrix ist (der gelernte Unterraum stimmt überein, die Basis ist nur nicht zwingend orthonormal).

Aufgabe 9.6

Eigene Aufgabe · Autoencoder-Anwendungen

- (a) Beschreiben Sie das Vorgehen der rekonstruktionsbasierten *Anomalieerkennung* mit einem Autoencoder (3 Schritte). Warum bietet sich hier unüberwachtes Lernen an?
- (b) Wie funktioniert das *Vortrainieren* eines tiefen Netzes mit Autoencodern, und gegen welches Trainingsproblem hilft es?
- (c) Welche zwei Spezialbausteine braucht der *Decoder* eines Convolutional Autoencoders, und was tun sie?

Lösung**(a)**

- (1) Autoencoder nur auf *normalen* Daten trainieren und die Statistik des typischen Rekonstruktionsfehlers erheben;
- (2) im Betrieb neue Daten (z. B. rollierendes Zeitfenster) komprimieren und rekonstruieren;
- (3) **Alarm, wenn der Rekonstruktionsfehler den Schwellwert überschreitet**, Ungewöhnliches passt nicht in die gelernte Kompression.

Unüberwacht, weil meist viele Daten, aber kaum gelabelte Anomalien existieren und Labeling teures Fachwissen erfordert.

(b) Schichtweise: Erst flachen Autoencoder auf den Rohdaten trainieren → Initialgewichte der ersten Schicht; dann einen zweiten Autoencoder auf der *reduzierten Darstellung* → Gewichte der zweiten Schicht; schließlich den Klassifizierer mit diesen Initialisierungen normal trainieren (Fine-Tuning). Hilft gegen das **Vanishing-Gradient-Problem** (gute Startwerte statt zufälliger).

(c) Unpooling (Upsampling): setzt mithilfe gespeicherter Max-Positionen (switch variables) die Werte zurück an ihre Stelle und füllt mit Nullen auf.

Transponierte Faltung (Deconvolution): eine Faltung, die Ein-/Ausgabedimension der zugehörigen Faltung vertauscht (über Padding/eingefügte Nullen); ihre Kerngewichte werden mitgelernt, sie ist *nicht* die mathematische Inverse der Faltung.